

2022년도 바이오빅데이터구축시범사업 최종보고서 (제출용, **세부과제용**)

① 부처사업명(대)	원천기술개발사업		④ 보안등급(보안, 일반)	일반			
② 사업명(중)	바이오·의료기술개발사업		⑤ 과제성격(기초, 응용, 개발)	기초			
③ 세부사업명(소)	바이오빅데이터구축시범사업						
⑥ 총괄과제명	임상유전체 정보 기반 바이오 빅데이터 활용 체계 구축						
⑦ 세부과제명	국 문	유전체 빅데이터 생산 및 분석 인프라 구축					
	영 문	Construction of infrastructure for genome big data					
⑧ 주관연구기관명	한국생명공학연구원		⑨ 사업자 등록번호	314-82-06063			
⑩ 위탁과제기관명	서울대학교, 울산과학기술원, 연세대학교, 조선대학교, 국립암센터						
⑪ 주관연구책임자	성 명	김선영	국가연구자번호	*****			
	전 공	미생물학	직급(직위)	책임급(센터장)			
	소속부서	국가생명연구자원 정보센터	전자우편	kimsy@kribb.re.kr			
	전 화	042-879-8500	휴대전화	*****			
⑫ 연구개발비 현황(단위: 천원)							
년 도	정부 출연금 (A)	기업체부담금			정부외출연금 (B)	합계 G=(A+B+E)	상대국 부담금 (F)
		현금 (C)	현물 (D)	소계 E=(C+D)			
1차년도	8,251,000			0		8,251,000	
2차년도	13,500,000			0		13,500,000	
3차년도							
4차년도							
5차년도							
6차년도							
7차년도							
8차년도							
합계	13,500,000	0	0	0	0	13,500,000	0
⑬ 총연구기간	2020. 05. 29 - 2022. 12. 31 (32 개월)						
⑭ 다년도연구기간	2020. 05. 29 - 2022. 12. 31 (32 개월)						
⑮ 참여기업 수	중소기업		중견기업		대기업		계
⑯ 국제공동연구	국가명		상대국 연구기관수		상대국 연구개발비		상대국연구책임자수
⑰ 실무담당자	성 명	박지환	휴대전화	*****		전자우편	jhpark706@kribb.re.kr

‘유전체 빅데이터 생산 및 분석 인프라 구축’ (연구개발 기간 : 2020. 05. 29. ~ 2022. 12. 31.)
과제의 최종보고서를 제출합니다.

주관연구책임자 : 김선영 (직인생략)

주관연구기관장 : 김장성 (직인생략)

국가연구개발혁신법 제17조(연구개발성과의 활용)에 따라
최종보고서 열람에 동의합니다.

과 학 기 술 정 보 통 신 부 장 관 귀 하

○ 공동연구개발기관 등 현황

공동연구개발기관 등 (해당 시 작성)	기관명	책임자	직위	휴대전화	전자우편	비고	
						역할	기관유형
공동연구개발기관							
위탁연구개발기관	서울대학교	최무림	부교수	*****	murimchoi@snu.ac.kr	1위탁	대학
	울산과학기술원	이세민	부교수	*****	seminlee@unist.ac.kr	2위탁	대학
	연세대학교	김영준	정교수	*****	yjkim@yonsei.ac.kr	3위탁	대학
	서울대학교	유희정	정교수	*****	hjyoo@snu.ac.kr	4위탁	대학
	조선대학교	이건호	정교수	*****	leekho@chosun.ac.kr	5위탁	대학
	국립암센터	한지연	최고연구원	*****	jymama@ncc.re.kr	6위탁	연구원
연구개발기관 외 기관							

〈 요약 문 〉

연구개발 목표 (500자 내외)	- 정밀의료의 바탕이 되는 바이오 빅데이터는 사후적 치료 중심에서 개인 맞춤형 치료·예방 의료로 전환되는 추세에 따라 그 중요성이 부각되고 있음. 수준 높은 의료서비스 제공 및 바이오헬스 산업 경쟁력 확보를 위해서는 바이오 빅데이터 구축이 시급하며, 이에 국가 바이오 빅데이터 구축의 표준화 및 활용을 위한 기반 마련을 위해 국가 바이오 빅데이터 구축 시범사업을 추진하고자 함. - 본 시범사업은 의료 질 향상, 미래 정밀의료 선도, 바이오헬스 산업의 성장 동력 확보를 목표로 2.5만명 규모의 임상정보·유전체 데이터로 이루어진 빅데이터 구축 및 활용 지원을 목표로 함. - 시범사업을 통해 (1) 희귀질환자 모집과 선도사업 연계를 통한 유전체 데이터를 확보하고자 하며, (2) 바이오뱅크 및 업무 프로세스를 구축하고, (3) 안전한 개인정보 보호체계 하에서 데이터 활용을 촉진하고자 함.			
연구개발 내용 (1000자 내외)	(1) 희귀, 선도사업의 자원 및 데이터 확보 ○ 정부 재원으로 수행된 데이터 보유 사업(선도사업)과 데이터 연계하여 유전체 데이터 확보(1만건) – 유전체 보유 선도사업(5,000건) 및 임상정보 보유 선도사업(5,000건) 선정하여 유전체 데이터 연계·확보 ○ 희귀질환 유전체 데이터 확보 (1.5만건) (2) 유전체 서열분석 및 분석보고서 작성 ○ 유전체 미보유 선도사업 및 신규 희귀질환 검체의 유전체 데이터 생산(2만건) – 유전체 생산기관 선정 및 유전체 데이터 생산, 이송, 관리 체계 구축 ○ 유전체 데이터 품질관리·분석 파이프라인을 구축(표준화)한 뒤, 유전체 데이터 분석 및 분석보고서 작성·배포(2.5만건) (3) 데이터 활용 및 보안체계 구축 ○ 사업 소개 및 연구지원 홈페이지 구축			
활용계획 및 기대효과 (500자 내외) (응용분야 및 활용범위 포함)	(의료서비스 분야) 한국인 호발 희귀·난치 질환의 유전자 원인을 규명하고, 구축된 빅데이터를 환자 맞춤형 정밀의료 진단·치료 기술 개발 및 신약개발 등에 활용 (산업적 활용) 유전체 데이터 분석 S/W의 국산화하며, 데이터를 활용한 신약 및 의료기기 제품 개발함으로써 바이오헬스 산업의 혁신적 성장을 도모 (데이터 연구 활용) 연구자들을 위한 고품질의 바이오 빅데이터를 제공하여, 바이오·의료 분야 연구자들의 연구 저변을 확대하고, 다양한 연구를 촉진함.			
국문핵심어 (8개)	빅데이터	유전체	임상정보	희귀질환
	오믹스	데이터 분석	임상분석 연구네트워크	연구지원 인프라
영문핵심어 (8개)	Big data	Genomics	Medical data	Rare disease
	Omics	Data analysis	CIRN	Infra

〈 연구 분야 〉

코드구분	중심분야		관련분야1		관련분야2		관련분야3		관련분야4	
	코드	비중	코드	비중	코드	비중	코드	비중	코드	비중
국가과학기술표준분류	LC0111	60 %	LC0112	40 %		%		%		%
국가과학기술표준분류 (적용분야)	X02	100 %		%		%		%		%
과학기술분야분류	G20906	50 %	G30302	30 %	G51205	20 %		%		%
6T 기술분류	020111	50 %	020113	30 %	010312	10 %	010315	10 %		%
NTRM 분류	B020218	50 %	B020219	30 %	B010115	20 %		%		%
원천기술개발분야	0419	50 %	0723	30 %	0199	20 %		%		%

< 목 차 >

1. 연구개발 목표 및 평가항목별 성과	1
2. 추진내용 및 연구개발결과	5
3. 연구 개발 결과의 활용 방안	98

1. 연구개발 목표 및 평가항목별 성과

1-1. 연구개발 목표

최종목표	○ 2.5만명 규모의 바이오 빅데이터 구축 및 활용체계 기반 마련
세부목표	- 희귀, 선도사업의 자원 및 데이터 확보 - 유전체 서열분석 및 분석보고서 작성 - 사업 소개 및 연구지원 홈페이지 구축
연차별목표	○ 1차년도 - 희귀, 선도사업의 자원 및 데이터 확보 - 희귀질환 유전체 데이터 5,000건 확보 - 선도사업 유전체 데이터 5,000건 확보 - 유전체 서열분석 및 분석보고서 작성 - 유전체 데이터 생산·이송·관리 체계 구축 - 선도사업 및 신규 희귀질환 검체의 유전체 데이터 생산(7,500건) - 국제 규격의 유전체 정도 관리·분석 파이프라인 표준화 및 구축 - 유전체 데이터 1만 건의 기본변이분석 수행 - 유전체 분석보고서(변이데이터) 양식 개발 및 분석보고서 1만 건 작성·배포 - 데이터 활용 및 보안체계 구축 - 한국인 유전체 데이터 등록·관리 시스템 구축 - 사업 소개 홈페이지 구축 ○ 2차년도(최종) - 희귀, 선도사업의 자원 및 데이터 확보 - 희귀질환 유전체 및 임상 데이터 1만 건 확보 (1, 2차년도 누적 1.5만 건) - 선도사업 유전체 및 임상 데이터 5천 건 확보 (1, 2차년도 누적 1만 건) - 유전체 서열분석 및 분석보고서 작성 - 유전체 데이터 생산·이송·관리 체계 고도화 - 선도사업 및 신규 희귀질환 검체 12,500건의 유전체 데이터 생산 (1, 2차년도 누적 2만 건) - 국제 규격의 유전체 정도 관리·분석 파이프라인 표준화 및 구축 - 유전체 데이터 1.5만 건의 기본변이분석 및 고도변이분석 수행 (기본변이분석 1, 2차년도 누적 2.5만 건, 고도변이분석 1, 2차년도 누적 1.5만 건) - 유전체 분석보고서(gvcf 등 변이데이터) 1.5만건 작성·배포 - 데이터 활용 및 보안체계 구축 - 한국인 유전체 데이터 등록·관리 시스템 고도화 - 사업 소개 홈페이지 고도화

1-2 평가항목별 성과

평가항목	가중치 (%)	관련 세부목표	연차	연차별 목표 (조건/환경)	실적요약	달성도 (%)	관련증빙
(정량) 희귀질환 유전체 데이터 확보 건수 1.5만 건	20	1,2	1차년도	희귀질환 유전체 데이터 확보 건수 5,000건	1, 2차년도 누적 1.5만 건 희귀질환 유전체 데이터 확보	100	1.희귀질환 데이터 생산 현황 2.희귀질환 1.5만건 데이터 목록
			2차년도 (최종)	희귀질환 유전체 데이터 확보 건수 10,000건			
(정량) 선도사업 연계 기반 유전체 데이터 확보 건수 1만 건	20	1,2	1차년도	선도사업 연계 기반 유전체 데이터 확보 건수 5,000건	선도사업 연계 기반 총 1만 건 유전체 데이터 확보 (1, 2차년도 누적) - 유전체 미보유 선도사업 (KoGES) 5,000건 완료 (1, 2차년도 누적) - 유전체 보유 선도사업 (대장암, 자폐증, 울산만명, 치매, 폐암 코호트) 5,000건 완료 (1, 2차년도 누적)	100	3.유전체 미보유 선도사업 (KoGES) 5,000건 데이터 목록 4.대장암 코호트 600건 데이터 연계 결과 등 5.울산만명 코호트 2,383건 데이터 연계 결과 등 6.자폐증 코호트 849건 데이터 연계 결과 등 7.치매 코호트 1,000건 데이터 연계 결과 등 8.폐암 코호트 168건 데이터 연계 결과 등
			2차년도 (최종)	선도사업 연계 기반 유전체 데이터 확보 건수 5,000건			
(정량) 유전체 분석 건수 2.5만 건	20	2	1차년도	유전체 분석 건수 1만 건 (기본변이분석)	- 유전체 데이터 기본변이분석 2.5만 건 완료 (1, 2차년도 누적) - 유전체 데이터 고도변이분석 1.5만 건 완료 (1, 2차년도 누적)	100	9.유전체 변이데이터 품질관리 결과
			2차년도 (최종)	유전체 분석 건수 1.5만 건 (기본·고도 변이분석)			

(정량) 유전체 분석 보고서 작성·생산 2.5만 건	10	2	1차년도	유전체 분석 보고서 작성·생산 1만 건	유전체 변이데이터 2.5만 건 배포 완료 (1, 2차년도 누적)	100	10. 유전체 변이데이터 (gvcf 등) 배포 목록
			2차년도 (최종)	유전체 분석 보고서 작성·생산 1.5만 건			
(정성) 유전체 분석 파이프라인 구축	10	2	1차년도	기본변이분석·품질관리 파이프라인 구축	- 유전체 기본변이분석·품질관리 파이프라인 구축·고도화 완료 - 유전체 고도변이분석 파이프라인 구축 완료	100	11. 변이분석·품질관리 표준작업절차서 12. 기존 변이분석 알고리즘 간 비교 분석 결과 및 표준참조유전체 데이터베이스
			2차년도 (최종)	기본변이분석·품질관리 파이프라인 고도화 및 고도분석 파이프라인 구축			
(정성) 개인정보 보호 및 데이터 활용을 위한 체계구축 및 가이드라인 작성	20	3	1차년도	개인정보 보호 및 데이터 활용을 위한 체계구축 및 가이드라인 작성	- 개인정보 보호 및 데이터 활용을 위한 보안전송망 기반 한국인 유전체 데이터 등록·관리 시스템 구축·고도화 - 사업 소개 홈페이지 구축·고도화	100	13. 한국인 유전체 데이터 등록·관리 시스템 화면 및 데이터베이스 설계도 14. 사업 소개 홈페이지 화면 및 URL 주소
			2차년도 (최종)	개인정보 보호 및 데이터 활용을 위한 체계 고도화			
합계	100						

1-3. 목표 미달 시 원인 분석 (해당시 작성)

○ 해당사항 없음

- (정책 수립 및 예타 대응) 본사업 예비타당성조사 기획·대응(3세부 과업) 및 산업적 활용방안 정책 수립(4세부 과업)
- 시범사업 수행기관 협의체 총괄(1세부 과업) 및 운영위원회 및 추진위원회 운영지원(3세부 과업)
- (수행기관 협의체) 출연금 사업과 질병청 사업의 원활한 통합 운영을 위해, 5개 수행기관(1~4세부 및 질병청) 연구책임자로 구성된 수행기관 협의체 운영(1세부 과업)

연번	개최일	수행기관 협의체 회의	주관
1	20.07.13	시범사업 실무협의체('20) 1차	질병청 (사무국, 질병청 사업)
2	20.08.03	시범사업 실무협의체('20) 2차	
3	20.09.22	시범사업 실무협의체('20) 3차	
4	20.12.23	시범사업 수행기관협의체 1차	
5	21.01.07	시범사업 수행기관협의체 2차	
6	21.01.20	시범사업 수행기관협의체 3차	
7	21.02.03	시범사업 수행기관협의체 4차	
8	21.02.17	시범사업 수행기관협의체 5차	
9	21.03.03	시범사업 수행기관협의체 6차	
10	21.03.17	시범사업 수행기관협의체 7차	
11	21.03.25	시범사업 수행기관협의체 8차	
12	21.04.14	시범사업 수행기관협의체 9차	생명연 (출연금 사업 총괄, 1세부)
13	21.04.28	시범사업 수행기관협의체 10차	
14	21.05.12	시범사업 수행기관협의체 11차	
15	21.06.02	시범사업 수행기관협의체 12차	
16	21.06.16	시범사업 수행기관협의체 13차	
17	21.06.30	시범사업 수행기관협의체 14차	
18	21.07.14	시범사업 수행기관협의체 15차	
19	21.07.28	시범사업 수행기관협의체 16차	
20	21.08.11	시범사업 수행기관협의체 17차	
21	21.08.25	시범사업 수행기관협의체 18차	
22	21.09.08	시범사업 수행기관협의체 19차	
23	21.09.29	시범사업 수행기관협의체 20차	
24	21.10.13	시범사업 수행기관협의체 21차	
25	21.10.26	시범사업 수행기관협의체 22차	
26	21.11.10	시범사업 수행기관협의체 23차	
27	21.11.24	시범사업 수행기관협의체 24차	
28	21.12.08	시범사업 수행기관협의체 25차	
29	21.12.22	시범사업 수행기관협의체 26차	
30	22.01.05	시범사업 수행기관협의체 27차	
31	22.01.19	시범사업 수행기관협의체 28차	
32	22.02.08	시범사업 수행기관협의체 29차	질병청 (사무국, 질병청 사업)
33	22.02.23	시범사업 수행기관협의체 30차	
34	22.03.10	시범사업 수행기관협의체 31차	
35	22.03.25	시범사업 수행기관협의체 32차	
36	22.04.06	시범사업 수행기관협의체 33차	
37	22.04.19	시범사업 점검회의	
38	22.05.03	시범사업 실무협의체('22) 1차	
39	22.05.17	시범사업 실무협의체('22) 2차	
40	22.06.07	시범사업 실무협의체('22) 3차	
41	22.06.23	시범사업 실무협의체('22) 4차	

42	22.07.07	시범사업 실무협의체('22) 5차	
43	22.09.14	시범사업 실무협의체('22) 6차	
44	22.09.27	시범사업 실무협의체('22) 7차	
45	22.10.11	시범사업 실무협의체('22) 8차	
46	22.10.27	시범사업 실무협의체('22) 9차	
47	22.11.08	시범사업 실무협의체('22) 10차	
48	22.11.22	시범사업 실무협의체('22) 11차	
49	22.12.13	시범사업 실무협의체('22) 12차	
50	22.12.29	시범사업 실무협의체('22) 13차	
51	23.01.26	본사업 관계부처 실무협의체	

- (운영위) 본 사업의 원활한 운영 및 참여기관 간의 협력을 위해서 과제부처 과장급으로 구성된 운영 위원회를 설치하여 운영함. 운영위는 정보, 출연연 **권소사업** 및 각 하위 조직 등의 지휘, 감독 중요 공모과제의 선정기준 등의 협의 및 일정관리, 추진위원회 상정 안건 사전 검토
- (추진위) 본 사업의 중요한 계획, 추진전략, 기획 등의 중요사항에 대한 심의, 의결을 위해 추진 위원회를 구성하여 운영함

연구개발 내용 및 방법

(1) 희귀, 선도사업의 자원 및 데이터 확보

- (가) 선도사업 연계 개요
- (나) 유전체 보유 선도사업 선정
- (다) 유전체 보유 선도사업 연계 및 코호트 별 고도화 연구

(2) 희귀, 선도사업 자원의 유전체 서열분석 및 분석보고서 작성

- (가) 유전체 생산기관 선정
- (나) 유전체 데이터 생산·품질 관리 체계 구축 및 고도화
- (다) 유전체 생산기관의 표준 운영·관리지침 수립 및 이송·관리 체계 구축 및 고도화
- (라) 데이터 관리방안 및 체계 구축
- (마) 유전체 데이터 품질관리·분석 파이프라인 표준화 구축 및 고도화
- (바) 유전체 데이터 분석 및 분석보고서 작성·배포

(3) 데이터 활용체계 구축

- (3-1) 한국인 유전체 데이터 등록·관리 시스템 구축·고도화
- (3-2) 사업 소개 홈페이지 구축·고도화

나. 연구개발 내용 및 방법


(1) 희귀, 선도사업의 자원 및 데이터 확보

(가) 선도사업 연계 개요

□ 선도사업 연계 개요

- (배경) 정부 재정이 투입된 선도사업과 국가 바이오 빅데이터 구축 시범사업과의 연계를 통한 연구의 연속성 및 확장성, 재정의 효율적 사용을 통한 결과 시너지 효과 창출
- (연계방안) 임상정보 및 유전체 분석을 위해 검체 분양이 가능한 선도사업 대상으로 1만명 연계(1차, 2차년도 각각 5천명)
 - (이원화) 유전체 데이터 보유 선도사업, 유전체 데이터 미보유 선도사업으로 이원화하여 연계
 - (데이터 이관) 선정된 선도사업에서 연계된 임상정보는 질병관리청·국가생명연구자원 정보센터(KOBIC), 연계된 유전체 데이터는 KOBIC이 각각 이관*받으며, 이후 절차는 동 사업의 희귀질환자 모집과 동일
 - * 이관된 임상·유전체 데이터는 최종적으로 질병관리청 국립중앙인체자원은행에 기탁
- (사업선정) 선도사업 연구책임자의 참여의사 확인 후, 선도사업 전문위원회 선정 결과를 토대로 선도사업과의 연계를 추진하며, 최종적으로 추진위원회 심의·의결

< 선도사업의 연계방안 >



□ 정부 재원으로 수행된 데이터 보유 사업(선도사업)과의 데이터 연계

○ 선도사업 전문위원회 구성·운영

- 선도사업 연계 기준 및 운영 방안 마련을 위해 「선도사업 전문위원회」를 구성·운영
- 선도사업 전문위원회는 기존 선도사업 연구책임자 및 의료계·학계·산업계 총 10인으로 구성

○ 선도사업 선정

- 다음을 포함한 기준을 충족하는 사업을 선도사업으로 선정
 - 샘플 품질관리(QC) 충족 여부
 - 유전체 데이터의 품질
 - 동 사업의 임상정보 표준안 준용 및 추가 보완(동의서 구득 등) 가능 여부
- 선도사업 전문위원회가 정한 참여기준을 토대로, 이를 충족한 선도사업 연구책임자의 참여 의사 확인 후 연계 추진

○ 선도사업 데이터 연계

- (연계 방안) 유전체 데이터 보유 선도사업, 유전체 데이터 미보유 선도사업으로 이원화하여 연계

구분	연계 방안
유전체 데이터 보유 선도사업	· 유전체 분석이 既 완료된 사업대상과 연계 추진 예) 울산 1만명 게놈 프로젝트 · 선도사업의 유전체 데이터는 국가생명연구자원정보센터(KOBIC)으로 전달되어 정보 품질관리(QC) 등 시행 · 품질관리(QC)를 통과한 유전체 데이터는 임상정보를 생산
유전체 데이터 미보유 선도사업	· 임상정보 既 보유한 사업대상과 연계 추진 예) 한국인유전체역학조사사업(KoGES) · 선도사업의 임상정보는 질병관리청으로 전달 · 선도사업 보유 샘플은 품질관리(QC) 이후 자원 제작기관·유전체 생산기관으로 전달되어 유전체 데이터를 생산


구분	1차년도('20.5~'21.5)	2차년도('21.6~'22.12)
유전체 보유 선도사업	2,500건	2,500건
유전체 미보유 선도사업	2,500건	2,500건
합계	5,000건	5,000건

□ 유전체 보유 선도사업

○ 제5차, 제11차 추진위원회에서 각각 1, 2차년도 유전체 보유 선도사업 연계방안 결정

- 선도사업이 보유한 유전체 데이터는 국가생명연구자원정보센터(KOBIC)으로 전달
- KOBIC에서 품질관리(QC) 후 변이 분석 시행하여 BAM 및 VCF 파일 생산 및 자체 시스템에 저장
- 품질관리(QC)를 통과한 유전체 데이터에 한하여 KOBIC에서 임상정보를 추가 수집(성별, 연령, 기저질환 유무 등 기존 수집된 임상정보 포함)
- 보완된 임상정보는 KOBIC에 저장되며, 추후 질병관리청 국립중앙인체자원은행에 기탁
- 이후의 임상정보·유전체 데이터 전달 및 공유 절차는 동 사업의 희귀질환자 모집과 동일

< 유전체 보유 선도사업 연계절차(1차년도) >




□ 유전체 미보유 선도사업

○ 제4차, 제11차 추진위원회에서 각각 1, 2차년도 유전체 보유 선도사업 연계방안 결정

- 선도사업의 임상정보는 임상정보 보완 및 동의서 구득한 뒤 질병관리청으로 이관·저장
- 한국인유전체역학조사사업(KoGES)의 임상정보는 질병관리청의 통합관리시스템에 저장되어 있으며, 他 유전체 미보유 선도사업의 임상정보는 질병관리청에 이관·저장
- 선도사업의 보유 샘플 중 임상정보·동의서 보완 완료된 샘플은 품질관리(QC) 시행 후 자원 제작기관 및 유전체 생산기관으로 전달되어 유전체 데이터를 생산
- 생산된 유전체 데이터는 국가생명연구자원정보센터(KOBIC)에서 품질관리(QC) 및 분석 시행
- 이후의 임상정보·유전체 데이터 전달 및 공유 절차는 동 사업의 희귀질환자 모집과 동일
- 유전체 미보유 선도사업의 모든 절차, 선정과정 등은 선도사업 전문위원회를 구성하여 정함(선도사업 전문위원회 구성은 각 부처의 추천된 전문가들로 구성)

< 유전체 미보유 선도사업 연계절차 >



- (유전체 보유 선도사업) 1·2차년도 선도사업 유전체 데이터(연차 별 2,500건, 총 누적 5,000건)에 대한 임상데이터 연계
- (유전체 미보유 선도사업) 1·2차년도 선도사업 임상데이터(연차 별 2,500건, 총 누적 5,000건)에 대한 유전체 데이터 생산·확보
- 선정된 선도사업의 데이터 이관 불이행 시 대응 방안
 - 선정된 선도사업이 선정위원회의 허가 없이 데이터 연계를 이행하지 않는 경우, 선도사업 선정 취소 및 기존 지불된 지원금 반환
- 선도사업 임상정보·유전체 데이터 연계 및 검체 이관 현황은 정기적으로 선도사업 전문위원회에 보고
- 선정된 선도사업과 정기적으로 회의를 개최하여 연계 시 애로사항을 반영하여 개선사항 도출

(나) 유전체 보유 선도사업 선정

□ 1차년도 선도사업 후보 현황 조사 및 선정

○ (1차년도) 유전체 보유 선도사업 후보 현황 조사

- 국내의 유전체 데이터를 보유한 후보사업을 전수 조사
 - 비식별화를 통해 제3자에게 데이터 제공 가능 여부 및 제공 가능한 데이터 양, 확보한 검체 수, 확보한 임상정보 등을 조사

⇒ (결과) 6개 사업을 연계 가능한 후보사업으로 발굴

< 후보사업별 검체·데이터 보유량 >

과제명	연구 책임자	확보 유전체 (건)	일반인/질환	확보 임상 정보(명)	제3자 제공 동의(명)*	추적 가능 (명)**	확보 검체 (건)
다중유전체 분석을 통한 비흡연 폐암 신규치료타겟 발굴 및 기전규명	박경찬	150	폐암: 150명	150	150 (‘20.4 기준)	150	150
대장암 다중유전체 통합분석 기반의 정밀의료 원천기술 개발	김영준	1,083	정상조직: 546명 대장암조직: 537명 (동일 환자의 조직)	546	406 (‘20.8 기준)	483	1,083 (데이터 기생산분)
국립암센터 수행 연구과제 다수	이은숙	461	정상조직: 46명 혈액: 143명 암조직: 272명	203	150 (‘20.4 기준)	126	25,600
치매국책연구단 사업	이건호	25	알츠하이머병	-	- (‘19.4 기준)	-	6,500
기초과학연구원 시냅스 뇌질환 연구단	김은준	2,014	정상인: 1,412명 자폐: 602명	2,014	600 (‘20.8 기준)	0	1,095 (데이터 미생산분)
울산 만명 게놈 프로젝트	이세민	3,987	일반인 2,769명 질환자 1,218명	2,455	1,710 (‘19.12 기준)	약 1,000	약 1,200 (데이터 미생산분)
총계		7,720		5,368	3,016	1,759	35,628

○ 1차년도 선정기준 및 선정절차 수립

- (1차년도, 선정기준) 동 사업으로 데이터의 수집·활용·제공 가능 여부, 품질기준을 충족하는 유전체 데이터 및 임상정보 보유 여부
- 선정기준을 만족하는 전장유전체 데이터를 보유한 규모에 따라 선도사업 선정 시 우선순위 부여

< 1차년도 선도사업 선정 기준 세부내용 >

구분	기준
① 동 사업 수집·활용· 제공 가능 여부	- 참여자 동의서·설명문·IRB 자료 확보 여부 (1) 선도사업에서 보유한 임상·유전체 데이터를 국가 바이오 빅데이터 구축 사업에 연계 가능* * 연계 시 참여자(환자 등)의 개인식별정보 포함을 권장 (2) 동 사업에서 해당 데이터를 분석하고 외부 연구자·기관(제3자)에 비식별화하여 제공 가능
② 유전체 데이터 및 임상정보 보유 여부	- 동 사업 품질기준(참고 1) 충족 여부 - 유전체 데이터에 상응하는 임상정보 보유 여부 및 임상정보의 보완 가능 여부* * 질환 별 특성과 동 사업에서의 활용성을 고려하였을 때, 선도사업에서 既 보유한 임상정보의 추가 보완이 필수적인 경우에 보완가능성 고려

○ 1차년도 유전체 보유 선도사업 선정결과

- 제3차 선도사업 전문위원회(2020.8.24)를 통해 3개 사업을 선도사업으로 선정

- 기초과학연구원 시냅스 뇌질환 연구단 사업, 대장암 다중유전체 통합분석 기반의 정밀의료 원천기술 개발, 울산 1만명 게놈 프로젝트 선정

< 1차년도 선정된 선도사업 세부현황 >

과제명	연구 책임자	임상정보 및 전장유전체 데이터 既생산 인원 수*	임상·유전체 데이터 연계 인원 수**
기초과학연구원 시냅스 뇌질환 연구단	김은준	600명	500명 이상
대장암 다중유전체 통합분석 기반 정밀의료 원천기술 개발	김영준	406명 (환자별 정상조직 및 암조직 보유)	400명 이상
울산 1만명 게놈 프로젝트	이세민	1,710명	1600명 이상
총 계			2500명 이상

* 제3차 제공동의가 완료되었으며, 임상·유전체 데이터 既 생산된 참여자 수

** 국립중앙인체자원은행에서 데이터 기탁 여부 확인 후 최종 확정될 예정

□ 2차년도 선도사업 후보 현황 조사 및 선정

○ (2차년도) 유전체 보유 선도사업 후보 현황 조사

- 보건복지부·과학기술정보통신부·산업통상자원부의 현행 R&D 과제(사업) 중, 참여자 동의서 가이드라인*을 만족하며, IRB 제공·변경심의를 통해 동 사업 컨소시엄에 데이터 연계·기탁이 가능한 임상 및 유전체 보유 사업(단)에 대한 현황조사

* 질병관리청 국립중앙인체자원은행에서 제공하는 가이드라인

- 참여자 동의서 가이드라인을 충족하며 IRB 제공·변경심의가 가능한 사업(단)에 대해 임상·유전체 데이터 보유 현황 파악
- 2차년도 선도사업에 지원할 의사가 있는 사업(단) 현황 확인
- 아래와 같은 기준으로 국내 유전체 보유 선행사업을 파악하고자 함

① 과제(사업) 참여자 인체유래물 연구 동의서 혹은 기증 동의서 기반 제3차 제공 동의 구득 여부

가. 인체유래물 연구 동의서(생명윤리법 시행규칙 별지 제34호서식)

- 1) 인체유래물 보존 기간 : **영구보존 / 동의 후 20년 이상**
- 2) 보존 기간 내 2차적 사용을 위한 제공 여부 : **포괄적 연구 목적으로 제공하는 것에 동의**
- 3) 2차적 사용을 위한 제공 시 개인식별정보 포함 여부 : **개인식별정보 포함에 동의**

나. 인체유래물 기증 동의서(생명윤리법 시행규칙 별지 제41호서식)

과제정보	과제명			
	부처		사업기간	
	연구책임자		연구책임자 소속	
임상정보	임상정보 수집책임자		임상정보 보유기관(병원)	

데이터/검체 구분	번호	항목명	설명	현재 (‘21. 10월 기준)
동의서 / IRB 3자제공 준수	1-1	동의서 구득 여부	임상·전장유전체 정보 보유 사업 참여자 중 인체유래물 연구 동의서의 아래와 같은 내용을 동의한 경우 1. 인체유래물 보존 기간: 영구보존 / 동의 후 20년 이상 2. 보존 기간 내 2차적 사용을 위한 제공 여부: 포괄적 연구 목적으로 제공하는 것에 동의 3. 2차적 사용을 위한 제공 시 개인식별정보 포함 여부: 개인식별정보 포함에 동의 *생명윤리법 시행규칙 별지 제34호서식 사용	예시) xx명
			임상·전장유전체 정보 보유 사업 참여자 중 인체유래물 기증 동의서에 동의한 경우 *생명윤리법 시행규칙 별지 제41호서식 사용	예시) xx명
			소계 - (1)	xx명
검체(샘플) 확보	2-1	기확보 검체/샘플	(1)의 소계에 해당하는 참여자 중, 기확보된 검체(샘플)가 존재하는 경우에만 해당 참여자 수(명) 기입 * WGS 생산 등으로 검체/샘플 소진된 경우도 포함	예시) 정상인 xx건, 질환자 xx건(정상조직 xx건, 위암조직 xx건)
	2-2	추가 유전체 확보	(1)의 소계에 해당하는 검체/샘플 중, 기존 상응하는 전장유전체 데이터는 생산된 바 없지만, 추후 전장유전체 데이터 생산이 가능한 샘플수	예시) 정상인 xx건, 질환자 xx건(정상조직 xx건, 위암조직 xx건)
임상정보 확보	3-1	검체/샘플 기보유 임상정보	(2-1)에 해당하는 참여자 중, 임상정보가 수집된 인원 수(명)	예시) 정상인 xx건, 질환자 xx건(정상조직 xx건, 위암조직 xx건)
	3-2	추적보완 가능한 임상정보	(2-1)에 해당하는 참여자 중, 임상정보의 추적보완(동의서 재구득 포함) 가능한 참여자 수(명)	(전장유전체) 예시) 정상인 xx명, 질환자 xx명 (추적조사 가능여부) 예시) 정상인 xx명, 질환자 xx명
전장유전체 데이터 (FASTQ 기준*)	4-1	검체/샘플 및 임상정보 기보유 WGS 데이터	(3-1)에 해당하는 참여자 중, 전장유전체(WGS) 데이터 생산 참여자 수(명)	예시) 정상인 xx건, 질환자 xx건(정상조직 xx건, 위암조직 xx건)
	4-2	시퀀싱 Coverage 기준	(4-1)의 데이터에 적용된 시퀀싱 평균 depth 기준	예시) 정상인 30X, 질환자 정상조직 30X, 위암조직 60X

② ①의 제3자 제공 동의 구득한 참여자로부터 유래된 검체/샘플 보유 여부

③ ②의 검체/샘플로부터 일관된 규격으로 생산된 임상·전장유전체* 데이터 보유 여부

* 전장유전체(Whole-genome sequencing, WGS) : 차세대염기서열분석(NGS) 기법으로 인간의 전체 유전체를 해독한 데이터, WGS 데이터의 건수는 조직 등으로 차별화된 검체 수를 말함
예) 동일 환자의 암 조직 및 정상 조직에 대해 각각 WGS 수행한 경우, 총 2건으로 산정

<바이오빅데이터 시범사업 유전체 정보 보유 선도사업 현황 조사표>

과제명	연구 책임자	확보 유전체 (건)	참여자 구성 (일반인/질환)	확보 임상 정보(명)	제3자 제공 동의(명)	추적 가능 (명)	확보 검체 (건)
자폐증 분자진단을 위한 바이오마커의 임상적 검증	유희정 (분당서울대), 김은준(IBS)	849건	정상인 1,100명, 자폐 스펙트럼 장애 800명	800명	3,500명	-	3,500건
다중유전체 분석을 통한 비흡연 폐암 신규치료타겟 발굴 및 기전규명	한지연 (국립암센터), 박경찬 (생명연)	300건	질환자 150명 (정상조직 150건, 폐암조직 150건)	150명	150명	150명	150건

과제명	연구 책임자	확보 유전체 (건)	참여자 구성 (일반인/질환)	확보 임상 정보(명)	제3자 제공 동의(명)	추적 가능 (명)	확보 검체 (건)
MRI기반 알츠하이머성 치매 특이 뇌손상 규명 및 뇌지도 구축	이건호 (조선대)	1,000건	질환자 5,000명 (정상인 3,000명, 경도인지장애 환자 1,000명, 치매 환자 1,000명)	5,000명	5,000명	2,500명	12,000건
울산 만명 게놈 프로젝 트	이세민 (UNIST)	3,180건	정상인 3,180건	3,180명	3,361명	3,233명	3,361건
대장암 다중유전체 통합 분석 기반의 정밀의료 원천기술 개발	김영준 (연세대)	1,400건	질환자 1600명 (정상조직 1600건, 대장암조직 1600건)	1,600명	1,600명	1,600명	3,200건
차세대 한국인 유전체 분석지원 센터 구축	진희정 (한의연)	3,000건	정상인 3,000명	3,000명	3,000명	3,000명	3,000건
	여민경 (충남대)	1,500건	염증성장질환 1,500명	1,500명	1,500명	1,500명	1,500건
	강예은 (충남대)	2,000건	갑상선암 1,000명 (정상조직 1,000건, 갑상선암조직 1,000건)	1,000명	1,000명	1,000명	2,000건
	이영 (충남 대)	-	피부노화 1,000명				
폐장암과 폐암 환자 유 래 삼차원적 세포주 기 반 유전체 분석 및 맞춤 형 항암제 예측 시스템 개발	이현숙 (서울대)	14건	-	-	32명	-	7건
국제 협력 기반 암 특이 적 후성유전체 마커 개 발	김영준 (연세대)	-	간암 환자 17건, 간 기증자(Donor) 3건, 유방암 환자 58건, 대장암질환자 (후 향적) 152명, 대장 암질환자 (전향적) 152명	382명	382명	-	382건
정밀의료기반 암 진단· 치료법 개발 사업단	김열홍 (고려대)	-	등록 암환자 모두 수집 (1만명 이상)	1만명 이상	-	-	1만건 이상
면역항암제 치료반응 유 전체-임상정보 통합 DB 기반 사업화 모델 개발	이세훈 (삼성서울병원)	-	738명	738명	738명	-	738건
유전체 통합정보 기반 림치증후군 고위험군 선 별검사 및 위험도 예측 알고리즘 개발	이한우 (주)선바이오 머티리얼스)	-	정상인 105명, 대 장암 질환자 75명, 기타 질환 495명	675명	2,325명	-	675건
난임 치료를 위한 자궁 내 마이크로바이옴 기반 치료 기술개발	배지수 (주)지놈앤 컴퍼니)	-	체외수정 시술자 200명	200명	200명	-	200건
유방암의 선별항암치료를 위 한 차세대염기서열분석법 기 반 액체생검기술의 상용화	조은해 (주)녹십자지놈)	-	질환자 465건	465명	565명	100명	565건
NGS기반 장내미생물 정 보연계 심혈관질환 조기 진단 기술 개발	기창석 (주)녹십자지놈)	-	정상488명, 고혈 압군172명, 고혈압 (약물복용) 47명	707명	707명	-	707건

과제명	연구 책임자	확보 유전체 (건)	참여자 구성 (일반인/질환)	확보 임상 정보(명)	제3자 제공 동의(명)	추적 가능 (명)	확보 검체 (건)
NGS 기반 바이오마커 발굴 및 치주질환 진단 시스템 개발	정진 (부산대)	-	정상인 100건, 질환자 650건 (치주염환자조직 600건, 치료전후환자조직 50건)	1,400명	750명	661명	3,263건
유전체기반 한국인 희귀 난치성 발달장애 미래형 맞춤의료(P4 medicine) 구현	김남순 (생명연)	-	160명(proband, 가족 샘플 포함)	160명	189명	80명	160건
연세대학교 자체 보유	김형표 (연세대)	-	대장암 환자 177명	177명	177명	-	177건
비교의학기반 반려견·인간 공통적용 유전암 진단 단기기술 개발	조제열 (서울대)	-	정상인혈액 127명	127명	127명	-	127건
단일세포 전사체 분석을 통한 폐암전이 예측 바이 오마커와 치료타겟 발굴 (세부과제명)	이혜옥 (가톨릭대)	-	질환자 82명 (정상조직 23건, 폐암조직 79건)	82명	97명	-	82건

※ 응답한 선행사업·과제 중, 선도사업 참여 기준(제3자 제공동의의 구득된 임상·전장유전체 데이터 100건 이상을 보유)을 충족하지 못한 선행사업·과제는 회색 음영으로 표기함

○ 2차년도 선정기준 및 선정절차 수립

- (2차년도, 선정기준 보완) 선정기준을 만족하는 전장유전체 데이터를 보유한 규모에 따라 선도사업 선정 시 우선순위 부여
 - 시범사업과의 연계를 통한 연구의 연속성 및 확장성, 재정의 효율적 사용을 통한 결과 시너지 효과 창출을 위해, 2차년도 선도사업을 선정하기 위한 기준 보완
- (선정규모) 시범사업 일정 및 선도사업 연계의 시급성을 고려하여 1차년도에는 3개 이하의 과제를 선도사업으로 선정하였으나, 2차년도에는 유전체 연계 데이터 규모(총 2,500건) 이내에서 과제 개수를 결정하지 않고 선정함
- (선정절차) 선도사업 전문위원회 논의·평가를 거쳐 1차 선정 후 운영위원회, 추진위원회를 통해 연계 대상사업 최종 확정

< 2차년도 선도사업 선정기준 개선(안) >

우선순위	기준
1	참여자 동의 여부(수집·활용·제3자 제공 가능)
2	데이터 연계·분석을 통한 성과 및 파급효과* * 선도사업 후보 측에서 해당 성과·파급효과를 간략히 서술하며, 선도사업 전문위원회에서 기대효과를 기반으로 과락 여부 결정 * (사례) ① 혁신적 예방법 혹은 조기 진단법 개발, ② 신약개발 활용, ③ 산업화 성과 창출, ④ 질병으로 고통받는 환자와 가족에 대한 혜택 제공, ⑤ 의료비 절감 등 국가 재정 개선 등
3	성과 및 파급효과를 가시화할 수 있는 임상정보 확보 가능 여부
4	성과 및 파급효과를 가시화할 수 있는 유전체 데이터 보유 여부

※ 선도사업 전문위원회 논의를 거쳐 선도사업 선정기준 보완안 마련

※ 각 세부 기준에 따라 선도사업 전문위원회에서 정성적으로 평가

< 유전체 보유 선도사업 선정기준(예시)>

데이터 제공 가능 여부 ... (필수 자격요건)

- 연계되는 데이터의 참여자 동의 여부(수집·활용·제3자 제공가능)가 있는지?
※ 국립중앙인체자원은행 가이드라인 기준 환자 동의서·설명문 및 IRB 자료 확인

데이터 활용의 우수성 및 실현 가능성 ... 50점

- 데이터 연계·분석을 통한 성과 및 파급효과가 있는지?
* 선도사업 후보 측에서 해당 성과·파급효과를 간략히 서술하며, 선도사업 전문위원회에서 기대효과를 평가
※ (사례) ① 혁신적 예방법 혹은 조기 진단법 개발, ② 신약개발 활용, ③ 산업화 성과 창출, ④ 질병으로 고통받는 환자와 가족에 대한 혜택 제공, ⑤ 의료비 절감 등 국가 재정 개선 등
- 성과 및 파급효과를 가시화할 수 있는 임상정보 확보 가능 여부
- 성과 및 파급효과를 가시화할 수 있는 유전체 데이터 보유 여부

데이터 생산·연계·보완 전문성 ... 50점

- 임상정보 항목 표준화 및 추적조사에 따른 임상정보의 보완이 가능한지?
- 유전체 데이터 및 검증용 데이터 생산을 위한 검체 확보의 전문성을 갖추었는지?
- 사업운동을 위한 전담인력(의료진·연구진) 및 데이터 생산·연계·보완을 위한 전문성을 갖추었는지?

○ 2차년도 유전체 보유 선도사업 선정결과

- 2차년도 유전체 보유 선도사업 선정기준(안) 및 선정절차(안) 심의·의결(' 21.11.19, 제 10차 국가 바이오 빅데이터 구축 시범사업 추진위원회)

- (선정기준) ①데이터 보유, 참여자 동의 구독 여부, ②정보 표준화·데이터 보완 등 사업 전문성, ③데이터 연계 시 기대성과·파급효과 등
- (선정절차) 공모를 통해 유전체 보유 선도사업 후보군 발굴 → 별도 평가위원회(7인)가 2차년도 선도사업 선정기준에 따라 신청사업을 평가하고 대상사업 추천 → 추진위 심의·의결하여 최종선정 후 생명(연) KOBIC(1세부) 위탁과제로 운영
- 공모로 선정한 선도사업으로부터 데이터를 우선 연계하고, 데이터 연계 목표(2,500건) 부족분 발생 시 추가로 선도사업 전문위가 대상 사업을 우선순위를 정해 추천하고, 추진위가 최종 선정하여 총 2,500건 연계 추진

< 공모, 평가 및 추천 >

- 공모) 국가 바이오 빅데이터 구축 시범사업 2차년도 유전체 보유 선도사업 공모(' 21.11.23~12.6) 및 2개 사업·과제 신청*

- * 분당서울대병원 유희정교수팀(자폐증, 349건), 한국한의학연구원 진희정박사팀(일반인, 600건)
- (사전 검토) 2개 신청 사업·과제의 자격요건* 검토(' 21.12.7~12.9)
 - * 선도사업별 연구·기증동의서 구득 여부(사업별 동의서 예시로부터 포괄적 동의, 2차적 사용 시 개인식별정보 포함, 보존기간 10년 이상 확인), 100건 이상 연계가 가능한 임상·전장 유전체 쌍 보유 여부
- (평가) 별도의 선도사업 평가위원회*를 통해 신청 사업·과제 발표평가 실시(' 21.12.27)
 - * 한국연구재단에서 우선순위 배정 하에 무작위로 추천한 3배수 후보 중, 제척사유가 없는 7인으로 구성
- (평가 결과) 2개 사업·과제 모두 70점 이상(적합)으로 평가기준 통과
- (일부 철회) 한국한의학연구원 연구팀으로부터 IRB를 포함한 내부 검토 결과, 참여 철회 의사 통보(' 22.1.13)
- (추천) 공모를 거쳐 선정된, 최종적으로 분당서울대병원 유희정교수팀 과제(자폐증, 349명)를 단독 추천하기로 결정(「참고 1」 참조)

《 현황조사 》

- 한국연구재단, 보건산업진흥원, 산업기술평가원 등 전문기관 협조하에 임상·유전체 연계 가능한 R&D 사업 현황조사 실시(' 21.10.8~11.11)
 - 총 19개 사업·과제 도출, 이 중 6개 사업·과제가 제3자 제공동의 구득된 임상·전장 유전체 데이터 100건 이상을 보유(「참고 2」 참조)

《 선도사업 전문위원회 추천 》

- 제8차 선도사업 전문위를 개최하여, 공모로 충족하지 못한 목표치 미달분에 대해 2차년도 유전체 보유 선도사업 추천(안) 마련(' 22.1.21)
 - (대상사업 추천 기본요건) 현황조사에 참여, 제3자 제공동의 구득된 임상·전장유전체 데이터 100건 이상 보유, 연구진 참여 의사가 확인된 사업·과제 ⇒ 총 5개 사업·과제 충족(공모 추천과제 1개 포함)
 - (연계규모) 공모 추천건(분당서울대병원 349건)을 제외한 미달분(2,151건 미달)에 대해, 총 4개 사업·과제 추천(「참고 3」 참조)
 - * 시범사업 동안 다양한 질환·일반인 코호트를 수집할 수 있도록 2차년도 신규 코호트, 1차년도 선도사업 코호트 순으로 각 2개 사업·과제씩 추천
- 인체자원은행 기탁에 대비해 질병청 사전컨설팅을 실시(' 22.2)하고, 현황조사 추천(2,151건) 코호트별 연계 규모(안) 확정

< 2차년도 유전체 보유 선도사업 선정 결과 >

구분		사업·과제명	연구 책임자	참여자 구성	1차년도 임상·유전체 연계 규모	2차년도 임상·유전체 연계 규모(안)
공모 추천		자폐증 분자진단을 위한 바이오마커의 임상적 검증	유희정 (분당 서울대)	자폐증 환자·부모	500건	349건
현 황 조 사 추 천	신규 코호트	다중유전체 분석을 통한 비흡연 폐암 신규 치료 타겟 발굴 및 기전 규명	한지연 (국립 암센터)	폐암 (정상· 암조직)	-	168건
		MRI 기반 알츠하이머성 치매 특이 뇌손상 규명 및 뇌지도 구축	이건호 (조선대)	알츠하이머 환자, 정상인 대조군	-	1,000건
	1차 년도 선도 사업 코호트	울산 만명 게놈 프로젝트	이세민 (UNIST)	일반인	1,600건	783건
		대장암 다중유전체 통합분석 기반의 정밀의료 원천기술 개발	김영준 (연세대)	대장암 (정상· 암조직)	400건	200건
합계					2,500건	2,500건

□ 선정된 1·2차년도 유전체 보유 선도사업의 세부내용

○ 울산 만명 게놈 프로젝트

- (사업목표) 자발적으로 참여한 1만명의 한국인 유전정보를 수집하여, 유전체 기반 질병 예측과 진단·치료 등 연구에 활용
- (사업기간) ' 16년~' 21.4월까지 1만 명 수집을 목표로 하여, ' 21.4월 10,044명 참여자에 대한 검체 확보 및 임상·유전체 데이터 생산 완료
- * ' 21.4월 이후에도 추가 검체 확보 및 임상·유전체 데이터 생산 추진
- (수행기관) 울산과학기술원(UNIST), 울산광역시, 울산대병원 등 공동 수행
- (참여자) 모집대상은 전국민이지만, 체혈 등의 이유로 반드시 병원 방문이 요구되므로 울산지역 거주 주민 위주로 모집
- 자발적으로 참여한 일반인이며, 그 중 일부는 질환자*
- * 당뇨병, 심혈관질환, 우울증, 암 등
- (데이터 수집·분석) 임상정보, 생활습관정보, 전장유전체분석(WGS) 정보 등을 울산과학기술원 게놈산업기술센터에 구축

○ 기초과학연구원(IBS) 시냅스* 뇌질환 연구단

- * 시냅스(synapse) : 신경세포의 신경돌기 말단이 다른 신경세포와 접합하는 부위로, 한 신경세포에 있는 흥분이 다른 신경세포로 전달
- (사업목표) 한국인 자폐스펙트럼장애* 차세대 시퀀싱 및 분자진단 바이오마커의 임상

적 검증을 위한 인체유래물저장소 구축·운영

* 자폐스펙트럼장애(ASD, Autism Spectrum Disorder) : 발달장애의 일종으로, 의사소통, 사회적 관계문제를 비롯해 반복되는 행동을 동반하는 질환

- (사업기간) ' 17~' 20년까지 검체·데이터를 수집하며, 각 검체는 ' 37.2.28 혹은 동의권자가 정한 기간만큼 보관
- (수행기관) 기초과학연구원(IBS), 분당서울대병원, 한국과학기술원(KAIST), 한국과학기술정보연구원(KISTI), 고려대학교 등
- (참여자) 임상적, 심리학적, 발달적 평가 결과 자폐스펙트럼장애로 진단된 환자와 그의 형제자매, 부모 및 일반대조군
- (데이터 수집·분석) 분당서울대학교병원에서 검체·임상정보 수집하며, 전장유전체 및 단백질 데이터 분석은 한국과학기술원(KAIST), 한국과학기술정보연구원(KISTI), 고려대학교에서 시행, 기초과학연구원(IBS)에서 보관

○ 대장암 다중유전체 통합분석 기반의 정밀의료 원천기술 개발

- (사업목표) 대장암 환자로부터 생산된 유전체·후성유전체 데이터를 임상정보와 통합 분석하여 대장암 진단·예후·치료예측을 위한 정밀의료 마커 개발
- (사업기간) ' 17~' 25년까지 2,400명 수집
- (수행기관) 연세대학교, 한국과학기술원(KAIST), 서울대병원 등 공동 수행
- (참여자) 대장암 환자
 - 동 환자의 종양 및 주변 정상 조직 채취
- (데이터 수집·분석) 서울대병원 및 협력병원에서 임상정보 및 검체를 수집하며, 연세대학교·한국과학기술연구원(KAIST) 등에서 전장유전체(WGS) 정보와 임상정보의 통합 분석 수행

○ MRI기반 알츠하이머성 치매 특이 뇌손상 규명 및 뇌지도 구축

- (사업목표) 치매 조기진단 및 예측을 위한 뇌지도 구축 및 융합기술 개발
- (사업기간) ' 14~' 19년까지 5,000명 임상정보(유전체 데이터 1,000건) 확보
- (수행기관) 조선대학교 치매국책연구단, 광주광역시 치매예방관리센터, 조선대학교병원 치매정밀검진센터 등 공동 수행
- (참여자) 치매질환자 1,000명, 경도인지장애환자 1,000명, 정상인 3,000명
- (데이터 수집·분석) 광주광역시 치매예방관리센터, 조선대학교병원 치매정밀검진센터에서 임상정보 및 검체를 수집하며, 조선대학교 치매국책연구단 등에서 전장유전체(WGS) 정보와 임상정보의 통합분석 수행

○ 비흡연 폐암 다중유전체 기반 신규치료타겟 및 기전 분석

- (사업목표) 한국인 특이적 비흡연 폐암의 진단 치료 표적 후보 선별·검증 및 임상적 치료기술 기반 확립
- (사업기간) ' 17~' 21년까지 검체·데이터를 수집·생산하며, 총 300례 이상에 대한 다중유전체 확보
- (수행기관) 국립암센터, 한국생명공학연구원, 한국과학기술연구원
- (참여자) 비흡연 폐암 환자
 - 동 환자의 종양 및 주변 정상 조직 채취
- (데이터 수집·분석) 국립암센터(NCC)에서 검체·임상정보를 수집하며, 단백질 데이터 생산 및 분석은 한국과학기술연구원(KIST)에서 수행, 전장유전체 및 전사체, 후성 유전체 데이터 생산 및 통합분석은 생명공학연구원(KRIBB) 수행

< 유전체 보유 선도사업 코호트 별 주요 임상역학정보 현황 >

자 폐 증	기본정보		검사 시행 기관, 환자 가족 정보, 환자 연령, 환자·부모 성별, 검사 시행일 및 당시 환자 개월 수
	진 단 정 보	행동평가	한국판 사회적 의사소통 검사, 사회성 반응성, 아동기 행동평가 척도 등
		지능검사	전체 지능지수, 언어성·동작성 지능지수, 언어 이해 지수, 시공간지수, 유동추론지수, 바인랜드 적응 행동척도 등
		정밀주의력 검사	시청각 누락 점수, 오경보 점수, 반응시간 점수 등
		자폐증 진단 검사	자폐증 진단 관찰 스케줄(5종), 자폐증 진단 면담지(6종), 아동기 자폐증 평정척도 등
폐 암	기본정보		환자 연령, 환자 성별, 가족력, 흡연 여부 등
	진단정보		진단시 병기, 유전적 변이 정보(MSI), 전이 정보 등
	생존정보		생존 여부, 생존 기간, 추적 기간 등
	치료정보		1기 예후, 재발 여부, 재발 후 추적 기간 등
치 매	기본정보		환자·참여자 연령, 환자·참여자 성별, 환자·참여자 교육년수
	신체계측		신장, 체중, 혈압(수축기, 이완기)
	진 단 정 보	혈액분석결과	혈색소(HbA1C), 혈중 콜레스테롤 수치(전체, LDL, HDL)
		인지기능	약식인지기능검사(MMSE)
		유전검사	APOE 유전형
울 산 만 명	기본정보		참여자 연령, 참여자 성별
	신체계측		신장, 체중, BMI, 비만도, 허리둘레, 혈압(수축기, 이완기)
	혈액분석결과		혈색소, 공복 혈중 혈당, 혈중 콜레스테롤 수치(전체, LDL, HDL), 혈중

		중성지방, B형간염바이러스(표면항원, 표면항체) 등
	신체기능검사	청각, 시력, 요단백 등
	영상검사	흉부촬영
대 장 암	기본정보	환자 연령, 환자 성별, 진단일 등
	진단정보	암위치 상세 정보(9종), 병리정보, 암 분화도, 유전적 변이 정보(MSI, KRAS, NRAS, BRAF 등), 진단 시 병기, 전이 정보, 중복암 여부 등
	생존정보	생존 여부, 생존 기간(사망일), 추적 기간(마지막 추적관찰일) 등
	치료정보	보조항암 치료정보, 방사선 치료 정보, 재발 정보, 후속 치료 정보(환자별 단계 치료 정보) 등

(다) 유전체 보유 선도사업 연계 및 코호트 별 고도화 연구

□ 유전체 보유 선도사업 연계 결과

○ 유전체 데이터 연계 및 검체 운송

- 보유한 전장유전체 데이터 연계 및 활용

- 선도사업 책임자는 보유한 유전체 원데이터(raw data)를 하드디스크로 국가생명연구자원정보센터(KOBIC)에 연계
- 질병관리청은 개별 임상정보·검체에 상응하는 유전체 ID를 생성하여 국가생명연구자원정보센터(KOBIC)에 전달
- 국가생명연구자원정보센터(KOBIC)는 연계된 유전체 원데이터에 대한 품질관리(QC) 및 변이분석을 수행하여 유전체 변이데이터(variant data) 생산
 - ※ KOBIC은 원활한 유전체 품질관리를 위해 필요한 추가정보(실험기록 등)를 선도사업 책임자에게 요청하여 제공받음

- 검체 운송 및 활용

- 유전체 데이터가 생산되지 않은 검체 중, 제3자 제공·활용 동의 구득 및 임상정보가 확보된 검체를 권소시험 참여기관으로 운송
- 운송된 검체를 활용하여 추가 전장유전체 데이터 및 검증용 데이터 생산 후 국가생명연구자원정보센터, 국립중앙인체자원은행에 기탁
 - ※ 1차년도에서는 사업의 시급성으로 인하여 운송될 검체의 데이터 생산을 선도사업단에서 수행한 후, 생산된 데이터를 기탁

○ 임상정보 보완

- 보유한 임상정보를 표준양식으로 수정·보완
- 각 코호트 별로 데이터의 연구 활용성 제고를 위해, 다양하고 복합적인 형태의 임상정보를 연계하여 시범사업에서 제공

○ 임상정보 이관

- 질병관리청 국립중앙인체자원은행에 임상정보 기탁*
- 국립중앙인체자원은행에서 개별 참여자에게 구득한 동의서·IRB 자료 및 품질관리(QC)된 임상정보 품질 확인 후 최종 데이터 기탁

< 본 사업 추진 시 시사점 >

- 희귀질환 외에 암, 난치질환 및 일반인 등 다양한 데이터를 사전에 확보하여 **업무 프로세스 검증 및 필요 임상정보 항목을 발굴**
 - (업무 프로세스) 희귀질환 외 다양한 코호트에 대한 **검체, 임상정보 확보 및 유전체 데이터 생산·변이분석 수행**
 - (임상정보 발굴) 임상, 유전체 데이터의 활용성을 제고하기 위해 **코호트 공통 및 질환 코호트별 임상정보 항목 도출**

□ 추진 결과

○ 추진 결과

- 시범사업 활용 및 외부 연구자 제공·활용 가능 여부 확인
 - 선도사업에 대한 참여자 별 동의서 확인 및 법률 검토*
 - * 질병관리청 ELSI(Ethical, Legal and Social Issues) 위원회에서 검토
- 위탁과제 추가·변경 신청에 대한 연구재단 승인
 - 유전체 데이터 보유 선도사업을 한국생명공학연구원의 위탁과제로 선정
 - ※ 선도사업별 임상·유전체 데이터 연계 대상자 수에 비례하여 예산 산정
- 선정된 선도사업별 IRB 제공심의·승인 후 유전체 데이터 연계(국가생명연구자원정보센터) 및 임상정보 연계(국가생명연구자원정보센터, 국립중앙인체자원은행)
- (울산만명 코호트) Genome Korea in Ulsan' 사업 추진을 위한 MOU('20. 7. 7)
 - ※ 울산시와 한국생명공학연구원 간 공동 협력 성과의 국가 바이오 빅데이터 사업 연계·공유, 울산 1만 명 게놈 해독·분석 연구를 위한 공동협력 등

□ 유전체 보유 선도사업 연계 및 코호트별 고도화 연구 결과

○ 2위탁 연구과제 (197,920천원)

과제명	국가 바이오 빅데이터 구축 시범사업을 위한 일반인 전장 유전체 데이터 생산
연구기관명	울산과학기술원
연구책임자명	이세민
연구기간	2021. 05. 29 - 2022. 12. 31 (20개월)
연구개발 목표	○ 일반인 임상정보 확보 및 샘플 해독을 통한 전장 유전체 데이터 추가생산 ○ 기 보유한 바이오 데이터와 신규 수집·생산 데이터의 통합을 통한 바이오 빅데이터 구축 ○ 바이오 빅데이터 연계 및 기탁
연구개발 내용	○ 일반인 임상정보 확보 및 샘플 해독을 통한 전장 유전체 데이터 추가생산 - 게놈 빅데이터 생산 표준화 프로토콜 고도화 - 확보된 시료의 전장유전체(whole genome sequencing) 생산 - 전장유전체에 해당하는 일반인 임상정보 확보 ○ 기 보유한 바이오 데이터와 신규 수집·생산 데이터의 통합을 통한 바이오 빅데이터 구축 - 기존 울산 만명 게놈 프로젝트로부터 생산된 1600명(1차)의 임상·전장유전체 데이터와 신규 구축한 데이터의 연계 및 통합 - 기존 울산 만명 게놈 프로젝트로부터 생산된 783명(2차)의 임상·전장유전체 데이터와 신규 구축한 데이터의 연계 및 통합 ○ 바이오 빅데이터 연계 및 기탁 - 신규 생산된 150명의 임상·전장유전체 데이터의 국가생명연구자원정보센터(KOBIC) 연계 및 국립중앙인체자원은행 기탁 ○ 기 구축된 한국인 게놈 총 유전자 변이체(KoVariome), 한국인 표준 게놈 서열(KOREF)에 정보를 추가하여 다각도의 데이터 분석, 한국인 게놈 정보 고도화 및 표준게놈 정보를 국가적으로 제공 ○ 게놈 표준 데이터 기반 맞춤의학, 신약개발 관련기업 창업 및 일자리 창출 ○ 국외 유전변이 정보를 기반으로 도출된 질병 등의 위험도를 한국인유전변이 정보를 활용하여 한국인 맞춤형 건강관리 시스템 및 개인맞춤의료 시스템 적용 ○ 게놈관련 바이오 빅데이터 산업 기술의 국산화 및 첨단 게놈-ICT 기반 융합 생명공학 산업 발전

가. 추진내용

(1) 일반인 임상정보 확보 및 샘플 해독을 통한 전장 유전체 데이터 생산

(가) 게놈 빅데이터 해독 프로토콜 구축

- DNA 추출 Kit별 프로토콜 구축

- 서열 해독을 위한 DNA 라이브러리 구축

- RNA 추출 프로토콜 구축
- 서열해독을 위한 RNA 라이브러리 구축
- Methylation 패턴 확인용 라이브러리 구축
- 전장 유전체 해독 프로토콜 구축 (NGS)

(나) 전장 유전체 데이터 생산

- 시료로부터 DNA 추출
- 시료로부터 RNA 추출
- 전장 유전체 해독 (Short-Read)

(다) 임상정보 확보

- 생산된 전장유전체 데이터에 해당하는 일반인으로부터 임상정보 확보

(2) 임상·전장유전체 데이터의 연계 및 기탁

- 기존 울산 만명 게놈 프로젝트로부터 생산된 1600명의 임상·전장유전체 데이터를 국가생명연구자원정보센터(KOBIC)에 연계 및 국립중앙인체자원은행에 기탁

(3) 게놈 빅데이터 구축

- 유전체, 생활습관 정보등 다양한 종류의 바이오 데이터 생산
- 기 수집된 바이오 데이터와 본 사업을 통해 수집·생산된 데이터의 통합을 통한 바이오 빅데이터 구축

나. 연구개발결과

(1). 일반인 임상정보 확보 및 샘플 해독을 통한 전장 유전체 데이터 생산

(가) 게놈 빅데이터 해독 프로토콜 구축 완료

- DNA 추출 Kit별 프로토콜 구축 완료
- 서열 해독을 위한 DNA 라이브러리 구축 완료
- RNA 추출 프로토콜 구축 완료
- 서열해독을 위한 RNA 라이브러리 구축 완료
- Methylation 패턴 확인용 라이브러리 구축 완료

- 전장 유전체 해독 프로토콜 구축 (NGS) 완료

(나) 임상정보 확보 완료

- 생산된 전장유전체 데이터에 해당하는 일반인으로부터 임상정보 확보 완료

(2) 임상·전장유전체 데이터의 연계 및 기탁

- 기존 울산 만명 게놈 프로젝트로부터 생산된 2,504명의 임상·전장유전체 데이터를 국가생명연구자원정보센터(KOBIC)에 연계 완료
- 전장 유전체 데이터 추가 생산 후 국립중앙인체자원은행에 기탁 완료

(3) 게놈 빅데이터 구축

- 유전체, 생활습관 정보등 다양한 종류의 바이오 데이터 생산
- 기 수집된 바이오 데이터와 본 사업을 통해 수집·생산된 데이터의 통합을 통한 바이오 빅데이터 구축

<연구개발 성과의 관련 분야에 대한 기여도>

가. 일반인 임상정보 확보 및 표준화 프로토콜 수립

- 2,504명의 임상 데이터와 그에 해당되는 115개 임상·역학 항목 확보, 유전체 데이터와 연계 및 기관 기탁
- 다수의 병원으로부터 가져온 임상 데이터에 따른 단위 표기 차이 표준화 프로토콜 수립 (mg, ng 등)
- 특정 임상 항목에 따른 다른 계산 방식 표준화 프로토콜 수립 (LDL, BMI 등)
- 국내 및 해외 의료 정보 표준에 최대한 맞춰 용어 정의 및 변경 (SNOMED CT)
- 추후 수집한 임상·역학 데이터가 표준화되는 자동화 시스템 구축




나. 인종특이적인 유전자연구에 유용한 유전자형 및 표현형 자료로 활용 될 수 있도록 전장 유전체 데이터 생성

- 정량화된 임상정보 데이터와 전장 게놈 데이터를 분석하여 단염기다형(SNP), 유일변이, 이중변이, 인델(indels)을 식별 할 수 있도록 기초 데이터 생성. 이런 다양한 유형의 게놈 변이를 기반으로 한 다른 인구와 비교되는 한국인 특이패턴 및 게놈 기능 발굴
- 참조표준 변이체 데이터로 활용함으로써 타 인종 변이체 세트와 비교할 때, 한국인을 표준 패널로 사용하면 암 샘플의 선천적 변이들을 사전에 필터링
- 전장 유전체 데이터의 single nucleotide variants (SNV), indels, copy number variations (CNV), transposable element (TE) 삽입, 그리고 한국인 population의 인간 백혈구 항원(HLA) 유형과 한국인 데이터를 다른 populations의 유사한 데이터와 대조하여 추후 분석에 활용
- 일반인 정보를 제공하여 다른 4개 코호트(ASD, 치매, 폐암, 대장암)와 같이 다양한 질환에 대해 예측, 예방, 진단을 할 수 있는 기반 마련

다. 국가 바이오 빅데이터 구축 사업 및 게놈 빅데이터 활용을 위한 임상·유전체 데이터 연계·기탁 및 플랫폼 구축

- 국가생명연구자원정보센터(KOBIC)·국립중앙인체자원은행에 생산·확보된 전장유전체 데이터와 임상정보의 연계 및 기탁
- 참여자 모집 및 임상정보 수집과 표준화 절차를 통해 지속가능한 데이터 수집체계 구축
- 참여자 동의 기반 빅데이터에 대한 구축 및 추적관리 시스템 구축 (2,504명)



〈연구개발 성과의 관리 및 활용〉

가. 임상·역학 정보의 지속적인 업데이트 및 표준화 거버넌스 구축

- 국제용어표준 (SNOMED-CT) 기반 표준참조용어세트에 맞추어 용어 매핑 가이드라인 설정
- 각각 샘플에 대해 EMR, CRF와 추가적인 임상 정보를 확보 및 표준화 하여 추후 분석을 위하여 기반 마련
- 보다 효율적인 데이터 교환 및 연계를 위해 CDA (Clinical Document Architecture)로 변환 및 추후에 FHIR(Fast Healthcare Interoperability Resource)로 운영될 수 있도록 가이드라인 개발
- 임상·역학 정보를 제공한 참여자의 의료 데이터를 추가, 확보하여 시계열 데이터로 변환하기 위해 PHR(Personal Health Record) 서비스 구축. 이를 위해, 데이터 유형별 수집 항목 및 표준제공항목 정의

나. 일반인 유전체 데이터 추가 검수, 표준화 및 추가 작업

- 추후 지속적인 샘플 수집 및 시퀀싱 예정. 각 데이터별 형식, 해독량, 구성, 내용 등의 파악을 통한 표준화 방안 수립
- 변이의 배치 효과 제거를 위해 주성분 분석(PCA) 과 연계 불균형(LD) 기반으로 필터링
- 울산 만명 게놈 프로젝트 데이터, KoGES, GnomAD, 1KGP 등 분석 후보 데이터 리스트업
- 특허 등록을 통해 수집될 데이터에 대해 일관적인 프로토콜 구축 예정


다. 위험인자 조사 및 분석 대상 위험인자 리스트 도출

- 기공개된 위험인자 관련 정보 수집(GWAS Catalog, ClinVar 등).만성질환 연관 유전변이 관련 공개 DB·문헌 조사와 기공개된 만성질환 연관 유전변이의 effect size, P value 정보 수집. 최종으로, 조사된 정보 취합을 통한 만성질환 연관 유전변이 리스트 도출

- 문헌조사를 통한 추가 위험인자 정보 수집
- 자체 보유 중인 위험인자 정보와 수집된 정보를 연계한 통합 위험인자 리스트 도출

라. 형질, 위험인자별 한국인 특이 effect size 도출 및 글로벌·지역별 비교 연구 수행

- 기구축된 한국과학기술정보연구원(KISTI)의 분석 인프라 활용
- 위험인자 평가 방법론 도출
- 위험인자 분석 파이프라인 구축
- 아시아, 유럽, 미국 등 인종별 effect size 비교 연구 수행
- 위험인자별 effect size 및 평가 결과 도출 · 제공



○ 3위탁 연구과제 (58,000천원)

과제명	대장암 바이오 빅데이터 활용을 위한 임상유전체 데이터 연계 및 플랫폼 구축
연구기관명	연세대학교
연구책임자명	김영준
연구기간	2021. 05. 29 – 2022. 12. 31 (20개월)
연구개발 목표	대장암 바이오 빅데이터 활용을 위한 임상유전체 데이터 연계 및 플랫폼 구축 - 대장암 임상정보 및 유전체 데이터를 활용하여 국가적 차원에서 데이터를 표준화 및 관리하고, 바이오 빅데이터 활용 체계 마련 등을 목적으로 함.
연구개발 내용	○ 대장암 전장유전체 데이터 연계 및 기탁 - “대장암 다중유전체 통합분석 기반 정밀의료 원천기술 개발” 과제에서 생산한 전향적 대장암 데이터(1차 200례 이상, 2차 100례 이상)를 국가생명연구자원정보센터(KOBIC)에 연계 및 국립중앙인체자원은행에 기탁 ○ 신규검체 확보, 데이터 추가 생산 및 보완 - 다기관 대장암 환자/샘플 및 임상정보 수집 - 기보관중인 샘플 처리 및 전장유전체 데이터 생산 ○ 임상정보 보완 및 이관 - 보유한 개인식별정보를 가명화하여 질병관리청 국립중앙인체자원은행에 임상정보를 기탁 - 보유한 임상정보를 표준양식으로 수정 및 보완하고, 추적조사 등을 통해 임상정보 추가 확보 및 보완 ○ 대장암 바이오 빅데이터 구축을 통해 국가적 차원에서 바이오뱅크 및 임상유전체 통합 데이터베이스를 구축, 관리함으로써 바이오헬스 산업의 성장과 환자 맞춤형 정밀의료 진단, 치료 및 기술개발 등에 활용하고자 함 ○ 포괄적인 대장암 임상/유전체 데이터베이스를 구축, 관리 플랫폼을 구성함으로써, 추후 본 연구의 산물이 효율적으로 활용될 수 있도록 함.

(1차년도)

1) 보유한 전장유전체 데이터 연계

- ‘대장암 다중유전체 통합분석 기반의 정밀의료 원천기술 개발’ 과제 내 다기관에서 수집된 임상정보 및 2차적 사용에 대한 동의서가 구득된 환자이면서, IRB 제공심의가 완료된 샘플 250례 확보함.
- 보유한 유전체 원데이터(raw data)를 하드디스크로 국가생명연구자원정보센터(KOBIC)에 연계함.
- IRB 승인일 이후 인체유래물 영구 보존에 동의하면서 2차적 사용에 대한 포괄적 동의 대장암 환자 197명에 대한 유전체 원데이터를 연계 · 기탁함.
- 국가생명연구자원정보센터(KOBIC)는 연계된 유전체 원데이터에 대한 품질관리(QC) 및 변이분석을 수행하여 유전체 변이데이터(variant data) 생산함.

2) 유전체 데이터 품질 관리

- (기준 1) 전처리 과정 후의 결과물에서 PCR 중복을 제거(PCR deduplication)*하였을 때, 잔여

mapped read에 해당하는 염기 개수의 총합이 85Gbase 이상

* Picard MarkDuplicates 등의 분석도구를 사용하여 PCR 중복 제거

※ GRCh38 기준 인간 유전체 전체 염기개수 = 3,272,116,950 base (약 3.3Gbase)

– 유전체 분석 전처리 과정

① (염기서열분석 신뢰도) 원데이터 read로부터 adapter 서열 및 PHRED score Q30 미만의 염기를 제거*

* Outadapt 등의 분석도구를 사용하여 adapter 서열 및 “-q 30” 등 옵션 적용

② (표준유전체서열 매핑) ①의 데이터를 표준유전체서열(GRCh38)에 매핑(mapping)*

* BAM-MEM 등의 분석도구를 사용하여 참조유전체서열에 대해 매핑(mapping)하며, mitochondrial genome 및 decoy sequence는 mapped read 개수 산정에 포함되지 않음

○ (기준 2) 샘플 뒤바뀐 · 중복 · 누락(swapping, duplication, omission of samples) 및 혼합 · 교차오염(mixed sample, cross contamination) 없음*

* 검수 때까지 확인 가능한 범위만을 품질관리 기준에 포함(성별, aneuploidy 확인 등)

3) 임상정보 이관

○ 질병관리청 국립중앙인체자원은행에 임상정보 기탁함.

– 보유한 개인식별정보를 가명화하여 기탁함.

– 국가생명연구자원정보센터(KOBIC)에 연계한 197명의 대장암 환자에 대한 환자 동의서 및 임상정보 197건에 대해 이관 완료함.

(2차년도)

1) 확보된 대장암 검체에 대한 유전체 데이터 생산 및 연계

○ ‘대장암 다중유전체 통합분석 기반의 정밀의료 원천기술 개발’ 과제 내 다기관에서 수집된 임상정보 및 2차적 사용에 대한 동의서가 구득된 환자이면서, IRB 제공심의가 완료된 샘플 202례 확보함.

○ 다기관 수집된 79례 대장암 검체에 대한 전장유전체 시퀀싱 데이터 생산 및 환자 동의서 / 임상정보 확보를 완료함.

○ 생산된 유전체 원데이터(raw data)를 국가생명연구자원정보센터(KOBIC)에 연계하여 유전체정보 원데이터에 대한 품질관리(QC) 및 변이분석을 수행하여 유전체 변이데이터(variant data)를 생산함.

1) 임상정보 보완 및 고도화

○ 기 보유한 임상정보를 표준양식으로 수정 · 보완하고, 각 선도사업별 특성에 따라 추적조사 등을 통해 확장 가능한 임상정보를 제시 및 보완함.

– 암 치료를 위해 선도사업 연계 병원에 내방한 환자 기록을 F/U 날짜 기준 1년 이내로 임상정보를 보완하여 제공함.

○ 향후 본 사업 추진을 고려하여, 임상정보 확보 및 보완 방안을 표준 작업절차서(SOP)의 형식으로 수립함.

2) 유전체 데이터 및 임상정보 기탁

○ 수집 · 연계된 202명 대장암 환자 데이터 중 2차적 사용에 대한 포괄적 동의한 125명 환자에 대

한 유전체 데이터 및 임상정보 기탁을 완료함.

- 질병관리청 국립중앙인체자원은행, 질병관리청 보건의료연구자원정보센터, 한국생명공학연구원 인체유래물은행 총 3개 기관에 유전체 데이터 및 임상정보를 기탁함.
 - 대장암 다중유전체 통합분석 기반의 정밀의료 원천기술 개발’ 내 인체유래물 2차적으로 포괄적 연구 목적으로 수집된 환자에 대해 각 1차년도 총 197명, 2차년도 125명에 대한 정상 / 암 조직의 유전체 데이터 및 임상정보 기탁을 완료함.

3) 데이터 분석·관리 및 보관

- 본 기관에서 연계 예정인 전장유전체 데이터 및 임상정보에 대하여, 국가생명연구자원정보센터(KOBIC), 한국과학기술정보연구원(KISTI), 질병관리청 3개 기관과 연계하여 데이터 저장 및 분석을 진행함.
- 본 기관에서 전장유전체 데이터 및 임상정보를 질병관리청 국립중앙인체자원은행, 질병관리청 보건의료연구자원정보센터, 한국생명공학연구원 인체유래물은행에 기탁함.

<연구개발 성과의 관련 분야에 대한 기여도>

- 대장암은 2020년 통계청 조사 결과 발병률 국내 4위 및 암 사망 원인 3위이며, 서구화된 식습관 등의 원인으로 발병률은 지속적으로 증가하는 추세이며 세계보건기구(WHO) 산하 국제 암연구소(IARC) 한국인 남성 대장암 발병률(10만명 당 46.9명)은 세계 4위, 아시아 1위에 달하는 실정임. 정밀의료의 바탕이 되는 바이오 빅데이터는 사후적 치료 중심에서 개인 맞춤형 치료·예방 의료로 전환됨에 따라 점차 중요성이 부각되고 있음. 따라서 국가적 차원의 바이오 빅데이터 구축을 통해 의료 질 향상, 미래 정밀의료 선도, 바이오헬스 산업의 성장 동력 확보에 기여할 것으로 기대됨.
- 해외 주요국들은 다양한 질병에 대한 임상정보 및 유전체 데이터 등 대규모 빅데이터를 이미 구축 중으로, 개인 맞춤형 의료 제공 기반을 마련하고 있음. 여러 질병에 대한 한국 특이적 임상정보 및 유전체 정보의 국가적 관리 및 보안을 통해 향후 다양한 연구의 기초자료로써 활용이 기대되며, 한국 정밀의료 및 바이오 산업 활성화에 기여할 것으로 기대됨.

<연구개발 성과의 관리 및 활용>

- 대장암에서 구축된 대용량의 유전체 및 임상정보를 통해 향후 다양한 연구에 기초 자료로 활용하고자 함.
- 한국 대장암 환자의 전장유전체 및 생존·치료 임상정보를 이용하여 암 발달에 대한 기전 및 대장암의 치료법에 대한 새로운 타겟의 연구 자료로서 활용하고자 함.
- 본 연구과제에서 생산된 전장유전체 데이터를 다양한 연구 분야와 연구자가 효율적으로 활용할 수 있도록 분량할 계획임.

○ 4위탁 연구과제 (93,760천원)

과제명	자폐스펙트럼장애 전장유전체 연구를 위한 유전체-표현형 데이터 공유 인프라 구축
-----	---

연구기관명	서울대학교
연구책임자명	유희정
연구기간	2021. 05. 29 – 2022. 12. 31 (20개월)
연구개발 목표	자폐스펙트럼장애(이하 ASD)는 유병률이 매우 높은 대표적인 뇌 발달장애로서, 유전적 이질성(genetic heterogeneity)과 임상적 subtype (또는 subgroup)의 다양성으로 인하여 진단을 위한 효과적인 표지자(biomarker)나 치료제 개발을 위한 타겟 인자가 확립되지 않은 난치성 질환임. 본 연구팀은 현재까지 500명의 ASD환자 및 가족의 69개의 임상정보를 공유 가능한 코드북 형태로 구축하고, 기 수집된 전장유전체 데이터와 임상정보를 국립중앙인체자원은행에 연계하였음. 본 연구의 목표는 1) 한국인 ASD 코호트의 환자 및 가족의 다양한 특성을 정확하게 파악하는 데 필요한 추가적인 임상검사들을 검토하고, 유전체 연구를 위한 표준 임상 프로토콜을 확립하며, 2) ASD 임상정보 및 전장 유전체 데이터의 생산 및 데이터의 품질관리, 연계 및 기탁을 수행하는 것임.
연구개발 내용	1. 연구개발 내용 가. 2차년도 1단계: ASD의 다양한 특성을 정확하게 파악하는 데 필요한 추가적인 임상검사들을 검토하고, 유전체 연구를 위한 표준 임상 프로토콜을 확립함. (1) 임상정보 품질 보완 방안 : 추가적인 표현형 평가를 위한 평가도구 항목 최적화 - 이상행동에 관한 측정 도구 (예: Aberrant Behavior Checklist) - 비언어성 지능의 평가 (예: K-Leiter-R 한국판 라이터 비언어성 지능검사) - 임신 및 출산 관련된 주산기 병력, 3대에 걸친 가족력 정보 수집 프로토콜 - 다중 광의의 자폐 표현형 가족 (multiplex broad autism phenotype family, MBAP)에 대한 평가 방안 - 부모 및 형제에서 나타나는 광의의 자폐 표현형 (broad autism phenotype) (2) 기존에 수집된 임상 정보의 데이터를 바탕으로 추가 데이터 수집 및 표준화, 정제를 실시함. 나. 2차년도 2단계 : ASD 임상정보 및 전장 유전체 데이터의 생산 및 데이터의 품질관리, 연계 및 기탁 (1) ASD 환자 및 가족의 임상 정보 수집 및 표현형 데이터 코드화 (2) 확보된 시료에서 생산한 전장유전체 데이터의 품질 검증 (3) 임상 표현형 및 유전체 데이터 공유를 위한 데이터 입력 및 공유 프로세스 확립 (4) 기 수집된 전장유전체 데이터와 본 사업을 통해 수집·생산된 데이터의 통합을 통한 데이터베이스 구축 2. 연구개발 결과의 활용 방안 (1) ASD 연구를 위한 임상자료와 유전체 자료를 연구자들에게 제공함으로써 병 발생 원인 메커니즘에 기반한 진단 체계 개발에 활용 (2) 유전변이의 포괄적 규명이 가능한 자료를 제공하고, 변이에 매칭되는 임상정보를 제공함으로써, 향후 임상 진단 가이드라인 및 치료제 개발에 활용할 수 있는 과학적 근거를 제공함. (3) 향후 ASD의 치료제 개발 파이프라인에 개발 단계에서 전장유전체 정보, 임상적 및 병리학적 증상, 특정 치료에 대한 반응성 예측을 위한 지표자로서 활용

(4) 영유아 시기에 ASD 가능성을 예측하는 가이드라인으로 활용하는 과학적 기반으로 활용

3. 기대효과

가. 임상의학적 효과

- (1) ASD 표현형 이질성을 이해할 포괄적인 유전-표현형 정보를 임상현장에 제공
- (2) 유전-표현형 정보를 기반으로 한 객관적 ASD 진단에 활용
- (3) ASD의 유전-표현형 정보의 변화추이에 대한 추적모니터링으로 예후예측에 활용
- (4) ASD 조기 진단 및 치료 효율을 높임으로써 사회적 비용을 줄이고 환자의 삶의 질 제고

나. 기초과학적 효과

- (1) 한국인 ASD 환자의 포괄적 유전체 데이터와 임상적 표현형을 제시함으로써, ASD 연구 및 진단, 치료제 개발을 위한 기초적인 정보를 제공할 것으로 기대함.
- (2) 한국인 환자들에게 직접적으로 관찰한 정보를 바탕으로 다양한 후속연구의 바탕이 됨
- (3) 향후 대규모 유전체 코호트 연구에 기반이 될 수 있는 데이터 공유 플랫폼 구축 및 활용 방안을 제시함.

(1) 유전체 정보 및 임상정보 기탁

1) 기 확보된 ASD 및 환자 및 가족 총 392명의 데이터 선별

- ◆ 유전체 정보 및 임상데이터가 확보되어 있는 ASD 환자 및 가족 중 아래와 같은 데이터 선별 기준에 의하여 data 기탁할 대상자 392명을 선별함. 데이터 선별 기준은 다음과 같음.
 - 보유한 데이터의 동의(보존) 기간, 제 3자 제공 여부, 포괄적 동의 여부, 동의서 오류 여부를 점검하여 기탁 대상을 결정함.
 - 데이터 동의(보존) 기간 : ‘영구’보존을 가장 우선순위로, ‘20년’ 보존을 차순위로 데이터를 선별함.
 - 제 3자 제공 여부 : 제 3자 제공 여부에 동의한 데이터를 선별함.
 - 포괄 동의 여부 : 포괄적 연구 목적으로 제공하는 것에 동의된 데이터를 선별함.
 - 동의서 오류 여부 : 기타 동의서 오류가 없는 데이터를 선별함.

[illegible]

2) 선별된 392명의 임상·전장유전체 데이터의 연계 및 기탁

- 기탁할 임상 정보 리스트 69개를 선별하였음. 선별된 392명의 69개 항목의 임상정보를 코드화하여 data 정제과정을 거침.

- [illegible]

[illegible]

- 한국생명공학연구원 인체유래물 은행에 기탁 완료함.

(2) 자폐스펙트럼장애 환자 및 가족의 임상 정보 수집 및 표현형 분석

가) 자폐스펙트럼장애 환자 및 가족의 임상 정보 수집 및 코딩화

자폐스펙트럼 임상정보 공개데이터 통합코드북(ver1)																					
변수 내용																					
일련 번호	공개 여부	태아분명 (국문)	태아분명 (영문)	변수명	변수설명	변수유형	설문지	대상나이	Frequency						기초통계						
									Total	9999	8888	7777	-1	0	유효값	Min	Max	Median	Mean	Stddev	
1	공개	환자정보	SNL_TMP2	6L10	검사 사항 기본번호																
2	공개	환자정보	SNL_TMP2	ID	아이디		아이디														
3	공개	환자정보	SNL_TMP2	PED	관계	1=부, 2=모, 3=PROBAND, 4=SIBLING	■ 관계 □, 부 □, 모 □, PROBAND (149명) □, SIBLING (51명) ● 보기때 감는 51명 (14세, 2세, 10세) 5는 SIBLING을 의미(예: 3형제와 경우, Proband는 3, 4형제 중 한명으로 4, 5를 순차적으로 붙임)		203	-	-	-	-	-	203						
4	공개	환자정보	SNL_TMP2	SEX	성별	1=남자, 2=여자	■ 성별 □, 남자 (149명) □, 여자 (60명)		203	-	-	-	-	-	203						
5	공개	환자정보	SNL_TMP2	BIRTHDAY	생년월일	YYYYMMDD	■ 생년월일														
6	공개	환자정보	SNL_TMP2	EDATE	평가 시행일	YYYYMMDD	■ 평가 시행일														
7	공개	환자정보	SNL_TMP2	AGE	평가 당시 나이(만)	만 ()세	■ 평가 당시 나이 만 ()세		203	-	-	-	-	-	203	1	28	6	7.98	5.4	
8	공개	환자정보	SNL_TMP2	AGE_M	평가 당시 개월 수	()개월	■ 평가 당시 개월 수 ()개월		203	-	-	-	-	-	203	21	345	74	101.40	66.2	
9	한국판 사회적 의사소통	SNL_TMP2	K_SQL_LIFE	The Korean version of Social Communication Scale: 500 Lifetime (한국판 사회적 의사소통 설문지, 평생) 측정	()점	연속형	■ The Korean version of Social Communication Scale: 500 Lifetime (한국판 사회적 의사소통 설문지, 평생) 측정		203	2	-	-	-	-	18	183	1	40	15	15.49	8.7
10	한국판 사회적 의사소통	SNL_TMP2	K_SQL_CURR	The Korean version of Social Communication Scale: 500 Current (한국판 사회적 의사소통 설문지, 현재) 측정	()점	연속형	■ The Korean version of Social Communication Scale: 500 Current (한국판 사회적 의사소통 설문지, 현재) 측정		203	4	-	-	-	-	19	180	1	40	13	13.31	8.4
11	사회성 반응성	SNL_TMP2	SRS	Social Responsiveness Scale: SRS (사회성 반응성 설문지) 측정	()점	연속형	■ Social Responsiveness Scale: SRS (사회성 반응성 설문지) 측정		203	2	-	-	-	-	1	200	1	175	82	80.82	42.7
02태아정보 코드북(국문/영문)																					

■ 인체유래데이터은행 인체유래 데이터 관리지침 [별지 제4호서식]

인체유래물동 이전 협약서

분당서울대학교병원 정신건강의학과 (소속기관명/소속부서명)의 교수 (직급/직위) 유희정 (기탁자명)은/는 한국인 자폐스펙트럼장애 자폐대시원성 및 분자진단 바이오마커의 임상적 검증에 위한 인체유래물지장소 연구 (사업/과제명)을/를 통하여 수집·생산한 인체유래물들을 한국생명공학연구원 인체유래데이터은행(이하 "은행"이라 한다)에 기탁함에 있어서 다음과 같이 협약을 체결한다.

제1조 (인체유래물동 기탁)
(1) 은행은 본 협약 체결 후 기탁자로부터 인체유래물들을 제공 받는다.
(2) 기탁기관은 본 협약 체결 후 인체유래물들을 은행에 기탁하며 그 내용은 다음과 같다.
1. 기탁 자원 정보
가. 기탁 명수 : 892명
나. 기탁 자원 종류별 수량

인체유래물동 종류	명수/건수	파일용량
임상·역학 정보	892/892	570KB
유전체 정보(fastq)	892/892	43TB
유전체 정보(gvcf)	892/892	5TB

다. 제공정보 : ■ 임상·역학정보 ■ 유전체정보 및 오믹스정보 □ 영상·이미지정보
■ 동의서 정보 □ 기타

2. 기탁 완료일
가. 기탁자는 제1조 (2)항에서 명시한 인체유래물들을 2022년 12월까지 은행으로 이전하며, 은행장과 기탁자가 기탁완료 확인서에 상호날인(서명)한 시점을 기탁 완료일로 한다.

제2조 (소유권) 원칙적으로 기탁자원에 대한 소유권은 은행에 이전되나, 기탁기관과 협의 하에 조율할 수 있다. 추가적인 사항이 발생하는 경우, 협약서에 해당 문구를 명시한다.

제3조 (기탁자원의 활용) 은행은 기탁 받은 인체유래물들을 공익을 목적으로 연구자들에 공개 분담하며, 분담시점은 기탁완료 즉시 시행한다.

제4조 (보관경비) 기탁된 인체유래물들의 보존·관리 비용은 은행이 부담한다.

제5조 (협약의 취소) 은행은 기탁기관이 기탁지침을 따르지 않거나, 협약서의 지정날짜까지 인체유래물들을 제공하지 않는 경우, 검수 오류 및 부적합 자원이 50% 이상일 경우 본 협약을 취소할 수 있다.

제6조 (협약의 변경) 본 협약의 내용은 은행장과 기탁자의 서면 합의에 따라 유효하게 변경될 수 있다.

제7조 (협약의 효력) 본 협약의 효력은 협약 당사자가 서명·날인한 이후부터 유효하고, 협약서는 원본 2부를 작성하여 중앙은행장과 기탁자가 각각 1부씩 보관한다.

2022년 12월 9일

인체유래데이터은행장 : 김선영
기탁자 : 유희정 또는

- 다음과 같은 포괄적인 평가 영역에 걸쳐, 아동과 가족(생물학적 부, 모, 형제)의 임상 정보를 수집하고 코드화하여 공유 가능한 데이터베이스를 구축하고 코드북에 통합함.
- 진단 및 표현형 수집의 주요 절차는 다음과 같음.

① 면담 및 병력 청취

발달 지표를 포함한 아동의 초기 발달력, 발달 초기의 이상 양상, 질병력과 약물 투여력, 가족력, 이전의 평가 및 치료 경력 등에 관한 포괄적인 임상 정보를 확보함. 아동의 의무기록을 검토하여 가능성 있는 신체질환 및 염색체이상, 공존 정신질환, 주산기력, 약물투여력에 관한 정보를 보완함.

② 이학적 검사 및 실험실 검사

- 이학적 검사: 신경학적 검사, 대-소근육 운동 협응능력, 형태이상학을 포함하는 포괄적인 검사를 시행함. 특히 미토콘드리아 기능과 관련이 있다고 생각되는 운동기능, 간질, 소화기계 질환에 대한 포괄적 병력을 확보함.
- 실험실 검사: 임상적으로 필요하다고 판단되는 경우 기존의 신체적 이상을 감별하고 스크리닝하기 위한 간기능 검사, 전해질 검사, 갑상선 호르몬 검사, 심전도 검사, 염색체 검사 등을 시행함.

③ 자폐스펙트럼장애 진단 평가

- 자폐스펙트럼장애를 정확히 진단하는 것은 연구의 정확성을 담보하기 위해 가장 기본적이고 중요한 단계임. 연구 대상 아동과 형제들은 세계적으로 표준이 되는 진단 도구이면서 본 연구팀에서 한국판을 개발한, 한국판 자폐스펙트럼장애 진단 관찰 스케줄(Korean Version of Autism Diagnostic Observation Schedule; K-ADOS, version 2; Yoo et al., 2017) 및 보호자 면담 도구인 한국판 자폐스펙트럼장애 진단 면담 - 개정판(Korean Version of Autism Diagnostic Interview - Revised; K-ADI-R; Park et al., 2014)을 통해 진단함. 이들 진단 도구의 시행은 연구 신뢰도가 있는 연구원에 의해 수행되었으며, 면담 과정을 모니터하며 매 면담마다 부모의 동의를 얻어 비디오 촬영을 하고, 이는 다른 연구원과 함께 검토하여 연구자간 일치도를 검증한 뒤 데이터베이스화 하였음. 사용된 도구의 개요는 다음과 같음.

㉞ Korean version of Autism Diagnostic Observation Schedule (K-ADOS)

- a. 도구 개요: ADOS는 1989년 Lord 등에 의해 개발된 반구조화된 자폐장애 진단 도구로, 아동과의 상호작용을 유발할 수 있는, 자연스럽고 흥미로운 상황을 제공함으로써 놀이를 통해 자폐스펙트럼장애와 관련된 사회성 및 의사소통 행동의 질을 관찰할 수 있게 고안됨.
- b. 도구의 구성: ADOS는 모두 네 가지 모듈로 구성되어 있는데, 모듈 1은 어구(phrase)를 일관되게 사용할 수 없는 아동을 대상으로 하며, 모듈 2는 어구를 사용하기는 하나 자유롭게 언어를 구사할 수 없는 아동, 모듈 3은 언어표현이 자유로운 아동, 모듈 4는 언어표현이 자유로운 청소년과 성인을 대상으로 함. 총 45분-1시간이 소요됨.
- c. 평가 가능한 행동 영역: ADOS를 시행한 후에는 관찰한 내용을 기록하고, 주어진 가이드라인을 따라 코딩한 뒤 진단적 평가를 내리게 되어 있음. 본 연구에서 이들 각각은 자폐스펙트럼장애의 표현형으로 기능하게 됨.

㉟ Korean version of Autism Diagnostic Interview - Revised (K-ADI-R)

- a. 도구 개요: ADI-R은 1994년 Lord 등에 의해 개발된 반구조화된 면담 도구로, 아동의 부모/보호자를 면담하는 과정을 통해 자폐스펙트럼장애를 진단하는 도구임. 위에 기술한 ADOS와 상보적으로 사용되며, 자폐장애 진단 기준에 포함된 의사소통, 사회적 상호작용, 행동과 관심의 제한 등 세 영역에 걸쳐 아동의 행동 양상을 포괄적으로 기술하고 평가하도록 되어 있음.
- b. 구성: 면담은 총 6개의 부분(section)으로 구성되어 있으며, 최근 3개월간의 상태와 과거 상태에 대한 기술을 결합하여 평가하도록 되어 있음. 면담은 양쪽 또는 한쪽 부모나 다른 보호자와 진행하며, 총 1.5-4시간이 소요됨.
- c. 평가 방법: 자폐장애와 자폐스펙트럼장애에 대한 경계 점수가 설정되어 있어 나이대별로 다르게 정해진 알고리즘에 따라 진단을 내리는데, 각각의 항목 및 영역별/하위 영역별 점수는 각각 행동적 표현형으로 분석 대상이 됨.

④ 기타 행동 양상을 해석하는 데 중요한 변수가 되는 지능, 인지능력, 수행능력(전두엽 기능, 주의집중력), 사회적 반응성, 이상행동, 강박증상, 틱, 공감능력 등의 형질과 공존 병리를 측정하여 수치화 함. 평가 계획에 포함될 수 있는 표현형 측정 도구들을 아래 표로 정리하였음.

표 1. ASD 환자와 가족의 표현형 평가 계획 요약

Domain	Parameters & Tests
환자 정보	ID 환자와의 관계(부,모,proband,sibling) 성별 생년월일 평가 시행일 평가 당시 나이(만, 개월수)
선별검사	Social Communication Questionnaire (K-SCQ) Social responsiveness scale (SRS)
진단검사	Autism Diagnostic Interview -Revised (K-ADI-R) Autism Diagnostic Observation Scale (K-ADOS) Childhood Autism Rating Scale: (K-CARS)
지능검사	Korean Educational Developmental Institute Wechsler Intelligence Scale for Children Leiter International Performance Scale
적응행동검사	Vineland Adaptive Behavior Scale
행동척도	Korean Child Behavior Checklist
실행기능검사	Advanced Test of Attention: ATA

- 연구에 참여하는 모든 가족의 표현형을 더욱 체계적으로 평가하기 위해 다양한 검사들의 번역과 역번역 과정을 거쳐 저자들에게 최종 승인을 받고 사용함 (그림 1).
- Broad Autism Phenotype Questionnaire (BAPQ):** 자폐스펙트럼장애 관련 특성을 측정하기 위한 자가 평가 도구임. 36문항으로 구성된 설문지이며, 점수들의 평균으로 aloof, restricted and repetitive behavior, pragmatic language의 하위 영역을 계산함.




그림 1. 설문지 준비 과정


나) 자폐스펙트럼장애 환자 및 가족의 임상 정보 분석

- 매주 가족들의 임상 자료를 검토하고 코딩에 따라 세분화하여 분석을 진행함 (그림2).

그림 2. 가족들의 표현을 검토하기 위한 자료 예시

- 수집한 임상적 자료를 토대로 부모의 정신 건강 문제, 공격행동과 서번트 능력과 같이 자폐스펙트럼장애 대상자들에게 흔히 보고되는 증상들의 분석을 진행했음.

SNP-D-905



부모 ADOS (비교점수)

Module	SA	RRB	총점
부	4	5 (3)	0 (1)
모	4	1 (1)	0 (1)

부모 (기타)

	AQ	SRS	BAFQ	Altoid	RRB	PL
부	31	76	3.75	2.67	3.08	
모	17	34	3.92	3.42	3.08	
			3.33	2.33	3.33	
			3.27	2.42	3.92	

KSCIRS

부	정신증 (65)
모	우울 (62) 수면문제 (61)

아동 ADOS (비교점수)

Birth Order	Module	SA	RRB	총점
1	1	18 (8)	6 (9)	24 (9)
2	1	15 (8)	6 (10)	21 (9)

아동 (ADI-R)

Birth Order	A	B_v	B_mv	C	D
1	22	11	11	3	4
2	15	10	10	5	4

아동 (기타)

Birth Order	SCQ_C	SCQ_L	SRS (T)
1	19	17	72
2	15	13	62

아동 (심리)

SA
1 언어이해 (48) 시공간 (52) 작업기억 (48) 전체척도 (42)
2 언어이해 (48) 시공간 (46) 작업기억 (48) 전체척도 (40)

아동 (CBCL)

Birth Order	내성	외향	반사회적	반사회적	반사회적	반사회적
1	-1	-1	-1	50	68	54
2	-1	-1	-1	50	65	50

아동 (기타)

사건	사건	사건	사건	사건	사건	사건
1	-1	59	-1	50	61	55
2	-1	59	-1	66	52	48

아동 (기타)

아동 (기타)	아동 (기타)	아동 (기타)	아동 (기타)	아동 (기타)	아동 (기타)	아동 (기타)
1	56	65	50	-1	50	56
2	56	50	53	-1	59	70

- **부모 정신 건강:** 자폐스펙트럼장애 자녀를 가진 264명의 부모 중 63.2%는 위험 수준의 정신 건강 문제를 가지고 있음. 그중에서 조증이 가장 많이 보고되었으며 스트레스 취약성, 대인 관계 민감성, 불안과 우울 관련 어려움을 겪고 있는 것으로 조사됨. 정신 건강 문제가 있는 그룹과 없는 그룹을 비교한 결과, 자폐스펙트럼장애 자녀의 연령, 성별, 증상 심각도, 기능 수준(예. 지능, 적응행동)은 비슷했으나 자폐스펙트럼장애 관련 특성들을 보는 자가 설문지와 배우자의 pragmatic language 영역에서 두 그룹간 유의미한 차이를 보임.
- **공격 행동:** 자폐스펙트럼장애와 정상 발달 그룹을 비교하였을 때, 자폐스펙트럼장애 대상자들의 공격 행동이 유의미하게 더 높았음. 공격 행동을 보이는 자폐스펙트럼장애 대상자들은 반복적인 행동과 제한된 관심사가 더 많은 것으로 보고되었으며, CBCL 설문지를 통해 다른 문제 행동들과도 연관이 있는 것으로 보임. 조절 효과를 분석한 결과, 의사소통 능력과 내면화 관련 어려움이 공격 행동에 간접 효과를 미치는 것으로 여겨짐.
- **서번트 능력:** 서번트 능력을 가진 대상자들의 비율이 정상 발달 그룹보다 자폐스펙트럼장애 그룹에서 더 높은 것을 확인함. 그중에서 기억력, 읽기와 시공간 관련된 능력들이 가장 많았음. 서번트 능력 여부로 자폐스펙트럼장애 그룹의 하위 집단을 나누었을 때, ADI-R 영역에서 유의미한 차이를 보였으며 고기능 대상자들에게 서번트 능력이 더 많은 것을 확인함.

<연구개발 성과의 관련 분야에 대한 기여도>

1) 임상의학적 효과

- (1) ASD 표현형 이질성을 이해할 포괄적인 유전-표현형 정보를 임상현장에 제공
- (2) 유전-표현형 정보를 기반으로 한 객관적 ASD 진단에 활용
- (3) ASD의 유전-표현형 정보의 변화추이에 대한 추적모니터링으로 예후예측에 활용
- (4) ASD 조기 진단 및 치료 효율을 높임으로써 사회적 비용을 줄이고 환자의 삶의 질 제고

2) 기초과학적 효과

- (1) 한국인 ASD 환자의 포괄적 유전체 데이터와 임상적 표현형을 제시함으로써, ASD 연구 및 진단, 치료제 개발을 위한 기초적인 정보를 제공할 것으로 기대함.
- (2) 한국인 환자들에게 직접적으로 관찰한 정보를 바탕으로 다양한 후속연구의 바탕이 됨
- (3) 향후 대규모 유전체 코호트 연구에 기반이 될 수 있는 데이터 공유 플랫폼 구축 및 활용 방안을 제시함.

〈연구개발 성과의 관리 및 활용〉

- 1) ASD 연구를 위한 임상자료와 유전체 자료를 연구자들에게 제공함으로써 병 발생 원인 메커니즘에 기반한 진단 체계 개발에 활용
- 2) 유전변이의 포괄적 규명이 가능한 자료를 제공하고, 변이에 매칭되는 임상정보를 제공함으로써, 향후 임상 진단 가이드라인 및 치료제 개발에 활용할 수 있는 과학적 근거를 제공함.
- 3) 향후 ASD의 치료제 개발 파이프라인에 개발 단계에서 전장유전체 정보, 임상적 및 병리학적 증상, 특정 치료에 대한 반응성 예측을 위한 지표자로서 활용이 가능함.
- 4) 영유아 시기에 ASD 가능성을 예측하는 가이드라인으로 활용하는 과학적 기반으로 활용

○ 5위탁 연구과제 (240,000천원)

과제명	치매 바이오 빅데이터 활용을 위한 임상유전체 데이터 연계 및 데이터 보완
연구기관명	조선대학교
연구책임자명	이건호
연구기간	2022. 05. 01 - 2022. 12. 31 (8개월)
연구개발 목표	2차년도 시범사업 과업에 해당하는 유전체 보유 선도사업 업무로써, 치매 바이오 빅데이터 활용을 위한 임상유전체 데이터 연계 및 데이터 보완
연구개발 내용	☐ 치매 코호트 데이터 연계·기탁 ○ 제3자 제공 가능한 고품질 임상·유전체 데이터 1,000건을 국가생명연구자원정보센터(KOBIC)에 연계하며, 품질관리를 거쳐 최종 국립중앙인체자원은행에 기탁 ☐ 임상정보 보완·고도화 ○ 선도사업별(질환 특이적) 임상정보 보완* 및 본사업 임상정보 표준화(구조화)를 위한 품질관리 항목·기준 제시 - 기 수집한 임상정보 항목을 임상 코드북을 통해 제시하고, 향후 시범사업·본사업에서 추적조사 등을 통해 확장 가능한 임상정보 항목 제시 ☐ 표준작업절차 마련 ○ 치매 코호트의 특성에 맞는 검체 확보·보관·운송** 및 임상정보 확보·보완(추적조사 등) 방안을 표준작업절차서(SOP)의 형식으로 수립 * 코호트 특성을 고려하여, 본사업에서 원활한 추적조사 수행을 위한 동의서·IRB 계획과 함께 고품질 임상정보 확보·보완 전략 마련 ** 유전체·멀티오믹스 데이터 등의 생산·연계를 위해 혈액, 고형조직, 뇌척수액(CSF) 등의 확보·보관·운송 방안 마련 ☐ 기 구축된 치매 임상·유전체 데이터를 바이오 빅데이터 구축 시범사업에 연계함으로써 바이오 빅데이터를 효과적으로 축적·확보하고, 본사업에

	대비하여 타 사업으로부터의 데이터 연계 프로세스를 정립·검증하고자 함. □ 본 연구에서 얻어진 다양한 종류의 임상 자료들은 국립중앙인체자원은 행에 기탁되어 차후 알츠하이머 질병에 대한 유전학적 연구를 위해 쓰일 수 있음.
--	---

□ 연구 개발 추진 내용

○ IRB(기관생명윤리위원회) 승인 획득

- 정밀의료 임상정보와 유전체 데이터의 연계 및 기탁을 위한 IRB 승인
- 조선대학교 및 조선대학교병원을 통한 IRB 신청 및 승인

○ 연구대상자 포함 및 배제 기준


- 연구대상자 포함 기준
 - 55세 이상인 대상자
 - 신경심리검사 등 검사에서 검사를 완료하는 데 영향을 끼치는 심한 청력, 시력, 또는 언어 장애를 가지고 있지 않은 대상자
 - 알코올 중독 또는 기타 물질 남용 상태, 뇌졸중의 병력 및 중추신경계 질환 또는 손상의 증거가 없는 대상자
 - 혈액 채혈에 동의한 대상자
 - 연구 참여에 동의한 대상자
- 연구대상자 제외 기준
 - 글을 읽거나 쓸 수 없는 대상자
 - 경련(뇌전증) 환자, 우울장애, 양극성 장애, 조현병, 물질사용장애인 환자
 - 뇌 관련(뇌졸중, 뇌 감염질환, 파킨슨병, 다발성경화증, 중풍, 뇌혈관장애 등) 질환이 있는 대상자
 - 정신건강관련(우울증, 알코올 중독) 약을 장기 복용 중인 대상자
 - 장애진단(한쪽 눈 실명, 한쪽 귀 청력상실)을 받은 대상자
 - 머리에 심한 충격을 받고 의식 소실이 있었던 대상자
 - 암 치료 종료 후 3년 미만의 암 환자
 - 금속 제제를 이식을 받은 대상자
 - 연구 참여에 동의하지 않은 대상자

○ 연구참가자에 대한 인지기능검사, 인체유래물 및 임상진단 자료 확보

- 기초 신체검진 및 피험자의 demography 정보
- 선별검진과 정밀검진을 통한 신경심리검사 기반의 인지기능 데이터
- 혈액에서 비롯된 전장 유전체 데이터
- 치매전문의의 임상진단 정보

○ 뇌구조 및 뇌기능 손상을 진단하기 위한 고해상도 MRI 영상 획득

- MRI는 자기장을 이용한 검사로 방사선에 의한 피폭이 없으며 뇌의 구조나 모양, 혈관, 근육, 연골, 인대, 신경 등의 연부조직은 CT 검사보다 선명한 영상을 얻을 수 있음(Jack et al., 2010)
- 3T 고해상도 MRI 촬영을 통하여, T1 MPRAGE, T2 SPACE, T2 FLAIR, fMRI, DTI 이미지 획득



뇌구조 기반 진단을 위한 MRI 뇌영상

○ 인체유래물(plasma, serum, DNA) 정제 프로토콜


- EDTA vacutainer(plasma) 나 상온에서 30분 보관한 SSTII vacutainer(serum)를 2,000g로 4℃에서 10분간 1차 원심분리
- 1차 원심분리 후, 상층액을 round tube로 옮겨 담고, hemolysis정도에 따라 생 정도 표기
- 3,000g로 4℃에서 10분간 2차 원심분리 후, 상층액을 보관용 tube로 옮겨 담고, 라벨 후 샘플 박에서 넣어 deep freezer에 보관
- EDTA vacutainer(plasma)의 하층 침전물(buffy coat)를 aliquot하여 -80도에서 보관
- 혈액샘플용 genomic DNA purification kit를 통한 DNA 추출

○ 광주치매 코호트로부터 수집된 전장유전체 데이터의 QC

- 광주치매 코호트에서 수집된 1,000건 이상의 대규모 피험자를 대상으로 유전체 데이터를 확보함
- 전장유전체 데이터에서 성별이 불일치한 샘플, outlier 샘플, genotype call rate < 95%인 샘플, 친인척 관계로 판명된 샘플, batch QC, plate QC에 위배되는 샘플을 제거
- 전장유전체 데이터에서 genotype call rate < 95%인 마커, MAF (Minor allele frequency) < 3% 마커, 하디-와인버그 평형 검사($p < 1.0 \times 10^{-6}$), batch QC, plate QC, cluster QC에 위배되는 마커 제거
- 동일한 샘플에 대한 genotype cal을 비교한 discordant rate < 3%인 샘플 제거

○ HRC 기반 전장유전체 데이터의 high-resolution imputation


- 전장유전체 데이터의 정확도, GWAS의 검정력을 높이고 보다 많은 마커를 찾기 위해 Haplotype Reference Consortium (HRC)의 참조패널을 사용함
- 20개의 international 컨소시엄을 통해 확보된 65,000여개의 haplotype으로 구성된 HRC 참조패널을 적용하여 phasing과 haplotype estimation을 시행함
- 동아시아인 400여명의 샘플과 4천만개의 variant로 구성된 HRC 참조패널을 적용하여 결측된 유전체 데이터를 추정함
- $r^2 < 0.5$ 와 chi-square test를 통한 imputation QC에 위배되는 마커 제거함으로써 95% 이상을 커버하는 whole genome data를 확보함



High-resolution imputation 방법

○ LD를 갖는 마커 제거(large p small n problem)-다중공선성 문제

- Imputation 과정이 완료된 유전체 데이터에서 r^2 가 0.5 이상인 마커를 제거함
- 첫 번째 단계는 처음 200개의 마커에 대한 연관 불평형의 계산한 후 r^2 가 0.5 이상인 마커를 제거함
- 두 번째 단계는 첫 번째 단계에서 제거된 마커를 제외하고 처음 5개의 마커를 제외한 200개의 마커에 대한 연관 불평형을 계산한 후 r^2 가 0.5 이상인 마커를 제거함
- r^2 가 0.5 이상인 마커가 나타나지 않을 때까지 첫 번째와 두 번째 단계를 반복적으로 수행함



전장유전체 기반 알츠하이머병 유발 유전변이 추출 과정

○ 수집된 자료의 질 관리

- 자료의 질 관리를 위한 데이터 모니터링 및 정제 작업
- 대상자의 인체자원(혈액 등)을 수집하고 인체자원은행 기탁에 필요한 정도관리 수행

○ 치매 코호트 데이터 연계·기탁


- 제3자 제공 가능한 고품질 임상·유전체 데이터 1,000건을 국가생명연구자원정센터(KOBIC)에 연계하며, 품질관리를 거쳐 최종적으로 국립중앙인체자원은행에 기탁

○ 임상정보 보완·고도화

- 선도사업별(질환 특이적) 임상정보 보완 및 본사업 임상정보 표준화(구조화)를 위한 품질관리 항목·기준 제시
 - 기 수집한 임상정보 항목을 임상 코드북을 통해 제시하고, 향후 시범사업·본사업에서 추적조사 등을 통해 확장 가능한 임상정보 항목 제시
- * 코호트 특성을 고려하여, 본사업에서 원활한 추적조사 수행을 위한 동의서·IRB 계획과 함께 고품질 임상정보 확보·보완 전략 마련

○ 표준작업절차 마련

- 치매 코호트의 특성에 맞는 검색 확보·보관·운송* 및 임상정보 확보·보완(추적조사 등) 방안을 표준작업절차서(SOP)의 형식으로 수립
- * 유전체·멀티오믹스 데이터 등의 생산·연계를 위해 혈액, 고형조직, 뇌척수액(CSF) 등의 확보·보관·운송 방안 마련



□ 연구개발결과

○ IRB(기관생명윤리위원회) 승인 획득

- 기 확보된 1,000명의 피험자에 대한 정밀의료 임상정보와 유전체 데이터의 연계 및 기탁을 위한 IRB 승인 획득
- 조선대학교 및 조선대학교병원을 통한 IRB 신청 및 승인 획득함

○ 연구참가자에 대한 인지기능검사, 인체유래물 및 임상진단 자료 확보

- 선별된 1,000명(정상군 500명, 환자군 500명)에 대한 기초 신체검진 및 피험자의 demography 정보
- 선별검진과 정밀검진을 통한 신경심리검사 기반의 인지기능 데이터
- 혈액에서 비롯된 전장 유전체 데이터
- 치매전문의의 임상진단 정보

○ 수집된 자료의 질 관리

- 자료의 질 관리를 위한 데이터 모니터링 및 정제 작업
- 대상자의 인체자원(혈액 등)을 수집하고 인체자원은행 기탁에 필요한 정도관리 수행함

○ 광주치매 코호트로부터 수집된 유전체 데이터의 QC

- 광주치매 코호트에서 수집된 1,000건 이상의 대규모 피험자를 대상으로 유전체 데이터를 확보함
- 유전체 데이터에서 성별이 불일치한 샘플, outlier 샘플, genotype call rate < 95%인 샘플, 친인척 관계로 판명된 샘플, batch QC, plate QC에 위배되는 샘플을 제거함
- 전장유전체 데이터에서 genotype call rate < 95%인 마커, MAF (Minor allele frequency) < 3% 마커, 하디-와인버그 평형 검사($p < 1.0 \times 10^{-6}$), batch QC, plate QC, cluster QC에 위배되는 마커 제거함
- 동일한 샘플에 대한 genotype cal을 비교한 discordant rate < 3%인 샘플을 제거함

○ 치매 코호트 데이터 연계·기탁

- 제 3자 제공을 위한 연구참가자 1,000명의 인체유래물 기증 동의서 확보
- 고품질 임상·유전체 데이터 1,000건을 국가생명연구자원정보센터(KOBIC)에 연계하며, 품질관리를 거쳐 최종적으로 국립중앙인체자원은행에 기탁

○ 임상정보 보완·고도화

- 기 수집한 치매 임상역학정보 항목에 대한 임상 코드북 작성

○ 표준작업절차 마련

- 치매 코호트 특성에 맞춘 검체 확보·보관·운송 방안 및 유전 및 오믹스정보에 대한 품질지침서(SOP) 작성

○ 6위탁 연구과제 (40,320천원)

과제명	폐암 바이오 빅데이터 활용을 위한 임상유전체 데이터 연계 및 플랫폼 구축
연구기관명	국립암센터
연구책임자명	한지연
연구기간	2022. 05. 01 - 2022. 12. 31 (8개월)
연구개발 목표	○ 최종목표: 국가 바이오 빅데이터 구축을 위한 비흡연폐암 임상유전체

	데이터 연계 및 플랫폼 구축 - 비흡연폐암 임상정보 및 유전체 데이터를 정제·수집하여 국가적 차원에서 데이터를 표준화 및 활용하고, 바이오 빅데이터 관리 체계 마련 등을 목적으로 함
연구개발 내용	○ 비흡연폐암 전장유전체 데이터 연계 및 기탁 - “비흡연폐암 다중오믹스 분석을 통한 한국인 특이적 비흡연 폐암의 신규 치료기술 개발” 과제에서 생산한 전향적 비흡연폐암 데이터(168건 이상)를 국가생명연구자원정보센터(KOBIC)에 연계 및 국립중앙인체자원은행에 기탁 - 근치적 수술 절제술을 받은 비흡연폐암 환자를 대상으로 치료타겟 유무 분류 및 치료타겟이 부재한 환자 시료에 대한 whole genome sequencing 데이터 연계 - 비흡연폐암 환자 조직의 전장유전체, 전사체, 후성유전체 등의 유전체 데이터 및 전체단백체 데이터에 대한 생산·수집·연계 절차(표준작업절차)를 미국 NCI CPTAC 등 국제협력 플랫폼 표준에 근거하여 수립 ○ 임상정보 보완 및 이관 - 보유한 개인식별정보를 가명화하여 질병관리청 국립중앙인체자원은행에 임상정보를 기탁 - 보유한 임상정보를 표준양식으로 수정 및 보완하고, 추적조사 등을 통해 임상정보 추가 확보 및 보완 ○ 국가 바이오 빅데이터 시범사업의 선도사업 연계절차를 통해, 비흡연폐암과 같이 다양한 질환이 있는 코호트의 참여로 국가적 차원에서 바이오뱅크 및 임상유전체 통합 데이터베이스를 구축, 관리함. 이를 통해 의료 산업의 성장과 환자 맞춤형 정밀의료 진단, 치료 및 기술개발 등에 활용하고자 함 ○ 포괄적인 비흡연폐암 임상/유전체 데이터를 구조화하고 국가 바이오 빅데이터 구축 시범사업에 연계함으로써, 추후 본 연구의 결과물이 다른 연구자에게 효율적으로 활용될 수 있도록 함

○ 연구 주요 목표

- 연구개발의 주요 목표는 ① 비흡연폐암 전장유전체 데이터와 임상정보의 기탁을 진행하고, ② 확보된 임상정보를 보완하고 전장유전체 데이터를 정제하여, 최종적으로 비흡연폐암 바이오 빅데이터 활용을 위한 임상·유전체 데이터 연계 및 플랫폼 구축에 지원하고자 함
- 「차세대 염기서열분석법을 이용한 비소세포암의 치료 타겟 유전체 분석」 과제에서 생산된 비흡연폐암 임상·전장유전체 데이터 총 168건(84명의 암·정상조직)을 한국생명공학연구원 인체유래물 은행 및 질병관리청 보건의료연구자원정보센터(CODA)에 연계하여 한국인 비흡연폐암의 정밀의학 실현을 위한 정보 제공에 기여하고자 함

○ 연구 배경

○ 치료 타겟 유전자 변이가 없는 비흡연 폐암 특이적인 오믹스 분석


- 폐암은 전 세계적으로 암사망률 1위에 해당하는 가장 치명적인 질환으로서, 90%의 폐암은 흡연자에서 발생하나, 비흡연 폐암의 빈도가 증가하고 있음. 또한, 우리나라를 포함한 동아시아 지역 여성 폐암은 약 85% 가 비흡연자에서 발생함
- 폐암의 치료타겟 유전자 변이는 주로 비흡연자 폐암에서 발견되었으며 유전자 변이를 진단하고

유전자 변이를 표적하는 치료제들이 개발되어 폐암 생존율을 크게 향상시킴. 그러나 약 40%의 비흡연폐암의 환자에서는 치료 표적이 불분명하여 정밀의료시대에도 불구하고 비정밀치료를 받고 있음

- 치료 타겟 유전자변이를 동반하는 경우도 대부분 표적치료 중 내성의 발생으로 암이 재발하고 사망에 이름. 최근 내성 기전 분석을 통한 새로운 세대의 치료제들이 개발되어 새로운 기대를 모으고 있음
- 치료적 측면에서 폐암의 치료타겟 유전자 변이는 주로 비흡연자 폐암에서 발견되어 이를 토대로 새로운 진단 및 치료법들이 개발되어 폐암환자의 생존률 향상을 이룩함. 그러나 약 40%의 비흡연폐암의 환자에서는 알려진 치료 표적이 불분명하여 비정밀치료를 받고 있는 상황이며, 폐암의 비침습적 진단을 위한 기술 개발에 있어서, 환자유래물로 부터 고농도 핵산추출을 위한 나노기술이 개발되고 있음.
- 본 연구는 국립암센터에서 확보하고 있는, 근치적 절제술을 시행 받고 약 2년 이상 임상적 경과 관찰로 임상데이터의 축적이 충분한 비흡연 폐선암 환자조직 1,000례로부터 선별된, 알려진 치료표적변이가 없는 환자시료를 대상으로 확보된 임상정보와 생산된 전장유전체의 분석·연계를 통하여, 새로운 치료표적의 발굴에 기여하고자 함

○ 기 구축된 코호트 선정 과정


- 비흡연폐암의 신규표적 및 내성극복 타겟을 발굴하기 위한 환자의 선정은 기 확보된 코호트 중 다음의 흐름에 따라 선정하고 분석하도록 함



비흡연 폐암 환자의 연구대상 선정 플로우

○ 기 구축된 코호트 검체·임상정보 수집결과

- 후향적 연구에 해당하는 비흡연 폐암환자에 대해, 동결보관된 조직을 국립암센터 종양은행으로부터 분양함. 이때 환자시료는 암호화한 번호를 새로 부여하여 환자의 개인정보를 보호하도록 하며, 정보파일은 암호화된 파일로 연구책임자가 보관
- 환자조직은 국립암센터 병리과의 면역염색분석 및 targeted sequencing을 통해 비흡연폐암환자의 유전자 변이 음성을 검증하여 선정
- 동결된 조직을 액화질소에서 파쇄




- DNA는 Qiagen Nucleic Acid Extractor M-48을 이용하여 48개 시료를 단위로 동시에 추출
- 비흡연폐암 환자 조직의 전장유전체 데이터에 대한 생산·수집·연계 절차를 미국 NCI CPTAC 등 국제협력 플랫폼 표준에 근거하여 수립

○ 비흡연폐암 전장 유전체 정보 생산 및 분석 방법

- 전장 유전체 데이터는 Illumina 사의 Hiseq X-10 장비를 활용하여 생산된 데이터를 연계하였으며, 이를 비흡연폐암 환자의 암 조직과 주변 정상 조직(혹은 혈액 시료)에서 동시에 분석하여 체세포 변이(somatic variant)를 발굴함.
- 전장 유전체 데이터 분석은 DRAGEN의 Bio-IT Platform DNA pipeline를 사용하여 진행하였으며, 이를 표준작업절차로 작성함
- ① QC 기준은 중복리드, MAPQ<1, Unmapped read, Soft-clipped bases, Bad Cigar, BaseQ<10을 대상으로 제거하였으며, ② QC 후 샘플수는 암·정상 조직 쌍으로 84건을 확인함
- (데이터 활용방안) 기존에 잘 알려진 폐암의 driver 돌연변이들 이외의 새로운 비흡연폐암 특이적인 돌연변이들을 발굴하기 위하여 동일한 파이프라인을 활용하여 비흡연폐암 데이터의 체세포 변이를 발굴함

○ 비흡연폐암 임상·유전체 데이터 연계 및 기탁

- 본 연구에서는 제3자 제공 가능한 비흡연폐암 데이터의 임상·유전체 데이터 쌍(168건)을 국가생명연구자원정보센터(KOBIC)에 연계하며, 최종적으로 한국생명공학연구원 인체유래물 은행, 질병관리청 보건의료연구자원정보센터(CODA) 및 질병관리청 국립중앙인체자원은행에 기탁
- 한국생명공학연구원 인체유래물 은행, 질병관리청 보건의료연구자원정보센터(CODA) 및 질병관리청 국립중앙인체자원은행에 기탁하기 위한 임상·유전체 정보 제공을 위한 IRB 심의 진행함
- 기탁하는 데이터는 모두 익명화 처리하여 기탁하며, 임상데이터의 경우 검체 분석



결과(전장유전체정보) 데이터와 관련 임상 데이터(수술 시 병기, 비흡연폐암 관련 유전자 검사 정보, 나이, 성별, 치료반응, 생존 기간 등)를 기탁함

- 한국생명공학연구원 인체유래물 은행, 질병관리청 보건 의료 연구자 정보 센터(CODA) 및 질병관리청 국립중앙인체자원은행과 협의하여 동의서 및 임상정보 세부 항목에 대한 검토 등 수행함

○ 비흡연폐암 임상정보 보완 및 고도화

- 비흡연폐암에 진료정보, 예후, 치료정보와 같은 항목의 경우 정형화 및 표준화 작업을 통해 품질관리기준을 제시하였으며, 부족한 부분의 경우 보완하여 최종적으로 임상정보 코드북으로 작성함
- 비흡연폐암 환자 코호트의 특이적인 임상정보에 대해 본사업 임상정보 표준화 및 품질관리를 위한 관리 항목·기준을 제시함

○ 본사업 표준작업절차 마련

- 이번 시범사업에서는 향후 본사업 추진을 고려하여, 각 코호트의 특성에 맞는 임상·전장유전체 데이터 확보·정제·분석 및 임상정보 보완(추적조사 등) 방안을 표준작업절차서(SOP)의 형식으로 수립함
- 또한 비흡연폐암 검체의 동의서·IRB 기탁절차와 함께 고품질 임상정보 확보·보완 전략 마련함
- 본사업을 고려하여 비흡연폐암의 임상·유전체 데이터에 대해 연구진·의료진이 원활하게 연계할 수 있는 방안을 마련함

〈연구개발 성과의 관련 분야에 대한 기여도〉

○ 비흡연폐암 임상·전장유전체 데이터 활용 진단 분야

- 폐암의 특성 상 암이 폐 부위에 존재하기 때문에 다른 고형암과 달리 암 조직의 채취가 용이하지 않는 경우가 많으며, 이로 인하여 종양 조직을 통하여 치료 전 환자 유전체 변이 확인 및 치료 중 모니터링하기가 어려운 한계가 있음. 이를 극복하기 위해서 비침습적인 방법으로도 종양 유전자를 채취하여 할 필요가 있음
- 혈장 내 cell free DNA (cfDNA)는 기술적인 한계로 1948년 처음 확인되고, 1977년 암 환자의

혈장에서도 확인되었음에도 불구하고, 최근에 와서야 이 tumor로부터 유래된 circulating tumor DNA (ctDNA)가 변이를 가지고 있다는 것이 증명되었음. Exosome의 경우, 2008년 Skog 등에 의해 exosome내에 RNA가 있음을 확인하고, RNA를 분리하여 microarray 분석을 수행한 결과, 암 세포로부터 유래된 exosome에서 3,000여개의 유전자의 발현이 증가되어 있음을 보고함

- 암 조직으로부터 빠져 나온 circulating tumor cell (CTC) 또한 다양한 방법을 통해 정상 세포와 구분하여 분리하고자 하는 노력이 진행 중임. 하지만, 여전히 혈액 내 극소량으로 존재하는 이들 세포 및 물질들은 분리하여 분석하는데 어려움이 있음. 따라서 극미량으로 존재하는 물질들로부터 다양한 암 관련 변이를 정확하고 세심하게 확인하는 해독 및 분석 연구가 필요함
- 질병 유의적 체세포 변이 시그니처를 환자 조직 또는 혈액 시료로부터 발굴하여 실질적으로 검증하여 임상적 적용을 앞당길 필요가 있으며, 이번 과제로 기탁되는 데이터를 통해 활용 가능성이 높은 것으로 예상함

○ 비흡연폐암 전장유전체 데이터 기반 진단 키트 분야

- 바이오마커 키트 시장은 체외진단시장과 분리하여 따로 정의하기는 쉽지 않으며, 실제로 바이오마커는 체외진단의 주요한 콘텐츠가 되므로 바이오마커 키트 시장은 체외진단 시장, 특히, 현장형 체외진단(POCT : Point-of-Care Testing) 시장에 해당함
- 현재 체외 진단 시장 중 바이오마커의 시장은 초기 성장단계로 임상개발을 위한 바이오마커 발굴 및 검증에 대한 투자가 지속적으로 요구되고 있음. 초기에는 오히려 바이오마커가 기존의 임상개발 과정을 보다 복잡하게 하여 그 기간과 비용이 다소 증가하는 경향을 보이지만 그 이후 정립된 바이오마커 발굴기술 플랫폼과 검증되고 강력한 바이오마커에 의해서 임상개발 비용 및 기간 감소 등으로 그 효율이 현저하게 증가할 것으로 기대됨
- 현재 체외 진단 시장에서의 기술 트렌드는 분자진단 기술로 급격히 이동되고 있음. 분자진단에서 중요한 기술적 요소는 특정 질환을 대표하는 분자진단용 핵산 바이오마커의 발굴기술과, 높은 민감도 및 특이도로 바이오마커를 감지할 수 있는 바이오마커 검출기술로 대별될 수 있음
- 본 연구과제를 통해 비흡연 폐암 데이터를 국가 바이오 빅 데이터 구축 시범사업에 연계함으로써 체세포 변이 분석 기반 진단 기술을 바탕으로 신규 바이오마커 개발의 가능성을 높일 수 있을 것으로 예상함. 또한 기존 폐암 마커를 활용하여 흡연과 비흡연 폐암 간 차이를 규명할 수 있는 진단플랫폼 기술을 최적화하는 데 있어 기여할 수 있을 것으로 기대함. 본 과제를 통해 연계된 데이터를 다양한 연구자가 활용할 경우 진단플랫폼의 구축 및 유효성 검증은 국가R&D의 사업화로 이어질 수 있을 것으로 예상함

○ 비흡연폐암 전장유전체 데이터 기반 치료 분야

- 오믹스간 융합연구에 대한 플랫폼 기술 기반 데이터 및 임상정보 데이터 활용으로 인한 질병 진단 및 신약개발의 기반 데이터 제공
- 비흡연성 폐암 환자의 항암제 특이적 감수성 또는 내성 예측으로 표적 항암제 선택의 용이성, 반응성 좋은 환자선별로 부작용 감소 및 치료 효능 증대 기대
- 비흡연성 폐암 환자의 약물의 효용성 예측 등 맞춤형 의료기술 구현을 위한 바이오 콘텐츠 개발
- 유전체 데이터 분석 기술의 발달이 가져온 정밀의료 연구를 통해 비흡연폐암의 고위험군 발굴하고 적절한 검진방안을 제시하게 되면 조기진단 및 근치적 치료가 가능하게 되어 비흡연 폐암환자의 생존률을 향상시킬 수 있을 것으로 기대함
- 다른 오믹스 데이터베이스와 비교·분석하여 치료제가 부재한 비흡연폐암 환자들에게 면역치료제를 비롯한 새로운 표적치료제의 반응성을 예측하는 바이오마커로 활용
- 신속하며 정확한 진단기술이 가능하게 되어 소량, 비침습적, 실시간, 원격 진단기술 개발에 따른 질환 예방 효과가 제고되고, 개발된 진단제/키트로 인하여 새로운 약물 치료에 따른 병행적 검증이 가능하여져서 신약개발의 성공 가능성을 획기적으로 제고할 것으로 기대

- 개인의 다양한 특성에 따른 개인 맞춤형 진단기술이 개발되고 이에 따른 개인 맞춤형 의료 서비스 산업 발전의 기반이 되며, 정밀한 진단에 기반한 환자의 고통 및 불필요한 의료비용 및 시간적 손실 절감
- 비흡연 폐암 맞춤치료의 치료타겟 도출 및 맞춤치료법기반 기술에 의한 새로운 플랫폼 구축으로 바이오 의약 산업의 원천기술을 제공하며 관련 산업의 활성화 및 국민 건강 증진에 기여

〈연구개발 성과의 관리 및 활용〉

○ 기탁 데이터의 관리

- 본 과제에서는 「차세대 염기서열분석법을 이용한 비소세포암의 치료 타겟 유전체 분석」 과제에서 확보된 조직 분석 결과 및 임상·전장유전체 데이터를 연계함
- 생명윤리 및 안전에 관한 법률, 생명연구자원의 확보&관리 및 활용에 관한 법률 (질병청 국립중앙인체자원은행)과 생명연구자원의 확보, 관리 및 활용, 국가연구개발혁신법 시행령 제 33조 (한국생명공학연구원 국가생명연구자원정보센터)에 근거하여 데이터를 기탁함
- 기탁하는 데이터에 해당하는 대상자는 인체유래물 기증 동의를 취득하여 국립암센터 바이오뱅크로부터 분양 받은 검체 자료로부터 얻은 데이터 중 유전체 정보가 확인된 총 168건(84명의 암·정상조직 쌍) 중 외부 기관 기탁 가능성이 확인된 자료를 기탁함
- 기탁된 데이터는 KISTI(한국과학기술정보연구원) 플랫폼에 분양 신청 이후 연구평가위원회, 분양심의위원회를 거쳐 KISTI의 CIRN 플랫폼(폐쇄망) 내에서 익명화된 임상정보, 변이/분석 데이터가 활용될 예정임
- 인체유래물데이터 보관 기간은 바이오뱅크에서 관리 중인 기증동의서 상의 동의 기간 동안이며, 이는 환자마다 상이할 수 있으며 그 이후에는 재동의를 받지 않는 경우 폐기함
- 데이터 기탁 시 국립암센터 바이오뱅크로부터 전달 받은 인체유래물 데이터 보관 기간을 포함한 동의 상태 정보를 함께 제공함
- 폐기 절차는 기탁 받은 기관의 원칙에 따라 복구 불가능한 형태로 폐기해야 하며, 요청 시 기탁 기관에서는 ‘데이터 폐기 확인서’ 등을 제출할 수 있음

(2) 희귀, 선도사업 자원의 유전체 서열분석 및 분석보고서 작성

(가) 유전체 생산기관 선정

□ 유전체 생산기관 선정 개요

○ 유전체 생산기관 선정 개요

- 국가 바이오 빅데이터 구축 시범사업의 샘플 기증자로부터 추출한 샘플 DNA로부터 유전체 정보 생산을 담당하는 전문기관* 선정 필요

* 시범사업 1차년도 동안 총 7,500명의 유전체 정보 생산을 위한 기관

○ 유전체 생산기관 용역 업무 주요내용

- (샘플 운송·품질관리) 국가 바이오 빅데이터 구축 시범사업에서 수집한 기증자(참여자)의 샘플 DNA(7,500건)를 자원 제작기관으로부터 운송 및 품질관리(QC)

- (데이터 생산을 위한 실험) 샘플 DNA로부터 시퀀싱 분석을 위한 라이브러리 제작 및 품질관리(QC)
- (데이터 생산) NGS* 기술이 적용된 시퀀서(sequencer)를 이용하여 전장유전체(WGS) 원데이터(raw data) 생산
 - * Next Generation Sequencing : 차세대 염기서열 분석법으로 기존 염기서열 분석법에 비해 대량의 유전정보를 동시 분석 가능
- (데이터 이관) 생산된 유전체 원데이터(raw data) 및 관련 데이터(실험기록, 폐기기록 등)를 국가생명연구자원정보센터(KOBIC)에 이관

□ 유전체 생산기관 선정 기준 수립

- 유전체 생산기관 선정기준은 운영위원회의 검토를 거쳐서 추진위원회의 심의의결을 거쳐 결정
- 선정기준에 따라 선정된 유전체 생산기관은 선도사업 및 희귀질환 검체에 대해 유전체 데이터 생산
- 생산기관의 선정은 생산기관 선정 전문위원회를 통해 선정절차, 방법 등을 정하고 이를 기반으로 생산기관을 선정하며, 선정된 기관의 플랫폼을 통해서 생산되는 데이터를 제공받음
- 유전체 생산기관 선정기준(안) 수립 추진경과

(1차년도)

- (전문위원회) 제1, 2차 유전체 생산기관 선정 전문위원회('20.5.19 / 6.11)에서 전문가 자문 및 선정기준 전문위원회(안) 수립
- (간담회) 유전체 생산기관을 대상으로 선정기준 전문위원회(안) 소개 및 의견 청취 (' 20.6.18)
- (운영위원회) 제2~4차 운영위원회(' 20.4.13 / 5.29 / 6.23)에서 선정기준 전문위원회(안) 검토
- (추진위원회) 제4, 5차 추진위원회에서 유전체 생산기관 선정기준 승인 및 최종 선정

(2차년도)

- (전문위원회) 제3차 유전체 생산기관 선정 전문위원회('21.3.30)에서 전문가 자문 및 선정기준 전문위원회(안) 수립
- (운영위원회) 제8차 운영위원회(' 21.4.12~13)에서 선정기준 전문위원회(안) 검토
- (추진위원회) 제7차 추진위원회(' 21.4.23)에서 유전체 생산기관 선정기준 승인 및 최종 선정

□ 유전체 생산기관 지원 기준

○ (유전체 생산기관 자격 기준) 유전자검사기관(업종코드 : 5331) 또는 학술·연구용역 업종(업종코드 : 1169) 해당

○ 유전체 생산기관 간의 공동수급체* 구성(공동이행방식)

* 구성원을 2개사 이상으로 하여 수급인이 해당계약을 공동으로 수행하기 위하여 잠정적으로 결성한 실체(기획재정부계약예규「공동계약운용요령」제2조 제2항 관련)

- 유전체 생산기관들(3~5개사) 간의 공동수급체를 구성*하여 사업에 참여하되, 선정된 공동수급체가 사업에서 요구되는 모든 유전체 정보 생산 담당

- 공동수급체에 참여하는 각 기관들은 기업회계기준 관계회사*에 해당하지 않으며, 각 참여기관은 10% 이상 40% 이하 지분율을 보유

* ① 회사간에 발행주식 총수의 20% 이상의 주식을 소유하거나 출자총액의 20% 이상을 출자하고 있는 경우

② 2개 이상의 회사가 동일인에 의하여 각 발행주식 총수의 과반수 또는 출자총액의 과반수가 소유되고 있는 경우

- 공동수급체 참여기관 모두가 지원 자격을 만족해야 함

- 각 분석기관은 공동수급체를 중복 결성하여 참여할 수 없음

- 공동수급체 참여기관에 소규모 업체(소기업·벤처기업)가 포함된 경우, 선정 평가 시 배점 부여

□ 유전체 데이터 품질 기준

○ 유전체 생산기관으로부터 생산된 개별 유전체 데이터는 다음의 기준을 필수적으로 만족해야 함(minimum requirement)

- (기준 1) 전처리 과정(아래 표 ①, ②) 후의 결과물에서 PCR 중복을 제거(PCR deduplication)*하였을 때, 잔여 mapped read에 해당하는 염기 개수의 총합이 85Gbase 이상

* Picard MarkDuplicates 등의 분석도구를 사용하여 PCR 중복 제거

※ GRCh38 기준 인간 유전체 전체 염기개수 = 3,272,116,950 base(약 3.3Gbase)

< 유전체 분석 전처리과정 >

• FASTQ 파일에 대해 다음의 전처리 분석 수행

① (염기서열분석 신뢰도) 원시데이터 read로부터 adapter 서열 및 PHRED score Q30 미만의 염기를 제거*

* Cutadapt 등의 분석도구를 사용하여 adapter 서열 및 “-q 30” 등 옵션 적용

② (표준유전체서열 매핑) ①의 데이터를 표준유전체서열(GRCh38)에 매핑(mapping)*

* BWA-MEM 등의 분석도구를 사용하여 참조유전체서열에 대해 매핑(mapping)하며, mitochondrial genome 및 decoy sequence는 mapped read 개수 산정에 포함되지 않음

- (기준 2) 샘플 뒤바뀔 · 중복 · 누락(swapping, duplication, omission of samples) 및 혼합 · 교차오염(mixed sample, cross contamination) 없음*


* 검수 때까지 확인 가능한 범위만을 품질관리 기준에 포함(성별, aneuploidy 확인 등)

□ 유전체 생산기관 선정 절차

- 조달청을 통한 ‘협상에 의한 계약 과정’ *으로 유전체 생산기관 선정

* 정보과학기술 등 집약도가 높은 지식을 활용하여 고부가가치를 창출하는 지식기반사업의 계약을 체결하는 경우에 협상에 의한 계약을 우선적으로 적용

※ 공고 및 계약과 관련하여 조달청과 사전협의 수행(6월)



※ 조달청 공고를 위해 원가조사기관에 의뢰하여 산출내역서 발급이 필요하며, 과제 규모상 40일(긴급 입찰 시 14일) 이상 조달청 공고기간 필요

- 입찰 시 공동수급체 참여기관 중 지분율이 가장 높은 기관(대표기관)의 책임자가 제안서 제출

※ 제안서 · 계약서 본문에는 모든 참여 기관 및 각 기관의 책임자를 지분율과 함께 명시

□ 선정평가 방안

- 제안서평가를 기술능력평가 (이하 “기술평가”)와 가격평가로 구분하여 선정평가표 구성(참고 1, 2)

기술평가				가격평가
①실험	②데이터	③관리기술	④기타	
· Library* 제작 능력 평가 · 샘플 DNA Library의 품질관리 능력 평가 · 동일 샘플의 유전체 데이터는 단일 장비에서 생산	· 품질 기준을 만족하는 데이터를 생산하기 위한 방안 수립 · KOBI에 데이터 전송시, 데이터-메타데이터의 무결성 보장 · (기타 반영사항) 필수 기준 외 유전체 생산기관에서 자체적으로 수립하여 제안한 데이터 품질관리 방안은 선정 평가 시 반영	· 동 시범사업 수행을 위한 보안사항, 관리 체계 요건 등에 대한 평가	· 현황분석, 사업수행 능력, 소규모업체 포함여부, 경영상태 등 평가	· 조달청 가격평가 기준 준용 · 샘플당 유전체 데이터 생산 비용을 기준 금액 (부가세 및 DNA 운송비용, Library 제작비용 포함) 이하로 제안하여야 함

* 유전체 분석 장비가 염기서열을 읽을 수 있도록 검체로부터 추출된 DNA를 절단(fragmentation) · 수선(repair) · 결합(ligation) · 증폭(amplification)하는 과정

- (기술평가) 기술평가를 위해 지원한 공동수급체의 제안내용(제안서)에 대한 서면평가 및 발표평가 수행

· ① 실험*, ② 데이터, ③ 관리기술, ④ 기타(현황분석**, 사업수행능력, 소규모업체 포함여부***, 경영상태)로 기술평가 항목을 구분

* 샘플 DNA 품질관리, Library 제작 · 품질관리, 시퀀싱 실험 등

** 해외 표준작업절차서(SOP)와 제안서 내용 간 비교를 통한 계획의 구체성 확인

*** 소기업 혹은 벤처기업 중 1개사 이상 포함 시 배점부여

- (가격평가) 입찰 시 공동수급체는 유전체 데이터(7,500건) 생산에 대한 비용*을 기준금액** 이하로 제안하여야 함

* 부가세(10%) 포함 가격이며, ① 자원제작기관에서 유전체분석기관으로의 운송, 유전체 생산기관에서 KOBIC으로의 운송 비용 및 ② 라이브러리 제작 비용 등 포함 여부 명시하여야 함

** 원가조사기관에서 작성한 원가계산서를 근거로 도출

○ 평가위원 구성(안)

- 생명(연) 내부 · 외부위원 인원 구성 및 외부위원 후보선정(안)에 대한 결정은 전문위원회에서 생명(연)으로 위임*

* 한국생명공학연구원의 용역과제 평가를 위한 예규에 따라 선정 예정

- 생명(연) 예규에 따른 평가위원 선정(안)

· ① 생명(연) 내부위원 2인과 ② 외부위원 10인으로 구성(총 12인)

· (외부위원 구성) 유전체 생산기관 선정 전문위원회의 위원 10인, 3개 부처 추천 전문가

20인(복지부·산업부 각 7인, 과기정통부 6인 추천) 중 무작위로 10인 선정*

* 생명(연) 자체 후보선정프로그램을 이용하여 외부위원 10인 선정

□ 유전체 생산기관 운영

○ 유전체 생산기관 운영

- 유전체 데이터 생산의 원활한 진행 및 품질관리를 위해 공동수급체의 참여기관 별 책임자 및 실무담당자를 지정
- 유전체 생산기관의 책임자들은 유전체 데이터의 생산 과정·일정 및 품질관리 등에 대한 관리·감독의 의무를 가지며, 매월 해당 현황을 과제총괄책임자*에게 보고
- * 한국생명공학연구원 국가생명연구자원정보센터 센터장
- 국가생명연구자원정보센터(KOBIC) 및 각 참여기관의 실무담당자는 정기적으로 협의하여 공동수급체 참여기관 간의 데이터 균일성을 보장하기 위한 생산기관 관리지침을 수정·보완
- 공동수급체의 데이터 생산량 및 비용집행 방안
- 공동수급체의 각 참여기관 별 유전체 데이터 생산량은 계약서에 명시된 지분율에 따라 결정되며, 他 참여기관이나 외부 기관에 대한 하도급을 허용하지 않음
- 용역 계약서에 명기된 공동수급체의 참여기관 별 지분율에 따라 한국생명공학연구원 에서 각 기관 별로 비용 집행

○ 품질 기준 판단 및 검수 관련 특기사항

- 유전체 생산기관에서 생산한 유전체 데이터의 품질 기준 충족 여부는 국가생명연구자원정보센터(KOBIC)의 데이터 품질관리 프로세스*에 의해 결정
- * 국가생명연구자원정보센터(KOBIC)는 각 유전체 데이터별 품질 기준 충족여부를 확인하여 유전체 생산기관에 안내
- 국가생명연구자원정보센터(KOBIC)의 데이터 품질관리 결과, 품질 기준을 충족하지 못하는 유전체 데이터는 유전체 생산기관에서 추가 비용 없이 (무상) 재생산

□ 유전체 생산기관 선정 기술평가 주요 내용

○ 유전체 생산기관 선정 기술평가 주요 내용

① (실험) 라이브러리 제작 능력 및 샘플 DNA·라이브러리 품질관리 능력 보유 여부 확인

- 라이브러리 제작 시 PCR 및 DNA 증폭(amplification) 없이 데이터를 생산하는 능력(확보된 DNA 양이 라이브러리 제작 시약의 권장 기준보다 적은 경우 예외적으로 PCR 허용)

※ 라이브러리 시약 및 실험과정에 PCR 및 DNA 증폭을 포함하지 않음

- 분석기관은 샘플 DNA 및 제작된 라이브러리가 전장유전체데이터 분석에 적합한지에 대한 여부를 확인할 수 있는 품질관리 체계를 구축

※ DNA 샘플이 품질 기준 미달한 경우, 자원 제작기관에 샘플 재요청 필요

- 샘플 DNA · 라이브러리 품질관리 수행 및 결과 제공 여부

* DNA 순수도, DNA 절편(fragment) 평균길이 및 표준편차 등

- 동일 샘플(참여자)에 대한 유전체 데이터는 동일 장비에서 생산

② (데이터) 생산된 유전체 데이터의 제공 및 데이터 품질 보장

- 유전체 데이터 품질 기준*을 충족하기 위한 데이터 생산방안 수립

* 국가생명연구자원정보센터(KOBIC)에서 각 샘플 별 품질 기준 충족 여부 확인하여 유전체 생산기관에 안내

- 생산된 유전체 데이터 및 관련 메타데이터의 무결성 보장

- (기타 반영사항) 제안요구사항의 필수 기준 외 유전체 생산기관에서 자체적으로 수립하여 제안한 데이터 품질보장 방안은 선정평가 시 반영

③ 관리기술 보유

- 동 시범사업 수행을 위한 보안 사항, 관리 체계 요건 등에 대한 기술

- (데이터 보안 책임자) 유전체 생산기관별로 국가생명연구자원정보센터(KOBIC)에서 지정한 책임자 및 실무담당자만이 업체 내 데이터 관리를 맡을 수 있음

- (데이터 관리 · 보안 1) 동 시범사업의 유전체 데이터 및 관련 정보를 보관 · 전달하기 위해 他 유전체 데이터를 저장한 기존 전산 장비와 별도로 분리 · 독립된 전산장비*를 사용

* 시퀀서와 물리적(유선)으로 연결된 전산장비는 예외

- (데이터 관리 · 보안 2) 분리 · 독립된 전산장비는 데이터의 유출 사고 예방 및 내부 보안 강화를 위해 시스템 접근제어* 및 통제 솔루션(CC인증)을 사용해야 하며, 관련 로그와 동영상 등은 국가생명연구자원정보센터(KOBIC)에게 제공

* 계정 접근권한 별 통제, 작업에 대한 모니터링(동영상 녹화) 등

- (운송 보안) 생산된 유전체 데이터를 국가생명연구자원정보센터(KOBIC)으로 직접 운송* 하는 경우, 택배 발송은 불가하며 지정된 책임자 및 실무담당자가 전용 하드디스크 보관 박스** 내에 저장스토리지를 담아 운송

* 하드디스크, 이동식 디스크 또는 보조저장매체(USB 등) 등의 저장스토리지 사용

** 잠금장치 및 완충장치 포함

※ 향후 보안체계 구축 후 고속전송시스템(GBBox 등)을 이용하여 데이터 전송 고려

- (관리기록 제공) 유전체 생산기관 책임자 및 실무담당자는 다음 사항을 기록하여 국가생명연구자원정보센터(KOBIC)에게 정기적으로 보고

- 샘플 운송 · 관리에 관한 사항

- 유전체 정보의 보호 및 처리에 대한 사항

- 잔여 샘플의 보존, 관리 및 폐기에 관한 사항
- 국가생명연구자원정보센터(KOBIC)으로의 데이터 이관과 관련된 사항
- (잔여 샘플 및 데이터 관리) 국가생명연구자원정보센터(KOBIC)에서 수행한 품질관리 결과, 품질 기준을 충족한 유전체 데이터 현황을 유전체 생산기관에 제공하며, 유전체 생산기관에서는 해당 데이터 및 샘플을 폐기*
- * 질병관리청, 국가생명연구자원정보센터(KOBIC)의 요청이 있는 경우 예외적으로 샘플 보관 가능

④ 기타사항

- 실험, 데이터, 관리기술 관련된 내용을 표준작업절차서(SOP)로 작성하여 제안서와 함께 제출
- (현황분석) 해외 주요 유전체 컨소시엄 사례(SOP)에 대한 현황분석 및 제안서의 SOP와의 비교를 함께 수행함으로써, 실험, 데이터, 관리기술 사항에 대한 보완 및 근거 마련
- 고품질 유전체 데이터를 생산하고, 공동수급체 간 분석결과의 일관성을 보장하기 위해 체계적인 표준작업절차서(SOP)* 수립 필요
- * 공동수급체의 ① 실험, ② 데이터, ③ 관리기술 등에 대한 표준작업절차서(SOP)가 공동수급체와의 계약체결 전에 수립되어야 함
- ※ 국제 유전체 컨소시엄의 SOP 기준 등을 준용

(나) 유전체 데이터 생산 및 품질 관리


□ 유전체 데이터 생산

- 유전체 생산기관은 유전체 데이터 생산 시, 해당 데이터와 함께 생산·제공·보안 등에 대한 기록을 생성하여 국가생명연구자원정보센터에 전송
- 선도사업 및 신규 희귀질환 검체에 대해 유전체 데이터 생산(7,500건)
- 유전체 데이터 생산 이력 기록 및 기록의 실시간 KOBIC 전달
 - 유전체 데이터 생산 이력의 자동화 기록 시스템 구축
 - 유전체 데이터 생산 상태 및 각 실험 메타데이터를 KOBIC에 자동으로 전달할 수 있는 시스템 구축 및 시행
 - 시료 수집기관, KOBIC, 유전체 생산기관 간의 정보 연계를 통해서, 검체의 수집·이동, 유전체 생산, 이송, 관리 체계를 자동화 실시간으로 정보 확인 및 모니터링 할 수 있는 시스템을 구축

□ 유전체 데이터 생산에서의 품질 관리

○ 품질 관리의 필요성

- 다수의 염기서열 분석 업체에서 염기 서열 분석을 진행할 예정이므로, 양질의 염기서열 분석 데이터 확보를 위해 염기 서열 분석을 위한 **DNA 샘플 및 시퀀싱 품질 기준을 마련**하고 이를 **표준 지침서화** 해서 **시퀀싱 업체간의 품질 차이를 최소화** 함
- 수집한 인체 유래 검체 및 이를 이용하여 생산되는 유전체 데이터는 정확한 유전체 정보 탐지를 위하여 높은 수준의 품질관리(quality control)가 필요함
- 시료 수집부터 변이 탐지까지의 전체 과정 중에서 일부에서 오류가 발생하더라도, 최종 유전체 정보의 수집에 큰 지장을 초래할 수 있음. 이러한 오류는 전체 파이프라인 어느 곳에서도 발생할 수 있음이 잘 알려져 있음(그림 3)



< 유전체 분석 과정에서 개입될 수 있는 오류의 종류 >

- 이러한 오류들은 크게 ① 시료 및 라이브러리 단계와 ② 유전체 데이터 생산 단계에서 발생하는 것으로 나눌 수 있으며, 각각의 오류 종류에 따라 샘플 수준에서 혹은 데이터 수준에서 정도 관리를 진행할 수 있음
- 시료 및 라이브러리 단계
 - 수집된 시료 (DNA 및 RNA)의 양, 질, 농도 등 시료의 처리 단계에서 확인할 수 있는 오류와, 수집된 시료를 다루는 (handling) 과정에서 생기는 통상적 실수 (e.g., 샘플의 뒤섞임, 외부 물질에 의한 오염, 잘못된 labeling) 가 포함됨
 - 시료를 보관하는 과정에서 시료에 손상 (damage)이 가해지면서 원래의 유전정보를 왜곡하는 경우도 존재함 (e.g., 포르말린 고정 파라핀 포매 (FFPE) 에 의한 cytosine deamination)
- 데이터 생산단계에서는 NGS 시퀀싱 과정에서 생기는 다양한 오류들이 포함됨
 - 대표적인 예로는 NGS 라이브러리 제작 단계에서 생기는 reagent에 의한 DNA 손상 (e.g. OxoG), 시퀀싱 에러 (base-call error), 플랫폼 특이적 서열 오류 (e.g., Ion Torrent에서의 homopolymer 영역 길이 오류) 가 일어날 수 있음
- 정확한 유전체 데이터 수집을 위하여, 보고된 모든 종류의 오류의 여부는, 유전체 분석 단계에서 일상적인 파이프라인 내에 포함되어야 함

○ DNA 샘플 품질 기준

- DNA 추출

- EDTA채혈튜브에서 전혈 1mL을 질관리용(QC)으로 Eppendorf tube에 분주하고, 그 외 EDTA 채혈튜브 혈액 또는 buffy coat에서 DNA를 추출함. 해당 방법을 표준지침서에 반영하여 이를 기반으로 DNA 추출을 진행
- WGS 데이터 분석에 적합한 품질의 DNA 확보를 위해 다음 요구사항에 맞도록 수행해야 함(표 1)

< DNA 추출시 요구사항 >

구분	내용
추출방법	자동화 추출방법을 우선적으로 고려한다. 추출방법은 제조사의 가이드라인과 실험실 표준운영절차(SOP)에 따라 수행되어야 하며, 전장유전체분석(WGS)에 적합한 고품질 DNA자원을 확보할 수 있는 방법이 검증되어야 한다.
DNA 증폭	추출된 DNA는 PCR법으로 증폭시키지 않는다.
DNA 정량	이중가닥 DNA 정량이 가능한 방법(Qubit, Picogreen, Glomax Quantifluor 등)으로 DNA를 정량한다. Nanodrop 같은 분광광도계는 DNA 정량에 사용하지 않는다.
DNA 순도	A260/A280 기준은 1.75 ~ 2.0, A260/230 기준은 1.7 이상이다.
DNA 절편 길이	시료의 분해여부와 절편의 60%이상이 23Kb 이상이 확보되는지 확인해야 하며, DNA integrity 검사로 평가한다.
DNA buffer	TE(10mM Tris/1mM EDTA) pH8.0/ 직접 제조하지 않고 QC를 통과한 상용화된 제품을 사용해야 한다.
총 DNA 양	20 ug* (예외사항에서 5 ug을 허용할 수 있다.)
최종농도	100-200 ng/ul** (예외적으로 50 ng/ul를 허용할 수 있다.)
최종용량	100 ~ 300 ul
DNA 희석	DNA 최종농도가 허용기준(200ng/ul)을 초과하거나, 최종용량이 최소 기준(100ul)보다 적은 경우 희석한다. 희석한 DNA자원에 대한 최종농도, 순도, integrity 결과 값을 제출해야 한다.

- DNA 정도 관리


- WGS 데이터 분석을 위해 DNA 정도 관리를 수행
- 이중나선 DNA(dsDNA) 정량을 위해 검증된 방법 (picogreen법 등)으로 농도 측정, A260/280 및 A260/230 ratio 값 측정, 전기영동 결과를 통한 DNA integrity 측정, 성별 PCR 측정, SNP genotyping (검체식별 필요시) 분석 등을 수행함
- DNA 품질관리 결과는 유전체 생산기관, KOBIC 및 국립중앙인체자원은행에 전달해야 함

○ 시퀀싱 품질 기준

- 시퀀싱을 위한 라이브러리 제작 및 시퀀싱 방법에 대한 표준화 된 프로토콜을 정립하고 이를 표준지침서에 반영하고 이를 기반으로 시퀀싱 분석을 진행
- 단일 장비에서 한번의 실행(run)으로 한 샘플(제공사) 당 유전체 서열 약 90Gb(30X) 이상의 고품질(예: PHRED score>20) 염기 확보
- 개별 리드(Read) 길이 최소 150bp 이상(paired-end 시퀀싱인 경우 2x150bp가능)


○ 시료 수집 및 관리 과정에서의 위험요소 탐지 및 해결 방안

- 시료 수집 및 관리 과정에서 크게 4가지의 위험요소가 존재하며, 이를 해결할 수 있는 방법은 아래와 같음(표 2)
- 시료의 절대량 및 농도 부족을 방지하고자, 분석하고자 하는 시료의 DNA량과 농도와 요구하는 플랫폼의 최소 수준을 만족하는지를 미리 측정하여야 함
 - DNA 량과 농도를 측정하기 위한 대표적인 방법으로는 UV 흡광도를 이용한 방법 (nanodrop), DNA 삽입 염료 (intercalating dye)를 이용한 방법 (QuBit), 가수분해 프로브와 qPCR을 이용한 방법 (Taqman), ddPCR을 이용한 방법 등이 있음
 - 각각의 방법은 정량 자체를 위한 DNA 량과 정량의 민감도가 다르므로, 이를 참조하여 최적의 정량법을 사용하여야 함
 - 시료의 절대량이 부족한 경우 이를 분석 과정에서 해결할 방법이 부족하므로, 해당 과정을 통과하지 못한 경우 시료를 재수집하여 다시 진행하여야 함
- 시료의 순수성 부족 문제 방지를 위해, 순수성 부족 방지를 위한 다양한 방법을 사용하여 검증해야 함
 - 시료의 교차 오염의 경우, 서로 다른 개인의 시료가 섞여 있는 것을 생식세포 변이 위치 (germ line variant)에서의 시료 내 variant allele frequency (VAF) 를 이용하여 탐지
 - 순수한 한 개인의 경우 VAF는 homozygote 인 경우 100%, heterozygote 인 경우 50% 일 것으로 기대되나, 두 사람 이상이 섞인 경우, 그 빈도가 변화함
 - 생산된 NGS 데이터를 이용하여 교차 오염을 탐지해 줄 수 있는 도구로 ConTest (Broad Institute) 및 ART-DeCo (Institut Curie) 등이 있음
 - 시료 외부 물질에 의한 오염인 경우, 해당 오염된 시료로부터 생산되는 read 중 인간 참조 유전체에 mapping 되지 않는 것을 확인할 수 있음.
 - 즉, mouse, bacteria, 및 virus 등의 참조 유전체에 대조함으로써 오염된 원인까지 파악할 수 있음. 대표적인 도구로 VirusSeq (MD Anderson Cancer Center), DecontaMiner (National Council of Italy) 등이 있음
 - 시료 자체가 순수성이 부족한 경우, 분석의 방향은 유지되나 분석 성능이 저하될 수 있음
 - 특히 암 유전체의 경우, 주변 정상 조직이 함께 포함됨으로서 암 조직에만 존재하는 체성 유전변이의 빈도가 떨어져 결국 낮은 VAF로 수렴할 수 있음 (그림 4)



< 시료의 비순수성으로 인한 변이의 VAF 저하. 실제 체성 변이 (우)에서 변이로 나타나는 빈도가 줄어드는 것이 예상됨 >

- 이러한 경우, 낮은 VAF를 특이적으로 탐지할 수 있는 분석 도구를 사용하여 해결할 수 있음. 대표적인 도구로 LoFreq (MIT), MuTect (Broad Institute), Virmid (UC San Diego), RePlow (Yonsei Univ.) 등이 있음
- 시료 자체의 손상에 의한 염기서열 변화를 분석 상에서 알아내는 것은 대단히 어려움
- 다만 FFPE의 경우 8-oxoG 에 의하여 생길 수 있는 변이를 복구할 수 있도록 UDG (Uracil DNA glycosylase)처리를 하면 이러한 DNA 손상의 상당량이 복구되는 것으로 알려져 있음
- 상업적인 DNA 분석 패널 중 UDG 처리가 포함되어 있는 상품이 존재함. 따라서 시료가 FFPE에서 오래 보관된 경우, 이러한 처리를 포함하는 방법으로 진행하는 것이 안전함
- 시료 불일치의 경우는 다음과 같은 경우에 발생함. 시료와 라벨(label)의 일치성을 살펴보기 위하여 한 사람으로부터 두 개 이상의 시료가 얻어지는 경우 (주로 암 분석), 해당 샘플끼리의 유전자 일치성을 확인할 수 있음(그림 5)



< SNP 위치를 이용하여 시료의 일치성을 찾아내는 방법 >


- 대부분의 경우 동일 시료내 SNP 일치성을 90%를 상회하는 데에 반해, 그렇지 않은 경우는 70% 이하의 일치성을 보이므로, 이러한 도구를 사용하면 쉽게 일치성 검사를 할 수 있음
- 시료 수집 및 관리 과정에서 생기는 위험요소를 탐지하고 복구하는 방법은 표 2로 정리할 수 있음

< 시료 수집 및 관리 과정 위험요소에 대한 탐지 및 해결 방안 >

연번	위험요소	탐지	해결방안
1	시료의 절대량 및 농도 부족	- UV 흡광도를 이용한 DNA/RNA 정량 - 분광광도계(fluorometer)를 이용한 염색 기반 정량 - Qubit, nanodrop	QC 실패시 데이터 생산 중단 및 시료 재수집
2	시료의 순수성 (purity) 부족	- UV 흡광도를 이용한 시료 DNA의 농도 측정 - qPCR을 이용한 DNA의 정량 - 외부 DNA 염기서열 포함 여부 검사	- 시료 QC 실패시 데이터 생산 중단 및 시료 재수집 - 시료 QC 성공 후 데이터가 생산된 경우, 오염된 DNA 서열을 제거하고 활용
3	시료 유전물질의 손상	- Agarose gel을 이용한 DNA의 크기 측정 - RIN (RNA integrity number)를 이용한 온전성 측정	QC 실패시 데이터 생산 중단 및 시료 재수집
4	시료 불일치	- 개인을 특정할 수 있는 마커를 이용한 대조 - 생산된 시퀀싱 데이터를 이용한 염기서열다형성 (polymorphism) 비교	- 원 시료 추적 시도 - 시료 추적이 가능하고, 코호트 내에서 수정이 가능한 경우 사용 - 그 이외의 경우 샘플 제거 및 재수집

○ 시퀀싱 데이터 생산 과정에서의 위험요소 탐지 및 해결 방안

- 시퀀싱 데이터의 평균 깊이 (depth)는, 생산된 데이터를 참조 유전체에 정렬 (alignment) 후, 각 위치를 커버하는 read의 수를 세어 비교적 쉽게 검사할 수 있음
 - 목표한 영역 (target region)에서 계산된 read depth를 이용하여, 1) 일정 이상의 coverage (e.g., 20)을 가지는 영역의 비율과 2) 평균 read depth를 계산하여, 목표치에 도달하는지 검사함
 - 목표치에 도달하지 못하는 경우, 추가적인 시퀀싱을 통하여 데이터와 결합한 후 사용할 수 있음
 - 검사를 위한 대표적인 도구로서 GATK (Genome Analysis ToolKit, Broad Institute), picard (Broad Institute) 가 있음
- PCR 중복은 align 된 NGS 데이터 상에서, 동일 위치, 동일 모양으로 존재하는 read를 tagging 함으로서 탐지할 수 있음
 - 특정 형태의 시퀀싱의 경우 (e.g., amplicon sequencing), 생산된 read 자체가 동일한 시작 영역을 공유하므로, PCR 중복 검사에 있어 주의하여야 함
 - 최근의 기술로는 PCR에 의하여 생성된 동일한 원본의 DNA 조각들 내에 존재하는 DNA 염기서열의 일치성을 조사하는 UMI (Unique molecular identifier) 가 있음
 - 이는 약 8~12mer 정도의 DNA oligo barcode를 원본 DNA 조각에 붙여서 PCR 생산물 들끼리 구별할 수 있게 함 (그림 6)



< UMI를 이용한 PCR 복제물간의 구별. 서로 다른 UMI 파랑,빨강,오렌지) 가 붙은 DNA 조각은 복제 이후에 서로 같은 서열을 공유할 것으로 예상되기 때문에, 그 중 일부에만 생성된 변이가 관찰되면 (붉은색 X표시) 이를 제거할 수 있음 >

- 라이브러리 제작 과정에서의 시료 손상은 상기 기술하였던 8-oxoG 에 의한 손상의 경우 UDG를 이용한 물리적 복구 방법 이외에도, NGS 데이터의 strand specificity 와 read orientation을 이용하여, 오류를 정정할 수 있는 분석 기술이 존재함
 - 또한 최근의 분석 방법에서는 플랫폼 특이적으로 발생하는 배경 잡음(background noise)를 추론하고, 분석과정에서 이를 활용하여 정확성을 올릴 수 있음
 - 그럼에도 불구하고, 해당 과정에서의 손상은 광범위한 영역에 걸쳐 매우 미미한 수준

으로 나타나므로 모든 영역을 복구하기는 어려움

- 다만, Illumina Hybrid Capture Seq과 같이 특정 손상 (8-oxoG) 에 취약하다고 알려진 경우, 상기 프로그램을 이용하여 점검하는 과정이 필수적임
- 서열 품질 저하는 생산된 모든 read 의 각 위치에서의 평균 base call quality를 점검하여 쉽게 확인할 수 있음
- 대표적인 도구로 FastQC(Babraham Institute), Trimmomatic(Aachen University, Germany) 가 있음
- 염기 서열 결정 에러는 모든 시퀀싱 기계는 자체적으로 알고 있는 경험적 확률 (empirical probability)를 보유하고 있어, 염기 서열 결정 당시에 예상되는 오류의 확률을 phred score (Q-score) 형태로 제공함
- 이를 이용하는 가장 단순한 방법은 Q-score가 특정 값(예: 20) 이하는 read를 모두 버림으로서 얻어질 수 있음
- 대부분의 서열 분석 프로그램은 이를 활용하고 있으므로, 특별한 분석이 아니면 따로 계산하여 제거할 필요가 없음

< 시퀀싱 데이터 생산 과정 위험요소의 탐지 및 해결 방안 >

위험요소	원인	위험성
시퀀싱 깊이 (depth) 부족	• 모든 유전체 영역에서의 global read depth 및 coverage 측정 • 타겟 영역에서의 read depth 측정	• 목표 read depth를 달성하지 못한 경우 추가 시퀀싱 데이터 생산
PCR 중복 (Duplication)	• 프로그램을 이용한 PCR 중복 측정 (동일 위치, 동일 서열)	• PCR 중복이 의심되는 read를 표기하고, 이후 분석에서 배제 • 단, 특정 경우 (high depth amplicon sequencing 등)에서는 사용하지 않아야 함
라이브러리 제작 과정에서의 시료 손상	• 각 손상별 염기 변이 특징을 시퀀싱 데이터로부터 추적 (e.g., OxoG 산화 손상, C>T 복제 손상 등)	• 손상 정도가 심한 경우 샘플 배제 • 손상 정도가 약한 경우, 해당 손상을 고려하는 분석법 사용
서열 품질 (quality) 저하	• 각 read의 위치별 평균 염기서열 품질 측정	• 현저한 품질 저하가 있는 위치의 read를 잘라내고 (trimming) 사용
염기 서열 결정 (base call) 에러	• 각 read의 염기위치에서 base call quality 측정	• base call quality가 일정 이하인 부분은 제거하고 사용 • base call quality가 전체적으로 나쁜 경우 전체 read 혹은 영역 배제
염기 길이 결정 에러(Ion Torrent 특화)	• Homopolymer 영역에서 근처에서 잦은 (frequent) indel 관찰	• 플랫폼에 최적화된 분석 파이프라인 활용 • 해당 영역 주변에서 realignment

		시도 유전체 정보가 도출된 경우 주의하여 분석
--	--	--

- 상기된 DNA 샘플 및 시퀀싱 품질 관리 기준 및 방안은 유전체 생산기관 표준 운영·관리지침에 반영하고, 해당 내용은 분석기관에서 품질 관리 업무 수행 시 준용

(다) 유전체 생산기관의 표준 운영·관리지침 수립 및 이송·관리 체계 구축

□ 유전체 데이터 생산·관리를 위한 “유전체 생산기관 표준 운영·관리 지침” 수립

- 생산기관 표준 운영·관리 지침서의 필요성
 - 다수의 유전체 생산기관에서 시퀀싱을 진행하기 때문에, 시료 및 DNA 품질 관리, 유전체 데이터의 품질 관리 및 데이터 관리 등에 관한 표준 지침서 수립 필요
 - 표준 운영·관리 지침서에는 아래의 시료 수집 및 관리 과정 및 시퀀싱 데이터 생산 과정에서의 위험요소에 대한 해결방안이 반영되어, 최상의 유전체 데이터 생산 및 관리가 될 수 있게 함
- 유전체 데이터 생산기관이 데이터를 생산 및 관리하면서 지켜야할 지침 작성 및 시행 관리 감독

□ 유전체 생산기관의 유전체 데이터 보안 유지·관리

- 데이터 관리 기본 원칙
 - 데이터를 취급하는 기관 또는 업체는 개인정보보호법, 생명윤리법 등 관련 법령을 준수하여야 함
- 유전체 데이터 생산을 위해 접근 제한된 폐쇄형 컴퓨터 구축
 - 인터넷 연결이 안되고, 접근이 제한되어 일부 권한있는 사용자만 접근 가능한 유전체 데이터 생산 및 관리 컴퓨터 구축
 - 분리·독립된 전산장비는 데이터의 유출사고 예방 및 내부 보안 강화를 위해 계정 접근 권한별 통제, 작업에 대한 모니터링(동영상 녹화) 등 시스템 접근제어 및 통제 솔루션(CC인증)을 사용해야 하며, 관련 로그와 동영상 등은 KOBIC에 제공해야함
 - KOBIC으로 전달 된 유전체 정보는 분석 담당자의 관리·감독하에 KOBIC 분석 서버에 업로드 함
- 유전체 정보의 암호화
 - 저장된 유전체 정보 파일을 접근하더라도 유전체정보를 바로 해독할 수 없게 암호화된 형태로 보관 및 디스크 전송
 - 유전체 정보 암호화를 위한 프로세스 정의 및 시행

○ 유전체 데이터 접근 권한 관리

- 유전체 생산업체/KOBIC에서 유전체 데이터 저장 컴퓨터 및 암호화된 유전체 데이터 접근을 위한 권한 관리 체계 구축 및 시행
- 파일 접근 권한과 암호화/복호화 권한을 따로 정의 및 관리

○ 데이터 무결성 및 안전성 확보

- 데이터의 무결성 확보를 위한 체계 수립
- 데이터 유실 방지를 위한 생산업체 백업 시스템의 구축
- 디스크 기반 전송 프로토콜의 확립 및 전송업체의 보안/안전성 확보

□ 유전체 데이터 이송

○ 유전체 데이터의 KOBIC 이송

- 유전체 서열 정보는 대용량인 관계로, 유전체 생산기관에서 KOBIC으로 하드웨어 형태로 전달함
- KOBIC의 데이터 분석 담당자는 하드 디스크 수령 시, 수령 확인서를 작성하여 유전체 생산기관에 제공

(라) 데이터 관리방안 및 체계 구축

□ 유전체 데이터 관리

○ 데이터 사용자 윤리지침 제정

- 데이터 사용자는 본 사업에서 제공하는 데이터의 종류, 접근 권한 등 본 사업에서 정한 데이터 공동 관리 지침을 숙지하고 따라야 함
- 데이터 사용자는 연구 계획서에 기재한 데이터 활용 목적 및 범위를 준수하여야 하며, 필요시 변경 신청을 할 수 있음
- 데이터 사용자는 실제로 수행하고자 하는 연구 계획서에 맞게 데이터 종류와 접근 권한을 요구하여야 함
- 데이터 사용자는 승인된 데이터와 접근 권한 내에서 연구를 수행하여야 하며, 데이터의 외부 유출을 시도해서는 안 됨
- 본 사업 데이터를 활용하여 수행한 연구로부터 얻게 된 사회적으로 민감한 정보는 반드시 윤리위원회에 회부하여 공개 여부 등을 윤리위원회 결정에 따라야 함

○ KOBIC에서의 유전체 데이터 접근 권한 및 관리

- KOBIC 분석 서버에 업로드한 유전체 정보를 담고 있는 하드 디스크의 경우, KOBIC 내 보안 시설에 보관하며, 분석 담당자만 접근할 수 있게 함


- KOBIC 분석 서버에 업로드 된 유전체 분석 데이터는 사전에 접근 권한이 부여된 데이터 분석 인원만이 KOBIC 내 보안 장소에서만 접근 가능함
- KOBIC에서 보관하고 있는 임상정보, 유전체 데이터 및 분석 단계에서 생산된 모든 정보는 KOBIC의 보안 정책에 따라 관리되고 있음

(마) 유전체 데이터 품질관리 · 분석 파이프라인 표준화 및 구축

□ 유전체 데이터 생산 품질 관리 파이프라인 표준화 및 구축


○ 유전체 데이터 생산 품질 관리 프로세스 구축

- DNA library 제작 후 GEL 사진을 검수하여 품질관리 수행
- 생산된 전장유전체 데이터의 품질이 전처리를 통해 PCR 중복 제거 이후 mapped read의 염기 총합이 85Gbase 이상의 충분한 depth 확보
- 샘플 뒤바뀔 · 중복 · 누락(swapping, duplication, omission of samples) 및 혼합 · 교차오염(mixed sample, cross contamination) 확인
- 품질 미달 시 재생산하여 고품질의 유전체 데이터를 확보




< DNA Library 제작 및 품질관리 >

- 생산 기관에서 전달 받은 파일의 md5sum 체크를 통한 데이터 이관 과정 검수
- SNP Genotyping(96)을 통한 샘플 뒤바뀔 검수
- 유전체 성별 확인 (Scaled mean depth on chrXvs ChrY) 및 임상 정보와 비교 검수



< 품질관리 프로세스 >



< 유전체 성별 확인 (Scaled mean depth on chr vs ChrY) >

Advanta Sample ID Genotyping Panel SNP List

SNP ID	Q	G	P	HP	HE	SNP ID	Q	G	P	HP	HE	SNP ID	Q	G	P	HP	HE
rs952718	✓					rs7522034			✓		✓	rs3736510			✓		✓
rs7803075	✓					rs6107027			✓		✓	rs2304891				✓	✓
rs9319336	✓					rs2275059			✓			rs9482			✓		✓
rs2397060	✓					rs3746805			✓			rs1137930				✓	✓
rs1344870	✓					rs4953042			✓		✓	rs1058486			✓		✓
rs2946788	✓					rs3817098			✓			rs27529				✓	✓
rs6591147	✓					rs6965201			✓			rs3177137				✓	✓
rs2272998	✓					rs5998				✓		rs1043615				✓	✓
rs7229946	✓					rs7259333			✓			rs1054975				✓	✓
rs9951171	✓					rs1802778			✓		✓	rs1060817				✓	✓
rs525869		✓				rs907157			✓			rs2232818			✓		✓
rs530501		✓				rs8064024				✓	✓	rs2273235			✓		✓
rs2040962		✓				rs3749970			✓			rs11054				✓	✓
rs2032624		✓				rs7933089				✓	✓	rs2236277				✓	✓
rs1865680		✓				rs2292745			✓			rs2293250				✓	✓
rs17307398		✓				rs1799932			✓			rs3182911				✓	✓
rs3795366				✓		rs4078313			✓			rs4799				✓	✓
rs2460111			✓			rs2266918				✓		rs13030				✓	✓
rs1675126				✓		rs805423			✓		✓	rs547497				✓	✓
rs1061629			✓		✓	rs540261				✓	✓	rs13180				✓	✓
rs538847				✓		rs3734586			✓		✓	rs957448			✓		✓
rs76432344				✓	✓	rs3753886			✓		✓	rs3108237				✓	✓
rs3750390			✓			rs3210635			✓		✓	rs164572				✓	✓
rs1624844				✓		rs2294024				✓		rs2175593				✓	✓
rs3803390			✓			rs3812471			✓		✓	rs2306641				✓	✓
rs2293768			✓			rs7786497			✓			rs1594				✓	✓
rs9358890			✓			rs1128933				✓	✓	rs7300444				✓	✓
rs11197835			✓			rs4656			✓		✓	rs1057908				✓	✓
rs1806191				✓		rs238148			✓		✓	rs2152092				✓	✓
rs7953			✓		✓	rs2074265			✓		✓	rs2358996				✓	✓
rs3736757				✓	✓	rs11274			✓		✓	rs4075325				✓	✓
rs2940779			✓			rs10069050			✓		✓	rs1057925				✓	✓

Q: Quality **G:** Gender **P:** Population **HP:** Highly polymorphic **HE:** Highly expressed

Table 1. SNP list for Advanta Sample ID Genotyping Panel. This 96-assay set includes 10 quality assessment SNPs, 6 gender SNPs, 40 exonic SNPs for population prediction (African, East Asian or European) and 40 exonic highly polymorphic SNPs with minor allele frequency (MAF) near 0.5 across the 3 population groups. SNPs that are in highly expressed exons are also identified.

< 품질관리에 사용된 SNP 마커 리스트 >

□ 유전체 데이터 분석 관리 파이프라인 표준화 및 구축

○ 데이터 저장 및 분석용 시스템 구축 및 분석파이프라인의 효율 증대

- 2 Petabyte에 해당하는 분석용 스토리지를 구축하여 1,000 samples/month 분석 가능
- Spark 기반 분석 파이프라인 구축을 통해 클러스터 사용 효율 증대
- Spark 도입으로 Mark duplicates 단계 이전의 sort 과정을 생략하여 I/O 및 storage 등의 분석 효율 10% 이상 증대 (샘플당80~100분 시간 단축)
- 전처리, 맵핑, 변이분석 등 정의된 분석 파이프라인의 최적화 시스템 구축(네트워크, 스토리지, CPU, GPU 등)
- 대용량/자동화를 위해 최적화된 시스템 설계 및 구축

GATK 기반 분석 파이프라인의 단계별 누적 소요 시간

각 분석 단계별 소요시간의 막대(Bar chart)로 나타냈으며, 누적 소요시간은 꺾은선(Polygonal line)으로 나타냄




❖ 성능 테스트 조건

- Input file : Paired-end reads 500Gb
- Server Specification : Processor, Intel(R) Xeon(R) Gold 6132 CPU @ 2.60GHz x 28 / Memory, 376G

<분석 파이프라인 분석 시간 개선>

□ 유전체 분석 파이프라인 표준화 및 구축

- 위탁과제 등을 통해 품질관리 파이프라인을 구축하며, 다음 과정을 포함한 분석 파이프라인 구축



< 시범사업을 통해 구축된 기본 변이 분석 파이프라인 모식도 >

○ Reads 전처리 및 Quality 확인

- 참조 유전체 (Reference genome) 준비
- cutadapt, Samtools, Picard등을 이용한 Adaptor sequences, Reads 오염도 검사, Low-quality Base들을 제거함
- Sequence나 string library material에서 기인하는 문제점들을 분석하는 Quality Control 리포트 제공
- 3' 말단의 염기서열들의 정확도 낮은 염기서열을 제거
- Burrows-Wheeler Aligner-MEM은 70-100bp 길이의 read에 대해 정렬을 수행했을 시 최적의 퍼포먼스를 보이는 알고리즘이기 때문에, minimum-length 70 저품질 서열을 제거 후 남은 read의 길이가 70bp보다 작은 경우 버리도록 함
- paired read 중 한 쪽이라도 버려질 경우 둘 다 폐기함 (--pair-filter=any)

○ Reads 매핑


- 짧은 read들을 참조유전체서열에 매핑시키는 프로그램인 Burrows-Wheeler Alignment (BWA)를 이용하여 시퀀싱 염기서열의 FASTQ 파일을 reference sequence에 mapping
- BWA-MEM 알고리즘은 로컬 정렬을 수행하면서 대상 서열의 각각 다른 부분에 다중 정렬을 생성할 수 있지만 picard와 같은 프로그램에서 MarkDuplicates을 수행 시 분할된 정렬에 대해 인식하지 못할 수 있기 때문에 이후 분석 과정에서 고려되기를 원하는 경우 이 옵션을 사용하여 다중 정렬 결과 중 상대적으로 짧게 정렬된 결과는 주 정렬이 아닌 보조 정렬로 표시
- NGS 기술로 생산된 유전체 데이터는 수억 ~ 수십억 개의 짧은 길이(100~200bp)의 DNA 서열(reads)로 구성
- 향후 특정 유전체 부위의 변이 발견 여부를 판단하기 위하여, 각 짧은 길이의 DNA 서열이 실제 인간 유전체의 어떤 부분에서 읽혀졌는지를 알아내는 과정이 필요하며 이 과정을 유전체 데이터 정렬(alignment)이라고 함
- 수억 ~ 수십억 개의 DNA 서열(~100GB)에 대한 정렬 과정을 수행하여야 하므로 오랜 시간이 소요됨
- 30X 전장유전체(~100GB)를 일반 컴퓨터(16 core)를 이용 시 약 20시간 소요
- 표준 레퍼런스로 GATK Resource Bundle에서 제공하는 표준 참조서열을 사용(resources_broad_hg38_v0_Homo_sapiens_assembly38.fasta): random, decoy 등을 포함한 3,366개 contig로 구성
- GATK에서 동일한 위치에 매핑된 리드들은 시퀀싱 과정 중, 증폭 과정에서 생긴 duplicate이라 판단하여 제거함 (Spark엔진은 대규모 데이터 처리를 빠르고 효율적으로 처리하기 위한 분석 엔진으로 기존 분석에서 시간이 많이 소요되는 과정에 적용됨)

○ Reads alignment의 정확도를 개선

- Genome Analysis Toolkit (GATK)를 이용하여 원 데이터(raw data) 생성과정에서 PCR

로 인해 duplicated된 Read들을 제거

- Indel 주변에 mapping된 read들을 조정하여 다시 align시킴으로써 indel 주변에 많이 발생하는 매핑 오류 및 artifact 보정
- GATK를 이용하여 Realignment를 수행해야 하는 영역들을 대상으로 SNP와 InDEL을 고려한 realignment를 수행
- Base quality score은 변이 발굴을 위해 필요한 핵심 정보 중에 하나이며, 개별 염기에 대한 신뢰도 값을 의미
 - 해당 score값에 기계학습 방법을 적용하여 reads들의 base score를 보정하는 base score recalibration 작업을 수행
 - base score들 사이에는 예를 들어 특정 시퀀싱 기계에서 A(아데닌)이 나온 이후 다시 A가 나온 경우는 오류일 확률이 더 적은 것과 같은 경향성이 존재함
 - 이런 정보를 이용하여 기계학습 방법을 통하여 read들의 base score를 보정하여 변이 검출의 오류를 줄이는 작업을 base score recalibration이라하며 변이 검출을 위한 서열 정렬 과정의 일부분으로 사용됨




< recalibration을 통하여 base score가 보정된 모습 >

○ 변이체 확보 - Germline variation (SNP, InDEL) 발굴

- Reads의 매핑 정보를 담고 있는 BAM 파일로부터 유전변이를 찾아내는 단계
 - HaplotypeCaller를 이용하여 단일염기다형성 (Single Nucleotide Polymorphism, SNP) 및 삽입-결손변이 (Insertion-Deletion, InDEL) 등의 변이 정보를 생성
- 변이 발굴을 위한 GATK HaplotypeCaller의 활용 (그림 12)
 - BAM 파일로부터 유전변이를 찾아내기 위해 HaplotypeCaller 사용
 - 단일염기다형성(Single nucleotide polymorphism, SNP) 및 삽입-결손변이

(Insertion-deletion, Indel) 등 두 가지 유형의 변이를 발굴

- VCF 형식으로 출력 파일 생성
- HaplotypeCaller 활용을 위해 분석에 필요한 기본 파라미터들의 상세 정의 필요
- 코호트의 germline 변이 발굴 분석을 위해 gVCF를 이용한 group calling 방법을 적용하며, 발굴된 변이들의 false positive를 줄이기 위해서 call set을 정제할 필요
- Variant quality score recalibration(VQSR)을 통하여 발굴된 변이의 quality score를 다시 계산하여 false positive를 줄임



< Genome Analysis Toolkit의 HaplotypeCaller의 분석 모식도 >

- Variant quality score recalibration (VQSR)을 통하여 발굴된 변이의 quality score를 다시 계산하여 false positive를 줄임

○ 변이체 주석달기

- ANNOVAR, VariantAnnotator 등의 분석도구를 이용하여 발굴한 변이체들에 대한 특성을 확인
- 변이 필터링, 변이체 관련 유전자 정보, 아미노산 변화 등의 변이체를 해석할 수 있는 정보를 통합

□ 구축된 분석 파이프라인의 표준화

- 구축된 분석 파이프라인을 구성하는 분석 도구의 소개, 적용 파라미터 등을 정리하여 표준 가이드라인을 작성·배포
- 국내외 연구자들이 본 사업에서 구축한 빅데이터를 활용하거나, 자체적으로 분석 파이프라인을 구성할 때 참고할 수 있는 전장유전체 변이분석 프로토콜 설명서(관련증빙 번호 11)를 작성하여 데이터 제공 시 함께 제공


□ 유전체 고속 분석 파이프라인 구축 및 분석

○ 고속분석 하드웨어 필요성

- 단위 하드웨어의 연산량이 2년 마다 2배로 증대된다는 무어의 법칙 (Moore's Law)의 종식으로 인하여 기존의 계산 집중형 응용 프로그램(compute-intensive application)들의 연산량을 CPU가 따라잡지 못하는 현상 발생
- 이런 문제에 대응하고자 가속기를 채택하는 응용들이 늘어나고 있음. 대표적인 가속기로서는 GPU, FPGA와 ASIC을 들 수 있음
- FPGA란 필드 프로그래머블 게이트 어레이라고 불리는 하드웨어로, 재프로그래밍이 가능하여 ASIC과 일반 범용 컴퓨팅 칩의 중간 형태임. 프로그래밍이 가능하면서 CPU 대비 100배 정도의 성능향상을 가져다 주어 사용량이 늘어나는 추세
- 대용량의 데이터의 각종 연산을 수행하여야 하는 유전체 데이터 처리에도 FPGA 등의 가속기 사용이 점차 보편화되는 추세

CPU, GPU, FPGA, and ASICs

Tradeoffs




< 하드웨어 선택시 장단점 >

○ FPGA 기반의 DRAGEN을 활용하여 기본변이 고속분석 파이프라인을 구축

- 암 체세포 돌연변이 고속분석 파이프라인은 다음과 같음

Tumor-Normal Mode



< DRAGEN 암 체세포변이 분석 파이프라인 >

- 파이프라인의 단계별 상세 기능 설명은 아래에 서술

○ 참조 유전체 해시 테이블 구축

- DRAGEN은 참조 유전체를 해시 테이블 파일로 전환하여 분석에 사용
- 해시 테이블은 참조 유전체로부터 겹치는 많은 Seeds(subsequences 또는 K-mer) 추출된 정보를 바이너리 파일 형태로 저장됨
- 참조 유전체 (Reference genome)는 hg38을 사용

○ 유전체 데이터 매핑(Mapping)

- Read로부터 seed를 생성하고 참조유전체로부터 정확히 일치하는 위치를 찾음
- DRAGEN Mapper는 각 Read에서 많이 겹치는 Seeds를 추출함.
- PCIe 카드의 메모리에 상주하는 해시 테이블에서 해당 Seed를 조회하여 일치하는 참조 유전체의 위치를 찾아냄으로서 참조 유전체내 read의 정확한 위치를 빠르게 찾아냄.

○ 유전체 데이터 정렬(Alignment)

- 매핑된 결과를 Smith-Waterman Alignment를 통해 seed의 일치 밀도가 가장 높은 위치로 정제하는 작업
- Read별로 참조 유전체에 매핑 되는 여러 후보 지역에 대해 서로 비교하며, 염기의 일치 또는 불일치, 결손 또는 삽입 정보들을 종합적으로 평가하는 Smith-Waterman score로 나타냄
- 가장 높은 스코어의 정렬(Alignment) 위치가 선택됨

○ Soft read trimming

- 실제로는 read의 base가 trimming되지 않았지만 Read 매핑할 때 trimming을 반영하여 결함이 있는 read의 미스매핑된 경우 정렬된 결과물내에 trimming 되지 않은 read 확보
- 주로 ploy-g 와 같은 결함이 포함된 Read가 참조 유전체의 G 호모폴리머에 매핑되거나 어댑터 서열이 참조 유전체에 매핑되는 것과 같이 결함이 있는 read의 미스매핑된 경우

○ FastQC


- 시퀀싱 데이터의 QC를 위해 선행되는 기본 분석
- Babraham Institute' s fasQC 분석 도구 사용

○ 중복 유전체 데이터 제거 (Remove duplicates)

- 매핑된 Read를 참조 유전체 서열 순서대로 정렬 (30x WGS 기준 6-7분 소요)
- DRAGEN의 duplicate-marking algorithm을 통해 중복되는 Read를 제거함 (30x WGS 기준 1-2분 소요)

○ 기본 변이 분석

- 기본 변이는 단일염기서열변화(Single nucleotide variation), 짧은 길이의 삽입, 결손 (Indel) 을 말함
- 매핑 및 정렬된 Read를 아래와 같이 필터를 거쳐서 통과한 변이는 PASS, 그렇지 않은 변이들은 filter에서 미흡한 이유에 대한 상세 정보를 VCF파일에 제공
- 변이위치와 겹치는 SNP은 dbsnp138 버전으로 annotation하여 VCF 파일에 정보 제공



< 변이분석 필터 과정 >

○ 기타 특이 사항

- Base quality score recalibration 과정이 별도로 필요 없음

○ 고속 분석 속도

- 30x 전장유전체 (~100GB)를 DRAGEN 서버로 분석하였을 때, 최종 결과물을 vcf만 산출한 경우 약 20분, normal 과 tumor의 bam파일까지 산출한 경우 약 1시간 소요

□ 대규모 전장유전체 데이터의 효율적인 처리를 위한 알고리즘 구축

○ 1위탁 연구과제 (50,000천원)

과제명	대규모 전장유전체 데이터의 효율적인 처리를 위한 알고리즘 구축
연구기관명	서울대학교
연구책임자명	최무림
연구기간	2021. 05. 29 - 2022. 12. 31 (20개월)
연구개발 목표	미래 정밀의료 선도, 희귀·난치질환 극복 등 의료 질 향상, 글로벌 바이오 빅데이터(다문화·외국인) 확보, 바이오헬스산업 성장 촉진등을 목표로 국가 바이오 빅데이터 구축 시범사업이 수행된다면 유래없는 규모의 유전체 데이터가 단기간에 생성될 것임. 병목현상을 최소화하기 위하여 유전체 데이터의 효율적인 공유, 관리를 위한 프로토콜 표준화를 위한 변이 콜링 알고리즘을 구축하고 검증함.
연구개발 내용	○ 시범사업의 1, 2년차에서는 매년 희귀질환 유전체 데이터 만건씩의 변이 목록을 소화해야 하며, 이를 위한 안정적인 변이 검출 알고리즘을 구축하고자 함. 이를 다음과 같이 세분화하여 수행 할 것임 - 1년차-1. Common 변이 검출 알고리즘 구축 - 1년차-2. 희귀 변이 검출 알고리즘 구축 - 1년차-3. 체세포 변이 검출 알고리즘 구축 - 2년차-1. 구조 변이 검출 알고리즘 구축 - 2년차-2. 위 알고리즘 성능 검증 ○ 이를 통하여 희귀, 선도사업의 유전체 데이터 확보와 데이터, 검체 연계하여 유전체-임상 연계를 도우며 유전체 분석 파이프라인 표준화 및 구축을 완료함. 시범사업 이후 (100만명 규모) 본 사업 유전체 분석 빅데이터 구축 사업 기획에 대응 가능할 플랫폼 지원.

○ 연구개발 내용 1: Common/희귀 변이 검출 알고리즘 선택, 구축

- Broad institute에서 권장하는 best practice 알고리즘에 근거하여 연구실의 환경에 맞게 알고리즘을 변환 사용하여 대규모 유전체 데이터에서 germline 변이 검출을 위한 알고리즘을 구축하였음 (그림 1, 2)
- 데이터의 규모가 크기 때문에 유전체를 작은 구간으로 분할하여 따로 변이 검출 후

이를 추후 통합하는 형식으로 진행 하며, 샘플별 따로 검출된 변이들은 GCVF 형식으로 통합되어 다시 join calling 과정으로 넘어감 (그림 2). Calling된 변이들은 recalibration 과정 후 여러 구간의 데이터를 통합 후 annotation을 진행하여 변이의 기능적 역할을 알 수 있게 됨

- 가장 중요한 annoation 정보 중 하나인 변이의 빈도 정보는 두 개의 대조군 데이터베이스에 비교하였음. (1) gnomAD는 12만명이 넘는 대규모 대조군 데이터베이스로 전세계 여러 민족 데이터가 망라되어 있음, (2) KOVA는 한국인 대조군 데이터베이스로 필터링 후 약 5천2백명의 WES/WGS data 유래 데이터가 구축되었음 (Lee et al., 2022 Exp Mol Med). 참고로 gnomAD가 보유한 한국인 데이터는 2천명이 넘지 않음.




그림 1. Broad institute에서 권장하는 germline 변이 검출 알고리즘의 개요도

(<https://gatk.broadinstitute.org>)




그림 2. WGS data의 FASTQ to VCF 파이프라인

- 이렇게 검출된 변이들은 annotation 정보에 따라, 그리고 바이오 빅데이터 유전체 데이터 상의 변이 정보에 따라 common vs rare variant로 분류 되었으며, 유전체 변이들은 주어진 집단 내에서 연속적인 빈도 분포를 띠고 있기 때문에 Common-rare를 구분하는 단정적인 기준은 모호함. 하지만 Common variant는 보통 1%가 넘는 빈도 분포를 보이며 그 수 자체가 많지 않기 때문에 구분이 가능하였음
- 그 중 trio sequencing(부모와 환자)이 수행된 경우는 de novo variant 검출이 가능해짐 (개인별 ~70개 정도). 이 단계는 WGS 분석 전문가인 고려대학교 안준용 교수의 자문을 받아 본 연구실에도 파이프라인 셋업이 완료됨 (ROCube; An et al. 2018, Science; Werling et al. 2018, Nature Genetics).
- 이러한 파이프라인의 구축에 더하여 이를 이용하여 두 가지 WGS 데이터셋에 대한 변이 콜링과 분석을 진행함

(1) 대조군 유전체 2,396 샘플의 WGS 데이터를 처리하여 각종 quality control 분석 후 중복, 친족관계가 없는 양질의 1,897 샘플을 얻음. 이 샘플들에서 SNV, indel 콜링을 수행하여 그에 대한 기본적인 분석 진행함 (그림 3)

(2) Rett 증후군은 MECP2라는 유전자의 돌연변이에 의하여 90%의 환자들이 발생하지만 나머지 10%의 환자들의 증상을 유발하는 돌연변이는 아직 많이 밝혀지지 않았음. 이를 위하여 MECP2 돌연변이가 없는 Rett 증후군 환자 9명을 모아 환자와 부모로 이루어진 트리오 WGS를 수행하여 환자만 특이적으로 가지고 있는 de novo variant 콜링을 수행하여 그에 대한 기능 분석을 진행함 (그림 4; 표 1)




그림 45. 파이프라인에 의거하여 한국인 WGS 1,900, WES 3,200명 data에서 콜링된 변이들의 기본 분석 결과 (a, c) allele frequency distribution, (b, d) sample 수에 의한 novel variant 수의 분포도, (e) 변이 패턴에 근거한 PCA 양상과 타 민족 데이터와의 상대적 위치, (f) splicing 변이의 분포도 (Lee et al., 2022 Exp Mol Med)




그림 4. 파이프라인에 의거하여 MECP2 돌연변이 음성인 Rett 증후군 환자 9명과 부모들의 WGS 분석 데이터에서 콜링된 변이들의 기본 분석 플로우차트

표 1. 9명의 Rett 증후군 환자와 부모에게서 콜링된 de novo 변이들의 요약 정보

샘플	de novo call의 수				
	Raw	Filtered	SNP	Indel	Mono-allelic
TWGS1	112,031	120	81	39	115
TWGS2	95,617	114	79	35	107
TWGS3	107,401	145	88	57	136
TWGS4	102,459	120	84	36	118
TWGS5	111,875	107	67	40	101
TWGS6	114,415	95	64	31	89
TWGS7	107,978	140	94	46	131
TWGS8	121,538	134	84	50	125
TWGS9	105,311	92	57	35	86
합계	978,625	1,067	698	369	672
평균	108,736	118.6	77.6	41.0	112.0

○ 연구개발 내용 2: 구조 변이 검출 알고리즘 선택, 구축

- 이미 많은 종류의 전장유전체 구조 변이 검출 알고리즘이 도출되었으나 전장유전체 데이터의 규모가 크고 인간 유전체상 sequence context 문제 때문에 제대로 구조변이를 잡아주는 알고리즘을 찾기가 어려움
- 이를 위하여 본 연구에서는 WGS data에서 SV calling 방법을 사용함. WGS-style SV

calling: gnomAD에서 구조 변이 분석을 위하여 사용한 네가지의 알고리즘 결과의 교집합 결과를 사용함 (그림 3): Manta, DELLY, MELT, cn.MOPS를 사용함. 본 연구실의 내부 비교 결과 Manta가 가장 안정적인 결과를 보여주기는 하였으나 대규모 데이터를 사용할 것이므로 어느정도 stringent한 알고리즘이 필요할 것이므로 네가지의 알고리즘의 교집합을 사용함. 그 후 실제 구조 변이 구간의 genotype을 비교하여 그 구조 변이의 true possibility를 유추함




그림 3. gnomAD 구조 변이 검출 알고리즘의 도식도 (<https://macarthurlab.org>)

○ 연구개발 내용 3: 구축된 알고리즘 검증

- 이렇게 구축된 알고리즘은 독립된 데이터베이스나 완전히 다른 방법에 의하여 생성된 동일 샘플 데이터의 비교에 의하여 그 performance를 기록하고 이에 의거하여 알고리즘을 개선하는 작업이 필요할 것임. 본 연구에서는 다섯가지의 알고리즘 검증 방법을 제시함

(1) 외부 데이터베이스 gnomAD 이용: 위에서도 설명하였듯이 gnomAD는 12만여명의 건강한 개인의 유전체 데이터(WES, WGS)를 모아 데이터베이스화 한 것임. 이 데이터는 모두 공개되어 있으며 각종 유전체 분석에 가장 중요한 대조군으로 사용되고 있음. 그렇기 때문에 본 연구 과제에서 구축한 알고리즘에 의하여 검출된 각종 변이들의 빈도 정보와 gnomAD에서 공유받을 수 있는 변이의 빈도 정보와 구조 변이의 유무와 빈도 정보 (common structural variant의 경우)간의 관계는 상당히 중요함 (그림 4). gnomAD 중 동아시아인과의 변이 빈도와 본 데이터의 변이 빈도간에는 >97% correlation을 요구 할 것임. 구조 빈도의 경우는 검출이 힘들고 빈도 계산도 정확하지 않기 때문에 >90% 정도의

correlation을 요구 할 것임




그림 4. gnomAD 데이터베이스에서 제공하는 변이와 구조변이의 예시 (TBX1 gene)




그림 50. 본 과제에서 구축한 SV 알고리즘을 이용하여 KOVA, gnomAD에 적용 한 결과




그림 51. KOVA에서 발견된 변이의 allele age를 분석함. 이를 통한 본 과제의 변이 콜링 알고리즘의 관리가 잘 되었음을 알 수 있음 (Lee et al., 2022 Exp Mol Med)

(2) 내부 데이터베이스 KOVA 이용: 위에서 설명한대로 본 연구진은 KOBIC과의 협업을 통하여 국내 유전체 데이터의 재활용, 한국인 고유의 대조군 유전체 데이터베이스 구축을 목표로 KOVA(Korean Variant Archive) version 2를 구축함. 현재 5천5백명의 대조군 유래 WES data, 천5백명의 대조군 유래 WGS data를 모집 중이며 변이 calling 작업 중임. 이 데이터베이스는 본 바이오 빅데이터 유전체 데이터와의 비교 분석에 매우 중요한 참조 데이터가 되었음. 본 데이터베이스의 변이 빈도와 본 데이터의 변이 빈도간에는 >97% correlation을 보임.

(3) SNP array 방법 생성된 데이터 비교 분석: 동일 샘플을 대상으로 WGS과 SNP array 방법으로 데이터 생성이 된다면 각각 점변이와 구조변이의 직접적인 비교가 가능해 질것임. 점변이의 경우 >99%의 correlation, 구조변이의 경우 >93%의 correlation을 목표하고 있음


(5) WES 방법 생성된 데이터 비교 분석: 역시 동일 샘플을 대상으로 WGS과 WES 방법으로 데이터 생성이 된다면 각각 점변이와 구조변이의 직접적인 비교가 가능해 질것임. 점변이의 경우 >99%의 correlation, 구조변이의 경우 >93%의 correlation을 목표하고 있음

(바) 유전체 데이터 분석 및 분석보고서 작성·배포

□ 유전체 데이터 분석

- 상기된 유전체 분석 파이프라인 중, 유전체 데이터 품질관리 및 기본변이 분석에 대한 파이프라인을 수립
- 1·2년차에 걸쳐 2.5만 건이상의 유전체 데이터 분석을 수행하여 VCF 파일을 생산
- Variant Call Format (VCF)
 - 유전체 기본 변이 분석의 최종 결과물
 - 각 샘플 별로 검출된 모든 유전 변이를 포함
 - VCF는 파일에 다수의 샘플에 대한 변이 정보 수록 가능하며, 단일 샘플에 대한 정보만 수록하는 것도 가능
 - VCF는 샘플 당, 수백 MB ~ 수 GB 수준으로 유전체 데이터에 비해서 작은 용량임*

* 100만명의 VCF의 경우 수백 TB 수준



```
1. zless IBS-ASD-5363-blood-wgs-ILLUMINA.fmarked_gap.wos.vcf.gz (ssh)
#CHROM POS ID REF ALT QUAL FILTER INFO FORMAT IBS-ASD-5363-blood-wgs-ILLUMINA IBS-ASD-
5363-blood-wgs-ILLUMINA IBS-ASD-5363-blood-wgs-ILLUMINA
chr1 12807 rs62635285 C T 10973.7 PASS AC=1;AF=0.154;AN=6;BaseQRankSum=-0.847;ClippingR
ankSum=-0.361;DB=0;DP=25988;ExcessHet=2.16748e+09;FS=0;InbreedingCoeff=-0.2575;MLEAC=143;MLEAF=0.187;MQ=25.67;MQRa
nkSum=-1.949;NEGATIVE_TRAIN_SITE;QD=2.83;ReadPosRankSum=0.198;SOR=0.081;VQSLOD=-5.781;culprit=QD;set=Intersection
GT:AD:DP:GQ:PGT:PID:PL 0/1:3,2:5:41:...:41,0,80 0/0:15,0:15:42:...:0,42,630 0/0:14,0:14:42...
...:0,42,543
chr1 13273 rs531730856 G C 83923.7 PASS AC=1;AF=0.119;AN=6;BaseQRankSum=0.492;ClippingRa
nkSum=-0.376;DB=0;DP=55120;ExcessHet=0.0167;FS=0;InbreedingCoeff=0.0912;MLEAC=217;MLEAF=0.119;MQ=36.69;MQRankSum=-
0.133;QD=12.22;ReadPosRankSum=0.36;SOR=0.709;VQSLOD=0.448;culprit=FS;set=Intersection GT:AD:DP:GQ:PGT:PID:PL
0/0:12,0:12:36:...:0,36,483 0/1:24,13:37:99:...:391,0,840 0/0:27,0:27:81:...:0,81,1150
chr1 13417 rs777038595 C CGAGA 86786.6 PASS AC=1;AF=0.107;AN=6;BaseQRankSum=0.424;ClippingRa
nkSum=-0.122;DB=0;DP=53256;ExcessHet=21.314;FS=9.72;InbreedingCoeff=-0.0773;MLEAC=197;MLEAF=0.106;MQ=32.71;MQRankS
um=0.34;QD=14.9;ReadPosRankSum=-0.361;SOR=1.313;VQSLOD=-1.313;culprit=FS;set=Intersection GT:AD:DP:GQ:PGT:
PID:PL 0/0:13,0:13:39:...:0,39,532 0/1:15,12:27:99:...:449,0,873 0/0:21,0:21:60:...:0,60,900
chr1 13613 T A 3749.64 PASS AC=1;AF=0.076;AN=6;BaseQRankSum=0.357;ClippingRankSum=-0
.425;DB=55120;ExcessHet=62.026;FS=81.394;InbreedingCoeff=-0.1143;MLEAC=125;MLEAF=0.067;MQ=25.26;MQRankSum=-2.444
;QD=1.06;ReadPosRankSum=0.578;SOR=0.902;VQSLOD=-21.11;culprit=FS;set=filterInv1-v2 GT:AD:DP:GQ:PL 0/1:14,2
:16:6,0,341 0/0:30,0:30:77:0,77,1170 0/0:21,0:21:0:0,0,659
```

< VCF 파일 형식 >

- 유전체 데이터 생산·분석 현황
 - (데이터 생산·분석) 1·2년차 전장유전체 데이터 생산 (2만 건) 및 변이분석 (2.5만 건) 진행
 - 유전체 미보유 선도사업 5,000명 운송 검체 데이터 생산 및 분석 완료 5,000건
 - 희귀질환 대상자의 검체 수집 및 데이터 생산 및 분석 완료 1.5만 건
 - 유전체 보유 선도사업 5,000명 데이터 이관 및 분석 완료

□ 분석보고서 양식 개발, 분석 보고서 작성·배포

- 분석보고서 양식 개발
 - 생산된 VCF와 함께 분석보고서를 제작하여 컨소시엄 혹은 필요시 외부 기관에 제공
 - ① 유전체 데이터로부터 VCF 생산 과정, ② 각 VCF 파일 혹은 gVCF 파일의 통계치 요약 등을 포함하도록 분석보고서 양식 개발

○ 분석보고서 작성·배포

- 2.5만 건의 유전체 데이터로부터 생산된 GVCF에 상응하는 분석보고서를 작성하여 컨소시엄 구성기관 등에 제공

□ 연구자를 위한 데이터 제공

○ 연구자용 데이터 제공

- 2.5만 건의 유전체 데이터로부터 생산 및 수집된 VCF에 상응하는 분석 결과를 연구자들에게 제공하기 위해서 KISTI에서 운영하는 CIRN에 연계 및 질병청 연계
- 제공되는 데이터는 분석에 필요한 모든 데이터이며, 필요시 추가 분석하여 제공함

□ 전장유전체 분석 파이프라인의 비교 분석

○ 기존의 전장유전체 분석 기술의 비교


- 기존의 개발되어 발표된 전장유전체 데이터 분석 기술들을 비교하여 각각의 장단점을 비교하여 본 사업에서 생산되는 전장유전체 정보의 분석을 위한 파이프라인을 확보함


(3) 데이터 활용체계 구축

(가) 한국인 유전체 데이터 등록·관리 시스템 구축·고도화

□ 한국인 유전체 데이터 등록 관리 시스템 시범 구축

- 유전체 자동 분석 프로세스 설계 및 구축을 위한 분석 모듈 및 입/출력 점검
 - 등록 관리 기능(백엔드/프론트엔드) 개발
 - 일괄 등록 데이터 검증 모듈, 이관(인수) 파일 연결 기능, 변이 분석 및 연계





〈한국인 전장유전체 데이터 등록·관리 시스템 개요〉

(나) 사업 소개 홈페이지 구축·고도화

□ 홈페이지 구성안


- 사업 및 선도사업 연계 운영 소개
 - 사업 체계 및 참여 기관 간의 협력 소개
 - 진행중인 국내외 협업 및 연구 현황 소개

〈국가바이오빅데이터구축 - Data Coordination Center, 홈페이지 메인화면〉



○ 연구지원 홈페이지 구성안

- 국가 바이오 빅데이터 구축을 위한 “Data Coordination Center” 소개
- 전장유전체 (WGS) 분석 파이프라인 소개
- 연구자의 Q&A, FAQ 서비스를 통한 연구지원 서비스
- 데이터 자료실 및 커뮤니티 서비스



< 홈페이지- 사업 소개 및 선도사업 페이지 >



< 홈페이지- 분석파이프라인, 추진체계 및 자료실 페이지 >

2-2. 추진 일정 실적

1차년도														
개발내용	추진 일정												책임자 (소속기관)	비고 (변경사유 등)
	1	2	3	4	5	6	7	8	9	10	11	12		
선도사업 선정 및 연계													김선영 (KRIBB)	-
유전체 생산기관 선정													김선영 (KRIBB)	추진위원회 개최 지연으로 인한 선정 지연
유전체 데이터 생산 및 품질관리													김선영 (KRIBB)	유전체 생산기관 선정 지연에 따라 생산 시작 일정 지연
유전체 생산기관의 표준 운영·관리지침 수립 및 이송·관리 체계 구축													김선영 (KRIBB)	-
데이터 관리방안 및 체계 구축													김선영 (KRIBB)	-
유전체 데이터 품질관리·분석 파이프라인 표준화 및 구축													김선영 (KRIBB)	-
유전체 데이터 분석 및 분석보고서 작성·배포													김선영 (KRIBB)	-
유전체 등록·관리시스템 및 사업 소개 홈페이지 구축													김선영 (KRIBB)	-

2차년도																							
개발내용	추진 일정																				책임자 (소속기관)	비고 (변경사유 등)	
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20			
선도사업 선정 및 연계																						김선영 (KRIBB)	선도사업 선정기준 추진위 검토·선정(~23년.3월) 및 선도사업 연계(~23년.8월)
유전체 생산기관 선정																						김선영 (KRIBB)	-
유전체 데이터 생산·품질관리 및 관련 체계 고도화																						김선영 (KRIBB)	-
유전체 생산기관의 이송·관리 체계 고도화																						김선영 (KRIBB)	-
데이터 관리체계 고도화																						김선영 (KRIBB)	-
유전체 데이터 품질관리·분석 파이프라인 고도화																						김선영 (KRIBB)	-
유전체 데이터 분석 및 분석보고서 작성·배포																						김선영 (KRIBB)	-
유전체 등록·관리시스템 및 사업 소개 홈페이지 고도화																						김선영 (KRIBB)	-

2-3. 연구개발성과의 관련 분야에 대한 기여정도

□ 기술적 측면

○ 데이터 중심 정밀의료 기술 혁신

- 구축된 유전체·임상·라이프로그 데이터를 통해 의료기술·신약·의료기기를 개발하고 데이터 분석역량을 증대시켜 정밀의료 기술 및 임상연구 기반을 혁신시킴
- 데이터 기반 건강관리 및 의료평가 등 데이터가 있어야 할 수 있는 특화 연구 모델 기획 가능
- 대규모 한국인 바이오 빅데이터 기반 표준 유전체 및 변이체 정보 제공을 통하여 한국인 맞춤형 정밀의료 실현

○ 의료의 질 향상 및 환자 개인맞춤형 정밀의학 시대 구현

- 공공영역의 보건의료 행정 데이터, 민간영역의 병원입상 데이터, 인간 유전체 연구 데이터를 하나로 연결하여 개인별 맞춤형 실시간 빅데이터 분석 가능
- 만성질환 예방, 맞춤형 치료 등을 통한 국가 차원의 의료비 절감 효과
- 환자 및 일반인은 유전체 분석 보고서를 활용해 잠재적 발병 확률을 확인하고 주의가 필요한 약물, 식이조절 등 맞춤형 관리를 통해 질병 예방
- 희귀질환·유전질환·암·전염병의 유전적 원인을 규명하고, 유전적 결함 정보를 통한 조기 질병 진단, 유전체와 개인 의료정보 분석을 통한 정밀 진단, 동반진단을 통한 효율적인 의료 중재 등 구현

□ 경제적·산업적 측면

○ 4차 산업혁명의 핵심인 의료서비스 분야 활성화 및 국가경제의 성장 동력으로 육성

- 구축된 개인 유전체 정보를 활용하여 바이오헬스케어 산업 발달의 기반 마련
- 국내 대표 IT 기업과 투자사의 바이오헬스케어 시장 진출을 통해 바이오 빅데이터 활용 플랫폼 개발 및 산업 연계 방안 구축
- 국내 유전체분석 및 정밀의료 서비스 시장 활성화로 해외시장 진출의 발판 마련
- 분자진단, 산전진단, 게놈 상담서비스, 개인게놈 분석서비스, 정밀건강검진 서비스 등 헬스케어 관련 산업성장 촉진
- 진입장벽이 높은 분야인 바이오헬스케어의 전환기를 활용한 국가차원의 선제적·전략적 투자를 통하여 미래 시장 선점

○ 국가 차원의 의료비 경감

- 유전체 빅데이터 정보와 주기적 건강검진 정보의 연계를 통한 보다 정밀하고 정확한 예방의료 및 건강관리를 구현하여 고령화로 인한 사회적 부담 및 의료비 경감
- 맞춤형 정보제공을 통해 중증질환으로의 이행을 감소시킴으로써 건강악화를 예방하고, 총 의료비 증가를 사전에 억제

- 국내 유전체분석 및 정밀의료 서비스 시장 활성화로 해외시장 진출의 발판 마련
- 희귀질환·유전질환·암·전염병 등의 유전적 원인 규명을 통한 의료비 부담 경감
- 특히 선도사업의 경우, 국가적으로 건강보험 및 의료비 지출이 큰 대장암·폐암·치매·자폐증에 대한 포괄적인 데이터를 시범사업에 연계하여 외부 연구자들에게 제공함으로써, 해당 질환 분야의 정밀의료 연구에 기여
- 본사업의 주요 모집군인 일반인(울산만명, KoGES)에 대한 다양한 데이터를 제공함으로써, 일반인들의 다양한 유전형·표현형 스펙트럼을 이해하고, 이를 바탕으로 질환의 조기 진단 연구 등을 수행함에 있어 표준참조데이터로 활용

○ 정밀의료 활성화를 통한 바이오·의료 분야의 양질의 일자리 창출

- 정밀의료 헬스케어 서비스 산업 및 의료기기 산업에서 보건의료 빅데이터 전문인력의 수요 증가 예상
- 다양한 보건의료 빅데이터의 병합과 수집이 가능해질 경우 제약 산업 분야에서 가장 높은 인력 수요 성장을 기대
- IT 산업의 경우 EMR 및 데이터 소싱 분야에서 보건의료 빅데이터 전문인력의 수요 증가 예상

○ 부처 간 협력 형 사업 추진을 통한 연구개발 사업 투자 효율성 확보

- 각 부처 및 산하기관이 공통으로 사업을 추진함으로써 산재하고 있는 분절된 데이터 간 연계 기반을 마련하고 부처별 중복된 연구개발 방지 및 예산 효율성 증대
- 데이터 연계를 통해 가치 시너지를 만들어 낼 수 있는 체제 구축
- 기존 수행된 선도사업들을 본 사업과 연계시킴으로써 투자의 연속성 및 재원의 효율적 사용

2-4. 연구개발성과의 관리 및 활용 계획

□ 연구 알고리즘 및 관련 데이터 제공 가능

- 유전체 데이터 확보와 분석, 관리, 활용에 사용
 - 본 과제에서 도출되는 각종 알고리즘은 1세부에서 수행하게 될 바이오 빅데이터 구축 및 활용체계 마련 중 유전체 데이터의 효율적인 분석파이프라인 구축. 결국
- 본 과제의 결과를 통하여 희귀, 선도사업의 유전체 데이터 확보와 데이터, 검체 연계하여 유전체-영상 연계를 도우며 유전체 분석 파이프라인 표준화 및 구축을 완료
 - 시범사업 이후 (100만명 규모) 본 사업 유전체 분석 빅데이터 구축 사업 기획에 대응 가능할 플랫폼을 지원

3. 연구 개발 결과의 활용 방안

□ 의료 서비스의 질 향상 및 관련 연구 활성화

- 희귀·난치 질환의 유전적 원인 규명, 환자 맞춤형 정밀의료 진단·치료 기술개발 및 신약 개발에 활용
- 한국인 호발 질환에 대한 유전체 기반 연구를 통해 한국인 맞춤형 정밀의료 기술 개발에 활용
 - 한국인 맞춤형 정밀의료 실현을 위해서는 대규모 한국인 바이오 빅데이터 기반 표준 유전체 및 변이체 정보 필요
- 국가 차원에서 구축된 바이오 빅데이터 및 플랫폼의 제공을 통하여 다양한 국내 연구자들의 정밀의료 연구 활성화 및 연구데이터 공유에 활용
- 연구 결과를 임상이가 쉽게 활용할 수 있는 형태로 제공하여 환자의 진료·치료에 활용

□ 유전체 데이터 분석 장비 및 소프트웨어 국산화

- 해외에 의존하는 유전체 데이터 분석 관련 소재·부품·장비 및 소프트웨어 국산화 지원
- 임상정보 및 유전체 데이터를 활용한 신약 및 의료기기 제품 개발
 - 범부처전주기의료기기연구개발('20-'25), 국가신약개발사업('21-'30) 등의 타 사업과의 연계성을 통한 효과성 제고
- 데이터 품질 고도화 및 산업적 활용 표준화 지원 체계 구축
- 비식별화 임상정보·개인건강정보와 연계한 디지털 헬스기기 및 관련 서비스 확산

□ 위탁 과제별 활용방안

- (1위탁 연구과제) 대규모 전장유전체 데이터의 효율적인 처리를 위한 알고리즘 구축

- 본 과제에서 도출되는 각종 알고리즘은 1세부에서 수행하게 될 바이오 빅데이터 구축 및 활용체계 마련 중 유전체 데이터의 효율적인 분석파이프라인 구축. 결국 유전체 데이터 확보와 분석, 관리, 활용에 사용 되었음
- 본 과제의 결과를 통하여 희귀, 선도사업의 유전체 데이터 확보와 데이터, 검체 연계하여 유전체-임상 연계를 도우며 유전체 분석 파이프라인 표준화 및 구축을 완료하였으며, 시범사업 이후 (100만명 규모) 본 사업 유전체 분석 빅데이터 구축 사업 기획에 대응 가능할 플랫폼을 지원함

○ (2위탁 연구과제) 국가 바이오 빅데이터 구축 시범사업을 위한 일반인 전장 유전체 데이터 생산

가. 기 생산된 바이오 빅데이터와 연계·통합 분석을 통한 한국인 집단 게놈분석 고도화

- 한국인 게놈 빅데이터를 활용한 정상인의 유전적 다형성을 바탕으로 게놈 기반의 인간의 다양성 및 비질병적 특성 해석 근거 확보
- 다양한 표현형 분석을 위해 게놈 빅데이터 정보융합 활용연구 지원
- 대규모 게놈을 동시에 저장, 처리, 고급분석하는 기술력 제고
- 한국인 바이오 빅데이터를 활용한 질병진단 및 유전자 편집 등 게놈 응용기술 개발을 위한 상용화(원천) 연구 수행

나. 신규 구축한 게놈 빅데이터를 KOREF/KoVariome 정보에 추가하여 다각도의 데이터 분석, 한국인 게놈 정보 고도화 및 표준게놈 정보를 국가적으로 제공

- 초장서열 데이터를 활용한 초정밀, 고효율 한국인 표준게놈 조립
- 최신 게놈 해독기술을 이용하여, 한국인 게놈 구조변이(SV, CNV*) 정보 확보
- 한국인 시료의 전장 게놈, 오믹스 데이터 등의 통합분석을 통한 한국인 변이체 정확도 향상

다. 임상·전장유전체 데이터의 지능형 분석기술 개발

- 데이터 수집/저장 시스템 대용량 바이오 데이터를 효과적으로 수집·저장·정제 가능한 처리시스템 개발
- 전장게놈 고효율 병렬 처리 모듈 개발
- 분석 모듈/결과 시각화 시스템 개발
- 바이오 데이터를 쉽게 저장, 분석하기 위한 클라우드 및 포털분석 서비스
- 바이오 데이터 분석 결과 리포팅 시스템 개발

라. 인공지능 기술 기반 게놈 데이터 중심의 이종 데이터 분석 및 연합 활용 기술 개발

- 유전체 데이터 기반의 SNP 데이터를 활용한 바이오마커 후보군 탐색 및 생물학적 검증을 통해 질병 예측 시스템 개발
- 변수가 방대한 유전체 및 임상, 역학데이터에서 feature selection을 수행하며 이를 바이오마커로 활용하고 이를 고려하여 유전자 질병 위험 나이 계산

○ (3위탁 연구과제) 대장암 바이오 빅데이터 활용을 위한 임상유전체 데이터 연계 및 플랫폼 구축

- 유전체 데이터 및 임상정보를 통해 추후 여러 연구에서 질병의 기전을 제시하고, 새로운 개념의 치료제 개발의 후보물질 발굴과 차세대 치료 기술 개발의 기반을 제공함.
- 본 연구과제에서 생산된 전장유전체 데이터를 다양한 연구 분야와 연구자가 이용할 수 있게 함으로써 한국 의료·바이오 연구 활성화시킴.
- 국가적 차원에서 여러 질병에서 구축된 데이터를 통해 향후 다양한 연구에 기초 자료로 활용이 가능함.

○ **(4위탁 연구과제)** 자폐스펙트럼장애 전장유전체 연구를 위한 유전체-표현형 데이터 공유 인프라 구축

- 가. ASD 연구를 위한 임상자료와 유전체 자료를 연구자들에게 제공함으로써 병 발생 원인 메커니즘에 기반한 진단 체계 개발에 활용
- 나. 유전변이의 포괄적 규명이 가능한 자료를 제공하고, 변이에 매칭되는 임상정보를 제공함으로써, 향후 임상 진단 가이드라인 및 치료제 개발에 활용할 수 있는 과학적 근거를 제공함.
- 다. 향후 ASD의 치료제 개발 파이프라인에 개발 단계에서 전장유전체 정보, 임상적 및 병리학적 증상, 특정 치료에 대한 반응성 예측을 위한 지표자로서 활용이 가능함.
- 라. 영유아 시기에 ASD 가능성을 예측하는 가이드라인으로 활용하는 과학적 기반으로 활용

○ **(5위탁 연구과제)** 치매 바이오 빅데이터 활용을 위한 임상유전체 데이터 연계 및 데이터 보완

- 기 구축된 치매 임상·유전체 데이터를 바이오 빅데이터 구축 시범사업에 연계함으로써 바이오 빅데이터를 효과적으로 축적 확보
- 또한 연계된 데이터를 활용한 치매 예측 기술을 산업화한다면, 국가에 상관없이 세계적으로 확대되고 있는 인터넷 기반을 통해 전 세계 곳곳에 서비스 제공 가능
- 치매를 비롯하여 인지장애가 발병하는 과정을 신경과학적으로 이해함으로써 인지장애에 대한 진단기술과 치료법에 기여
- 정상 노화로 인한 인지기능 저하와 퇴행성 뇌질환의 차이점과 공통점을 규명하고 인지기능 저하의 뇌과학적 이해를 통해 노화로 인한 인지기능을 향상시킬 수 있는 개선 방법을 연구하는 데 기여

※ **연구개발 결과의 기대효과**

구분	기대 효과
----	-------

기술적 측면	○ 고령화로 인한 인지기능 저하에 대한 신경생물학적 원리 규명 및 이해 증진 ○ 첨단 뇌영상 분석기술의 국산화와 인프라 구축은 걸음마 단계에 머물고 있는 국내 인지신경과학 분야의 연구 활성화에 크게 기여 ○ 치매를 비롯한 각종 뇌질환의 조기 진단에 적용할 수 있는 핵심적인 플랫폼의 개발을 통해 국내 진단 의학계의 획기적 발전 도모 ○ BT(뇌과학)와 IT(컴퓨터 기술)을 접목한 본 기술은 산학/학제간 융합 연구의 모범사례로서 이를 통한 융합형 인재 양성에 기여
경제적 산업적 측면	○ 치매예측과 조기진단은 퇴행성 뇌질환에 대한 체계적인 관리를 가능하게 하여 개인과 사회가 부담해야할 막대한 비용을 경감시킬 수 있음 ○ 치매환자의 진료 및 치료에 들어가는 연 1조원의 막대한 재정적 부담을 조기진단관리를 통해 경감 ○ 뇌영상기반 치매예측 및 분석기술은 21세기 고령화 사회의 삶의 질 향상에 크게 기여 ○ 치매노인의 부양 가족은 경제적·신체적·심리적·사회적으로 큰 고통을 받음 ○ 조기진단을 통한 치매 예방은 노인뿐만 아니라 가족 전체의 행복과 삶의 질에 크게 기여 가능 ○ 첨단 뇌영상 분석기술을 통한 치매 예측 시스템 개발은 전 세계를 대상으로 한 의료시장에 막대한 경제적 부가가치를 창출할 수 있음

○ (6위탁 연구과제) 폐암 바이오 빅데이터 활용을 위한 임상유전체 데이터 연계 및 플랫폼 구축

- 미국 NCI와의 국제 공동협력을 기반으로 미국 및 다른 나라의 폐암환자 데이터와의 비교 분석을 통한 한국인 특이적인 폐암 진단·치료 기술 기반 확립
- 치료타겟 유전자 변이가 없는 비흡연폐암 특이적인 체세포 변이 시그니처 발굴 및 검증을 통한 신규 치료타겟 발굴 또는 치료 가이드라인 확립
 - 비흡연 폐암 연구 및 치료제 개발을 위한 한국인 비흡연 폐암 유전체 정보 구축으로 한국인에 맞는 비흡연 폐암 진단 및 치료 타겟 발굴
- 신규 폐암 치료표적 유전자 및 내성마커 활용 폐암(병용)치료 기술 확립
 - 비흡연 폐암의 신규 치료타겟 발굴 및 투약조건 판단 등의 각종 의료개발연구에 활용
- 면역치료제 등의 반응성을 예측하고 최적의 치료 요법을 제시함으로써 비흡연폐암 환자 생존률 향상
 - 비흡연성 폐암 환자의 항암 내성 원인 규명 및 효율적 병용 치료법 개발에 의한 비흡연 폐암환자의 항암 내성 극복에 활용
- 비흡연폐암 환자를 진단할 수 있는 분자진단키트 개발로 기존의 진단방법을 대체 혹은 보조
 - 폐암 표준치료로 치료되기 어려운 비흡연 폐암 환자에게 비흡연폐암 특이적인 체세포 변이 정보를 활용하여 진단 및 치료의 효율을 극대화

(별첨) 평가의견에 대한 수정 · 보완 대비표

평가의견 (수정 및 보완사항)	수정 및 보완 내용	해당 페이지	비고
○ 2만 5천 명 시범 사업 데이터 추가 분석을 통해 이 데이터 사업이 어떤 측면에서 의미가 있는가 하는 것을 보여 줄 수 있는 결과가 필요하다고 생각함. 빅데이터의 생산이 국민 건강 증진에 어떻게 기여할 수 있는가 하는 측면에 대한 고민 더 필요하다고 생각함.	○ 선도사업의 경우, 국가적으로 건강보험 및 의료비 지출이 큰 질환(대장암 · 폐암 · 치매 · 자폐증)에 대한 포괄적인 데이터를 연계하여 외부 연구자들에게 제공함으로써, 향후 의료비 경감을 위한 정밀의료 연구에 기여할 수 있음을 서술 ○ 또한 선도사업 중, 일반인 데이터(울산만명 · KoGES)가 지닌 다양한 유전형 · 표현형 스펙트럼을 이해함으로써, 이를 바탕으로 질환의 조기 진단 연구 등을 수행함에 있어 표준참조데이터로 활용될 수 있음을	p.96	

	서술		
○ 각 세부 간의 유기적인 연계에 대한 추가적인 설명이 필요해 보임.	○ 출연금 사업(1~4세부) 및 질병청 사업의 과업을 전체 사업 운영 절차와 함께 설명하는 것으로 보완하였음	p.5~7	
○ 다양하고 복합적인 형태의 데이터를 수집하고 제공할 필요도 있음.	○ 각 선도사업 코호트 별로 데이터의 연구 활용성 제고를 위해 다양하고 복합적인 형태의 임상정보를 연계하여 시범사업에서 제공	p.22	
○ 2만 5천명의 유전체의 빅데이터를 분석하고 구축한 후 어떻게 효과적으로 활용하여 정밀의료에 이용되어 국민건강에 이용할 수 있을것인지에 대한 방향과 구체적인 접근에 대한 고민이 필요할것으로 판단됨. 연구과제에서 수행한 대장암, 폐암, 치매, 희귀질환을 선택한 근거가 다소 미흡함.	○ 선도사업의 경우, 국가적으로 건강보험 및 의료비 지출이 큰 질환(대장암·폐암·치매·자폐증)에 대한 포괄적인 데이터를 연계하여 외부 연구자들에게 제공함으로써, 향후 의료비 경감을 위한 정밀의료 연구에 기여할 수 있음을 서술 ○ 또한 선도사업 중, 일반인 데이터(울산만명·KoGES)가 지닌 다양한 유전형·표현형 스펙트럼을 이해함으로써, 이를 바탕으로 질환의 조기 진단 연구 등을 수행함에 있어 표준참조데이터로 활용될 수 있음을 서술 ○ 희귀질환의 경우, '19.4.25 과학기술관계장관회의에서 단기 성과(시범사업 단계) 창출이 용이한 희귀질환을 데이터 구축 대상으로 결정 ○ 유전체 보유 선도사업(대장암·폐암·자폐증·치매·일반인)의 경우, 제5차, 제11차 추진위원회에서 사전 현황조사 및 공모 절차를 통해 선정	p.5, p.10~19, p.96	

[뒷면지]

주 의

1. 이 보고서는 보건복지부, 과학기술정보통신부, 산업통상자원부에서 시행한 원천기술개발사업 국가바이오빅데이터구축시범사업 최종보고서이다.
2. 이 연구개발내용을 대외적으로 발표할 때에는 반드시 보건복지부, 과학기술정보통신부, 산업통상자원부(한국연구재단)에서 시행한 국가바이오빅데이터구축시범사업의 결과임을 밝혀야 한다.
3. 국가과학기술 기밀 유지에 필요한 내용은 대외적으로 발표 또는 공개하여서는 안 된다.