

제목: 소아 발달장애 멀티모달 뇌영상과 유전·대사체 및 행동표현형의 대규모 AI 파운데이션 모델
적용과 임상경과 바이오마커 발굴과 검증

Large-scale AI Foundation Model Approach to Brain Images, Genomics, Metabolomics, and
Behavioral Phenotypes in Developmental Disability for Discovery and Verification of Clinical Progress
Biomarkers

W

1. 최종 목표 및 내용

● 최종 목표 내용(1333 characters):

- 배경: 발달장애 아동의 수의 증가로 사회적 비용이 증가하고 있으나, 복합적인 특성을 지닌 발달장애의 진단에 다중 데이터를 효과적으로 통합, 이용하는 분석법이 부재함.
- 본 연구는 발달장애를 조기에 진단하고 임상 경과를 예측할 수 있는 바이오마커를 발굴하기 위해 멀티모달 뇌영상, 오믹스, 영상 기반 행동 데이터 등의 다중 데이터를 통합할 수 있는 AI 모델의 개발하는 것을 최종 목표로 함.
- 이를 위해 발달장애 아동을 대상으로 임상, 바이오 및 디지털 빅데이터를 수집·정제·표준화하여 고품질 멀티모달 데이터 기반 글로벌 플랫폼을 구축할 것임.
- 또한 대규모 공공 텍스트-이미지 데이터 기반의 파운데이션 모델을 적극적으로 활용하고, 뇌발달장애의 멀티모달 데이터의 특성에 맞는 최적의 AI 방법론을 개발하여 적용할 것임(연합모델, 샘플 효율적 학습 및 최적화 알고리즘, 불확실성 정량화 방법).

- 연구개발 내용(1333 characters):

- 뇌영상, 오믹스, 행동표현형, 임상 데이터를 수집·정제·표준화 하여 고품질 멀티모달 데이터 기반 플랫폼 구축, 바이오마커 후보군 제시
 - 고품질의 소아 발달장애 바이오메디컬 빅데이터 구출을 위한 멀티모달 데이터 정의, 수집
 - 멀티모달 뇌영상 데이터 수집, 정제, 표준화
 - 유전체 및 타겟 질환 동물모델 데이터 탐색 및 수집
 - 영상 기반 행동 데이터 큐레이션 및 표준 데이터 관리 시스템 구축
 - 소아 발달장애 바이오메디컬 빅데이터 품질 관리 및 국내외 데이터 공유 플랫폼으로의 확장
 - 멀티모달 뇌영상, 오믹스, 영상 기반 행동데이터로부터의 후보 바이오마커 제시(기존 데이터 기반 AI 모델링 및 바이오인포매틱스)
- 대규모 파운데이션 모델 기반의 뇌영상, 오믹스, 행동표현형, 임상 데이터의 통합 AI 모델 개발, 이를 통한 발달장애 조기 진단과 임상 경과 예측을 위한 바이오마커의 발굴 및 실증적 검증
 - 정제된 데이터를 활용하여 발달장애 분류 및 진단을 위한 뇌영상, 오믹스, 행동 데이터의 모달리티별 AI 모델 개발
 - 대규모 파운데이션 AI 모델을 이용한 뇌영상-오믹스-행동 비디오-임상평가 기반 발달장애 모델 개발
 - 전향적 코호트 데이터의 추가적 수집 및 바이오마커의 임상유효성 평가 준비
 - 개발된 예측/진단 응용 AI 모델 및 바이오마커의 임상적 유용성 확인
 - 개발된 AI 모델의 공개를 통한 발달장애 바이오마커 검증 후속 연구 장려

- 연구개발 성과 및 활용 계획 및 기대 효과(1333 characters):

- 신규 바이오마커 및 AI 모델을 활용한 새로운 임상 연구 촉진
 - 발견된 신규 바이오마커와 AI 모델을 이용한 장기 추적 임상경과 반영 및 뇌구조와 임상적 특성에 따른 예측 활용
 - 다양한 모달리티의 바이오뱅크 데이터 수집을 통한 발달 지연의 복합적 메커니즘 연구 촉진

- 시계열 임상평가 결과와 유전체, 대사체 데이터 분석을 통한 임상적 경과 반영 및 어린 연령에서의 정확한 진단 가능성 제공
- 웹 기반의 발달장애 아동 바이오뱅크 데이터 및 연구 결과 카탈로그 시스템 구축
 - 뇌이미징, 오믹스, 행동 영상 데이터를 포함한 연구 결과의 시각화 및 웹 기반 카탈로그 시스템 구축
 - 시스템을 통한 연구자들의 새로운 연구 디자인 지원, 데이터 효과적 활용 촉진, 새로운 지식의 축적 및 연구 탐색 촉진
- 고품질 데이터 수집 도구의 개발 및 배포
 - 고품질의 데이터 수집 도구 개발 및 다른 연구 기관이나 병원에서의 사용 가능성 제공
 - 데이터 품질 관리 기준 설정을 통한 연구 결과의 정확도 향상 및 데이터 관리의 자동화와 효율성 증대
- 향상된 데이터 분석 및 활용 교육 프로그램 개발
 - 데이터 관리 및 분석 기술 교육 프로그램 개발을 통한 연구자와 의료 전문가들의 연구 데이터 효과적 활용 지원
 - 프로그램을 통한 참가자들의 데이터 분석 도구 직접 사용 학습 및 실제 임상 상황에서의 적용 방법 학습 제공

2. 단계별 목표 및 내용

1단계

- 최종 목표 내용(1333 characters):
 - 뇌영상, 오믹스, 행동표현형, 임상 데이터를 수집, 정제, 표준화, 공개하고, 고품질 멀티모달 데이터 기반 플랫폼 구축, 바이오마커 후보군 제시
- 연구개발 내용(1333 characters):
 - 1년차: 플랫폼 구축 및 AI 모델 개발을 위한 멀티모달 데이터 수집, 정제, 그리고 표준화
 - 목표 1-1: 고품질의 소아 발달장애 바이오메디컬 빅데이터 구축을 위한 멀티모달 데이터 정의, 수집

- 세부목표 1-1-1: 국내외 공공데이터 탐색 및 선행 연구 등을 통한 플랫폼 구축 대상 멀티모달 데이터군 정의 및 단위 확립과 기존 공공데이터에 수가 부족하거나 없는 데이터에 대한 다기관 다시점 후향적 멀티모달 데이터 변수 단위 설정 및 수집
- 세부목표 1-1-2: 데이터 수집 및 제공을 위한 IRB/DRB 승인
- 세부목표 1-1-3: 2단계 임상적 유효성 검증 및 융합 모델 개발을 위한 전향적 코호트 데이터 수집을 위한 프로토콜 설계와 수행 시작
- 목표 1-2: 멀티모달 뇌영상 데이터 수집, 정제, 표준화
 - 세부목표 1-2-1: 구조, 확산, 기능 뇌영상 데이터 수집 및 큐레이션
 - 세부목표 1-2-2: 정량적 자화율 매핑(Quantative Susceptibility Maps 및 χ -separation) 뇌영상 데이터 수집, 정제, 표준화
- 목표 1-3: 유전체 및 타겟 질환 동물모델 데이터 탐색 및 수집
 - 세부목표 1-3-1: 발달장애 아동의 인체 유래물 수집 및 유전체 데이터 정제
 - 세부목표 1-3-2: 타겟 질환 동물모델 구축 및 선행연구 탐색과 분석목표 수립
- 목표 1-4: 영상 기반 행동 데이터 큐레이션 및 표준 데이터 관리 시스템 구축
 - 세부목표 1-4-1: 행동 비디오 데이터 수집을 위한 인프라 및 표준 데이터 관리 시스템 설계
 - 세부목표 1-4-2: 표준 데이터 관리 시스템 및 프로토콜 구축 및 소아 발달장애 데이터베이스 구축을 위한 데이터 수집
 - 세부목표 1-4-3: 표준 데이터 관리 시스템 검증 및 도입, 소아 발달장애 데이터 베이스 구축을 위한 데이터 정제 및 가공
- 2년차: 멀티모달 데이터 수집 지속 및 병인 기전과 바이오마커 후보군 제시
 - 목표 2-1: 소아 발달장애 바이오메디컬 빅데이터 품질 관리 및 국내외 데이터 공유 플랫폼으로의 확장
 - 세부목표 2-1-1: K-BDS 플랫폼과 동기화된 표준 데이터 관리 인프라 및 통합 발달장애 데이터베이스 구축과 이를 기반으로 한 지속적인 AI 모델 업데이트 인프라 구축
 - 세부목표 2-1-2: 글로벌 뇌과학 플랫폼(brainlife.io)에 데이터 공유
 - 세부목표 2-1-3: 소아발달 바이오뱅크 벤치마크 및 카탈로그 시스템 구축을

통한 연구생태계 활성화

- 목표 2-2: 멀티모달 뇌영상, 오믹스, 영상 기반 행동데이터로부터의 후보 바이오마커 제시(기존 데이터 기반 AI 모델링 및 바이오인포매틱스)
 - 세부목표 2-2-1: 바이오마커 후보군과 병인 기전에 대한 임상적 자문
 - 세부목표 2-2-2: 공공 뇌영상데이터 기반 멀티모달 뇌영상 “사전 학습” AI 모델 개발
 - 세부목표 2-2-3: 공공 imaging-omics 데이터 정량화마커 기반 발달장애 위험 계산모델 개발
 - 세부목표 2-2-4: 공공데이터와 생물정보학분석모듈을 이용한 자폐스펙트럼 관련 유전자 제시
 - 세부목표 2-2-5: 동물모델의 장내 미생물 유래 대사체 및 인체유래물 데이터 분석 기반 바이오마커 후보군 도출

2단계

- 최종 목표 내용(1333 characters):
 - 대규모 파운데이션 모델 기반의 뇌영상, 오믹스, 행동표현형, 임상 데이터의 통합 AI 모델 개발, 이를 통한 발달장애 조기 진단과 임상 경과 예측을 위한 바이오마커의 발굴 및 실증적 검증
- 연구개발 내용(1333 characters):
 - 3년차: 멀티모달 데이터 수집 지속 및 바이오마커 발굴에 따른 동물모델에서의 유효성 검증 및 응용 AI 모델 사용성 평가
 - 목표 3-1: 정제된 데이터를 활용하여 발달장애 분류 및 진단을 위한 뇌영상, 오믹스, 행동 데이터의 모달리티별 AI 모델 개발
 - 세부목표 3-1-1: 구조 및 자화 매핑 뇌영상과 임상 데이터를 사용한 멀티모달 AI 모델의 개발
 - 세부목표 3-1-2: 점진적 학습 패러다임을 적용한 멀티모달 뇌영상-언어 AI 모델
 - 세부목표 3-1-3: LLM을 활용한 멀티오믹스-언어 멀티모달 AI 모델의 개발
 - 세부목표 3-1-4: 멀티오믹스 기반의 자폐스펙트럼 예후 및 치료효과 관련

유전자 규명

- 세부목표 3-1-5: 행동동영상데이터를 이용한 발달장애 분류 모델 개발
- 목표 3-2: 대규모 파운데이션 AI 모델을 이용한 뇌영상-오믹스-행동 비디오-임상평가 기반 발달장애 모델 개발
 - 세부목표 3-2-1: 뇌영상-오믹스-행동비디오-임상평가 멀티모달 AI 모델 개발
 - 세부목표 3-2-2: 멀티모달 데이터에서의 샘플 효율적 학습과 불확실성 정량화 AI 방법론 개발
 - 세부목표 3-2-3: 다기관 데이터 연합학습 AI 모델 개발
- 목표 3-3: 전향적 코호트 데이터의 추가적 수집 및 바이오마커의 임상유효성 평가 준비
 - 세부목표 3-3-1: 전향적 코호트 데이터 지속적 수집
 - 세부목표 3-3-2: 진단·예측 응용 AI 모델의 임상현장 사용성 평가
 - 세부목표 3-3-3: 바이오마커의 실증 및 임상유효성 평가를 위한 IRB 승인
 - 세부목표 3-3-4: 바이오마커의 확립과 동물모델 적용을 통한 검증
- 4년차: 바이오메디컬 빅데이터 기반 응용 AI 모델의 예측력 검증, 임상적 유용성 확인 및 AI 모델 공개
 - 목표 4-1: 개발된 예측/진단 응용 AI 모델 및 바이오마커의 임상적 유용성 확인
 - 세부목표 4-1-1: 뇌영상-오믹스-행동비디오-임상평가 멀티모달 AI 모델의 임상적 유용성 검증
 - 세부목표 4-1-2: 신규 바이오마커 및 AI 솔루션의 다기관 실증 및 유효성 평가
 - 세부목표 4-1-3: 다양한 중재치료(집중재활치료, rTMS, 약물치료 등)에 따른 효능이 도출된 바이오마커에 의해 입증되는지 검증
 - 목표 4-2: 개발된 AI 모델의 공개를 통한 발달장애 바이오마커 검증 후속 연구 장려
 - 세부목표 4-2-1: 글로벌 플랫폼에 개발된 응용 AI 모델 공개

본문1 연구개발계획서 PART2(작성서식)

0. 연구개발기관 현황

가. 공동연구개발기관 등 현황

공동연구개발기관	기관명	책임자	직위	휴대전화	전자우편	참여연구 기관	기관유형
주관연구개발기관	서울대학교 산학협력단	차지욱	교수	010-2575 -7188	connectome@s nu.ac.kr	24.07~ 27.12	비영리기관 (대학)
공동연구개발기관1	차의과학대학교 분당차병원	김민영	교수	010-5318 -3697	kmin@cha.ac.kr	24.07~ 27.12	비영리기관 (병원)
공동연구개발기관2	루먼랩 주식회사	임재현	대표이사	010-2615 -9006	jhlim@lumanla b.com	24.07~ 27.12	영리기관

나. 연구개발기관 일반 현황

1) 비영리기관 현황

순번	해당 기관명	서울대학교 산학협력단	차의과학대학교 분당차병원
1	사업자등록번호	119-82-03684	129-82-03681
2	법인등록번호	114371-0009224	114633-0005169
3	대표자 성명/국적	김재영 / 대한민국	김춘복 / 대한민국
4	기관 유형 (대학, 정부출연연, 중소기업 등)	대학	병원

2) 기업 현황

	수행 기관명		루먼랩 주식회사	
	구분			
①	사업자등록번호		136-86-02126	
②	법인등록번호		110111-7974151	
③	대표자 성명		임재현	
	대표자 국적		대한민국	
	대표자 성별		남	
④	최대 주주 성명		임재현	
	최대 주주 국적		대한민국	
⑤	기업(기관) 유형 (중소기업, 중견기업, 대기업)		중소기업	
⑥	설립 연월일		2021.07.30	
⑦	주생산 품목		소프트웨어	
⑧	상시 종업원 수		7	
⑨	전년도 매출액(백만 원)		15.74	
⑩	매출액 대비 연구 개발비 비율		1.46	
⑪	부채 비율	2023년	719.85	
		2022년	17.73	
⑫	유동 비율	2023년	101.77	
		2022년	598.26	
⑬	자본 잠식 현황	자본 총계 (백만 원)	2023년	150.42
			2022년	1,934.846
		자본금 (백만 원)	2023년	641.29
			2022년	4.933
⑭	이자 보상 비율		2023년	-8,437.19
			2022년	0
⑮	영업 이익 (백만 원)		2023년	-1,791.47
			2022년	-1,199.16
⑯	주소(구 까지)			세종특별자치시
⑰	수행 기관별 실무 담당자	성명		이인선
		부서/직위		연구원
		사무실 전화		-
		휴대전화		010-9926-1294

		팩스번호	-
		E-mail	islee@lumanlab.com

〈 목 차 〉

1. 연구개발의 필요성	2
2. 연구개발과제의 목표	30
3. 연구개발과제의 내용, 추진체계 및 일정	44
4. 연구개발 성과의 활용 방안 및 기대효과	203
5. 연구수행 역량	208
6. 연구개발비 사용에 관한 계획	246
7. 연구개발성과의 사업화 전략 및 계획	253
첨부1 [필수] 연구책임자의 대표적 연구실적 증빙자료	262
첨부2 [해당 시] 연구장비도입 심의요청서	
첨부3 [협약 시] 안전관리 계획 등	
첨부4 [협약 시] [해당 시] 청년 의무채용 관련 계획	
첨부5 [협약 시] 평가의견에 대한 수정·보완 대비표	
첨부6 [해당 시] 영리기관의 연구실운영비 활용·관리계획	

1. 연구개발의 필요성

- 1-1. 발달장애의 국내외 현황 및 연구 개발의 필요성
- 1-2. 발달장애 연구의 한계점 및 멀티모달 바이오뱅크 구축의 필요성
- 1-3. 통합적 데이터 처리를 위한 멀티모달 파운데이션 모델의 필요성
- 1-4. 멀티모달 AI 모델의 발달장애 적용에서의 한계 및 극복 방안

1-1. 발달장애의 국내외 현황 및 연구 개발의 필요성

1. 발달장애 임상현장 현황

- 발달장애의 임상적 분류
 - 전반적 발달지연(Global developmental delay, GDD)은 5세 미만의 아동에서 운동, 언어, 인지, 사회성, 자조의 다섯 가지 영역 중 두 가지 이상의 영역에서 동일연령 내 -2 표준편차 미만의 현저한 지연을 보일 때로 정의됨. 세계적으로 1~3%의 유병률로 보고되고 있으며, 많은 경우 그 이후에도 기능 수행능력이 저조한 상태의 장애를 가지고 살아가게 되며 조기 치료로 호전될 가능성이 높아지므로, 주의 깊게 관찰하여 적절한 치료를 필요로 함.
 - 이들 중 사회적 상호작용이 결여되는 양상을 보이는 아동들은 자폐증(autism) 또는 자폐 스펙트럼 장애(Autism spectrum disorder, ASD)의 범주로 분류되며, 인지 능력이 저하되는 경우 5세 이상부터는 지적 장애(intellectual disability; ID)로 분류하고 있음. 이들은 대부분 5세 미만의 나이에서는 GDD로 진단되었던 경우들임¹.

¹ Moeschler, J. B., Shevell, M., Committee on Genetics, Moeschler, J. B., Shevell, M., Saul, R. A., et al(2014). Comprehensive

- 국내 발달장애 임상현황




그림2. 국내 영유아 검진시 발달사항 평가결과

- 국내에서는 2007년부터 시작한 영유아 검진 사업 안에 발달 선별 검사인 Korean developmental screening test(K-DST)를 도입하여 발달 지연이 의심되는 아동들을 조기에 발견해내고자 노력하고 있음. 영유아 검진에서 발달 선별 검사 진행 후 ‘심화평가 권고’를 받은 아동들은 해마다 증가 추세를 보이고 있는데, 최근 2022년에는 발달 관련 평가를 받은 영유아 중 202,801명(11.8%)이 추적 검사를 받아볼 것을 권고 받았고, 53,021명(3.1%)이 ‘심화평가 권고’를 받았다는 사실이 2023년 국민건강보험공단에 의해 발표됨. 영유아 검진 중 추적검사나 ‘심화평가’가 권고될 경우 발달장애인으로 고정될 가능성이 높아 상급 병원에서의 추가 정밀 검사 및 치료가 필요할 수 있음.




그림 3. 국내 발달장애인 추이

- 보건복지부에서 발표한 2022년 발달장애인 실태 조사에 따르면 등록된 발달장애인은 26만 3천 209명으로 매년 지속적으로 7-8천명씩 증가하는 추세임. 그 중 지적 장애인은 약 22만 6천명(85.7%), 자폐성 장애인은 약 3만 7천명(14.3%)이었음². 진단을 받는 시기는 치료가 필요한 시기에 비해 대체적으로 늦은 것으로 나타났음. 자폐성 장애는 평균 3.1세에 의심증세의 발현이 발견되고, 1.5년 후인 4.6세에 진단을, 7.1세에 등록을 하는 것으로 나타났고, 지적 장애는 평균 7.9세에 발견되어 4.9년 후인 12.8세에 진단을 받고, 평균 19.3세가 되어서야 장애 등록이 이루어졌음³.

- 초기 진단의 필요성 및 초기 진단의 어려움

- 아동 발달장애는 일생에 걸쳐 지속되며, 보건 사회 연구소 조사에 따르면 환자 1인당 평생손실액이 3.5억원, 부모 작업손실액은 1조 6천억 원임.
- 조기 중재의 효과가 분명한⁴에 대한 ASD 보고가 증가됨에 따라 ASD 및 ID

² 보건복지부, 2023

³ 보건복지부, 2022

⁴ Matson, J. L., & Sipes, M.(2010). Methods of early diagnosis and tracking for autism and pervasive developmental disorder not otherwise specified(PDDNOS).Journal of Developmental and Physical Disabilities, 22, 343-358.

아동들에 대해 어린 나이에 정확한 상태를 파악할 필요에 대한 인식이 높아지고 있음. 즉, 무엇보다 정확한 조기 진단이 중요함.

- 하지만 36개월 이전에는 그 양상이 뚜렷하게 구분되지 않고 모두 전반적 발달지연(GDD)의 양상을 띄는 경향이 있으며, 사회적 관계 형성과 행동의 이상 등으로 가정에 고통을 주는 ASD를 일찍부터 감별할 수 있는 진단 도구가 많지 않음. 실제로 만 16-30개월 아동에서 유효성 확인을 거쳐 사용 중인 도구인 Modified Checklist for Autism in Toddler(M-CHAT)는 연구에 따라 민감도(0.22-1.00) 및 특이도(0.27-1.00)의 범위가 매우 큰 양상을 보임⁵. 특히 18개월 경 시행하였을 때는 증상이 더 늦게 발현되거나 설문에 참여하는 부모의 자폐 증상에 대한 무지로 인해 선별에 실패하는 경우가 종종 있어 24개월 이후 재선별을 하는 것이 권고됨^{6 7}. Autism Diagnostic Observation Schedule-2 (ADOS-2) 역시 유아기에서 시행할 수 있는 검사 중 하나이지만 이 검사 역시도 지능이 낮거나, 불안, 과잉 및 충동행동 등이 동반될 경우 위양성으로 판별되는 비율이 높았으며(34%)⁸ 시간과 전문적 훈련을 받은 인력의 필요⁹, 고비용등의 단점에 따라 국내 의심 소아들에게 보편적으로 실시할 수 없음.
- 2021년 8월 대한소아청소년정신의학회의 조사에 따르면 전문의 진료 및 정밀한 심리평가, 치료 시설이 서울/경기관 집중(전체 중 약 60%)되어 있어 의료접근성에 한계가 있음.

⁵ Su, W., Culotta, M., Tsuzuki, D., & Bhat, A.(2022a). Cortical activation during cooperative joint actions and competition in children with and without an autism spectrum condition(ASC): An fNIRS study.Scientific Reports, 12(1), 5177.

⁶ Dai, Y. G., Miller, et al .(2020). Incremental utility of 24-month autism spectrum disorder screening after negative 18-month screening.Journal of Autism and Developmental Disorders, 50, 2030-2040.

⁷ Øien, R. A., et al(2018). Clinical features of children with autism who passed 18-month screening.Pediatrics, 141(6)

⁸ Greene, R. K., et al.(2022). Autism diagnostic observation schedule(ADOS-2) elevations in a clinical sample of children and adolescents who do not have autism: Phenotypic profiles of false positives.The Clinical Neuropsychologist, 36(5), 943-959.

⁹ Kamp-Becker, I., et al(2018). Diagnostic accuracy of the ADOS and ADOS-2 in clinical practice.European Child & Adolescent Psychiatry, 27, 1193-1207.

- 따라서 발달장애의 조기 진단이나 선별을 가능하게 하기 위한 기술 개발이 절실히 필요함.

2. 발달장애 소아의 진단을 위한 다면적 접근의 필요성

- 발달은 대동작, 소근육, 언어, 인지, 자조 및 사회적 능력 등 여러 영역을 아우르고 있으며 아동마다 개별적으로 지연을 보이는 영역이나 지연의 정도가 다양함. 단독 기능 손상으로 분류되지는 않으나 감각통합 발달도 환자의 특성에 관여하는 등, 임상에서는 각각의 기능에 대한 다면적 평가를 통하여 지연된 영역을 찾아 치료방침을 결정함¹⁰.
- 발달장애 아동 진단을 위한 다면적 기능을 파악하기 위하여 다면적 접근으로 아동의 행동을 평가하는 것이 필요하며, 이를 위한 평가에는 사회적 상호작용 행동과 돌발 행동 평가, 반구조화된 면접을 통한 적응기능 평가 등이 있음¹¹.
- 발달장애의 원인으로는 명확한 뇌손상과 같은 경우들도 있으나, 많은 GDD, ASD와 ID에서 쉽게 후천적인 원인을 찾지 못함¹². 10여년 전부터 유전학의 발달과 함께 선천적인 원인, 즉 염색체나 유전자 등의 이상이 발견되는 경우들이 증가하고 있음¹³. 또한, 뇌의 심한 구조적 변형은 드물게 관찰되고, 미세구조적 발달이상이 점차 더 밝혀지고 있음¹⁴. 그 외, 뇌파 등 뇌기능 이상, 지방대사 이상과 장내세균 이상 등 이들의 뇌기능 저하 상태와 연관된 연구 결과들이 증가하고 있는 추세임^{15 16 17}.

¹⁰ Mithyantha, R., et al.(2017). Current evidence-based recommendations on investigating children with global developmental delay.Archives of Disease in Childhood, 102(11), 1071-1076.

¹¹ Scahill, L.(2005). Diagnosis and evaluation of pervasive developmental disorders.Journal of Clinical Psychiatry, 66, 19.

¹² Thomaidis, L., et al (2014). Predictors of severity and outcome of global developmental delay without definitive etiologic yield: A prospective observational study. BMC Pediatrics.

¹³ Miller, D. T., et al (2010). Consensus statement: Chromosomal microarray is a first-tier clinical diagnostic test for individuals with developmental disabilities or congenital anomalies.The American Journal of Human Genetics.

¹⁴ DiPiero, M., et al. (2023). Applications of advanced diffusion MRI in early brain development: A comprehensive review.Brain Structure and Function.

¹⁵ Chernikova, M. A., et al.(2021). The brain-gut-microbiome system: Pathways and implications for autism spectrum disorder.Nutrients, 13(12), 4497.

¹⁶ Forsberg, H.(2019). Microbiome programming of brain development: Implications for neurodevelopmental disorders.Developmental Medicine & Child Neurology.

¹⁷ Su, W., et al (2023). The use of functional near-infrared spectroscopy in tracking neurodevelopmental trajectories in infants and children with or without developmental disorders: A systematic review. Frontiers in Psychiatry.

- 따라서, 발달장애아의 정확한 진단에는 아직 많은 어려움이 있으나 임상적으로 다면적인 평가를 주기적으로 추적 관찰해 가며 환자의 특성을 파악하는 일과 유전체 및 뇌영상과 아직 밝혀지지 않은 새로운 접근을 통한 진단 기술의 발전이 필요하다.

3. 발달장애 소아의 뇌영상 검사 관련현황

- 발달장애 환자 대상 뇌영상 검사 기법의 활용
 - 발달장애 아동의 뇌영상 검사 소견을 통해 뇌의 손상여부와 신경발달이상 등 원인을 추정하고, 아동의 재태기간, 임상 진단, 여러 임상 지표들과 뇌영상검사 소견의 상관관계를 분석함으로써, 특정 영역의 발달장애와 관련된 고유한 구조적 이상을 도출하기 위한 많은 시도가 이루어지고 있음.




그림 4. fNIRS를 이용한 발달장애 환자의 관심영역 별 뇌활성 패턴 및 정량적 측정

- 현재 발달장애를 진단하기 위한 뇌영상 검사 기법으로는 대표적으로
 뇌 구조 파악 : 자기공명영상검사(Magnetic Resonance Imaging; MRI),
 뇌기능 파악 : 기능적자기공명영상(Functional Magnetic Resonance Imaging; fMRI), 뇌파 검사(Electroencephalography; EEG)등이 사용되어 오고 있고, 비교적 최신 뇌영상 검사 기법인 기능적

근적외선분광분석법(Functional Near-Infrared Spectroscopy; fNIRS)는 발달장애의 임상연구 분야에서 그 활용이 증대되고 있음.




그림 5. 발달장애의 병인을 규명하기 위한 신경로 종류^{18, 19}

- 발달장애 대상 뇌구조와 기능을 파악하기 위한 연구의 국내외 현황
 - 발달장애 아동 대상 확산텐서영상 선행연구는 뇌병변을 동반한 아동들을 제외하고는 주로 ASD에 대한 연구가 이루어졌음. 특정 연령의 신경로 분석 결과 뇌량, 갈고리다발, 띠다발, 아래세로다발, 위세로다발과 같이 인지 혹은 심리 기능과 관련된 신경로들이 정상아와 비교하여 높은 분할비등방도(Fractional Anisotropy, FA)와 낮은 방사확산성(Radial Diffusivity, RD)가 나타남이 보고되었음²⁰. 더불어, 신경로 분석 지표를 머신러닝 기법에 활용하여 자폐를 구분하고자 한 연구에서 청소년기에서는 비교적 명백한 분류가 가능하지만, 영유아기에는 그 분류가 어려움을 보고함²¹.
 - ASD 아동 대상으로 뇌파 검사를 진행하여 휴식기의 알파 피크와 기능적

¹⁸ Ha, S., & Sung, Y.(2021). Changes of neural pathways after vojta approach in a child with developmental delay.Children, 8(10), 918.

¹⁹ Solso, S., et al. (2016). Diffusion tensor imaging provides evidence of possible axonal overconnectivity in frontal lobes in autism spectrum disorder toddlers.Biological Psychiatry, 79(8), 676-684.

²⁰ Muetzel, R. L., et al. (2018). Tracking brain development and dimensional psychiatric symptoms in children: A longitudinal population-based neuroimaging study.American Journal of Psychiatry, 175(1), 54-62.

²¹ Bahathiq, R. A., et al. (2022). Machine learning for autism spectrum disorder diagnosis using structural magnetic resonance imaging: Promising but challenging.Frontiers in Neuroinformatics, 16, 949926.

연결성을 측정하여 이에 따른 ASD를 구분하기 위한 연구가 진행되었음.
뇌파의 기능적 연결성을 통해 ASD의 구분이 가능하지만, 분류의 성능이 비교적 약한 것을 확인하였음²².

- 기능적 근적외선분광분석법(fNIRS)을 활용하여 ASD 및 정상 아동을 대상으로 게임 과제 수행 시 나타나는 피질 수준의 활성도를 측정하였을 때, ASD 아동들에서는 superior temporal sulcus에서 낮은 활성도를, inferior parietal lobe에서는 높은 활성도를 보이는 것으로 보고되었음²³. 위의 선행연구를 포함한 발달장애 아동에서 fNIRS를 활용한 연구들에서는 대상자의 수가 20명 수준으로 샘플 수가 매우 적었으며, 연령의 범위는 8세 이후로 특정 과제를 수행하는 동안 일부 관심 영역의 활성도만을 측정하는 등 제한적으로 임상특성을 파악하기 위한 접근만이 이루어졌음.
- GDD와 ID에 대한 뇌영상과 뇌파 등의 연구는 거의 찾아보기 어려움.
- 발달장애 대상 뇌영상 기법의 조기 진단 및 예후 예측을 위한 바이오마커 연구현황
 - EEG는 임상검사로서의 다양한 활용에도 불구하고, 검사 과정이 복잡하고, 그 과정에 전문적 기술을 요구한다는 점에서 발달장애 진단에 활용의 접근성이 떨어진다는 현실적인 문제가 있음.
 - fNIRS는 EEG에 비해 측정 방법이 간단하고 특정 과제를 수행하는 중의 뇌활동을 측정할 수 있다는 특징으로 인해 임상연구에서 많이 사용되어 오고 있으나²⁴, 분석에 전문 지식을 요구한다는 점에서 발달장애 아동 대상 임상현장에서의 다양한 활용이 어렵다는 한계점이 있음.

²² Guo, X., Zhai, G., Liu, J., Cao, Y., Zhang, X., Cui, D., & Gao, L. (2022). Inter-individual heterogeneity of functional brain networks in children with autism spectrum disorder. *Molecular Autism*, 13(1), 52.

²³ Su, W., Culotta, M., Tsuzuki, D., & Bhat, A. (2022b). Cortical activation during cooperative joint actions and competition in children with and without an autism spectrum condition(ASC): An fNIRS study. *Scientific Reports*, 12(1), 5177.

²⁴ Ferrari, M., & Quaresima, V. (2012). A brief review on the history of human functional near-infrared spectroscopy(fNIRS) development and fields of application. *NeuroImage*, 63(2), 921-935.

- 또한, 개인별 뇌활성 패턴의 이질성^{25 26}, 발달장애 기전의 다양성으로 인한 뇌활동 패턴의 복잡성^{27 28}, 선행 연구들에서의 비교적 적은 표본 크기^{29 30}로 인해 EEG와 fNIRS를 발달장애의 예후·예측 및 치료 효과 입증의 바이오마커로서 활용할 수 없다는 한계점이 있었음.
- 하지만, EEG, fNIRS가 가지고 있는 한계점에 대해 뇌의 해부학적 구조를 제공하는 MRI, 임상기능평가 등을 통한 멀티모달 데이터와의 연계를 통해 개인별 발달장애의 병인 기전 및 치료 효과에 대한 바이오마커 발굴이 가능할 것으로 제시되고 있음³¹.

4. 발달장애 대상 유전학 및 유전체 국내외 연구현황

- GDD, ASD, ID의 원인은 매우 다양하나 다운증후군, fragile X 증후군과 같은 유전적 원인과 더불어 태아 알코올 증후군, 신생아 시기의 감염성질환이나 독성물질에 노출 등의 환경적인 요인들이 잘 알려져 있음.
- 유전적 원인은 해당 환자의 약 50% 이상일 것으로 추정되나, 정확히 규명되지 못한 경우가 대부분임³².
- 환자들의 유전적 원인을 규명하기 위해서 염색체 핵형분석을 기초로 해서, 염색체 미세결실/중복 검사, FMR1, NLGN3/4, TSC1/2 등 연관성이 잘 알려진 일부

²⁵ Doi, H., & Shinohara, K.(2017). fNIRS studies on hemispheric asymmetry in atypical neural function in developmental disorders.Frontiers in Human Neuroscience, 11, 137.

²⁶ Luschekina, E. A., Luschekin, V. S., & Strelets, V. B.(2019). EEG spectral power in children with autistic spectrum disorders: Heterogeneity of the group.Human Physiology, 45, 242-248.

²⁷ Bosl, W., Tierney, A., Tager-Flusberg, H., & Nelson, C.(2011). EEG complexity as a biomarker for autism spectrum disorder risk.BMC Medicine, 9, 1-16.

²⁸ Gu, Y., Miao, S., Han, J., Zeng, K., Ouyang, G., Yang, J., & Li, X.(2017). Complexity analysis of fNIRS signals in ADHD children during working memory task.Scientific Reports, 7(1), 829.

²⁹ Bosl, W. J., Tager-Flusberg, H., & Nelson, C. A.(2018). EEG analytics for early detection of autism spectrum disorder: A data-driven approach.Scientific Reports, 8(1), 6828.

³⁰ Zhang, F., & Roeyers, H.(2019). Exploring brain functions in autism spectrum disorder: A systematic review on functional near-infrared spectroscopy(fNIRS) studies.International Journal of Psychophysiology, 137, 41-53.

³¹ Zhao, Y., Liu, Y., Gao, X., Wang, D., Wang, N., Xie, R., et al(2023). Early biomarkers of neurodevelopmental disorders in preterm infants: Protocol for a longitudinal cohort study.BMJ Open, 13(6), e070230.

³² Walker Jr, W. O., & Johnson, C. P.(2006). Mental retardation: Overview and diagnosis.Pediatrics in Review, 27(6), 204-212.

유전자들에 대한 염기서열 분석 등이 임상검사로써 시행되고 있으며, 분석기술이 발달함에 따라 2010년대 이후로는 chromosome microarray(CMA) 분석이 우선적으로 시행되고 있음³³.

- 최근에는 전체 게놈/엑솜 염기서열분석(whole genome/exome sequencing)을 통해서 많은 질환 유발 변이들이 연구되고 특정됨. 이런 연구들에 대한 메타분석(meta-analysis)을 통해서 미국 의학 유전 및 유전체 학회(American College of Medical Genetics and Genomics)에서는 선천성 기형, 발달지연 및 지적장애 소아에 대해서 전체 게놈/엑솜 염기서열분석을 우선적으로 시행할 것을 권고하고 있음³⁴.

- 특히, ASD의 유전적 관계성은 매우 복잡하고, 자폐와 관련되었다고 보고된 유전자는 지금까지만 해도 600~1,200개임. 전체 ASD 관련 유전자 중에서 5% 이하가 매우 치명적인 1개의 유전자(NLGN3, NLGN4, NRXN1, MECP2, SHANK3, FMR1, TSC1/2, UBE3A)로부터 발병하는 SNP를 지닌 것으로 알려져 있음³⁵. 약 10%는 유전자의 복제로 인한 단백질의 잘못된 접힘, 또는 chromosome 상의 비정상적인 반복서열, 제거 등이 원인이 됨. 특정 유전자의 돌연변이로 인한 발병은 세 번째 ASD 발병 유형으로 구분되고 있음. 지속적인 유전학의 발전과 더불어 유전적 원인의 발견이 계속 증가 중임.

³³ Miller, D. T., Adam, M. P., Aradhya, S., Biesecker, L. G., Brothman, A. R., Carter, N. P., et al(2010). Consensus statement: Chromosomal microarray is a first-tier clinical diagnostic test for individuals with developmental disabilities or congenital anomalies. The American Journal of Human Genetics, 86(5), 749-764.

³⁴ Manickam, K., McClain, M. R., Demmer, L. A., Biswas, S., Kearney, H. M., Malinowski, J., et al(2021). Exome and genome sequencing for pediatric patients with congenital anomalies or intellectual disability: An evidence-based clinical guideline of the american college of medical genetics and genomics(ACMG). Genetics in Medicine, 23(11), 2029-2037.

³⁵ Varghese, M., Keshav, N., Jacot-Descombes, S., Warda, T., Wicinski, B., Dickstein, D. L., et al(2017). Autism spectrum disorder: Neuropathology and animal models. Acta Neuropathologica, 134, 537-566.

5. 발달장애의 장-뇌 축 개요

- 초기 뇌발달에 장내미생물의 역할

- 균형이 잘 이루어진 건강한 장내 미생물구성(symbiosis)과 장내 미생물유래 대사체는 혈관-뇌 장벽(Blood-Brain Barrier; BBB)의 발달 및 구성, 시냅스 형성, 미세아교세포의 발달, 수초화등 초기 뇌 발달에 직접적인 역할을 수행함.

- 혈관-뇌 장벽(BBB)과 대사체

1. BBB는 자궁 내 태아에서부터 형성되어 발달하고 태아에서는 투과율이 높다가 성인이 되면서 투과율이 급격히 감소함. 무균 마우스의 경우 혈액뇌관문의 투과율이 성체가 되어도 접합단백질(junctional proteins)인 occludin, claudin-5이 충분히 발현되지 않고 감소 하지 않음.
2. 장내미생물 유래 대사체인 Butyrate(short-chain fatty acid; SCFA)를 무균 마우스에 처리하면 BBB의 투과률이 감소함.

- 신경세포생성(Neurogenesis)

1. 신경세포생성(Neurogenesis)은 신경줄기세포(Neural stem cell) 또는 신경전구세포(neuroprogenitor cell)로부터 신경세포로의 분화를 의미함. 해마(hippocampus)에서 신경세포생성의 감소는 학습과 기억장애, 우울증, 불안장애 등과 밀접하게 관련이 있음.
2. 직접적으로 항생제를 처리하거나 생애초기 스트레스 요인에 노출시켜 장내 미생물의 불균형을 유도한 마우스의 해마에서 신경세포생성이 감소한 소견을 보였음.

- 수초화(Myelination) 발달 및 유지

1. 축삭돌기의 수초화는 인지기능에 중요한 요소이며 신경세포 가소성(neuronal plasticity)의 결정적인 요소임. 사람의 경우 축삭돌기(axon)가 수초화 myelination)되지 않은 상태로 태어난 후 2-3년 내에 희소돌기신경교세포(oligodendrocyte)에 의해서 급속히 수초화가 진행됨.

2. 장내 미생물은 수초화에 관련된 유전자를 조절하여 수초화에 직접적으로 관여함. 항생제로 장내 미생물 불균형으로 유도한 마우스에 장내미생물 대사체인 Butyrate를 구강투여하여 행동장애, 수초화 발달장애 등을 일부 회복시킴.

○ 미세아교세포(Microglia) 발달

1. 미세아교세포는 뇌발달, 항상성유지 및 뇌질환에 중요한 역할을 하며 중추신경계에 상주하는 면역세포로 전체 신경교세포의 10-15%를 차지함.

2. 미세아교세포는 안정한 상태에서는 지속적으로 중추신경계의 유지를 위하여 각종 외부 병원성 물질 침입이나 스트레스에 대한 방어 작용을 함. 한편 과도한 미세아교세포의 활성화는 염증 반응을 유도하여 중추신경계에 부정적인 영향을 미치게 되어 뇌질환의 원인이 됨.

● 장내미생물과 발달장애

○ 발달장애에서 X선 영상과 장내미생물 활용 가능성

1. 정상적인 배변 과정은 자율신경계에 의한 장운동의 움직임 자극 또는

억제, 연동 운동과 곧창자의 괄약근 조임 기능을 거쳐 일어나며, 정상 발달 아동의 경우 18개월 경부터 배변 훈련을 시작할 수 있으며, 4세경이 되면 완전히 조절할 수가 있음.

2. 아동 변비 환자의 90% 이상은 기능성 변비임. 이는 Rome III 또는 IV criteria에 의해 진단 가능한 동시에³⁶, X선 검사를 통해서도 발견이 가능하고³⁷, 장내미생물 프로파일링을 통해서도 감별해낸 바 있음^{38 39}.
3. ASD(odd ratio 7.92)나 GDD 아동(odds ratio 4.55)에서는 정상 아동들에 비해 높은 빈도로 장 관련 문제들이 보고되고 있는데⁴⁰, ASD와 ID 뿐만 아니라 학습장애, 주의력결핍 과잉행동장애, 조현병 등 뇌발달장애를 갖고 있는 아동의 장내미생물군 다양성 감소, 불균형이 보고됨(그림 6).

³⁶ Vriesman, M. H., Koppen, I. J., Camilleri, M., Di Lorenzo, C., & Benninga, M. A.(2020). Management of functional constipation in children and adults.Nature Reviews Gastroenterology & Hepatology, 17(1), 21-39.

³⁷ Rodriguez, D. A., Dahlwi, G., Gould, M., Marcon, M., & Benninga, M.(2024). The diagnostic accuracy of abdominal X-ray in childhood constipation: A systematic review of the literature.Gastrointestinal Disorders, 6(1), 94-102.

³⁸ Avelar Rodriguez, D., Popov, J., Ratcliffe, E. M., & Toro Monjaraz, E. M.(2021). Functional constipation and the gut microbiome in children: Preclinical and clinical evidence.Frontiers in Pediatrics, 8, 595531.

³⁹ de Meij, T. G., de Groot, E. F., Eck, A., Budding, A. E., Kneepkens, C. F., Benninga, M. A., et al(2016). Characterization of microbiota in children with chronic functional constipation.PloS One, 11(10), e0164731.

⁴⁰ Chaidez, V., Hansen, R. L., & Hertz-Picciotto, I.(2014). Gastrointestinal problems in children with autism, developmental delays or typical development.Journal of Autism and Developmental Disorders, 44, 1117-1127.




그림 6. 발달장애 태아의 장내미생물군의 다양성 감소 및 불균형과 뇌 내 시냅스 변화와의 상관관계 규명 필요

4. 특히 ASD 아동의 46-85% 정도는 동반질환으로 변비 및 설사 등의 위장관질환으로 고통을 받는데⁴¹, 이들의 경우 정상적인 아동에 비해 유해균인 Firmicutes가 높고 유익균인 Bacteroidetes가 낮은 장내 미생물의 불균형을 보여, 질환과 장뇌축과 연관성이 있음을 보여줌⁴².
5. 추후 발달장애 아동들에서, 장내미생물 프로파일링과 X선 영상 지표를 함께 활용하여 진단을 세분화하는데 활용할 수 있을 것으로 판단됨.
 - 장내미생물 유도 대사체(Gut microbiota-derived metabolites)의 병태생리학적 연관성

1. 장내미생물 유도 대사산물의 수는 정확히 추정하기 어려우며 수 많은

⁴¹ Dovgan, K., Gynegrowski, K., & Ferguson, B. J.(2023). Bidirectional relationship between internalizing symptoms and gastrointestinal problems in youth with autism spectrum disorder.Journal of Autism and Developmental Disorders, 53(11), 4488-4494.

⁴² Song, Y., Liu, C., & Finegold, S. M.(2004). Real-time PCR quantitation of clostridia in feces of autistic children.Applied and Environmental Microbiology, 70(11), 6459-6465.

대사체의 생리학적 역할도 정확하게 규명되지 않았음. 특히 질환의 유병률과 직접적인 연관성이 있는 대사체의 병태생리학적 역할규명은 연구초기 단계임(그림 7).

2. 인체에서 일어나는 생화학적 매개체인 대사체를 연구함으로써 독특하고 동적인 세포 경로를 추적하고 질병 특이적인 경로를 차단하여 대사성질환뿐 아니라, ASD와 같이 발병시기와 진행의 시점이 중요한

질병의 진단에 기여할 수 있음.




그림 7. 장내 미생물유래 대사체 및 대사체의 생리적인 기능⁴³

3. 생화학적인 유전자들의 조절과 결과를 보여주는 대사체를 총체적으로 분석 연구하는 분야인 대사체 오믹스는 유전자형과 환경에 의해 조절된 결과로써 생겨나는 모든 대사물질의 발현을 유전체와 연관시켜 생명현상의 변화와 원인에 대한 정보를 제공할 수 있음 이미 당뇨 등 대사질환에서 혈액 등의 대사체 분석을 통해 대사질환의 마커를 발굴하고 진단한 바 있음⁴⁴

⁴³ Gong, Y., Chen, A., Zhang, G., Shen, Q., Zou, L., Li, J., . . . Liu, W.(2023). Cracking brain diseases from gut microbes-mediated metabolites for precise treatment.International

⁴⁴ Vrieling, F., Alisjahbana, B., Sahiratmadja, E., van Crevel, R., Harms, A. C., Hankemeier, T., . . . Joosten, S. A.(2019). Plasma

4. 특히, 환자의 식이 등의 환경에 따른 장내미생물군체의 구성 및 다양성의 변화는 발달장애, 퇴행성 뇌질환, 정신질환의 유병률이 증가한다는 보고가 있어 장내미생물 유도 대사체가 병태생리학적으로 작용한다는 것을 시사함(그림 8).




그림 8. 대사체 바이오마커와 질환의 이해

○ 뇌발달과 연관된 주요 대사체

1. p-Cresol/p-Cresyl Sulfate: Tyrosine-derivative로 ASD 장애아동의 소변에서 증가되어있음⁴⁵. 정상 마우스에게 4주 동안 물과 함께 p-Cresol를 먹인 경우, 자폐 장애 행동을 보이고 도파민 신경세포의 활성도가 저하되고 장내미생물의 불균형이 유도되었음⁴⁶. p-Cresol의 정확한 병태생리학적 기전은 아직 규명되지 않았음.

metabolomics in tuberculosis patients with and without concurrent type 2 diabetes at diagnosis and during antibiotic treatment. Scientific Reports, 9(1), 18669.

⁴⁵ De Angelis, M., Piccolo, M., Vannini, L., Siragusa, S., De Giacomo, A., Serrazanetti, D. I., et al(2013). Fecal microbiota and metabolome of children with autism and pervasive developmental disorder not otherwise specified. PloS One, 8(10), e76993.

⁴⁶ Bermudez-Martin, P., Becker, J. A., Caramello, N., Fernandez, S. P., Costa-Campos, R., Canaguier, J., . . . Dumas, M.(2021). The microbial metabolite p-cresol induces autistic-like behaviors in mice by remodeling the gut microbiota. Microbiome, 9, 1-23.

2. Short chain fatty acids(SCFA): 사람의 경우 SCFA는 장내미생물이 맹장(cecum), 결장(colon)에서식이섬유를 분해하여 만들어내는 물질로 Acetate, Propionate, Butyrate등 다양한 대사산물이 생산되고 장내에 고농도(1 uM)로 존재함. 체내에 Acetate가 가장 많이 존재하는 SCFA이지만, Butyrate가 장내에 매우 높은 농도로 존재하며 장막세포의 에너지로 쓰이며 신경가소성, 후성유전학, 유전자 발현, 미세아교세포 성숙에 관여함. 특히 ASD 장애아동의 경우 Propionate가 증가한 반면 Butyrate이 감소한 결과가 보고됨에 따라 장내미생물의 불균형에 의한 SCFA의 구성비율도 변성됨.
3. 5-aminovaleric acid(5-AVA), Taurine 등의 뇌발달에 영향을 주는 아미노산 대사산물이 보고되었으며 태생 전이나 태생 후 4주간 처리한 경우 ASD 장애 행동이 완화되는 결과가 보고됨.

1-2. 발달장애 연구의 한계점 및 멀티모달(multimodal) 바이오뱅크 구축의 필요성

1. 발달장애 대상 국내외 연구의 제한점 및 문제점

표 1. 발달장애 관련 국내 공공 데이터베이스			
데이터 종류	질환/명수	변수구성	연계 데이터
유전체	ASD	whole genome	행동,사회성 평가
	ASD(324명), 가족(568명)	sequencing	인지평가
뇌영상	우울 및 중독	MRI	심리평가(KSAD-COMP, KCDI)
	총 254명(7~12세)	fMRI	인지평가
	ASD, ADHD	뇌파	신체정보
	정상/ASD/ADHD 각 250명		진단명 및 중증도

- 이제까지 수집되어 공개된 DB들은 ASD에만 국한된 결과들이 대부분이고, 조기

치료가 가능한 GDD 단계에서의 연구는 없음.

- 또한, ID에 대한 데이터도 없으며, ASD와 ID를 동시에 유병된 경우가 약 70%로 보고되고 있으나^{47 48}, 두 진단을 구분하여 감별하는 것에 초점을 맞춘 연구 결과들은 없었음.
- 그리고, 다양한 임상적 경과를 순차적으로 볼 수 있는 결과들을 연계하여 보여준 연구가 없으며, 대부분 인지나 심리평가에 국한된 임상자료만 연계하였을 뿐 다면적 평가가 제대로 포함된 연구도 없었음.

2. 발달장애 대상 선행 뇌영상 연구의 한계점 및 과제

- 여러 발달장애 증상이 섞여 있는 소아의 특성상 임상 현장에서의 환아들의 운동, 인지, 심리 등 다양한 평가를 통한 다면적인 진단이 필수적이나, 기존 발달장애 대상 뇌영상/유전자/대사체 연구들은 발달장애의 특징을 파악하는 임상평가에 대한 연계가 부재하고, 뇌영상검사 결과 자체만을 해석하는데 그쳤다는 아쉬움이 있음.
- 발달장애에서의 특징적인 신경학적 변화를 확인하고 예후 예측을 위해서는 한 시점이 아닌 다시점의 추적 검사를 통해 뇌의 신경학적 시계열 변화를 파악하는 것이 필수적이나, 기존 연구들에서는 단일 시점에서 나타나는 상태만을 파악하는데 그쳤으며, 대부분 6세 이후의 연구가 주로 이루어져 있음⁴⁹.
- 3세이전의 발달장애의 조기 판별을 시도했던 기존의 선행연구들에서는 청소년기나 성인기 진단에 비해 비교적 낮은 성능을 보였는데, 이는 수십 명 내외의 적은 숫자의

⁴⁷ Fombonne, E.(2005). Epidemiology of autistic disorder and other pervasive developmental disorders.Journal of Clinical Psychiatry, 66, 3.

⁴⁸ Ritvo, E. R., Freeman, B. J., Pingree, C., Mason-Brothers, A., Jorde, L., Jenson, W. R., et al(1989). The UCLA-university of utah epidemiologic survey of autism: Prevalence.The American Journal of Psychiatry, 146(2), 194-199.

⁴⁹ Rapoport, J. L., et al(2001). Imaging normal and abnormal brain development: New perspectives for child psychiatry.Australian & New Zealand Journal of Psychiatry, 35(3), 272-281.

대상자로 인한 한계라고 볼 수 있음⁵⁰.

- 다양한 뇌영상 기법을 연계하여 발달장애 환자의 전반적인 뇌신경학적 구조 및 기능을 파악하는 것이 장애의 조기 진단 및 예후 예측에 매우 중요하나, 현재까지 발달장애 대상 뇌영상 연구들에서는 단일 뇌영상 기법만을 활용하여 발달장애의 뇌구조와 기능의 포괄적인 이해가 부족했다는 문제점이 있음^{51 52 53}.

3. 발달장애 대상 선행 유전학 및 유전체연구의 한계점 및 과제

- 발달장애 아동에서 발견되는 유전자(체) 변이들은 다양한 데이터베이스(표2)를 활용해서 질병과의 연관성을 판단하게 됨.

표 2. 발달지연, 자폐, 지적장애와 관련 유전자(체) 변이 데이터베이스	
DB website	Description
https://dbd.geisingeradmi.org/	Developmental Brain Disorder Gene Database; Intellectual disability, Autism, Attention Deficit Hyperactivity Disorder, Schizophrenia, Bipolar disorder, Epilapsy, Cerebral palsy
https://www.clinicalgenome.org/	The clinical relevance of genes and variants for use in precision medicine and research
https://www.deciphergenomics.org/ddd/overview	Developmental disorder genotype-phenotype database
https://gene.sfari.org/	SFARI Gene database for autism spectrum disorders
https://www.ncbi.nlm.nih.gov/clinvar/	ClinVar database - information about genomic variation and its relationship to human health
https://www.ncbi.nlm.nih.gov/dbvar/	Database of human genomic structural variation – large variants >50 bp including insertions, deletions, duplications, inversions, mobile elements, translocations, and complex variants
http://dgv.tcag.ca/dgv/app/home	catalogue of human genomic structural variation

- 전체 게놈/엑솜 염기서열분석법은 기존의 CMA 분석보다 높은 진단율을 보이지만,

⁵⁰ Bahathiq, R. A., et al(2022). Machine learning for autism spectrum disorder diagnosis using structural magnetic resonance imaging: Promising but challenging. *Frontiers in Neuroinformatics*, 16, 949926.

⁵¹ Guo, X., et al(2022). Inter-individual heterogeneity of functional brain networks in children with autism spectrum disorder. *Molecular Autism*, 13(1), 52.

⁵² Muetzel, R. L., et al(2018). Tracking brain development and dimensional psychiatric symptoms in children: A longitudinal population-based neuroimaging study. *American Journal of Psychiatry*, 175(1), 54-62.

⁵³ Zhao, Y., et al(2023). Early biomarkers of neurodevelopmental disorders in preterm infants: Protocol for a longitudinal cohort study. *BMJ Open*, 13(6), e070230.

환자 중 50% 이상은 여전히 병인을 알지 못하고 원인발견에 많은 허들이 존재함(예, 그림 9). 또한 유전체 분석에서 발견되는 변이들 중 상당수는 아직 생물학적 기능이나 임상적 의의를 특정할 수 없는 variants of uncertain significance(VUS)로 더 많은 수의 사례분석과 생물학적 기능분석이 요구됨. 특히 아동과 부모가 포함된 trio 유전체 분석은 변이의 유전 여부와 특성을 규명하는 데 매우 중요함.

- 유전체 변이는 인종에 따라서 차이가 있을 수 있으며, 특히 SNP 기반의 GWAS 연구로부터 밝혀진 질병 위험 인자들의 종류와 대립인자의 빈도는 한국인과 외국 집단 사이에 큰 차이를 보일 수 있음.
- 따라서 유전체 분석 데이터를 기반으로 질병의 위험성을 예측하기 위해서는, 한국인 유전체변이의 특성을 이해하는 것이 필요함. 다인자성 질환(multifactorial disorders)인 심혈관계질환, 당뇨, 비만 및 일부 암에 대해서는 한국인 집단을 대상으로 다유전자 위험점수(polygenic risk score)를 통한 질병위험도 예측 연구결과들이 보고되고 있으나^{54 55 56}, GDD, ASD, ID와 관련된 연구 결과는 미미한 실정임.

⁵⁴ Park, Y. S., et al(2024). Evaluating cardiovascular disease risk stratification using multiple-polygenic risk scores and pooled cohort equations: Insights from a 17-year longitudinal korean cohort study.Frontiers in Genetics, 15, 1364993.

⁵⁵ Song, M., Kwak, S. H., & Kim, J.(2024). Risk prediction and interaction analysis using polygenic risk score of type 2 diabetes in a korean population.Scientific Reports, 14(1), 6790.

⁵⁶ Yoon, N., & Cho, Y. S.(2023). Development of a polygenic risk score for BMI to assess the genetic susceptibility to obesity and related diseases in the korean population.International Journal of Molecular Sciences, 24(14), 11560.




그림 9. 환자 가계에 대한 CMA분석 결과. 환자에서 발견된 8번염색체 단완의 2.26Mb의 중복은 모계로부터 유래한 것으로 확인됨.

4. 발달장애 대상 선행 대사체 연구의 한계점 및 과제

- 현재까지 다양한 뇌발달에 관련된 장내미생물 유래 대사체가 발굴되고 있으나 대사체의 기전 및 병태생리학적인 기능을 갖는 대사산물의 발굴은 제한적임.
- 전세계적으로 다양한 질환모델에서 장내미생물유래 대사체에 대한 연구가 진행되고 있으나 발달장애와 장내 미생물유래 대사체에 대한 연구는 시작 단계임.
- ASD 관련 유전자들 중에 뇌의 대사와 관련되어있는 많은 부분이 대사체를 직접 조절하여 다양한 행동장애를 일으킬 수 있음(그림 10). 이들 중 상당수는 장내 미생물 유래 대사체에서 유도됨. 따라서 장내 미생물 유래 대사체를 통해 ASD 아동들의 진단, 치료에 따른 예후에 나타나는 바이오마커 뿐 아니라, 임상적 예후를 알아보는 데 중요한 지표가 될 수 있음.
- 특히, 국내 발달장애 아동의 장내미생물의 구성 및 대사체가 다른 국가의 발달장애

아동의 장내미생물 구성 및 대사체가 상이하여 우리 국민을 대상으로 하는 연구결과가 절실히 필요함.




그림 10. ASD 관련 유전자들과 ASD 관련 대사체들의 상관관계⁵⁷

5. 멀티모달 바이오뱅크 구축의 필요성

- 지속적으로 발달장애 위험군 아동이 증가하고 있으나, 국내외 아동 발달 관련 객관적인 데이터 자료가 미비하고 일부 발달지연 아동 판별을 위한 데이터도 대부분 비공개 자료인 상태임.
- 아동의 객관적 발달평가를 위해서는 유전체, MRI, 뇌파, 행동 영상, 기존 발달평가 도구 등 전문가에 의해 검증된 다학제적 데이터 확보가 필수적이며, 여러 데이터를 통합함으로써 발달장애 진단 및 예측 정확도를 높일 수 있다는 연구들이 나오고 있음⁵⁸.

⁵⁷ Nisar, S., & Haris, M.(2023). Neuroimaging genetics approaches to identify new biomarkers for the early diagnosis of autism spectrum disorder.Molecular Psychiatry, , 1-14.

⁵⁸ Dcouto, S. S., & Pradeepkandhasamy, J.(2024). Multimodal Deep Learning in Early Autism Detection—Recent Advances and

- 따라서 여러 종류의 데이터를 통합하기에 적합하며, 데이터 해석과 평가에 대한 편향을 최소화할 수 있는 빅데이터 기반 인공지능 기술 개발이 필수적임.
- 인공지능 기술을 개발하기 위한 핵심 조건은 양질의 다중 데이터를 수집하는 것 뿐만 아니라, 그러한 데이터를 쉽게 공유할 수 있는 생태계의 구축임. 가령, 외국에서는 UK Biobank나 Adolescent Brain Cognitive Development(ABCD), Healthy Brain Network(HBN) 등의 대규모 프로젝트를 통해 정신 질환 바이오마커 탐색을 위한 멀티모달 데이터를 수집하고자 하는 시도들이 활발히 이루어지고 있음. 이들 기관들은 뇌이미징과 유전체 데이터를 표준화된 파이프라인으로 전처리하여 연구자들이 활용할 수 있도록 함으로써 전 세계인이 협력하여 자국에서 당면한 정신 질환 문제를 해결할 수 있도록 돕고 있음. 그러나, 국내에서는 이러한 시도가 전무한 실정임.
- 개별 병원과 연구 기관에서 뇌 이미징과 유전 데이터를 수집하고는 있으나, 표준화되지 않은 뇌 이미징 촬영 프로토콜과 전처리 파이프라인으로 인해 서로 다른 병원 및 기관에서 수집된 데이터를 함께 활용하는 데에는 한계가 존재함. 또한 발달장애의 특성 상 수년 간에 걸친 추적 관찰이 필수적인데, 이로 인해 발생하는 연구의 비용과 연속성의 부재는 발달장애 연구에 큰 제약이 됨.
- 따라서 본 프로젝트에서는 다중 데이터를 효과적으로 수집하여 통일된 파이프라인으로 전처리하고, 이들을 효과적으로 활용할 수 있는 인공지능 기술을 개발하며, 그 결과를 효과적으로 국내외 연구자들에게 공유할 수 있는 통합적인 바이오뱅크 구축을 제안함.

1-3. 통합적 데이터 처리를 위한 멀티모달(multimodal) 파운데이션 모델의 필요성




그림 11. 다중 모달리티 데이터 처리를 위한 파운데이션 모델인 OneLLM⁵⁹

1. 다중 데이터 처리를 위한 파운데이션 모델의 현황


- 기존에는 각 분야에 특화된 데이터만을 활용하여 응용 범위가 국한된 기계학습 모델을 만들었던 것에 반해, 최근 기계학습 분야는 다양한 모달리티의 대용량 데이터에 기반하여 초거대 신경망 모델을 자기지도학습하는 파운데이션 모델(foundation model)의 방향으로 패러다임이 바뀌었음⁶⁰.
- 초거대 데이터를 적극 활용 하여 사전훈련(pretraining) 시킨 파운데이션 모델은 그 뒤에 소량의 특정 응용 분야의 데이터만을 가지고 미세조정(fine-tuning) 하는 것만으로도 기존 알고리즘보다 월등히 더 우수한 성능을 달성함.
- 최근 AI 대기업들이 만드는 모델, 예컨대 GPT-4, DALL-E, 들은 챗봇이나 이미지 생성모델에서 인간을 앞서는 놀라운 성능을 보이고 있음. 이미지와 텍스트 모달리티를 주로 다루었던 초기의 파운데이션 모델들에서 더 나아가, 최신의 인공지능 연구들은 하나의 파운데이션 모델이 세 종류 이상의 다중 데이터와 태스크에도 범용적으로

⁵⁹ Han, J., Gong, K., Zhang, Y., Wang, J., Zhang, K., Lin, D., ... & Yue, X.(2023). Onellm: One framework to align all modalities with language. arXiv preprint arXiv:2312.03700.

⁶⁰ Bommasani, R., Hudson, D. A., Adeli, E., Altman, R., Arora, S., von Arx, S., ... & Liang, P.(2021). On the opportunities and risks of foundation models. arXiv preprint arXiv:2108.07258.

기능할 수 있음을 보임.

- 일례로, 2023년 Meta AI에서 발표한 ImageBIND는 다중 모달리티의 파운데이션 심층신경망으로서 이미지, 오디오, 동영상, 텍스트, 열적외선 이미지, 심도 이미지, 자기중심시점 동영상 등 서로 연관이 없어 보이는 모달리티 데이터 또한 심층 신경망을 통해 통합될 수 있다는 것을 보임⁶¹.
- 더 나아가, OneLLM은 각 데이터 종류를 위한 인코더 구조를 따로 학습하지 않고 각 데이터를 하나의 범용적인 인코더(Universal Encoder)로 투영(projection)하는 것만으로도 이미지와 자연어, 뇌영상을 포함한 여러 데이터를 통합할 수 있음을 보임. 이같은 이미지-뇌영상의 관계 학습을 통해 기능적 자기 공명 뇌영상으로 촬영한 시각 피질 영역의 뇌 활동으로부터 피험자가 무엇을 보고 있는지 예측하는 시각 디코딩을 효과적으로 수행할 수 있음을 보임(그림 11).



⁶¹ Girdhar, R., El-Nouby, A., Liu, Z., Singh, M., Alwala, K. V., Joulin, A., & Misra, I.(2023). Imagebind: One embedding space to bind them all. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition(pp. 15180–15190).

2. 의료 분야의 멀티모달 파운데이션 모델의 가치

- 파운데이션 모델의 가능성에 대한 관심이 최근에는 의료 및 신경과학에까지 뻗치고 있음⁶³. 일반적인 딥러닝 모델이 임상 장면에서 활용할 정도의 예측 성능을 갖추기 위해서는 많은 양의 학습 데이터를 필요로 하나, 이러한 다중 데이터를 수 천명 이상의 발달장애 아동을 대상으로 수집하는 것은 현실적으로 매우 어려움.
- 그러나 사전 학습된 대규모 파운데이션 모델의 지식을 전이 학습을 통해 활용한다면, 상대적으로 적은 다중 데이터를 활용해서도 높은 예측 성능을 보일 것으로 기대함.
- 가령, 2023년 Google Research에서 제안한 Med-PaLM M에서는 대규모의 자연어와 이미지 데이터로 사전 학습된 파운데이션 모델을 상대적으로 크기가 작은 멀티모달 데이터(MultiMedBench)로 미세조정(fine-tuning)함으로써 특화된 모델에 비해 여러 의료 태스크에서 더 나은 성능을 보인다는 점을 시사함(그림 12). 특히 직접 수집한 다중 데이터인 MultiMedBench와 학습된 Med-PaLM M모델 파라미터를 다른 연구자들이 활용 및 재현할 수 있도록 공개함으로써 큰 주목을 받음.
- 따라서, 기존 모델들, 예를 들어 특정 뇌 질환을 예측하는데에 특화된 인공지능망 모델같은 것을 만드는 것이 아니라 사전 학습된 멀티모달 파운데이션 모델을 추가적인 뇌이미징-유전-행동 데이터로 파인튜닝하여 파운데이션 모델을 만들게 되면, 이를 정신 발달장애의 의학적 진단에 효과적으로 적용하는 것이 가능할 것으로 기대됨.

1-4. 멀티모달 AI 모델의 발달장애 적용에서의 한계 및 극복 방안

⁶² Tu, T., Azizi, S., Driess, D., ... & Natarajan, V.(2024). Towards generalist biomedical ai. NEJM AI, 1(3), AIoa2300138.

⁶³ Moor, M., Banerjee, O., Abad, Z. S. H., Krumholz, H. M., Leskovec, J., Topol, E. J., & Rajpurkar, P.(2023). Foundation models for generalist medical artificial intelligence. Nature, 616(7956), 259 – 265.

1. 적은 샘플의 문제: 샘플 효율성이 높은 기계학습 알고리즘의 필요성

- **샘플 효율성**: 제한된 수의 데이터 포인트로부터 최대한의 정보를 추출하여, 효과적인 결정을 내릴 수 있는 시스템의 능력. 고비용의 실험 환경이나 시간적 제약이 큰 상황에서 이러한 특성은 비용 절감과 더 빠른 결과 도출에 핵심 요소임. 샘플 효율성은 계산과학에서의 최적화 문제를 해결할 때 중요한 고려 사항으로, 특히 발달장애 임상 연구와 같이 자원(샘플)이 제한된 상황에서 데이터를 최대한 활용할 수 있도록 함.
- 샘플 효율적인 알고리즘은 데이터 포인트 각각에서 가능한 많은 정보를 추출하려 시도하며, 이를 위해 고급 통계 기법, 기계 학습 모델, 최적화 알고리즘 등이 사용됨.
- 예를 들어, 베이저안 최적화(Bayesian Optimization)는 목적 함수의 확률 모델을 유지하고, 관찰되지 않은 포인트에서의 목적 함수 값의 분포를 기반으로 새로운 포인트를 평가하는 기술임. 이는 샘플 효율적인 검색을 위한 주요 방법이며, 구조화된 입력 공간 또는 고차원 입력 공간에 적용하기 위해 사용됨.
- 또한 잠재 공간 최적화(Latent Space Optimization, LSO)는 먼저 딥 생성 모델(Deep Generative model)을 사용하여 낮은 차원의 연속적인 공간에서 입력 공간의 데이터 매니폴드로의 맵핑을 학습함. 이렇게 구성된 잠재 매니폴드 위에서 대리 모델을 사용하여 목적 함수를 최적화함⁶⁴.
- 샘플 효율성 연구를 뇌 발달장애 연구에 적용하는 것은 혁신적인 잠재력을 가지고 있음. 뇌 발달장애는 다양한 유형이 존재하며 각각 복잡한 원인과 다양한 발현 양상을 가지고 있어, 대규모 데이터 수집이 어려운 상황에서 샘플 효율성 연구는 귀중한 정보를 최대한 추출할 수 있게 함. 또한, 이 분야는 아직 광범위하게 연구되지 않아,

⁶⁴ Gómez-Bombarelli, R., et al(2018). Automatic chemical design using a data-driven continuous representation of molecules. ACS central science, 4(2), 268-276.

샘플 효율적인 접근법은 더 많은 발견과 이해를 가능하게 하며, 연구에 필요한 시간과 비용을 줄일 수 있음. 이러한 접근법은 임상 연구와 재료 과학에서 이미 증명된 바와 같이, 연구 개발 비용을 절감하고 혁신을 촉진할 수 있는 중요한 방법론임. 하지만 뇌발달장애에서 이런 최선의 계산과학적 접근이 이뤄진 바가 아직 없음. 본 연구에서 이를 다룰 것임.

2. 도메인 적응과(domain adaptation) 일반화 가능성을(domain generalization) 위한 연합 학습(federated learning)

- 인공지능 기반의 생명과학 연구에서 뇌영상, 오믹스, 행동 데이터와 같은 다양한 데이터 유형을 활용하는 경우, 도메인 일반화와 도메인 적응(domain generalization and adaptation)은 연구의 성공을 위해 필수적인 요소임. 이러한 접근법들은 인공지능 모델이 학습하거나 경험한 데이터 세트를 넘어서, 다양한 환경과 조건에서도 유효하게 적용될 수 있도록 함.
- 의생명과학 및 임상연구 분야에서 연합학습(Federated Learning)의 채택은 데이터의 민감성과 분산된 특성을 고려할 때 필수적인 전략임. 여러 연구 기관이 자신의 데이터를 직접 공유하지 않고도 공동으로 인공지능 모델을 학습할 수 있게 해주며, 이는 프라이버시를 보호하고 규제 요건을 충족하면서도 일반화 가능성 및 도메인 적응성이 높은 모델 구축이 가능함.
- 도메인 일반화(domain generalization): 인공지능 모델이 학습 중에 접하지 못한 새로운 도메인(환경, 그룹, 조건 등)에 대해서도 잘 작동하도록 설계함. 이를 위해 다양한 환자군, 다양한 질병 상태, 다양한 연령 및 인종 그룹에서(해외 데이터 이용) 수집된 데이터를 다양하게 학습 과정에 포함시켜야 함.

- 이와 더불어, 메타러닝(meta-learning)과 같은 학습과정을 걸쳐 일반적인 학습 전략을 개발하거나, 도메인 불변 특징을 중점적으로 학습함으로써 모델이 도메인 간 일관된 특성을 추출하도록 유도할 수 있음. 특히, 생물학적 데이터는 출처, 수집 방법, 대상 집단의 특성 등에 따라 매우 다양하기 때문에, 이러한 도메인 일반화는 생명과학 연구에서 매우 중요함. 예를 들어, 다른 인종 또는 연령대에서 수집된 오믹스 데이터를 통해 인공지능 모델이 일반화된 생물학적 메커니즘을 학습할 수 있도록 도메인 일반화 기법을 적용하는 것은 모델의 유용성을 극대화할 것임.
- 도메인 적응(domain adaptation): 하나 이상의 도메인에서 학습된 모델을 다른 새로운 도메인으로 효과적으로 적용하기 위해 필요함. 이는 전이 학습(transfer learning)을 통해 모델이 새로운 도메인의 소량의 데이터로 추가적인 학습을 수행하거나, 데이터 관련 정규화 및 조정을 통해 새로운 도메인에 맞게 모델을 조정함. 또한, 다중 도메인 학습을 실시하여 여러 도메인의 데이터를 동시에 사용하고 각 도메인에 최적화된 모델 파라미터를 도출하는 방법도 가능함.
- 이러한 과정은 특히 다양한 임상 환경에서 효과적인 진단, 예후, 치료 결정을 지원하기 위해 필수적임. 예컨대, 특정 임상 시험에서 효과적이었던 뇌영상-오믹스-행동표현형 기반 진단법이 다른 인구 집단에서도 동일한 효과를 나타내도록 인공지능 모델을 조정하는 것이 중요함. 이러한 적응 과정은 실제 환경에서의 인공지능 기반의 의료 솔루션의 신뢰성과 정확성을 보장하는 데 결정적인 역할을 할 것임.
- 연합학습(federated learning)의 중요성은 우선 데이터 보호에 있음. 임상/생물학 데이터는 개인의 건강 정보를 포함할 수 있어 매우 민감하며, 연합학습은 이러한 데이터가 원본 위치를 벗어나지 않고도 학습에 사용될 수 있도록 함으로써 정보

노출의 위험을 크게 줄임. 이는 데이터 소유자가 데이터의 물리적 이동 없이 모델 업데이트를 공유하는 방식으로 이루어짐. 또한, 연합학습은 다양한 규제 환경에서도 연구와 개발을 안전하게 진행할 수 있는 프레임워크를 제공함. 더 나아가, 이 과정은 모델의 도메인 일반화와 적응 능력을 강화하는 데에도 기여함. 다양한 환경과 조건에서 수집된 데이터를 통해 모델은 더 넓은 범위의 의료 환경에 적용 가능한 유용한 인사이트와 패턴을 추출할 수 있음.

- 이러한 최신 AI 기법을 이용한 발달장애 연구는 현재 국내외에서 거의 전무한 상황이며, 본 연구진에서 이를 해결하고자 함.

3. 기계학습 예측의 신뢰성 문제(uncertainty quantification)

- 현대 딥러닝 모델은 이미지 인식, 자연어 처리, 자율 주행 등과 같이 다양한 분야에서 혁신을 주도하고 있음. 그러나 이러한 모델들이 복잡한 결정을 내리거나 예측을 하는 과정에서 정확성과 신뢰성은 매우 중요한 요소가 되며, 특히 의료 진단과 같은 고위험 결정을 해야하는 분야에서는 그 중요도가 가중됨⁶⁵. 불확실성에 대한 정량화는 모델이 데이터에 내재된 불확실성을 인지하고, 이를 효과적으로 처리할 수 있도록 도와주어 모델의 신뢰도를 높이고, 잘못된 결정으로 인한 리스크를 줄이는 데 핵심적인 역할을 함.
- 신뢰성 향상: 불확실성 정량화를 통해 모델은 자신의 예측에 대해 확신이 낮은 경우 이를 명시적으로 표현할 수 있음. 이는 의료 진단 혹은 예후 예측과 같이 고위험 결정에서 특히 중요함. 예를 들어, 의료 진단에서 모델이 진단에 확신이 낮다고 판단되면, 추가적인 검사를 권장하여 잘못된 진단으로 인한 위험을 줄일 수 있음.

⁶⁵ Jiang, H., et al.(2018). To trust or not to trust a classifier. Advances in neural information processing systems, 31.

- **모델의 일반화 능력 강화:** 딥러닝 모델은 훈련 데이터와 유사한 새로운 데이터에 대해서는 잘 작동하지만, 완전히 다른 종류의 데이터를 만났을 때 오류를 범할 수 있음. 불확실성 정량화는 모델이 이러한 '분포 이탈(out-of-distribution)' 상황을 인지하고, 예측에 대한 불확실성을 고려하여 더 신중한 결정을 내리는데 유용함.
- **안정성:** 자율주행차나 의료 데이터를 통한 질병 예측 등과 같은 시스템에서는 예측의 불확실성이 높을 때 보수적으로 행동하도록 설정하는 것이 중요함. 불확실성 정량화는 시스템이 잠재적인 위험 상황에서 안전하게 작동하도록 지원함.
- **효율적 데이터 활용:** 불확실성 정보를 이용하여 어떤 데이터가 추가 훈련에 도움이 될지 판단할 수 있음. 모델이 불확실성을 높게 평가한 데이터를 중심으로 추가 학습을 진행함으로써, 모델은 더욱 효율적으로 학습할 수 있고 성능을 향상시킬 수 있음.
- 불확실성 정량화는 현대 딥러닝 시스템에서 선택적인 요소가 아닌 필수적인 요소이며, 이는 모델의 신뢰성과 안전성을 보장하고, 불확실한 상황에서도 효과적으로 작동할 수 있도록 하는 데 결정적인 역할을 함.
- 본 연구진은 딥러닝 기반 시스템의 불확실성을 적절히 관리하고 정량화하는 메커니즘을 갖추어 실제 환경에서의 성공적인 적용이 가능한 모델을 개발할 것임. 이러한 불확실성 정량화는 모델의 설계 초기 단계에서부터 고려되어야 하며, 지속적인 연구와 개발을 한다면 그 방법론과 효율성은 더욱 개선될 수 있을 것임.

1-5. 발달장애 연구에서 멀티모달 파운데이션 모델의 활용 가능성과 혁신성

- 현재 거대 언어 모델과 같은 파운데이션 AI 모델들이 전 세계적으로 확산되고 있는 가운데, 이러한 모델들은 발달장애의 진단, 치료, 연구에 혁신적인 가능성을 제공함.

특히, 발달장애가 가지는 복잡한 양상과 다양한 발현을 정밀하게 이해하고 분석할 수 있는 새로운 도구로서, 파운데이션 모델은 이 분야에 귀중한 기여를 할 수 있음.

- 발달장애 연구는 고도로 개인화되고, 맞춤화된 접근을 필요로 하는데(뇌영상, 오믹스, 행동데이터에 기반), 파운데이션 모델은 대규모 데이터를 기반으로 개인의 특징을 파악하고, 그에 맞는 정보를 제공하는 능력이 뛰어남. 예를 들어, 자폐 스펙트럼 장애를 가진 아동을 위한 맞춤형 개입 프로그램 개발, 각기 다른 유형의 발달장애에 최적화된 치료 방안 제시 등이 가능해질 것임.
- 또한, 파운데이션 모델을 이용한 AI 모델은 발달장애가 있는 개인의 행동 패턴, 언어 사용, 사회적 상호작용 등을 분석하여, 장애의 조기 진단 및 진행 상황을 모니터링하는데 사용될 수 있음. 이는 전통적인 진단 방법보다 더 빠르고 정확한 데이터를 제공하여, 조기 개입이 가능하게 함으로써 장기적인 치료 결과를 개선할 수 있음.
- 국제적으로 이러한 기술의 개발과 적용은 한국이 글로벌 AI 기술 경쟁에서 유의미한 위치를 확보하는 데 기여할 수 있음. 특히, 한국은 빅데이터와 AI 기술을 활용한 의료 분야에서 이미 일정 수준의 경쟁력을 가지고 있으며, 이를 발달장애 연구에 특화하여 국제적으로 인정받는 혁신을 이룰 수 있음.
- 따라서, 파운데이션 AI 모델의 발달장애 연구 적용은 단순히 기존 모델의 확장인 아니라, 발달장애의 복잡성과 다양성을 깊이 있게 다룰 수 있는 새로운 방법론과 기술의 개발을 필요로 함. 멀티모달 데이터 공개와 더불어, 이를 통해 한국은 발달장애 연구와 치료 분야에서 세계적인 리더가 될 가능성을 제시하며, 이 분야에 새로운 지평을 열어갈 수 있음.

2. 연구개발과제의 목표


○ 단계별 목표·현재 기술수준(TRL)

기술수준(TRL)	1단계 목표	3	2단계 목표	4	현재	2
-----------	-----------	---	-----------	---	----	---

1단계: 플랫폼 구축 및 AI 모델 개발을 위한 멀티모달 데이터 수집, 정제, 그리고 표준화 및
병인 기전과 바이오마커 후보군 제시

소아 발달장애 멀티모달
(영상/뇌영상/유전체/대사체/행동) 데이터
정의 및 전·후향 수집(다기관/다시점)

멀티모달 데이터 플랫폼 전송
바이오마커 후보군 제시



2단계: 발달 장애 분류 및 진단을 위한 응용 AI 모델의 개발 및 공개, 추가로 수집된 데이터 등록,
그리고 발굴한 바이오마커의 의학적 유용성 검증

데이터 종별 전문 연구팀간 협력을 통한
바이오마커 도출 및 AI 모델 개발

도출된 AI 모델 결과의
실증/바이오마커의 in vitro, in vivo,
임상적 검증



연구개발과제의 목표

2-1. 연구개발과제의 최종 목표 및 세부 목표

최종목표	“최종 목표: 소아 발달장애 멀티모달 뇌영상과 유전·대사체 및 행동표현형의 대규모 AI 파운데이션 모델 적용과 임상경과 바이오마커 발굴과 검증” [1단계 목표: 뇌영상, 오믹스, 행동표현형, 임상 데이터를 수집·정제·표준화 하여 고품질 멀티모달 데이터 기반 플랫폼 구축, 바이오마커 후보군 제시] [2단계 목표: 대규모 파운데이션 모델 기반의 뇌영상, 오믹스, 행동표현형, 임상 데이터의 통합 AI 모델 개발, 이를 통한 발달장애 조기 진단과 임상 경과 예측을 위한 바이오마커의 발굴 및 실증적 검증]
1단계목표 (연차별)	1단계: 뇌영상, 오믹스, 행동표현형, 임상 데이터를 수집·정제·표준화 하여 고품질 멀티모달 데이터 기반 플랫폼 구축, 바이오마커 후보군 제시 ● 1년차: 플랫폼 구축 및 AI 모델 개발을 위한 멀티모달 데이터 수집, 정제, 그리고 표준화 ○ [차병원] 목표 1-1: 고품질의 소아 발달장애 바이오메디컬 빅데이터 구축을 위한 멀티모달 데이터 정의, 수집 세부목표 1-1-1: 국내외 공공데이터 탐색 및 선행 연구 등을 통한 플랫폼 구축 대상 멀티모달 데이터군 정의 및 단위 확립과 기존 공공데이터에 수가 부족하거나 없는 데이터에 대한 다기관 다시점 후향적 멀티모달 데이터 변수 단위 설정 및 수집 세부목표 1-1-2: 데이터 수집 및 제공을 위한 IRB/DRB 승인 세부목표 1-1-3: 2단계 임상적 유효성 검증 및 융합 모델 개발을 위한 전향적 코호트 데이터 수집을 위한 프로토콜 설계와 수행 시작 ○ [서울대] 목표 1-2: 멀티모달 뇌영상 데이터 수집, 정제, 표준화 세부목표 1-2-1: 구조, 확산, 기능 뇌영상 데이터 수집 및 큐레이션 세부목표 1-2-2: 정량적 자화율 매핑(Quantative Susceptibility Maps 및 χ-separation) 뇌영상 데이터 수집, 정제, 표준화 ○ [차병원] 목표 1-3: 유전체 및 타겟 질환 동물모델 데이터 탐색 및 수집 세부목표 1-3-1: 발달장애 아동의 인체 유래물 수집 및 유전체 데이터 정제 세부목표 1-3-2: 타겟 질환 동물모델 구축 및 선행연구 탐색과 분석목표 수립 ○ [루먼랩] 목표 1-4: 영상 기반 행동 데이터 큐레이션 및 표준 데이터 관리 시스템 구축 세부목표 1-4-1: 행동 비디오 데이터 수집을 위한 인프라 및 표준 데이터 관리

시스템 설계

세부목표 1-4-2: 표준 데이터 관리 시스템 및 프로토콜 구축 및 소아 발달장애 데이터베이스 구축을 위한 데이터 수집

세부목표 1-4-3: 표준 데이터 관리 시스템 검증 및 도입, 소아 발달장애 데이터 베이스 구축을 위한 데이터 정제 및 가공

- 2년차: 멀티모달 데이터 수집 지속 및 병인 기전과 바이오마커 후보군 제시

- 목표 2-1: 소아 발달장애 바이오메디컬 빅데이터 품질 관리 및 국내외 데이터 공유 플랫폼으로의 확장

세부목표 2-1-1: K-BDS 플랫폼과 동기화된 표준 데이터 관리 인프라 및 통합 발달장애 데이터베이스 구축과 이를 기반으로 한 지속적인 AI 모델 업데이트 인프라 구축

세부목표 2-1-2: 글로벌 뇌과학 플랫폼(brainlife.io)에 데이터 공유

세부목표 2-1-3: 소아발달 바이오뱅크 벤치마크 및 카탈로그 시스템 구축을 통한 연구생태계 활성화

- 목표 2-2: 멀티모달 뇌영상, 오믹스, 영상 기반 행동데이터로부터의 후보 바이오마커 제시(기존 데이터 기반 AI 모델링 및 바이오인포매틱스)

세부목표 2-2-1: 바이오마커 후보군과 병인 기전에 대한 임상적 자문

세부목표 2-2-2: 공공 뇌영상데이터 기반 멀티모달 뇌영상 “사전 학습” AI 모델 개발

세부목표 2-2-3: 공공 imaging-omics 데이터 정량화마커 기반 발달장애 위험 계산모델 개발

세부목표 2-2-4: 공공데이터와 생물정보학분석모듈을 이용한 자폐스펙트럼 관련 유전자 제시

세부목표 2-2-5: 동물모델의 장내 미생물 유래 대사체 및 인체유래물 데이터 분석 기반 바이오마커 후보군 도출

2단계목표 (연차별)	2단계: 대규모 파운데이션 모델 기반의 뇌영상, 오믹스, 행동표현형, 임상 데이터의 통합 AI 모델 개발, 이를 통한 발달장애 조기 진단과 임상 경과 예측을 위한 바이오마커의 발굴 및 실증적 검증 ● 3년차: 멀티모달 데이터 수집 지속 및 바이오마커 발굴에 따른 동물모델에서의 유효성 검증 및 응용 AI 모델 사용성 평가 ○ 목표 3-1: 정제한 데이터를 활용하여 발달장애 분류 및 진단을 위한 뇌영상, 오믹스, 행동 데이터의 모달리티별 AI 모델 개발 - 세부목표 3-1-1: 구조 및 자화 매핑 뇌영상과 임상 데이터를 사용한 멀티모달 AI 모델의 개발 - 세부목표 3-1-2: 점진적 학습 패러다임을 적용한 멀티모달 뇌영상-언어 AI 모델 - 세부목표 3-1-3: LLM을 활용한 멀티오믹스-언어 멀티모달 AI 모델의 개발 - 세부목표 3-1-4: 멀티오믹스 기반의 자폐스펙트럼 예후 및 치료효과 관련 유전자 규명 - 세부목표 3-1-5: 행동동영상데이터를 이용한 발달장애 분류 모델 개발 ○ 목표 3-2: 대규모 파운데이션 AI 모델을 이용한 뇌영상-오믹스-행동 비디오-임상평가 기반 발달장애 모델 개발 - 세부목표 3-2-1: 뇌영상-오믹스-행동비디오-임상평가 멀티모달 AI 모델 개발 - 세부목표 3-2-2: 멀티모달 데이터에서의 샘플 효율적 학습과 불확실성 정량화 AI 방법론 개발 - 세부목표 3-2-3: 다기관 데이터 연합학습 AI 모델 개발 ○ 목표 3-3: 전향적 코호트 데이터의 추가적 수집 및 바이오마커의 임상유효성 평가 준비 - 세부목표 3-3-1: 전향적 코호트 데이터 지속적 수집 - 세부목표 3-3-2: 진단·예측 응용 AI 모델의 임상현장 사용성 평가 - 세부목표 3-3-3: 바이오마커의 실증 및 임상유효성 평가를 위한 IRB 승인 - 세부목표 3-3-4: 바이오마커의 확립과 동물모델 적용을 통한 검증 ● 4년차: 바이오메디컬 빅데이터 기반 응용 AI 모델의 예측력 검증, 임상적 유용성 확인 및 AI 모델 공개 ○ 목표 4-1: 개발된 예측/진단 응용 AI 모델 및 바이오마커의 임상적 유용성 확인
------------------------	--

	세부목표 4-1-1: 뇌영상-오믹스-행동비디오-임상평가 멀티모달 AI 모델의 임상적 유용성 검증 세부목표 4-1-2: 신규 바이오마커 및 AI 솔루션의 다기관 실증 및 유효성 평가 세부목표 4-1-3: 다양한 중재치료(집중재활치료, rTMS, 약물치료 등)에 따른 효능이 도출된 바이오마커에 의해 입증되는지 검증 ○ 목표 4-2: 개발된 AI 모델의 공개를 통한 발달장애 바이오마커 검증 후속 연구 장려 세부목표 4-2-1: 글로벌 플랫폼에 개발된 응용 AI 모델 공개
--	---

2-2. 연구개발과제 평가기준

평가항목	가중치 (%)	관련세부 목표	연차	연차별 목표(조건/환경)
다양한 모달리티의 데이터 표집 및 데이터 베이스 구축	20	1-1-1 ~ 1-5-3	1차연도 (1단계 1차연도)	(정량) 임상데이터 연계 멀티모달 빅데이터 2000례 이상 제공 - 국내외 공공데이터 탐색 및 선행 연구 등을 통한 플랫폼 구축 대상 멀티모달 데이터군 정의 및 단위 확립과 DRB 획득 - 축적하고 있는 샘플을 활용한 유전체 데이터 분석 - 40가족 이상 trio NGS, SNP, 50가족 이상 개인 유전체(장기적 임상 데이터 보유) (정성) 신규 장내 미생물 유래 대사체 뇌발달 기능검증과 신규 바이오 마커 도출을 위한 빅데이터 제공 - 장내 미생물 유래 대사체 프로파일링 플랫폼 설립 (정량) 영유아 행동 동영상 데이터 수집 SW 개발 및 데이터 500례 이상 제공 - 행동 데이터 항목 선정 및 UI/UX 기획서 작성
			2차연도 (1단계 2차연도)	(정량) 임상데이터 연계 멀티모달 빅데이터 2000례 이상 제공 - 축적하고 있는 연계된 멀티모달 디지털 빅데이터(표준화된 발달평가, 기본 MRI와 DTI등) 2000례 이상 제공 (정량) 질환별 검증용 멀티모달 빅데이터 300례 이상 제공 - 국내외 공공데이터 탐색 및 선행 연구 등을 통한 플랫폼 구축 대상 멀티모달 데이터군 정의 및 단위 확립과 DRB 획득 - 축적하고 있는 샘플을 활용한 유전체 데이터 분석 - 40가족 이상 trio NGS, SNP, 50가족 이상 개인 유전체(장기적 임상 데이터 보유) (정성) 신규 장내 미생물 유래 대사체 뇌발달 기능검증과 신규

평가항목	가중치 (%)	관련세부 목표	연차	연차별 목표(조건/환경)
				바이오 마커 도출을 위한 빅데이터 제공 - 환자 장내 미생물, 마우스 조직 및 혈액의 대사체 프로파일링을 통한 장내 미생물 유래 대사체의 유래기전 연구 (정량) 영유아 행동 동영상 데이터 수집 SW 개발 및 데이터 500례 이상 제공 - 동영상 데이터 수집을 위한 소프트웨어 개발 - 영유아 행동 동영상 데이터 500례 이상 수집
			3차연도 (2단계 3차연도)	(정량) 질환별 검증용 멀티모달 빅데이터 300례 이상 제공 - 임상데이터와 연계된 멀티모달 디지털 데이터(표준화된 발달평가, 기본 MRI와 DTI 등) 300례 이상 제공 (정성) 신규 장내 미생물 유래 대사체 뇌발달 기능검증과 신규 바이오 마커 도출을 위한 빅데이터 제공 - 대사체의 뇌발달 조절 능력 측정 스크리닝 (정성) 발달장애아동 특화된 정량적 자화 영상 정제 및 가공 - 수집한 데이터에 대한 전처리 파이프라인 구축 - 발달장애아동의 병변이 포함된 데이터에 대한 정제 및 가공 - 정량적 자화율 측정 및 품질 평가 (정성) 표준 데이터 관리 시스템 검증 및 도입 - 표준 데이터 관리 인프라 도입 및 사용성, 정확도 평가 - 구축 데이터에 대한 반자동 데이터 검토 알고리즘 개발 (정성) 발달지연 데이터베이스 구축을 위한 데이터 정제 및 가공

평가항목	가중치 (%)	관련세부 목표	연차	연차별 목표(조건/환경)
				● 공공 데이터 허브 데이터 정제 및 가공 ● 행동 데이터 품질 평가 및 정제 ● 행동 데이터 표현형 평가 및 전문가 검수
			4차연도 (2단계 4차연도)	(정성) 신규 장내 미생물 유래 대사체 뇌발달 기능검증과 신규 바이오 마커 도출을 위한 빅데이터 제공 ● 장내 미생물 유래 대사체의 뇌발달 영향 기능 분석 (정량) 영유아 행동 동영상 데이터 수집 SW 개발 및 데이터 500례 이상 제공 ● 영유아 행동 동영상 데이터 500례 이상 공개
다양한 모달리티의 데이터 표준화 및 통합 데이터 베이스 구축과 서비스 공개	20	2-1-1 ~ 2-1-3, 4-2-1	1차연도 (1단계 1차연도)	(정량) 임상데이터 연계 멀티모달 빅데이터 2000례 이상 제공 ● 2000례 이상 임상 데이터와 연계된 각종 유전자 결과 데이터베이스화(뇌영상 데이터 연계됨) ● 다기관 데이터 제공 시작 (정량) 발달지연 표준 데이터 관리 인프라 SW 개발 및 특허 출원 ● 데이터 품질 관리를 위한 가이드라인 작성
			2차연도 (1단계 2차연도)	(정량) 질환별 검증용 멀티모달 빅데이터 300례 이상 제공 ● 300례 이상 임상 데이터와 연계된 각종 유전자 결과 데이터베이스화(뇌영상 데이터 연계됨) ● 다기관 데이터 제공 시작 (정성) 각종 모달리티 데이터들의 표준화 및 통합 바이오뱅크 데이터 베이스 구축 ● 축적된 각종 모달리티의 데이터들을 K-BDS의 형식에 맞춰 표준화 수행 ● K-BDS와의 연계를 통한 데이터의 체계적인

평가항목	가중치 (%)	관련세부 목표	연차	연차별 목표(조건/환경)
				품질관리 및 공유 ● 각 데이터 종류별 표준 항목 정의서 작성 및 AI 학습용 Minimal Common Data 제시 (정량) 발달지연 표준 데이터 관리 인프라 SW 개발 및 특허 출원 ● 데이터 관리 UI, UX 기획서 및 요구사항 명세서 작성
			3차연도 (2단계 3차연도)	(정성) 글로벌 뇌과학 플랫폼을 통한 AI 모델 공개와 데이터 베이스 연계 ● 다양한 모달리티의 데이터를 글로벌 뇌과학 플랫폼인 Brainlife의 데이터 베이스와 연계 ● 발달장애 아동 조기진단을 위한 다중 모달리티 AI 모델과 모델 학습에 사용된 데이터를 사용하기 쉬운 App의 형태로 Brainlife를 통해 공개 (정량) 발달지연 표준 데이터 관리 인프라 SW 개발 및 특허 출원 ● 표준 데이터 관리 인프라 SW 개발 ● 표준 데이터 관리 인프라 특허 출원
			4차연도 (2단계 4차연도)	(정성) K-BDS 플랫폼과 동기화된 표준 데이터 관리 인프라 구축 ● K-BDS 플랫폼과 데이터 동기화를 위한 백엔드 인프라 구축 ● 인공지능 활용을 위한 배포 API 구성 ● 추가 데이터에 대한 표준데이터 확장과 인공지능 갱신을 위한 CI/CD/CT 구축 (정성) 통합 발달지연 데이터베이스의 K-BDS 등록 ● K-BDS 등록을 위한 통합 데이터 검수 및 명세 작성

평가항목	가중치 (%)	관련세부 목표	연차	연차별 목표(조건/환경)
				- 구축된 데이터베이스의 K-BDS 등록 (정성) 아동발달 바이오뱅크 벤치마크 데이터셋 및 웹 기반의 카탈로그 시스템 구축 - 아동발달 바이오뱅크 데이터베이스를 벤치마크 데이터셋으로 가공하여 AI 모델 개발 챌린지 커뮤니티를 통해 공개 - 아동발달 바이오뱅크 데이터베이스를 웹 기반의 카탈로그 시스템화하여 데이터베이스에 대한 연구자들의 진입장벽을 낮춤 - 바이오뱅크 데이터베이스 기반의 다양한 연구 결과들에 대한 시각화 서비스를 제공하여 발달장애 연구의 플랫폼으로 발전 (정성) 글로벌 플랫폼을 통한 AI 모델의 공개 - Github와 huggingface등 글로벌 AI 모델 공유 허브를 통해, 개발된 AI 모델 공개
다양한 모달리티 데이터로부터 신규 바이오마커 발굴	20	2-2-1 ~ 2-2-3	1차연도 (1단계 1차연도)	(정량) 자페스펙트럼 관련 공공데이터 수집 및 전처리 20개(2000례) 이상의 유전체/전사체 코호트 수집 및 전처리 (정량) 장내 미생물 유래 대사체 발굴 기술 기반 신규 바이오마커 도출 장내 미생물 유래 특이적 대사체 동정 30종 이상
			2차연도 (1단계 2차연도)	(정량) 공공 뇌영상데이터 기반 멀티모달 뇌영상 사전학습 AI 모델 개발 - 멀티모달 뇌영상 사전학습 및 전이학습용 공공데이터셋 구성 - 효과적인 사전학습 방법 탐색 및 사전학습 진행

평가항목	가중치 (%)	관련세부 목표	연차	연차별 목표(조건/환경)
				사전학습된 모델을 활용해 자폐 스펙트럼 장애, 전반 발달 지연 등의 발달장애 바이오마커 탐색 (정량) 장내 미생물 유래 대사체 발굴 기술 기반 신규 바이오마커 도출 - 자폐 스펙트럼 및 뇌발달장애 환자 특이적 장내 미생물 유래 대사체 동정 5종 이상 (정량) 자폐스펙트럼 관련 유전자 선별 3000개 이상의 자폐스펙트럼 후보유전자 pool 형성 100개 이상의 자폐스펙트럼 중요 후보유전자 전임상연구팀에 인계
			3차연도 (2단계 3차연도)	(정량) 장내 미생물 유래 대사체 발굴 기술 기반 신규 바이오마커 도출 - BBB를 통과 가능한 대사체 및 전구체 분석 5종 이상 (정량) 멀티오믹스와 유량네트워크 기반의 Upstream 유전자 규명 10개 이상의 자폐스펙트럼 중요후보 유전자 제시
			4차연도 (2단계 4차연도)	(정량) 장내 미생물 유래 대사체 발굴 기술 기반 신규 바이오마커 도출 - 뇌발달 기전 손상 마우스 모델에서 뇌발달 필수 대사체 >1종 이상 발굴 및 대사체 유효성 평가 (정량) 예후/치료반응 관련 바이오마커 제시 20 - 30개 이상의 자폐스펙트럼 예후/치료반응 바이오마커 제시

평가항목	가중치 (%)	관련세부 목표	연차	연차별 목표(조건/환경)
발달장애 조기진단을 위한 다중 모달리티 데이터 통합 AI 모델 개발	20	3-1-1 ~ 3-2-3	1차연도 (1단계 1차연도)	(정량) 대규모 파운데이션 AI 모델을 이용한 뇌영상-오믹스-행동 비디오-임상평가 기반 발달장애 모델 개발 ● 발달장애 아동들의 뇌영상 데이터와 각종 임상평가 데이터를 활용하여 발달장애 조기진단용 언어-뇌영상 AI 모델 개발
			2차연도 (1단계 2차연도)	(정량) 텍스트-이미지 파운데이션 AI 모델을 활용한 발달장애 아동 조기진단용 뇌영상 AI 모델 개발 ● 점진적 학습방법을 활용하여 진단의 정확성과 구체성 고도화
			3차연도 (2단계 3차연도)	(정량) 텍스트-이미지 파운데이션 AI 모델을 활용한 발달장애 아동 조기진단용 뇌영상 AI 모델 개발 ● 멀티모달 데이터에서의 샘플 효율적 AI 학습과 불확실성 정량화 방법론 개발 ● 다기관 멀티모달 데이터의 연합 학습 AI 모델 개발 (정량) 언어-뇌영상 발달장애아동 진단 AI 모델 개발 ● 언어-구조적 MRI, 언어-자화영상 2가지 모달리티 데이터를 활용한 발달장애아동 진단 AI 모델 개발 ● 뇌영상의 다양한 종류를 조합함으로써 진단 AI 모델의 성능에 가장 크게 기여하는 바이오마커 제시
			4차연도 (2단계 4차연도)	(정량) 뇌영상-오믹스-행동 비디오-임상평가 데이터의 다중 모달리티 통합 AI 모델 개발 ● 앞선 연차의 연구들을 통해 개발된 개별 모달리티 AI 모델들을 통합하여 발달장애 아동 조기 진단을 위한 다중 모달리티 통합 AI 모델 개발

평가항목	가중치 (%)	관련세부 목표	연차	연차별 목표(조건/환경)
				(정량) 다유형의 멀티모달리티 데이터를 활용한 AI 모델 개발 ● 모달리티의 수를 늘리면서 각 정보를 효과적으로 융합함으로써 발달장애아동 진단 AI 모델을 개발 ● 앞선 연차의 연구들보다 더 개선된 진단 성능 달성.
발달 지연 조기진단을 위한 AI 모델과 바이오마커의 임상적 유용성 검증	20	3-2-1 ~ 4-1-4	1차연도 (1단계 1차연도)	-
			2차연도 (1단계 2차연도)	-
			3차연도 (2단계 3차연도)	(정성) AI 모델의 임상 현장 사용성 평가 ● AI 모델 파일럿 테스트 및 성능 검증 ● AI 솔루션의 UI/UX에 대한 의료진 피드백 ● MLMD 사용 적합성에 대한 평가 설계 (정성) 바이오마커의 실증 및 임상 유효성 평가를 위한 IRB 승인 ● 참조 표준 구축 기준 및 방법 제시 ● AI 모델과 바이오마커의 임상유효성 평가를 위한 타겟 질환 아동 대상 임상연구 프로토콜 계획 (정량) 동물모델을 활용한 바이오마커의 검증 ● 발달장애 아동의 장내 미생물을 이식한 동물의 대사체 및 뇌 조직 전사체 분석
			4차연도 (2단계 4차연도)	(정량) 다중모달 AI 모델의 임상적 유용성 검증 ● 이중맹검을 진행하여 AI 모델의 임상 소견에 대한 타당성 검증 (정량) 신규 바이오마커 및 AI 솔루션의 다기관 실증 및 유효성 평가

평가항목	가중치 (%)	관련세부 목표	연차	연차별 목표(조건/환경)
				- 분당 차병원의 산모아동 통합 데이터 플랫폼과 의료 기기 실증 플랫폼을 활용하여 신규 바이오마커 및 AI 솔루션의 유효성 테스트 및 평가 진행 (정성) 신규 바이오마커의 증재치료에 따른 증상 개선 반영여부 확인 - 새롭게 발굴된 바이오마커가 다양한 증재치료를 진행하는 아동들의 증상 개선도를 반영하는지 검증
합계	100			

2-3. 평가주안점의 설정근거

평가항목	목표 설정근거
다양한 모달리티의 데이터 표집 및 데이터 베이스 구축	현재 국내에서 진행되고 있는 발달장애 연구는 여러 가지 제한점을 지니고 있음. 특히, 기존의 데이터베이스는 자폐 스펙트럼 장애(ASD)에만 집중되어 있으며, 전반적 발달 지연(GDD)이나 지적 장애(ID)와 같은 다른 형태의 발달장애에 대한 연구는 매우 부족함. 또한, ASD와 ID가 동시에 나타나는 경우가 많음에도 불구하고 이를 구분해서 연구한 사례는 드뭄. 이러한 연구의 한계는 뇌영상, 유전학 및 대사체 연구에도 그대로 나타나고 있음. 대부분의 뇌영상 연구는 단일 시점의 데이터에 의존하며, 유전체 연구에서는 질병과 직접적인 연관성을 가진 유전자 변이를 찾는 데 한계가 있음. 또한, 대사체 연구는 발달 초기의 질환 예측과 진단에 필요한 바이오마커 개발이 아직 초기 단계에 머물러 있음. 최근 영유아 행동 동영상 데이터 또한 행동 수준에서 발달 지연 정도를 예측할 수 있는 중요한 요인임이 밝혀지고 있음. 이에 따라, 다양한 수준에서의 멀티모달 데이터를 통합하여 체계적으로 수집하고 연구할 수 있는 바이오뱅크의 필요성이 대두됨. 이러한 통합

	데이터베이스는 다양한 데이터 유형의 연결고리를 찾아내어 발달장애의 조기 진단 및 치료에 있어서 획기적인 발전을 가져올 수 있을 것임. 따라서, 본 연구팀은 다양한 장애 유형에 대한 광범위한 연구를 가능하게 하는 새로운 연구 플랫폼과 데이터베이스 구축을 위한 연구를 진행하고자 함. 특히, 데이터를 수집하기 위한 편의 소프트웨어를 개발함으로써 추후 발달장애 아동의 조기 개입과 치료에 큰 기여를 하고자 함.
다양한 모달리티의 데이터 표준화 및 통합 데이터 베이스 구축과 서비스 공개	발달장애 아동 연구를 위한 다양한 모달리티의 데이터로 구성된 바이오뱅크 데이터베이스는 많은 연구자들이 활용함으로써, 발달장애 연구를 촉진할 수 있는 가능성과 잠재성을 가지고 있음. 특히, 각 모달리티의 데이터들을 전문적으로 다뤄온 연구자들 뿐만 아니라, 다양한 모달리티의 데이터들을 통합적으로 활용한 연구를 진행하고자 하는 연구자들이 데이터베이스를 적극 활용하여 연구를 진행할 수 있음. 이를 위해서는 데이터베이스를 구성하고 있는 각종 데이터들을 탐색하고, 이 데이터들을 통해 진행된 연구의 결과들을 시각적으로 쉽게 이해할 수 있도록 압축적으로 정리되어 있는 서비스가 필요함. 이는 데이터베이스를 활용한 연구를 진행하고자 하는 연구자들의 진입 장벽을 낮추고 새로운 연구들을 디자인 하는 것에 큰 도움이 됨. 특히, 벤치마크 데이터셋과 벤치마크 AI 모델의 성능을 공개함으로써, 데이터 분석가들과 AI 모델 개발자들로 하여금 더욱 발전된 발달장애 아동 조기진단 AI 모델의 개발을 촉진할 수 있음. 이에 본 연구팀은 본 연구들을 통해 표집한 데이터들을 표준화하고, 웹 기반의 카탈로그 시스템과 벤치마크 데이터셋의 형태로 데이터베이스를 공개하고자 함. 뿐만 아니라, 이 데이터들로 진행된 연구 결과들을 시각화 하여 제공하는 서비스를 카탈로그 시스템에 통합시킴으로써, 관련 연구들의 동향을 계속해서 업데이트 해나가고 이를 통해 새로운 연구들을 촉진하는 선순환 구조를 만들고자 함. 특히 데이터 수집의 표준화와 품질 관리를 위한 체계적인 가이드라인을 작성하여, 연구자들과 임상가들이 발달장애 아동에 대한 데이터를 효율적으로 분석하고 활용할 수 있는 강력한 도구를 제공하고자 함.
다양한 모달리티	다양한 모달리티의 데이터들로부터 신규 바이오마커 발굴을 위한 연구는 자폐 스펙트럼

데이터로부터 신규 바이오마커 발굴	장애(ASD)와 같은 발달장애에 대해 더욱 깊이 있는 이해와 효과적인 진단 방법을 제공함. 최근에는 대규모 뇌영상 데이터셋을 활용하여 딥러닝 모델의 예측 성능을 향상시키고자 하는 연구가 활발히 이루어지고 있음. 이러한 연구는 특히 다양한 연령대의 데이터를 분석함으로써 소아 발달장애의 특정 바이오마커를 발굴할 수 있는 가능성을 제시하고 있음. 또한, 오믹스 데이터를 통한 접근은 ASD의 유전적 및 환경적 요인을 밝혀내고, 이를 통해 정량적인 바이오마커를 개발함으로써 진단과 치료에 활용될 수 있는 새로운 방법론을 제공함. 이러한 연구는 전통적인 임상 진단 방법의 한계를 극복하고, 발달장애의 조기 진단 및 개인화된 치료 전략 개발에 크게 기여할 것으로 기대됨. 이에 본 연구팀에서는 기계학습을 활용한 뇌이미징과 유전체 분석 연구 뿐만 아니라 다양한 오믹스 데이터를 활용한 발달장애 위험 점수 기반의 연구들을 통해서 다양한 모달리티의 데이터들로부터 발달장애에 대한 신규 바이오마커를 밝혀내고자 함. 이를 위해 경제성, 효율성, 과학적 정확성, 추후 임상적 유용성 등을 기준으로 하여, 유전자 패널을 제작하고 오믹스 데이터의 종류를 선정하는 과정 등을 평가 목표로 설정함.
발달장애 조기진단을 위한 다중 모달리티 데이터 통합 AI 모델 개발 및 검증	최근 AI 연구의 패러다임은 다양한 모달리티의 대용량 데이터를 활용하여 자기지도학습하는 파운데이션 모델로 전환되고 있음. 이러한 모델들은 다양한 데이터를 사전 훈련시킨 후, 특정 응용 분야의 소량 데이터로 미세 조정을 통해 탁월한 성능을 발휘함. 이미지, 오디오, 동영상 등 다양한 모달리티를 통합할 수 있는 심층 신경망 개발은 특히 발달장애의 조기 진단과 예후 예측에 중요함. 예를 들어, Google Research의 Med-Palm M이나 Microsoft의 LLaVA-med와 같은 프로젝트는 의료 이미지와 텍스트를 넘어 다수의 의료 데이터 형식을 처리할 수 있음을 입증하고 있으며, 이는 뇌영상 데이터와 유전 데이터를 포함한 다양한 의료 데이터를 효과적으로 분석할 수 있는 가능성을 시사함. 특히 이러한 모델은 제한된 샘플에서도 높은 예측 정확도와 일반화 능력을 발휘할 수 있도록 도와주며, 특히 연합학습과 같은 기술을 통해 다기관 데이터의 통합이 가능하므로, 다양한 임상 환경에서의 응용이 기대됨. 그러나 발달장애의 특성상 데이터 불확실성 관리와 적절한 도메인 적응, 일반화 기술의 적용이 필수적이며, 이를 위해 샘플 효율성과 불확실성

	정량화에 중점을 둔 연구 개발이 요구됨. 이런 접근법은 발달장애 아동의 조기 진단 및 치료에 크게 기여할 수 있으며, 임상 의사결정의 신뢰성을 높이고 의료 비용을 절감하는데 중요한 역할을 할 것임. 본 연구팀에서 진행할 이러한 멀티모달 AI 모델의 개발과 적용은 발달장애 연구 및 치료 분야에 혁신을 가져올 것으로 기대됨.
발달 지연 조기진단을 위한 AI 모델과 바이오마커의 임상적 유용성 검증	본 연구를 통해서 새롭게 발굴된 다양한 바이오마커와 새롭게 개발될 다중 모달리티 데이터 기반의 AI 솔루션은, 그 임상적 유용성을 다각적으로 검증하는 과정을 거칠 필요가 있음. 이에 본 연구진은 다각적인 임상적 유효성 평가를 진행할 예정임. 신규 바이오마커의 임상적 유효성을 평가하기 위해, 아동들의 바이오마커 대사체와 전사체를 동물 모델에 이식하여 분석 및 검증하는 과정에서부터 신규 바이오마커가 중재치료를 통한 증상 개선을 반영하는지를 종합적으로 검증하고자 함. AI 솔루션의 임상적 유효성을 평가하기 위해서, 이중맹검을 통한 AI 모델의 임상 소견에 대한 타당성 검증에서부터 AI 솔루션의 UI/UX의 접근성과 사용성에 대한 평가에 이르는 전체적인 검증 및 피드백을 바탕으로 한 개선을 진행하고자 함. 이러한 전방위적인 임상적 유효성 검증과 사용 편의성에 대한 평가는, 본 연구들을 통해서 개발될 진단 도구들을 제품화하고 사업화하여 실질적인 임상 보조 도구로서의 적용에까지 나아갈 수 있도록 하는 데에 중요한 역할을 할 것임.

3. 연구개발과제의 내용, 추진체계 및 일정

3-1. 연구개발과제의 내용(추진전략 및 방법)

가. 1단계 - 1차 연도: 플랫폼 구축 및 AI 모델 개발을 위한 멀티모달 데이터 수집, 정제, 표준화

연구개발 목표 1-1: 고품질의 소아 발달장애 바이오메디컬 빅데이터 구축을 위한 멀티모달 데이터 정의, 수집, 및 다기관으로의 전송




그림 13. 연구개발목표 1-1의 요약

세부목표 1-1-1. 국내외 공공데이터 탐색 및 선행연구 등을 통한 플랫폼 구축 대상 멀티모달 데이터군 정의 및 단위 확립과 기존 공공데이터에 수가 부족하거나 없는 데이터에 대한 다기관 다시점 후향적 멀티모달 데이터 변수 단위 설정 및 수집

[1. 근거 및 배경]

- 배경에 서술한 바와 같이 국내·외 뇌영상 공공데이터는 대부분 성인을 대상으로 하고 소아 영상은 그 수가 절대적으로 부족함. 또한, 일부 아동 데이터의 경우도 대부분 6세

전송하여 추후 공개를 위한 작업을 진행하고자 함.

[2. 최종 목표]

- 국내외 공공데이터 탐색 및 선행연구 등을 통한 플랫폼 구축 대상 멀티모달 데이터군 정의 및 단위 확립
- 다기관 다시점의 후향적 멀티모달 데이터의 정의와 수집 및 전송
- 수집 중인 후향적 데이터의 정제
- 연구개발 고도화를 위한 모자 연계 데이터 제공
- 수집 데이터 선정과 AI 모델 개발과정 초기부터 인허가를 위한 가이드라인 제공

[3. 접근]

[국내외 공공데이터 탐색 및 선행연구 등을 통한 플랫폼 구축 대상 멀티모달 데이터군 정의 및 단위 확립]

- 임상데이터와 뇌영상 데이터 정의 및 단위 확립
 - 연구 참여기관 분당차병원은 수년 간 추적관찰이 이루어진 8개월~10세 소아의 다시점 소아 발달장애의 다면적 임상평가(베일리 발달, 웨슬러 지능, 행동척도, 대동작, 시지각, 소근육 등) 연계 뇌영상(기본 MRI와 DTI)를 2000례 이상 보유하고 있어 이 데이터를 제공하고자 함.
 - 분당차병원이 축적한 MRI 데이터들은 일반 MRI 대비 3D Volumetry를 통해 뇌의 특정부위의 부피나 면적, 특정 섬유다발의 굵기 등을 정량화 하여 정확한 뇌의 구조적 정보를 파악할 수 있고 이를 일반인과 비교할 수 있다는 장점이

있음. 또한, 이 데이터는 DTI 분석을 통해 뇌의 백질 섬유 다발을 시각화 하고 그 연결성을 분석하는 데 용이하며, 이를 통해 도출된 뇌 영역 간 연결 강도를 측정하여 뇌의 기능적 연결성을 파악하는데 강점으로 작용함.

- 뇌의 구조적인 이상/손상 여부나 미세구조적 발달이상을 확인하기 위한 도구인 MRI와 뇌기능을 확인하기 위한 도구인 fMRI 분석에서도 다년간의 연구를 통해 분석에 가장 최적화된 파라미터를 확립하였음. GE Signa System(General Electric, Milwaukee, WI, USA)사의 GE SIGNA HDxt 3T, GE SIGNA Architect 3 장비를 활용하여 뇌구조와 뇌기능과 관련된 뇌영상을 습득할 수 있도록 아래 파라미터를 구축함.

- 뇌구조 영상 파라미터(예)

- 3DT1 MRI : resolution T1-weighted fast-spoiled grass gradient recalled(FSPGR) 3D MRI sequence, TR(Time of repetition) 8.9~10.3ms, TE(Time of echo) 1.2~1.6ms, flip angle(FA) 10° , voxel size 1x1x1mm
- Diffusion tensor image : TR/TE 107~110/9.8~14.5, FA = 90° , voxel size = 2x 2 x2

- 뇌기능 영상 파라미터(예)

- Resting state fMRI : T2* weighted echo-planar imaging, 180 volumes, 45 slices, slice thickness 3.5 mm, FOV 240 mm, TR 3000ms, TE 30ms, FA 90° , voxel size 1.9x1.9x3.0mm, flare

[다기관 다시점의 후향적 멀티모달 데이터의 정의와 수집 및 전송]

- 발달장애 환자 대상 확보된 다시점 멀티모달 데이터

- 분당차병원 재활의학과에서는 선행연구를 통하여 2010년부터 자폐, 지적 장애, 발달 지연, 뇌성마비, 다운증후군 등 다양한 질환군의 8개월~10세 아동들을 대상으로 2500례 이상의 임상평가 연계 뇌영상 데이터를 확보 중임.
- 임상 데이터에는 기능별 연령에 맞는 베일리 발달평가, 웨슬러 지능평가, 이상행동 및 자폐 평가, 언어평가(수용, 표현 등), 대동작 기능평가, 소근육 평가, 시지각 평가 및 일상생활 자조능력 평가 등이 포함되며 이러한 결과들이 시계열적으로 축적되어 있음.

1. 연계된 임상 데이터 중 GDD, ASD, ID에 초점을 맞춘 도구들을 선별하고 도구 별로 가장 효과적인 변수를 정의하여야 함.
2. 또한 정의된 변수에서 사용에 가장 적합한 단위를 설정하는 과정이 필요함.

- 예를 들어, 발달 평가 도구 중 하나인 베일리 영유아 발달검사 3판의 경우 검사자가 인지, 언어, 운동 영역의 평가를 시행하며, 부모 설문을 통해 사회-정서발달, 적응행동 발달까지를 평가함. 각 영역은 평가 결과에 따라 원점수, 척도 점수, 발달 지수, 백분위 점수, 발달 월령 등의 변수 지표를 제공함. 연구 목적에 따라 원점수나 발달 월령을 분석하기도 하지만, 연령에 따른 변화를 제외하고 판단하기 위해 척도 점수나 발달 지수, 백분위 점수를 분석하기도 함.

3. 공공데이터와 선행 연구 논문 등에서 제공하는 진단기준과 기능 평가 점수 등을 검토하여 변수 정의 및 단위 선정을 진행하고, 추후 분석에서 활용할 수 있는 지침을 제공할 수 있도록 해야 함.

4. 뇌영상은 GE Signa System(General Electric, Milwaukee, WI, USA)사의 GE SIGNA HDxt 3T, GE SIGNA Architect 3 장비를 활용하여 뇌구조와 뇌기능과 관련된 뇌영상을 습득할 예정임.

- 뇌의 해부학적 구조 및 신경로의 변화 파악을 위한 뇌기능 영상 데이터, 대동작 및 시각-운동 협응 능력을 파악하기 위한 운동평가 데이터, 발달 상태 및 감각통합 기능을 파악하기 위한 작업평가 데이터, 수용 및 표현 언어발달 상태를 파악하기 위한 언어평가 데이터, 지능 및 사회적 행동 등을 파악하기 위한 심리평가 데이터 등의 수집을 통해 발달장애를 가진 아동의 기능 및 상태를 다면적으로 파악하고 정확한 진단명과 데이터가 연계되어 있음.
- 초진부터 치료 주기마다 시계열 데이터가 수집되고 있어 중재 진행에 따른 데이터를 습득하고 있으며, 저연령 때부터 연속 수집이 되어 있음.
- 분당차병원에 확보된 멀티모달 데이터 요소는 초기 검사결과를 포함하고 있기 때문에 예후 예측 모델 개발에 레퍼런스가 될 수 있음.

측정요소	수집요소
임상적 기초 데이터	• 개인 인적사항 - 나이, 성별, 재태 연령, 유전자 검사 소견 • 신체 계측 - 키, 체중
발달평가	• 베일리 영유아 발달검사 2판(Bayley Scales of Infant Development-second edition, BSID-II) • 베일리 영유아 발달검사 3판(Bayley Scales of Infant Development-third edition, BSID-III) • 뮌헨기능발달검사(Munchener Funktionelle Entwicklungs Diagnostic, MFED) • 덴버 발달 선별 검사(Denver Developmental Screening Test, DDST) • 감각프로파일 검사(Sensory Profile, SP)
인지평가	• 지능 검사(Wechsler preschool and primary scale of intelligence, WPPSI/Wechsler intelligence scale for children. WISC) • Beery 시각-운동통합검사(Beery Visuo-Motor Integration, Beery-VMI)

행동, 사회성 평가	• 아동/청소년 행동 평가 척도(Child Behavior Checklist, CBCL) • 아동기 자폐증 평정 척도(Childhood Autism Rating Scale, CARS) • 유아기 자폐증 평가 척도(Modified Checklist for Autism in Toddler, M-CHAT) • 자폐증 진단관찰 스케줄 2(Autism Diagnostic Observation Schedule, ADOS-2) • 사회성숙도검사(Social Maturity Scale, SMS)
언어평가	• 영유아 언어발달 검사(Sequenced Language Scale for Infants, SELSI). • 취학전 아동 수용언어 및 표현언어 척도 평가(Preschool Receptive-Expressive Language Scale, PRES) • 수용표현 어휘력 검사(Receptive & expressive vocabulary test, REVT) • 학령기 아동 언어검사(Language Scale for School-aged Children, LSSC) • 아동용 발음평가(Assessment of Phonology and Articulation for Children, APAC) • 우리말 조음음운검사2(Urimal Test of Articulation and Phonology 2, UTAP2)
자조능력 평가	• 아동용 일상생활 기능독립측정평가(Functional Independence Measure for Children, Wee-FIM)
운동평가 데이터	• 대동작수행능력평가(Gross Motor Performance Measure, GMPPM) • 대동작기능평가(Gross Motor Function Measure, GMFM) • 손기능평가도구(Erhardt Developmental Prehesion Assessment, EDPA) • 협응동작 평가(Purdue pegboard test) • 알버타 영아 운동 척도(Alberta Infant Motor Scale, AIMS)
의료영상 데이터	• 자기공명영상(Magnetic Resonance Imaging, MRI) • 확산텐서영상(Diffusion Tensor Imaging, DTI) • 기능적자기공명영상(Functional Magnetic Resonance Imaging, fMRI) • 복부를 포함한 whole spine AP X-ray
유전체 데이터	• 고해상도 염색체(high resolution chromosome) • Multiple ligation dependent probe amplification assay(MLPA) • Chromosomal microarray(CMA) • Whole exome sequencing

표 3. 분당차병원 확보 멀티모달 데이터 요소

- 다기관 발달장애 아동 대상 데이터 수집 및 데이터 공유를 위한 라벨링과 추가 요소
데이터 확립 및 수집
 - 분당차병원 재활의학과에서는 대부분의 임상평가와 뇌 영상 데이터에

대해서는 선행연구를 통하여 2000례 이상 라벨링을 완료함.

- 확보는 하고 있으나 라벨링과 정제가 부족한 X-ray와 일부 임상 평가들에 대해서 1차연도 내 라벨링 완료와 플랫폼 전송을 목표로 함.
- 다기관 후향적 데이터 확보를 위해 분당차병원에서의 데이터 수집 요소를 기준으로 하여 충남대학교 내원 환아를 대상으로 후향적 데이터를 확보할 것임.
- 임상 표현형 데이터 수집의 표준화를 위한 데이터 입력 및 공유 프로세스 확립함.

[수집 중인 후향적 데이터의 정제]

- 플랫폼으로 임상 데이터 제공을 위한 후향적 데이터의 정제
 - 다기관 후향적 수집 데이터의 공유를 위한 개인정보 익명화
 - 다기관 후향적 수집 데이터들의 항목별 단위 확립
 - 예를 들어, 베일리 발달 검사에서는 원점수, 척도 점수, 발달 지수, 백분위 점수, 발달 월령 등의 변수 지표 중 발달 지수인 $DQ(\text{Developmental Quotient}) = \{(\text{development age})/(\text{chronological age})\} \times 100$ 의 결과를 단위로 설정 가능함. DQ가 85점 이상인 경우 normal, 71-84점 mild-to-moderate delay, 70점 이하 severe delay로 대상자를 범주화 함.
 - 다기관 후향적 수집 임상 데이터의 AI 모델 활용을 위한 의학적 분류 기준과 개발기관의 니즈에 맞는 데이터별 표준화

[필요시 연구개발 고도화를 위한 모자 연계 데이터 제공]

- 공공데이터에 부족한 대조군 데이터를 위하여 분당차병원 기관 자체 구축하고 있는 데이터를 활용할 수 있음.




그림 15. 분당차병원 기관 자체 구축 데이터 플랫폼

[수집 데이터 선정과 AI 모델 개발과정 초기부터 인허가를 위한 가이드라인 제공]

- 식약처 최신 규정에 따른 가이드라인을 마련하고자 함.
- 본 연구 개발물은 질병을 진단·예측하는 임상결정지원(Clinical Decision Supporting, CDS) 소프트웨어나 의료영상진단보조(Computer-Aided Detection/Diagnosis, CAD) 소프트웨어를 포괄하는 기계학습 가능 의료기기(Machine Learning-enabled Medical Devices, MLMD)의 범위에 들어감.

- 해당 연구결과물이 임상현장에 빠르게 적용되고 실용화가 되기 위해서는 개발 초기부터 인허가 과정을 고려한 설계가 필수적임.
- AI 모델 개발을 위한 훈련 데이터 셋을 편향(bias)을 고려하여 설정해야 하며, 편향의 유형과 원인은 ISO/IEC TR 24027을 기준으로 대표적 편향은 아래와 같음.
 1. 인지 편향(자동화 편향, 사회적 편향, 확증 편향을 포함)
 2. 데이터 편향(통계학적 편향, 데이터 처리 편향, 데이터 집계 편향을 포함)
 3. 공학적 결정에 따른 편향[예: 변수 가공(feature engineering), 알고리즘 선정 및 모델 편향]
- 기술문서 작성을 위하여 의료기기 허가·신고·심사 등에 관한 규정」 제26조(심사자료의 종류 및 범위 등) 및 제28조(심사자료의 면제)와 [별표 7]의 ‘기술문서 등 제출 자료의 범위’에 따라 작성될 수 있도록 가이드 제공함.

세부목표 1-1-2. 데이터 수집 및 제공을 위한 IRB/DRB 승인

[1. 근거 및 배경]

- 분당차병원의 데이터는 아직 공개되지 않은 데이터이므로 K-BDS에 기탁 및 공개하기 위해서는 데이터심의위원회(DRB)의 승인을 획득해야 함. 또한 소아 임상 데이터를 이용한 연구를 수행하기 위해서 기관생명윤리위원회(IRB)의 승인을 얻을 필요가 있음.

[2. 최종 목표]

- 확보하고 있는 데이터의 외부기관 제공을 위한 기관 데이터심의위원회 승인 획득
- 다시점 멀티모달 전향적 데이터 확보를 위한 코호트 데이터 수집 연구의 기관윤리심의위원회 승인용 임상연구계획서 작성 및 신청

[3. 접근]

- 확보하고 있는 데이터의 외부기관 제공을 위한 기관 데이터심의위원회 승인 획득
 - 익명화와 데이터 표준화는 주관 및 공동2 기관인 루먼랩과 협력하여 자동화함.
- 다시점 멀티모달 전향적 데이터 확보를 위한 코호트 데이터 수집 연구의 기관윤리심의위원회 승인용 임상연구계획서 작성 및 신청
 - 우수한 데이터의 신속하고 많은 확보를 위하여 충남대학교 병원과 다기관으로 데이터를 획득함.
 - 본 기관은 다기관 소아 데이터 수집 경험이 풍부하며, 뇌영상, 임상평가, 유전자 등에 본 과제에서 목표로 하는 데이터에 대하여 오랜 기간 수집을 진행하고 있음.

통지서

※ 본 계획의 문서보존기간은 3 년입니다.					
연구책임자	재활의학과 장민영				
연구책임자	CHAMC	심사위원	심장계획서	통지일자	2024.01.04
연구과제명	발달 지연을 보이는 아동의 원인 규명을 위한 연구				
연구과제명	A study to identify the causes of developmental delay in children				
임상시험코드	Study Nick Name				

통지서

※ 본 계획의 문서보존기간은 3 년입니다.					
연구책임자	재활의학과 장민영				
연구책임자	CHAMC	심사위원	심장계획서	통지일자	2024.04.22
연구과제명	자폐 스펙트럼 장애 조기 진단을 위한 행동 기반 선별 초도도를 개발을 위한 (초량적) 대량 조사형 연구				
연구과제명	A pilot study to develop a behavior based screening protocol for early diagnosis of autism spectrum disorders				
임상시험코드	Study Nick Name				

통지서

※ 본 계획의 문서보존기간은 3 년입니다.					
연구책임자	재활의학과 장민영				
연구책임자	CHAMC	심사위원	심장계획서	통지일자	2023.11.01
연구과제명	발달장애 시각적 통각 연구(Berry-Vivi)의 인공지능 기반 분석 솔루션 개발을 위한 다기관 실험 연구				
연구과제명	A multicenter empirical study to develop an artificial intelligence based analytics solution for the Visual Perception Assessment for Developmental Disabilities (Berry-Vivi)				
임상시험코드	Study Nick Name				

통지서

※ 본 계획의 문서보존기간은 3 년입니다.					
연구책임자	재활의학과 장민영				
연구책임자	CHAMC	심사위원	심장계획서	통지일자	2024.02.08
연구과제명	소아 biphenyl 계열을 위한 재활치료 data 다기관 연구				
연구과제명	A pilot study to develop a behavior based screening protocol for early diagnosis of autism spectrum disorders				
임상시험코드	Study Nick Name				

그림 16. 소아 관련 주요 IRB 승인 현황

세부목표 1-1-3. 2단계 임상적 유효성 검증 및 융합 모델 개발을 위한 전향적 코호트 데이터 수집을 위한 프로토콜 설계와 수행 시작

[1. 근거 및 배경]

- 소아 발달장애의 특성상 시간이 경과함에 따라 생기는 신경학적 변화가 분명하기 때문에 다시점 데이터를 수집하는 것이 필수적임. 이는 아동의 예후 예측이나 바이오마커 발굴을 통한 질환의 조기 진단에도 도움이 됨.
- 분당차병원에서는 멀티모달 데이터를 치료 주기마다 수집하여 여러 시점의 데이터를 이미 구축해 두었음. 이를 기반으로 다시점 데이터 수집 프로토콜을 점검하고 개선한다면 하나의 시점만을 포함한 데이터가 갖는 한계 극복할 수 있을 것임.

[2. 최종 목표]

- 다면적, 다시점 전향적 멀티모달 데이터 확보

[3. 접근]

- 전향적 코호트 데이터 수집 프로토콜 설계 및 확립
 - 다면적, 다시점 전향적 데이터 확보를 위한 측정 및 수집 요소 선정
 1. 발달장애의 다양한 특성을 정확하게 파악하는 데 필요한 추가적인 임상 검사들을 검토하고, 표준 임상 프로토콜을 설계함.
 2. 수집 중인 다시점 후향적 데이터를 기반으로 뇌기능 영상, 임상적 기능 평가 데이터와 더불어 유전체 및 단백체 데이터 추가 수집 요소 선정함.
 3. 기존에 수집된 임상 데이터를 바탕으로 추가 수집 요소의 데이터 특성에 최적화된 표준화, 정제 방안을 마련함.
 4. 개발되는 다양한 AI 모델의 향후 유효성 검증을 위한 우수한 시험

데이터 셋 생성을 위한 훈련 데이터 셋과 분리된 전향적 멀티모달 데이터 확보함.

5. 전향적 멀티모달 데이터의 윈도우는 6개월 간격 2회 이상 수집 목표로 함.

측정요소	수집요소
임상적 기초 데이터	• 개인 인적사항 - 나이, 성별, 재태 연령, 유전자 검사 소견 • 신체 계측 - 키, 체중
발달평가	• 베일리 영유아 발달검사 3판(Bayley Scales of Infant Development-third edition, BSID-III) • 뮌헨기능발달검사(Munchener Funktionelle Entwicklungs Diagnostic, MFED) • 덴버 발달 선별 검사(Denver Developmental Screening Test, DDST) • 감각프로파일 검사(Sensory Profile, SP)
인지평가	• 지능 검사(Wechsler preschool and primary scale of intelligence, WPPSI/ Wechsler intelligence scale for children. WISC) • Beery 시각-운동통합검사(Beery Visuo-Motor Integration, Beery-VMI)
행동, 사회성 평가	• 아동/청소년 행동 평가 척도(Child Behavior Checklist, CBCL) • 아동기 자폐증 평정 척도(Childhood Autism Rating Scale, CARS) • 영유아기 자폐증 평가 척도(Modified Checklist for Autism in Toddler, M-CHAT) • 자폐증 진단관찰 스케줄 2(Autism Diagnostic Observation Schedule, ADOS-2) • 사회성숙도검사(Social Maturity Scale, SMS)
언어평가	• 영유아 언어발달 검사(Sequenced Language Scale for Infants, SELSI). • 취학전 아동 수용언어 및 표현언어 척도 평가(Preschool Receptive-Expressive Language Scale, PRES) • 수용표현 어휘력 검사(Receptive & expressive vocabulary test, REVT) • 학령기 아동 언어검사(Language SScale for School-aged Children, LSSC) • 아동용 발음평가(Assessment of Phonology and Articulation for Children, APAC) • 우리말 조음음운검사2(Urimal Test of Articulation and Phonology 2, UTAP2)
자조능력 평가	• 아동용 일상생활 기능독립측정평가(Functional Independence Measure for Children, Wee-FIM)
운동평가 데이터	• 대동작수행능력평가(Gross Motor Performance Measure, GMPPM) • 대동작기능평가(Gross Motor Function Measure, GMFM) • 손기능평가도구 Erhardt Developmental Prehesion Assessment(EDPA) • 협응동작 평가 Purdue pegboard test • 알버타 영아 운동 척도(Alberta Infant Motor Scale, AIMS)

의료영상 데이터	• 자기공명영상(Magnetic Resonance Imaging, MRI) • 확산텐서영상(Diffusion Tensor Imaging, DTI) • 기능적자기공명영상(Functional Magnetic Resonance Imaging, fMRI) • 복부를 포함한 whole spine AP X-ray
유전체 데이터	• 아동 및 가계에 대한 genome-wide SNP data • 아동 및 가계에 대한 Whole exome sequencing • 아동 및 가계에 대한 CNV data • Transcriptome analysis(RNA-seq) • Non-coding RNA-seq
대사체 데이터	• 동물 모델 및 아동의 혈액에서 대사체(metabolites) • 동물 모델 및 아동의 분변에서 장내 미생물의 대사체(metabolites) • 동물 모델 및 아동 분변에서 장내세균 유전체(gut microbiome)

표 4. 전향적 시계열 데이터 수집 요소(분당차병원/충남대학교병원)

연구개발 목표 1-2: 멀티모달 뇌영상 데이터 수집, 정제, 표준화



그림 17. 연구개발목표 1-2의 요약.

세부목표 1-2-1. 구조, 확산, 기능 뇌영상 데이터 수집 및 큐레이션

[1. 근거 및 배경]

- 뇌 자기공명영상은 비침습적이며 부작용 없이 사람의 뇌 구조와 기능을 연구할 수 있게끔 하는, 뇌과학 연구에 있어 핵심적인 데이터임. 지난 수십년간 뇌영상을 활용한 연구들이 활발하게 수행됐으며, 그 과정에서 인간의 뇌 발달 궤적에 대한 신경과학적 지식 또한 상당히 축적되었음. 특히, 뇌의 발달이 빠른 속도로 이뤄지는 영유아의 뇌 발달 궤적을 밝혀내고자 구조, 확산, 그리고 기능 뇌영상과 같이 다양한 모달리티의 데이터가 활용되어 옴^{66 67 68}.

⁶⁶ Giedd, J. N., & Rapoport, J. L.(2010). Structural MRI of pediatric brain development: what have we learned and where are we going?. *Neuron*, 67(5), 728-734.;

⁶⁷ Ouyang, M., Dubois, J., Yu, Q., Mukherjee, P., & Huang, H.(2019). Delineation of early brain development from fetuses to infants with diffusion MRI and beyond. *Neuroimage*, 185, 836-850.

⁶⁸ Zhang, H., Shen, D., & Lin, W.(2019). Resting-state functional MRI studies on infant brains: a decade of gap-filling efforts.

- 최근 들어, 뇌영상 분야가 AI 기술의 발달과 대규모 뇌영상 데이터셋 공개에 힘입어 새로운 국면에 접어들고 있음. 이러한 연구는 기존의 집단간 통계분석을 넘어서서 각종 뇌질환의 진단과 질환 예후의 더욱 정밀한 예측 및 발달장애의 이질적(heterogeneous)이고 복잡한 신경과학적 기전에 대한 이해를 가능케 함. 최근 Science지에 발표된 연구인, 자폐 스펙트럼 장애 임상군과 정상군을 분류하고 각 집단에 특이적인 뇌의 구조적 특징 및 두 집단이 공유하는 특징을 밝히는 딥러닝 연구가 그 예시임⁶⁹.
- 하지만, 소아 발달장애를 연구하기 위한 뇌영상 데이터셋은 국내뿐만 아니라 전세계적으로도 잘 구축되어 있지 않음. 왜냐하면 개별 병원 차원에서 의료 데이터를 정제하고 공개하기가 어려울 뿐더러 발달장애 임상군 소아 데이터가 절대적으로 부족하기 때문임. 2024년 5월 기준 청소년 이하의 나이대를 포함하는 공개 뇌영상 데이터셋의 예시는 아래의 표 5와 같음. 해외 데이터셋과 비교했을 때 현재 국내에 공개되어 있는 뇌영상 데이터셋의 규모는 현저하게 작으며, 영유아의 뇌영상을 포함하고 있지 않음. 따라서, 분당차병원에 이미 확보되어 있는 약 2000례의 소아발달 뇌영상 데이터를 정제하여 공개하는 것만으로도 소아 발달장애 연구에 있어 큰 도움이 될 것임. 특히, 분당차병원에 수집되어 있는 데이터는 멀티모달인 구조와 확산 뇌영상으로 아동 뇌 구조의 거시적인 측면과 미시적인 측면을 모두 살펴볼 수 있다는 장점이 있음.

데이터셋	규모(N)	연령(만 나이)	MRI 모달리티
AI Hub 소아청소년 심리검사 및 뇌영상 데이터	254	6-11	구조, 기능

Neuroimage, 185, 664-684.

⁶⁹ Aglinskas, A., et al .(2022). Contrastive machine learning reveals the structure of neuroanatomical variation within autism. *Science*.

ABCD(Adolescent Brain Cognitive Development) study	11759	9-10	구조, 확산, 기능
HCP Development	652	5-21	구조, 기능
Lifespan Baby Connectome Project	500	0-5	구조, 기능
Developing Human Connectome Project(dHCP)	1056	1.6-3.6 (Gestational age)	구조, 확산, 기능
Large dataset of infancy and early childhood brain MRIs	833	0-3	구조
Healthy Brain Network	3448	5-21	구조, 확산, 기능
Enhanced Nathan Kline Institute – Rockland Sample	771	5-85	구조, 확산, 기능
Calgary Preschool MRI Dataset	126	2-6	구조, 확산, 기능

표 5. 청소년 이하의 피실험자를 포함한 공개 뇌영상 데이터셋의 예시

- 한편, 뇌영상 연구의 고질적인 문제인 재현가능성 문제를 해결하기 위해서는 재현가능하며 표준화된 뇌영상 전처리의 사용, 분석 방법의 투명한 공개, 그리고 데이터의 공유가 필수적임⁷⁰. 이러한 문제의식에서 출발한 연구 플랫폼인 brainlife.io는 전세계 뇌과학 연구자들이 신경과학 데이터, 전처리 파이프라인, 분석 앱 등을 공유할 수 있도록 재현가능하며 투명한 연구 생태계를 구축함⁷¹. 본 플랫폼을 활용하여 소아 뇌영상 데이터를 정제하고 공개한다면 동일한 파이프라인으로 전처리된 기존 데이터들 및 추후에 수집되어 정제될 데이터와의 융합이 용이해질 뿐만아니라 글로벌 연구자들의 데이터 접근성이 크게 확장될 것임.

[2. 최종 목표]

- 기확보된 분당차병원의 소아 구조(T1-weighted) 및 확산(Diffusion-weighted)

⁷⁰ Poldrack, Russell A., et al. "Scanning the horizon: towards transparent and reproducible neuroimaging research." *Nature reviews neuroscience* 18.2(2017): 115-126.

⁷¹ Hayashi, Soichi, et al. "brainlife. io: a decentralized and open-source cloud platform to support neuroscience research." *Nature Methods*(2024): 1-5.

뇌영상 데이터 2000례 이상 수집 및 큐레이션

- 추가로 확보한 소아 구조(T1w), 확산(DWI), 기능(sleeping fMRI) 뇌영상 데이터 300례 전처리 및 큐레이션
- 재현가능하며 표준화된 방식의 뇌영상 전처리, 정제 및 데이터 공개

[3. 접근]

- 분당차병원의 소아 뇌영상 기존 데이터 큐레이션 및 추가 데이터 수집, 정제
 - 분당차병원의 데이터는 아직 공개되지 않은 데이터이므로 K-BDS 데이터 기탁을 위하여 분당차병원 데이터 심의위원회와 서울대학교 IRB에 연구 승인을 받는 과정을 먼저 거칠 예정임. 그 이후, 기존에 확보된 2000례의 분당차병원 발달장애 임상군 소아 구조(T1w) 및 확산(DWI) 뇌영상을 뇌영상 데이터 구조의 표준인 BIDS 형태로 정리할 것임. 전처리 이전의 데이터는 주관기관인 서울대학교 커넥톰랩의 보안화된 연구실 서버 스토리지로 전송하여 관리할 계획임.
 - 또한 연구 수행기간 동안 추가로 임상 및 정상 소아의 구조(T1w), 확산(DWI), 기능(sleeping fMRI), 그리고 정량적 자화율 매핑 영상을 위한 경사 에코(GRE) 뇌영상 약 300례를 수집하고 전처리를 위해 서울대학교 커넥톰랩의 연구실 서버에 전송하여 저장할 것임.
- 재현가능하며 표준화된 뇌영상 전처리 및 정제
 - 이렇게 확보된 뇌영상은 모두 brainlife.io의 전처리 파이프라인을 통해 정제함. 이때, 대부분의 전처리 파이프라인은 소아가 아닌 성인에게 맞춰져 있기

때문에 영유아의 뇌영상에 적합한 전처리 파이프라인을 업로드하여 사용할 계획임. 모든 뇌 구조, 확, 기능 영상은 기본적으로 developing Human Connectome Project의 pipeline을 사용하여 전처리할 예정임^{72 73 74}. 또한 전처리된 영상의 품질을 확인하고, 필요에 따라 최근에 발표된 딥러닝 기반 뇌영상 전처리 툴을 사용하여 개선된 전처리 파이프라인을 구축할 예정임⁷⁵.

- 전처리된 뇌영상의 quality assessment(QA)나 quality control(QC)와 같은 품질 관리는 일차적으로 자동화된 툴을 사용하여 진행할 예정임. 구조 이미지는 freesurfer용 QC tool인 fsqc, 확산 이미지는 FSL의 eddyQC, 그리고 기능 이미지는 AFNI의 APQC를 사용하여 QA/QC를 수행할 것임. 자동화된 툴에서 QA/QC에 통과하지 못한 이미지들과 QC threshold의 경계에 있었던 이미지들은 직접 데이터를 확인하는 과정을 거친 뒤 제외할 예정임.

[4. 예상되는 난관과 극복 방안]

- 대규모 데이터셋의 수집 및 큐레이션이 필요로 하는 많은 양의 연산 자원과 인적 자원
 - 난관: 2000레 정도의 대규모 뇌영상 데이터를 처리하기 위해서는 많은 양의 CPU, RAM, 그리고 저장공간이 필요함.

⁷² Makropoulos, Antonios, et al. "The developing human connectome project: A minimal processing pipeline for neonatal cortical surface reconstruction." *Neuroimage* 173(2018): 88-112.

⁷³ Fitzgibbon, Sean P., et al. "The developing Human Connectome Project(dHCP) automated resting-state functional processing framework for newborn infants." *NeuroImage* 223(2020): 117303.

⁷⁴ Bastiani, Matteo, et al. "Automated processing pipeline for neonatal diffusion MRI in the developing Human Connectome Project." *Neuroimage* 185(2019): 750-763.

⁷⁵ Wang, Li, et al. "iBEAT V2. 0: a multisite-applicable, deep learning-based pipeline for infant cerebral cortical surface reconstruction." *Nature protocols* 18.5(2023): 1488-1509.

- 극복 방안: brainlife.io를 사용하면 해당 플랫폼에서 제공하는 연산자원을 쓸 수 있으며 책임연구자인 차지욱 교수 연구실은 이미 해당 플랫폼을 사용하여 청소년 뇌영상 데이터를 전처리한 경험이 있기 때문에 본 과제가 요구하는 전처리 과정도 원활하게 수행가능할 것임. 또한 책임연구자인 차지욱 교수 연구실은 96개의 CPU를 탑재한 4개의 연산 노드와 465 TB의 스토리지 노드를 보유하고 있으며, 이외에도 미국 NERSC의 Perlmutter, 국가슈퍼컴퓨팅센터 KISTI, 광주 인공지능산업융합사업단 AICA와 같은 연구용 고성능컴퓨팅 자원이 활용가능한 상황임. 따라서 brainlife.io에 데이터를 업로드하고 연산자원을 활용하는 방안이 실패하더라도 보유 자원을 통해 로컬 환경에서 전처리를 할 수 있음.
- 기 확보된 뇌영상 데이터의 촬영시기별 서로 다른 MRI 프로토콜 문제
 - 난관: 분당차병원의 뇌영상 데이터는 2010년부터 수집되어 왔기에 중간에 MRI 촬영 프로토콜이 몇 차례 변경되었음. 서로 다른 프로토콜로 촬영된 뇌영상은 같은 기기를 사용하였더라도 전처리 이후 데이터 품질에 영향을 미치기 때문에 고품질 데이터셋 구축을 위해서는 이 요소를 고려해야만 함.
 - 극복 방안: MRI harmonization 문제는 여전히 제대로 해결되지 않은 문제이므로 데이터 전처리부터 모델링까지 전부 이를 고려해야 함. 최근에 발표된 MRI harmonization 논문을 참고하여 서로 다른 프로토콜이나 기기의 영향을 최소화하는 방향으로 전처리를 수행하고, 데이터 설명에도 이에 관한 내용을 명시하여 연구에 사용하는 사람들이 숙지할 수 있도록 조치할 예정임⁷⁶.

⁷⁶ Liu, S., & Yap, P. T.(2024). Learning multi-site harmonization of magnetic resonance images without traveling human phantoms. *Communications Engineering*, 3(1), 6.

[5. 기대되는 결과 및 유의성]

- 세계 최초 대규모 소아 발달장애 뇌영상 데이터셋 구축이 본 세부목표의 핵심적인 결과임. 위에서 언급했듯이 소아 뇌영상 데이터는 국내에서 공개된 적이 없음. 더군다나 소아 발달장애 데이터는 전세계적으로도 아직까지 구축된 데이터셋이 없기 때문에 본 데이터셋의 공개는 소아 발달장애의 신경과학적 기전을 연구하는 데 큰 기여를 할 것임. 특히 멀티모달 데이터의 특성상 소아 뇌 발달의 다양한 측면을 복합적으로 연구할 수 있게 될 것임.
- 본 데이터셋을 정제하는 과정에서 재현가능하며 표준화된 파이프라인을 사용할 예정이므로 기존에 동일한 파이프라인을 사용했던 데이터셋과의 융합을 꾀할 수 있음. 또한 추후에 수집될 데이터를 정제할 때에 이미 사용한 파이프라인을 사용한다면 데이터셋의 규모를 점차 확장하는 것도 가능해질 것임.

세부목표 1-2-2. 정량적 자화율 매핑(Quantative Susceptibility Maps 및 χ -separation) 뇌영상 데이터 수집, 정제, 표준화

[1. 근거 및 배경]

- 자기공명 영상을 사용한 자폐 스펙트럼 장애 연구는 다양한 영상법을 활용한 접근 방법이 존재함. 자기공명 영상법을 이용한 해부학적인 연구부터^{77 78}, 미엘린 영상법⁷⁹ (Myelin Water Fraction), 최근의 경우 정량적 자화율 매핑^{81 82 83} (Quantitative Susceptibility Maps)을 활용한 연구 등이 진행되고 있음. 특히 정량적 자화율 매핑의 경우, 철 분자와 자폐 스펙트럼 장애와 관련이 있다는 연구가 알려지며 전세계적으로 자화율 연관 데이터가 생성되고 있는 추세임.
- 본 연구실에서는 이러한 정량적 자화율 매핑과 관련한 연구를 오랫동안 진행하였으며, 정량적 자화율 매핑의 개념을 바탕으로 제작된 딥러닝 기반 정량적 자화율 매핑(QSMnet)을 개발하였음. 딥러닝 기반 정량적 자화율 매핑은 고전 정량적 자화율 매핑(MEDI, TKD)이 가지는 품질 문제를 해결하고, 정확성을 올려 대규모의 자화율 정보를 안정적으로 도출하는 이점을 가지고 있음.
- 더 나아가, 본 연구실은 정량적 자화율 매핑의 한계인 상자성 물질과 반자성 물질이

⁷⁷Pagnozzi, Alex M., et al. "A systematic review of structural MRI biomarkers in autism spectrum disorder: A machine learning perspective." *International Journal of Developmental Neuroscience* 71(2018): 68-82.

⁷⁸Chen, Rong, Yun Jiao, and Edward H. Herskovits. "Structural MRI in autism spectrum disorder." *Pediatric research* 69.8(2011): 63-68.

⁷⁹Kleinhans, Natalia M., et al. "Age-related abnormalities in white matter microstructure in autism spectrum disorders." *Brain Research* 1479(2012): 1-16.

⁸⁰Deoni, Sean CL, et al. "White-matter relaxation time and myelin water fraction differences in young adults with autism." *Psychological medicine* 45.4(2015): 795-805.

⁸¹Du, Lei, et al. "Decreased brain iron deposition based on quantitative susceptibility mapping correlates with reduced neurodevelopmental status in children with autism spectrum disorder." *Cerebral Cortex* 34.13(2024): 63-71.

⁸²Tang, Shilong, et al. "Application of quantitative magnetic resonance imaging in the diagnosis of autism in children." *Frontiers in Medicine* 9(2022): 818404.

⁸³Tang, Shilong, et al. "Quantitative susceptibility mapping shows lower brain iron content in children with autism." *European Radiology* 31(2021): 2073-2083.

작은 영역에 동시에 존재할 경우 두 성질을 구분할 수 없게 되는 문제점을 해결하여 전 세계 최초로 미엘린과 철 분자의 정량적 값을 측정하는 고급 정량적 자화율 매핑⁸⁴(χ -separation)을 개발하였음. 궁극적으로 정량적 자화율 매핑 및 고급 정량적 자화율 매핑을 모두 사용하여 현재 존재하는 자기공명 영상법 중 자폐 스펙트럼 장애의 원인에 대응하는 가장 핵심적인 정보를 제공함.

[2. 최종 목표]

- 자폐 스펙트럼 장애와 철 분자, 그리고 미엘린과 높은 상관관계를 가지고 있음에 따른 자폐 스펙트럼 장애를 위한 자화 영상의 파라미터를 조정하여 자폐 스펙트럼 장애에 최적화된 정량적 자화율 매핑 및 고급 정량적 자화율 매핑 영상 획득.
- 정량적 자화율 매핑과 고급 정량적 자화율 매핑의 최적화 과정 중, 자폐 스펙트럼 장애를 앓고 있는 환자의 영상으로부터 바이오마커를 특정한 후, 바이오마커와 자폐 스펙트럼 장애간 상관관계, 바이오마커의 정확도, 신뢰도 등을 측정.
- 최적화된 영상법을 사용하여 정량적 자화 영상 및 고급 정량적 자화 영상의 데이터의 정제 과정을 거침. 최종적으로 표준화된 영상법을 바탕으로 다량의 고품질 데이터의 수집.

[3. 접근]

- 딥러닝 기반 정량적 자화율 영상법(QSMnet)
 - 정량적 자화율 영상법은 생체 내 철 분자 등 자화율이 있는 분자의 양을 측정할

⁸⁴ Shin, Hyeong-Geol, et al. " χ -separation: Magnetic susceptibility source separation toward iron and myelin mapping in the brain." *Neuroimage* 240(2021): 118371.

수 있는 자기공명영상 기법으로, 파킨슨병, 다계통위축, 자폐 스펙트럼 장애 등 철 분자 관련 질환의 진단에 유용하게 이용될 수 있음.

- 기존의 영상 복원 기술은 복원 단계에서 나타나는 인공물에 의해 이미지의 질이 낮아짐. 이미지의 질을 높이기 위하여 추가 촬영을 진행하면 되지만, 이 또한 촬영 시간이 증가하는 단점이 존재함.
- 본 연구기관에서는, 영상재구성에 인공신경망을 적용하여 MRI 추가 촬영 없이 영상 복원능력을 향상하는 기술을 제시한 바 있음(그림 18). 딥러닝 기반 영상 재구성 방법은 기존의 영상재구성 방법(MEDI⁸⁵, TKD⁸⁶ 등)에 비해 현저히 향상된 품질의 정량적 자화율 지도를 재구성해 내는 데 성공함. 본 기술은 자기공명영상 기법의 하나인 정량적 자화율 영상법(QSM)에 인공신경망(Deep Neural Network)을 적용하여 영상의 품질을 월등히 향상한 것으로 관련 연구에 있어서 세계 최초로 논문으로 제시된 기술임⁸⁷.
- 또한, 주관연구기관에서는 환자의 데이터가 정상군의 데이터에 비해 상대적으로 적은 의료영상 도메인의 특성을 파악하여, 환부의 정량적 자화율을 정확히 매핑할 수 있도록 시뮬레이션 데이터를 이용해 임상데이터에서의 정량적 ‘선형성’을 회복하는 방식을 제안한 바 있음. 이러한 경험을 바탕으로 의료영상 데이터의 불균형한 특성을 고려한 자폐 스펙트럼 장애의 정량적 분석이 가능함.

⁸⁵ Liu, Tian, et al. "Morphology enabled dipole inversion(MEDI) from a single-angle acquisition: comparison with COSMOS in human brain imaging." *Magnetic resonance in medicine* 66.3(2011): 777-783.

⁸⁶ Shmueli, K., de Zwart, J.A., van Gelderen, P., Li, T.-Q., Dodd, S.J., Duyn, J.H., 2009. Magnetic susceptibility mapping of brain tissue in vivo using MRI phase data. *Magn. Reson. Med.* 62(6), 1510–1522

⁸⁷ Yoon, Jaeyeon, et al. "Quantitative susceptibility mapping using deep neural network: QSMnet." *Neuroimage* 179(2018): 199-206.




그림 18. QSMnet의 개념도 및 결과. 인공신경망을 이용하여 MRI 측정 영상으로부터 정량적 자화율 영상을 복원하는 기술로 그 결과는 기존 영상재구성 방법(TKD, MEDI)과 대비 월등히 향상된 결과를 보여줌.




그림 19. 동일한 뇌 영상을 기반으로 재구성할 경우, 기존 방식 대비 딥러닝 방식의 재구성 상자성 영상에서 안정적으로 품질 개선 효과를 보여줌.

- 생체물리학적 모델링 기반의 고급 정량적 자화율 매핑(χ -separation)

- 정량적 자화율 매핑은 신경퇴행성질환 연구에 널리 쓰임. 하지만 기존 방식에서는 한 복셀(3차원 픽셀) 내 상자성 물질과 반자성 물질이 동시에 존재할 경우, 이들의 서로 반대되는 자화율이 상쇄되어 개별적 값을 확인할 수 없음.
- 본 연구실에서는 이러한 한계를 극복하고자, 한 복셀 내부의 마이크로미터 크기 미세구조체에 대한 정보를 자성체의 성질을 활용해 영상화하는 새로운 자기공명 영상 기술을 개발하였음. 이 기술은 철(상자성)과 미엘린(반자성)을 개별적으로 정량화할 수 있는 능력을 제공함.
- 본 연구의 기술을 다중 모달 데이터에 포함하여 사용하면 딥러닝을 진행할 때, 보다 상세한 정보를 네트워크에 입력함으로써 진단 성능 향상에 기여할 것으로 예상됨. 이 새로운 기술은 기존 MRI 영상보다 더 많은 정보를 담고 있어 진단의 정확도를 높일 것이라 기대함.




그림 20. 생체 내 자화율 분리 결과와 문헌에 나타난 철 및 미엘린 조직학 간의 비교. 상자성 및 반자성 자화율 맵이 각각 철과 미엘린의 조직학적 결과와 잘 일치함을 보여주어, 본 연구의 신뢰도를 입증하며, 이를 통해 생체

내 철과 미엘린에 대한 연구가 더욱 활발히 이루어질 수 있음을 시사함.

[4. 예상되는 난관과 극복 방안]

- 난관: 본 연구실에서 개발된 고급 정량적 자화율 매핑을 자폐 스펙트럼 장애에 적용하는 케이스는 전세계 최초이며, 고급 정량적 자화율 매핑을 자폐 스펙트럼 장애에 특화된 파이프라인을 제작해야 함.
- 극복 방안: 본 연구실은 고급 정량적 자화 영상을 다양한 질병에 도입하는 중에 있으며 과거에도 참조 논문이 없는 환경에서 특정 질병에 대한 파이프라인을 성공적으로 구축한 경험을 보유함⁸⁸. 따라서 질병 특화된 파이프라인 구축 노하우를 경험한 이점을 바탕으로 자폐 스펙트럼 장애에 특화된 고급 정량적 자화율 매핑 파이프라인을 개발할 것임. 이를 위해 본 연구진의 자폐 스펙트럼 장애 전문가와 협력하여 자폐 스펙트럼 장애의 병리학적 특성을 철저히 분석할 예정이며, 이러한 특성을 반영할 수 있는 맞춤형 정량적 자화율 매핑 기술을 개발할 것임.

⁸⁸ Kim, Woojun, et al. "χ-Separation imaging for diagnosis of multiple sclerosis versus neuromyelitis optica spectrum disorder." Radiology 307.1(2022): e220941.

[5. 기대되는 결과 및 유의성]

- 정량적 자화영상법 및 고급 정량적 자화율 매핑을 동시에 사용하여 자폐 스펙트럼 장애를 분석할 경우, 기존에 사용되었던 데이터를 상회하는 정보량을 바탕으로 멀티모달 뇌영상과 대규모 AI 파운데이션 모델 적용과 임상경과 바이오마커 발굴을 진행할 수 있음.

연구개발 목표 1-3: 유전체 및 타겟 질환 동물모델 데이터 탐색 및 수집




그림 21. 연구개발목표 1-3의 요약

세부목표 1-3-1. 발달장애 아동의 인체유래물 수집 및 유전체 데이터 정제

[1. 최종 목표]

- 발달장애 아동들의 혈액 및 피부조직 수집
- 아동의 말초혈액 및 피부조직을 이용한 RNA-Seq 분석
- 발달장애 아동의 분변 수집 및 대사체 분석
- 한국인집 v2.0을 이용한 발달지연, 지적장애 및 자폐 아동에 대한 유전자 변이 분석
- 전장 엑솜 분석(whole exome sequencing)

[2. 접근]

- 발달장애 아동들의 인체유래물 수집 전략

- 발달장애 아동들의 전향적 임상데이터(평가, 의료영상 등) 수집 시점(6개월 간격 2회 이상)과 매칭하여 인체유래물을 수집함.
- 발달장애 아동의 혈액 및 피부조직 수집
 - 비침습적으로 채취 가능한 혈액 조직을 프로파일링 대상으로 수집함.
 - 표피 피부 세포와 뇌신경 세포는 발생학적으로 외배엽에서 기원하기 때문에, 발달장애 아동 유전자 선별을 위하여 피부 조직 또한 유전자 프로파일링 대상으로 선택함.




그림 22. 멀티오믹스 기반의 유전자 데이터 생성

- 아동의 말초혈액 및 피부조직을 이용한 RNA-Seq분석
 - Chen 등(2023)은 메타분석을 통해서 신경 염증(neuroinflammation)이 다양한 뇌질환과 관련되어 있으며, 면역관련 유전자들 중 60% 이상이 환자에서 발현의 차이가 있으며, 유전자 및 유전자 네트워크 수준에서 전사체 변화를 이해하는 것이 신경학적 질환을 규명하는데 도움이 될 수 있음을 보고함⁸⁹.
 - 본 연구에서는 아동 말초혈액 내 면역관련 세포에서 RNA-seq을 이용한 total mRNA 전사체 분석을 시행하고 주로 면역관련 유전자들의 발현 양상을 기존에 발표된 해외 데이터와 비교하고자 함.

⁸⁹ Chen, Y., Dai, J., Tang, L., Mikhailova, T., Liang, Q., Li, M., . . . Chen, C.(2023). Neuroimmune transcriptome changes in patient brains of psychiatric and neurological disorders.Molecular Psychiatry, 28(2), 710–721.

- RNA-seq은 검증된 유전체분석기관을 통해서 Illumina 플랫폼을 이용하여 진행할 예정이며, 본 연구과제를 통해서 생성되는 유전체 및 대사체 데이터와 비교분석을 통해서 질환 특이적인 표지를 발굴하고자 함.
- RNA-seq으로는 mRNA와 long non-coding RNA를 분석할 예정이고, 그 외에 small non-coding RNA는 short RNA-seq으로 분석할 것임.
- 발달장애 아동의 분변 수집 및 대사체 분석
 - 16s rRNA sequencing
 - 복잡한 미생물군집이나 연구하기 어려운 환경에서 박테리아 다양성을 식별하고 비교하는 무배양 방법임. 발달장애 아동에게서 얻은 분변으로부터 gDNA를 추출하여 16s rRNA(V4 region)을 detection 할 수 있는 primer를 사용하여 PCR을 진행 뒤 NGS 시퀀싱을 통해 데이터 분석함.
 - 대사체(Metabolomics)




그림 23. 장내 미생물 군집에 따른 대사체 분석 예⁹⁰

- 대사체는 계통 특이성이 있음. 특히, 포유류 검체가 아닌, 장내

⁹⁰ Han, S., Van Treuren, W., Fischer, C. R., Merrill, B. D., DeFelice, B. C., Sanchez, J. M., ... & Sonnenburg, J. L.(2021). A metabolomics pipeline for the mechanistic interrogation of the gut microbiome. Nature, 595(7867), 415–420.

미생물에서 다양한 소분자를 정확하게 식별하고 분석하는 것은 화학 구조 다양성, 매트릭스 효과 및 이온 검출의 선형성과 같은 다양한 기술적 요인으로 인해 한계가 있음.

- 본 공동연구팀에서 보유하고 있는 액상 크로마토그래피-질량 분석(Liquid chromatography - mass spectrometry, LC-MS) 파이프라인은 다양한 생물학적 샘플에서 대사체를 측정하는데 유리함.
 - LC/MS의 장점은 mass 1(MS1)과 mass 2(MS2; mass-mass) 분석방법을 사용하여 세균 및 숙주 대사를 특징 짓는 다양한 화학 계열 화합물의 탐지 가능성을 가짐.
 - 다양한 매트릭스에서 발생하는 보존 시간(RT) 변화를 확인하여 우리의 m/z-RT(mass to charge ratio; mass scale) 참조 라이브러리에서의 RT 데이터를 사용하여 생물학적 샘플의 대사물질을 정확하게 식별할 수 있는지 여부 결정함.
 - 다양한 농도 범위에서 신호의 선형성, 샘플 비교를 수행하고 배율 변경의 차이를 결정하는데 필수적임.
 - 생물학적 샘플에서 식별된 고농도 대사물질을 유효화하기 위해 MS/MS로 대사체를 확인함.
- 한국인칩 v2.0을 이용한 GDD, ASD, ID 아동에 대한 유전자 변이 분석
 - 한국인칩 v.2.0은 질병관리청 주도로 한국인 특성을 고려해서 개발한 정밀의료 연구 플랫폼으로 당뇨, 심혈관질환, 알츠하이머 등 다양한 질환연구에 활용됨.
 - 한국인칩 v.2.0은 총 168만개의 유전변이를 검출할 수 있으며(그림 24), 표준화된 분석법이 제공되어 연구의 수월성이 매우 높다고 할 수 있음.

- 기확보된 개별 환자군 검체 50개와 환자와 부모로 구성된 trio 30 가계를 대상으로 한국인 칩 v.2.0을 이용해서 SNP 분석을 시행하고, 한국인 참조 유전체 데이터베이스 등과 비교해서 질환 관련 표지를 발굴하려고 함.
- SNP 분석은 질병관리청으로부터 한국인칩 v.2.0 공인분석기관으로 지정된 업체를 통해서 수행되어 적절한 품질의 SNP 데이터가 확보될 수 있을 것임.

분류	세분류	한국인칩 v1.1	한국인칩 v2.0
임상 및 질환 관련	ClinVar 데이터베이스	1,118	131,994
	질환 및 임상 관련 (공개 데이터베이스)	66,852	276,263
	ACMG ^a 관련 유전자	3,630	43,016
	약물 반응 및 ADME ^b 관련 유전자	2,845	18,113
단백질 기능 관련	단백질 변형 (Nonsyn., Indels)	213,513	488,890
면역 관련	HLA, KIR 지역	11,338	84,270
한국인 유전체 대표성 (tagging)	Imputation 정확도 향상 ^c	584,364	963,516
성염색체	X, Y, MT 염색체	2,815	34,468
계		827,926	1,675,805

※ 한국인칩 v2.0은 v1.1 모든 콘텐츠 포함, 각 분류 별 유전변이 수는 중복될 수 있음

a ACMG(American College of Medical Genetics) 임상 관련 73개 유전자

b ADME(Absorption, Distribution, Metabolism, and Excretion) 약물 반응 68개 유전자

c Imputation: 전염기서열정보 수준으로 확장하는 통계 기법

그림 24. 한국인칩 v.2.0 콘텐츠 특징(<https://www.koreanchip.org/2>)

- 전장 엑솜 분석(whole exome sequencing)
 - 한국인칩 v.2.0 분석에 사용되었던 동일한 검체에 대해서 전장 엑솜 분석을 시행할 것임.
 - 전장 엑솜 유전체 분석은 ThermoFisher 사의 Ion S5XL system을 이용하여 수행할 예정이며, AmpliseqTM library kit를 이용하여 library pool을 제작하고 Ion540 CHIP을 이용하여 sequencing 함.
 - 생산된 raw data는 Ion Reporter에 upload 하여 분석하고, 고품질의 시퀀싱 데이터를 선택하기 위해 유전자 범위가 60% 이상, 변이 대립유전자 빈도(VAF)가 30% 이상인 변이체를 우선으로 선정함.

- 발견된 유전자 변이들은 그림 25에서 제시한 과정을 거쳐서 후보 유전자 변이를 검출함.




그림 25. 데이터베이스 분석과 후보 유전자 변이 발굴과정

- 전체 엑솜 데이터에서 후보 유전자 변이체를 선택하기 위한 포함 기준은 다음과 같음:(1) 공공 데이터베이스의 동아시아 인구에서의 minor allele frequency(MAF)가 5%이내 일 것(2) 표현형 및 유전자의 해당 질병과의 관련성이 예측될 것(3) 단백질 예측 소프트웨어(MutationTaster2, PolyPhen-2, Varsome 및 InterVar 등)에 의해 병원성으로 예측될 것
- Recurrent pregnancy loss(RPL)의 경우 trio 분석을 통해서 유전자 변이의 유전 여부를 확인함.
- 최종 후보 유전자 변이는 Sanger 염기서열 분석법을 통해 다시 한번 확인함

[1. 최종 목표]

- 유전자 기반 GDD, ASD, ID 마우스 모델 구축
- GDD, ASD, ID 마우스 장내미생물 구성 분석 및 대사체 분석

[2. 접근]

[GDD, ASD, ID 마우스 모델 구축]

- 유전자 기반 동물모델의 확보.
 - ASD와 ID의 표현형을 보이는 동물모델의 구매 및 계통 보존
 - Shank3 knockout(KO) mouse model: Shank3 유전자의 경우 현재까지 5종류의 적중 mouse model이 보고되었으며, 행동학적 특징에 있어서 자폐적 행동, 특히 사회적 행동 장애가 공통적으로 보고된 바 있음. 시냅스의 특성에 있어서는 AMPA, NMDA 글루타메이트 수용체의 발현 감소와 더불어 흥분성 시냅스의 형태적 기능적 약화가 관찰되었다는 보고가 있음⁹¹.
 - Shank2 mutant mouse model: Shank2 돌연변이는 ASD, 중증도 ID, 발달지연 및 경미한 운동 장애와 관련이 있는 것으로 보고된 바 있음.
 - 해당 모델들을 현재 기 확보 중에 있으며, 추후 계속해서 계통 보존을 통해 본 과제에 활용하고자 함.
 - Valporic acid(VPA) 투여 mouse model: 본 기관은 선행연구를 통하여 VAP 투여에 따른 ASD 동물모델을 확보하였음. VPA를 임신 10-12일차 어미쥐의

⁹¹ Jiang, Y. H., & Ehlers, M. D.(2013). Modeling autism by SHANK gene mutations in mice. Neuron, 78(1), 8-27.

피하에 투여함. 이후 태어난 새끼 쥐들을 40일까지 키운 뒤 행동양상을 확인한 결과 자폐양상의 행동결과를 나타내었으며, 본 과제에 활용하고자 함.

- GDD, ASD, ID 동물모델 구축을 위한 행동평가 확립함.
 - The three-chamber test: 동물모델의 사회성에 대해 가장 일반적으로 사용되는 테스트로 처음에는 직렬로 연결된 세 개의 챔버 가운데 배치되며 끝 챔버에는 아무것도 포함하지 않고자 물체 또는 다양한 친숙한 동물을 위치시킴. 일정기간 동안 습관화한 후 반대측 챔버에 낯선 동물을 위치시켜 관심행동양상을 관찰함.
 - Marble burying/digging test: ASD 아동은 반복적이거나 강박적인 행동이 증가하는 양상을 보이며 해당 테스트는 동물모델의 marble burying 행동의 지속성을 정량화하는 방법임.

[GDD, ASD, ID 마우스 장내미생물 구성 분석 및 대사체 분석]

- GDD, ASD, ID 마우스의 분변에서, 장내 미생물 유래 특이적인 대사체를 동정하고, 정성 및 정량적 분석이 가능한 플랫폼 구축

연구개발 목표 1-4: 영상기반 행동데이터 큐레이션 및 표준 데이터 관리 시스템 구축

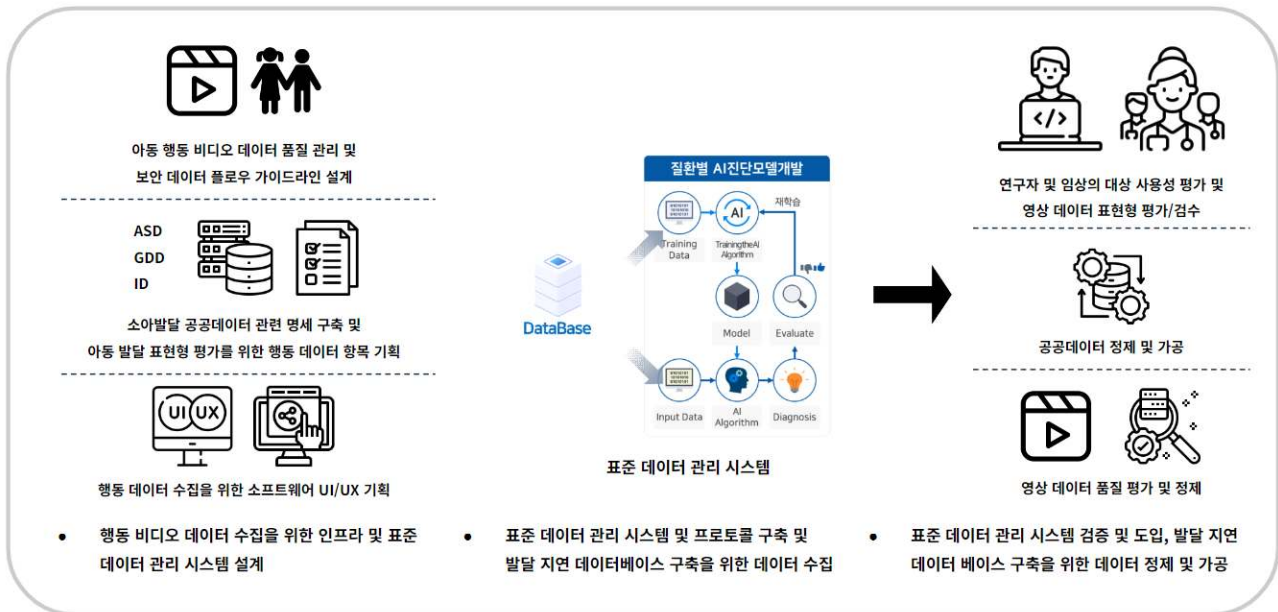


그림 27. 연구개발목표 1-4의 요약

세부목표 1-4-1. 행동 비디오 데이터 수집을 위한 인프라 및 표준 데이터 관리 시스템 설계

[1. 근거 및 배경]

- 소아 발달장애 아동들의 비대면 진단 도구로써 행동 비디오 데이터를 수집 및 활용하기 위해서는 고품질의 데이터를 표준화된 방식으로 수집할 필요가 있음.
- 수집된 데이터의 보안을 유지하고 개인정보를 보호하기 위한 인프라가 필요함.
- 이를 위해서는 데이터 수집을 위한 소프트웨어를 설계하고 개발함에 있어 임상 분야의 전문가들과의 논의를 통해서 데이터 수집 항목을 명확하게 설정하여야 함. 또한 소프트웨어의 개발이 사용자 친화적이고 개인정보를 보호하는 방향으로 진행되어야 함.

[2. 최종 목표]

- 표준 데이터 관리 시스템 구축을 위한 도메인 요구사항 파악 및 기존/신규 데이터

수집을 위한 인프라 설계.

[3. 접근]

- 데이터 전주기 품질 관리를 위한 가이드라인 설계
 - 품질 관리 기준 정립: 데이터의 수집부터 처리, 공개에 이르기까지 각 단계별 품질관리기준의 설정. 이 기준은 국내외 데이터 관리 법규와 규정을 준수하도록 설계될 것임.
 - 검증 절차 개발: 수집된 데이터의 정확성과 신뢰성을 확보하기 위한 검증 절차를 개발함. 이는 자동화된 도구를 통해 데이터의 일관성과 정확성을 지속적으로 모니터링하고 평가하기 위한 것임.
 - 데이터 수집 및 관리 훈련 프로그램: 데이터 관리자 및 연구자를 대상으로 한 훈련 프로그램을 개발하여 데이터의 정확한 수집과 관리 방법을 교육함. 이 프로그램은 최신의 데이터 관리 표준을 반영할 것임.
 - 지속적인 품질 개선 메커니즘 구축: 데이터의 품질을 지속적으로 개선하기 위한 가이드라인을 작성하고, 이를 통해 피드백 시스템과 정기적인 리뷰 프로세스를 포함한 변경되는 요구사항에 능동적으로 대응할 수 있도록 할 것임.
- 단계적 분할 보안 데이터 플로우 알고리즘 및 가이드라인 설계
 - 보안 알고리즘 설계: 데이터의 보안성을 강화하기 위해 다층적 암호화와 접근 제어를 통합하는 분할 보안 데이터 플로우 알고리즘을 설계.
 - 데이터 접근 권한 관리: 각 단계별로 데이터 접근 권한을 설정하고, 사용자 인증과 권한 부여 절차를 강화해 무단 접근을 방지할 것임.
 - 안전한 데이터 전송 프로토콜 적용: 데이터가 시스템 내외부로 전송될 때는

안전한 전송 프로토콜을 사용하여 데이터 무결성과 기밀성을 유지하게 됨.

- 지속적인 보안 감사 및 업데이트: 보안 시스템의 효과성을 주기적으로 검토하고 최신 보안 위협에 대응하기 위해 주기적으로 시스템 업데이트를 실시할 것임.

- 품질 관리 시스템 구축 및 필요 조건 파악을 위한 도메인 전문가 인터뷰

- 전문가 선정 및 인터뷰 준비: 발달장애 관련 분야의 도메인 전문가들을 선정하고, 인터뷰를 통해 품질 관리에 필요한 구체적인 요구 사항을 파악함
- 인터뷰 결과의 문서화 및 분석: 인터뷰에서 얻은 정보를 문서화하고, 이를 분석하여 품질 관리 프로세스와 프로토콜 개발에 적용할 것임.
- 전문가 권고안 통합: 통합된 전문가의 권고안을 활용하여 품질 관리 시스템 구축 및 추가 연구 개발에도움이 될 수 있는 형태로 가공함.

- 공공 데이터 허브 데이터 명세 구축 및 관리 체계 설계

- 데이터 명세 정의: ASD, GDD, ID를 포함하는 소아 발달장애 관련 원천 데이터의 특성 및 메타 데이터에 따라 표준 명세를 정의하여 데이터의 구조와 형식 표준화 및 일관성을 보장할 수 있음.
- 관리 체계구축: 데이터 명세에 따라 공공 데이터 허브의 관리 체계를 설계하고 구현하며, 데이터의 입력, 저장, 검색 및 공유 기능을 포함함.
- 데이터 품질 관리: 입력된 데이터가 명세에 부합하는지 정기적으로 검토하고 품질 관리 프로토콜을 통해 데이터의 정확성과 신뢰성을 유지함.

- 아동 발달 표현형 평가를 위한 행동 데이터 항목 기획

- 데이터 항목 선정: 발달 지연을 평가하기 위한 핵심 행동 지표의 선정. 이는 아동의 사회적 상호작용, 언어 능력, 운동 기술 및 인지발달 등 아동 발달의 각

영역을 모두 포괄할 수 있도록 설계될 것임.

- 연령별 데이터 수집 기준 설정: 각 연령대에 맞는 발달 표준을 바탕으로 특정 행동의 발달 수준을 평가할 수 있는 기준을 설정함 .
- 멀티모달 데이터 수집 계획: 비디오 분석, 부모 및 교사의 설문을 통한 다각적 데이터 수집 방법을 통해 아동에 대한 통합적 발달 평가를 가능하게 하고 데이터의 활용도를 높임.
- 행동 데이터 수집을 위한 소프트웨어 UI/UX 기획 내용
 - 사용자 중심 설계 접근법 채택: 사용자의 요구와 편의성을 우선하여 비전문가도 쉽게 동영상을 업로드하고 관리할 수 있는 시스템을 기획.
 - 인터랙티브요소: 실시간피드백, 오류 동영상 수정, 자동 검수 등 데이터 입력 과정에서 사용자의 참여를 유도하고 오류를 최소화하기 위한 인터랙티브 요소의 도입.
 - 접근성 및 호환성 강화: 다양한 기기 및 플랫폼에서 원활하게 작동할 수 있도록 반응형 디자인을 적용하여 시각적으로 접근하기 쉬운 레이아웃과 폰트 사용을 고려.
 - 데이터 보안 및 개인정보 보호: 사용자의 데이터 보안을 최우선으로 고려하여 데이터 암호화, 안전한 로그인 프로세스 및 사용자 데이터에 대한 접근 제어 기능을 강화.

[4. 예상되는 난관과 극복 방안]

- 난관: 데이터 수집의 목적으로 사용될 소프트웨어의 수집 데이터 항목을 설정하는 것은 발달장애 아동들의 조기 진단을 위해 충분히 활용될 수 있어야 하고 이후의 데이터 수집에도 영향을 끼치기 때문에, 소프트웨어 설계 초기 단계에서 전문가들의

충분한 의견이 필요함.

- 극복 방안: 본 연구팀에 참여하고 있는 아동 발달 분야의 전문 임상가들의 참여를 통해 소프트웨어 설계 초기 단계에서의 충분한 논의에서 소프트웨어를 통한 수집 데이터 항목을 설정하고자 함. 더불어 소프트웨어 개발단계에서의 지속적인 전문가들의 피드백을 통해서 필요한 데이터 항목을 효과적으로 수집하기 위한 방향으로 소프트웨어를 개선하고자 함.

[5. 기대되는 결과 및 유의성]

- 공공데이터의 수집 뿐만 아니라 새로운 데이터 생성 시의 가이드라인 설정은 표준화된 데이터 생성에 기여할 것.
- 표준화된 방법을 통한 고품질의 데이터 생성, 유지, 관리 가능.
- 보안을 고려한 데이터 수집 소프트웨어의 개발을 통해 추후 임상 장면에서 보조적인 데이터 수집을 위한 도구로써 확장 사용될 수 있음.

세부목표 1-4-2. 표준 데이터 관리 시스템 및 프로토콜 구축 및 소아 발달장애 데이터베이스 구축을 위한 데이터 수집

[1. 근거 및 배경]

- 가정과 임상 장면을 비롯한 다양한 상황에서 지속적이고 신뢰감 있게 활용될 수 있는 아동 행동 비디오 데이터 수집 소프트웨어의 개발을 위해서는, 시범적인 사용 과정을 통한 소프트웨어의 개선이 필요함.
- 다양한 환경에서 활용될 수 있는 데이터 수집 도구를 개발하기 위해서는, 실제 수집 과정에서의 데이터의 유형, 형식 및 품질 기준에 대한 조사와 이를 참고하여 표준화된 가이드라인이 필요함.

[2. 최종 목표]

- 표준 데이터 관리 시스템 및 프로토콜 구축 및 소아 발달장애 데이터베이스 구축을 위한 데이터 수집

[3. 접근]

- 발달장애 아동 표준데이터 관리 프로토콜 작성
 - 데이터 검증 및 정제 절차 선정: 수집된 데이터의 품질을 보장하기 위해 정확한 검증 및 정제 절차를 설계함. 이 과정에서 발견된 오류를 매뉴얼로 수정하고, 데이터의 일관성과 신뢰성을 유지함.
 - 접근성 및 사용권한 관리: 데이터 접근성을 제어하기 위한 명확한 지침을 수립, 데이터 사용 권한은 연구 목적에 따라 제한되며 필요한 사용자만 접근할 수

있도록 함. 또한 장기간의 데이터 보관 및 보안을 위한 프로토콜을 개발하여 데이터의 안정성을 보장하고 무단 접근으로부터 보호하기 위한 조치를 포함시킬 것임.

- 품질 관리 인프라 요구사항 명세서 및 UI/UX 기획
 - 요구사항 명세서 개발: 발달장애 아동 데이터 품질 관리를 위한 전체적인 요구사항을 명확히 기술함. 이를 위해서 1차 연도에 수집된 전문가 인터뷰 및 데이터 명세, 데이터 항목 등을 참고하게 될 것임. 데이터 수집, 검증, 저장, 보안 등 모든 단계를 포함한 명세서를 개발.
 - 사용자 경험 디자인: 데이터 관리 시스템의 사용자 인터페이스를 설계.
 - 프로토타입 테스트 및 피드백: 초기 UI/UX 디자인을 바탕으로 프로토타입을 제작하고, 실제 사용자 테스트를 통해 피드백을 수집하여 시스템을 개선함.
- 공공 데이터 허브 데이터 수집
 - 데이터 소스 식별: 다양한 소스에서 발달장애 관련 데이터를 수집하기 위해 국내외 의료 기관, 교육 기관, 연구 센터 및 공개된 데이터 허브들의 작성된 명세를 참고하여 데이터를 수집. 데이터 소스로부터 수집될 정보의 유형, 형식 및 품질 기준을 명확히 설정함.
 - 기술 인프라 구축 준비: 데이터 수집, 저장, 처리를 위한 기술 인프라를 구축하기 위한 사전 자료로서 데이터 명세 및 예시 데이터를 활용.
- 행동 데이터 수집을 위한 소프트웨어 개발 및 사용성 평가
 - 소프트웨어 설계 및 개발: 1차 연도에 설정된 항목 및 기획된 요구사항 명세서, 프로토타입 등을 활용하여 소프트웨어를 설계 및 개발.

- 실험 설계 및 시행: 실제사용 환경을 모사한 실험을 설계하고, 실 사용자 그룹을 대상으로 소프트웨어 사용성을 평가함.
- 데이터 수집 및 분석: 초기 사용자로부터 수집된 피드백과 인터랙션 데이터를 분석하여 소프트웨어 개선점 도출 및 개선.
- 행동 데이터 수집
 - 소프트웨어 배포: 개발된 소프트웨어를 앱스토어에 등록 및 배포하여 가정을 비롯한 다양한 환경에서 아동 데이터를 수집할 수 있도록 함.
 - 행동 데이터 수집 프로토콜: 행동 데이터 수집을 위한 표준 프로토콜을 활용하여 수집된 데이터들에 대한 정제 및 가공을 수행함.

[4. 예상되는 난관과 극복 방안]

- 난관: 데이터 수집 환경의 다양성으로 인해 소프트웨어를 통해 수집된 데이터의 품질 유지의 어려움.
- 극복 방안: 국내외 의료기관, 교육기관, 연구 센터 및 공개된 데이터 허브들에서 데이터를 표집한 유형과 형식 및 품질 기준을 포괄적으로 조사한 뒤, 이를 바탕으로 표준화된 가이드라인을 위해 필요한 세목들을 우선적으로 마련하고자 함. 이후, 다양한 환경에서의 사용자들의 피드백과 가이드라인의 비교를 통해서 표준화를 위해 필요한 세목들을 개선하고 이를 바탕으로 다양한 환경에서 최대한 동일한 품질의 데이터를 수집할 수 있도록 소프트웨어를 개선하고자 함.

[5. 기대되는 결과 및 유의성]

- 전문가들과의 협의를 통해 개발된 소프트웨어가 임상 장면 뿐만 아니라 가정과 같은 다양한 환경에서의 데이터 수집에 활용됨으로써, 소아 발달장애의 조기 진단을 위한 보조 도구로써 확장 활용될 수 있을 것.

세부목표 1-4-3. 표준 데이터 관리 시스템 검증 및 도입, 소아 발달장애 데이터 베이스 구축을 위한 데이터 정제 및 가공

[1. 근거 및 배경]

- 최근의 AI 모델 개발은 고품질 데이터의 대량 생산을 가장 중요시하며, 새롭게 생성된 데이터의 정제 및 가공 과정 또한 매우 중요하게 여겨지고 있음.
- 행동 비디오 데이터 기반의 소아 발달장애 아동 조기 진단 AI의 개발을 위해서 고품질의 행동 비디오 데이터를 수집하는 것이 가장 중요함.
- 발달장애 아동이라는 특수성을 고려하였을 때 새로운 데이터를 생성하는 것에는 한계가 있기 때문에 이미 존재하는 데이터를 잘 정제하는 것 또한 중요함.

[2. 최종 목표]

- 표준 데이터 관리 시스템 검증 및 도입, 소아 발달장애 데이터 베이스 구축을 위한 데이터 정제 및 가공

[3. 접근]

- 표준 데이터 관리 인프라 도입 및 사용성, 정확도 평가
 - 표준 데이터 관리 시스템 도입: 발달장애 데이터를 효율적으로 관리하기 위하여 표준 데이터 관리 인프라를 도입함.
 - 사용성 평가: 실제 데이터 작업자 및 발달장애 연구자, 전문가들을 대상으로 표준 데이터 관리 시스템의 사용성을 평가함. 이 평가는 시스템의 인터페이스, 사용 편의성, 학습 곡선 등을 포함하게 됨.
 - 데이터 정확도 및 무결성 검증: 데이터 관리 인프라를 통해 수집된 데이터의 정확도와 무결성을 평가하고 이를 전문가의 검수 결과와 비교해 시스템의

신뢰성을 평가함.

- 구축 데이터에 대한 반자동 데이터 검토 알고리즘 개발
 - Anomaly detection 기반 반자동 데이터 검토 데이터 생성: 구축 데이터에서 이상을 감지하기 위한 알고리즘을 개발하여 설계하고 구현함. 특정 오류 패턴과 불일치를 식별하여 데이터 관리자에게 알릴 수 있음.
 - 사용자 인터페이스 통합: 사용자가 쉽게 검토 결과를 확인하고 필요한 조치를 취할 수 있도록 직관적인 사용자 인터페이스에 알고리즘을 통합함.
- 공공 데이터 허브 데이터 정제 및 가공
 - 데이터 정제 프로토콜 개발: 공공 데이터 허브로부터 2차 연도에 수집된 데이터를 대상으로 데이터의 품질을 담보하기 위한 정제 프로토콜을 개발하고 이를 적용하여 불필요하거나 오류가 있는 데이터를 제거함.
 - 데이터 가공: 데이터들의 메타데이터들의 명세를 활용하여 전체 데이터의 활용성을 높이기 위한 태블러 데이터를 제조하고 데이터의 품질과 활용도를 최대화함.
- 아동 행동 영상 데이터 품질 평가 및 정제
 - 품질 평가기준설정: 아동 행동 영상데이터에 대한 품질평가기준을 설정함. 이 기준은 데이터의 완전성, 정확성, 일관성 및 타당성 등을 중심으로 검토함.
 - 데이터 샘플링 및 검증: 정제된 데이터 샘플을 선택하여 수동으로 검증하고, 데이터의 품질을 확인하고 추가 정제 조치를 결정함.
 - 품질 보고서 작성 및 피드백 반영: 정제 과정과 결과에 대한 상세한 품질 보고서를 작성하고, 사용자 및 전문가의 피드백을 수집하여 데이터 정제 프로세스를 지속적으로 개선함.

- 아동 행동 영상 데이터 표현형 평가 및 전문가 검수
 - 표현형 평가 기준 개발: 아동 행동 영상 데이터를 분석하기 위한 표현형 평가 기준을 개발.
 - 전문가 평가 시스템 구축: 아동의 비디오 분석을 통해 아동의 발달 상태를 평가하고 해석할 수 있는 전문가 평가 시스템을 구축.
 - 데이터 검증 및 교차 검사: 수집된 영상 데이터를 다양한 전문가가 독립적으로 평가하여 데이터의 신뢰성을 높이고 이 과정에서 발견된 불일치는 추가 분석을 통해 해결될 수 있음.
 - 연구 결과의 적용 및 개선: 연구 결과는 아동 발달 표현형의 정확한 평가와 개선을 위해 사용될 것임. 결과는 연속적으로 데이터베이스에 반영되어 평가 기준의 정확성을 높이는데 기여할 것임.

[4. 예상되는 난관과 극복 방안]

- 난관: 이미 수집된 공공 데이터 허브의 데이터들의 품질과 새롭게 생성되는 데이터의 품질을 균등하게 정제하고 가공하는 것.
- 극복 방안: 공공 데이터 허브의 데이터들을 정제 및 가공 과정과 새롭게 생성되는 데이터의 정제 및 가공 과정에 대한 품질 보고서를 상세히 작성하고, 이를 바탕으로 사용자와 전문가들의 피드백을 수용하여 데이터 정제 프로세스를 지속적으로 개선하고자 함. 또한 프로토타입 테스트를 통해 새롭게 생성된 데이터에 대한 정량 및 정성적 분석 결과와 공공 데이터 허브의 데이터에 대한 정량 및 정성적 분석 결과를 비교하여, 두 데이터의 품질을 최대한 균질화 하고자 함.

[5. 기대되는 결과 및 유의성]

- 기존 데이터와 새롭게 생성되는 데이터의 정제 및 가공 과정의 개선으로 인한

데이터의 품질 향상은, 이를 기반으로 한 발달장애 아동 조기 진단 AI 모델 개발에 중요하게 기여할 것.

- 이상 감지 알고리즘에 기반한 반자동화 된 데이터 정제 및 가공 과정은 추후 고품질의 데이터 생성 및 데이터베이스 구축을 위해 지속적으로 기여할 것.

나. 1단계 - 2차 연도: 멀티모달 데이터 수집 지속 및 병인 기전과 바이오마커 후보군 제시

연구개발 목표 2-1: 소아 발달장애 바이오메디컬 빅데이터 품질 관리 및 국내외 데이터 공유 플랫폼으로의 확장



그림 28. 연구개발목표 2-1의 요약

세부목표 2-1-1. K-BDS 플랫폼과 동기화된 표준 데이터 관리 인프라 및 통합 발달장애 데이터베이스 구축과 이를 기반으로 한 지속적인 AI 모델 업데이트 인프라 구축

[1. 근거 및 배경]

- 데이터베이스의 구축 및 관리 과정에서의 표준화된 인프라를 마련하는 것은 추후에 수집되는 데이터들이 기존의 데이터베이스로 통합되는 것에 필수적임.
- 다양한 연구자들이 표준화된 과정을 통해서 데이터를 생성하고 이를 기존의 데이터베이스에 통합할 수 있다면, 데이터베이스의 규모를 확장할 수 있고 이는 발달장애 아동 조기 진단 AI 모델의 정확도를 고도화하는 것에 결정적으로 기여할 것

- 이를 위해서는 데이터 생성의 가이드라인과 데이터베이스를 오픈소스로 공개하고, 연구자들이 데이터베이스에 쉽게 접근할 수 있도록 진입장벽을 낮추는 것이 필요함.
- 국내에서 생성되는 바이오데이터를 기업과 연구자들에게 제공하는 플랫폼은 K-BDS는 이를 위한 좋은 교두보가 됨.

[2. 최종 목표]

- K-BDS 플랫폼과 동기화된 표준 데이터 관리 인프라 구축 및 통합 발달장애 데이터베이스의 K-BDS 등록.
- 본 연구를 통해 개발되는 발달장애 아동 조기 진단 AI 모델의 공개 및 API 배포.
- 소아 발달장애 분류 AI 학습 위한 Minimal Common Data(MCD) 정의 및 제시
- 새롭게 생성되는 데이터를 기존의 데이터베이스에 통합하고, 이를 기반으로 하여 AI 모델을 지속적으로 학습 업데이트 할 수 있는 인프라 구축.

[3. 접근]



그림 29. K-BDS 전송 프로세스 예시

- K-BDS 플랫폼과 데이터 동기화를 위한 백엔드 인프라 구축
 - 인프라 아키텍처 설계: K-BDS 플랫폼과 동기화될 수 있는 백엔드 인프라를 설계하여 데이터의 효율적인 흐름과 실시간 처리를 지원하게 함.
 - 데이터 동기화 프로토콜 개발: 플랫폼 간 데이터 동기화를 위한 프로토콜을 개발하여 데이터의 일관성과 무결성을 유지할 수 있음.
 - 시스템 통합 및 테스트: 개발된 백엔드 인프라를 기존의 K-BDS 플랫폼에 통합하고 광범위한 테스트를 통해 시스템의 안정성과 성능을 검증함.
- 인공지능 활용을 위한 배포 API 구성
 - 공동 연구기관 및 주관 연구기관에서 개발된 AI 활용을 위한 API를 구성 및 배포.
 - API 설계 및 개발 : 인공지능 모델의 기능을 외부 시스템과 통합할 수 있는 RESTful API를 설계하고 개발함. 이를 통해 사용자의 요청을 받아 모델을 사용할 수 있음.
- 추가 데이터에 대한 확장과 인공지능 갱신을 위한 CI/CD/CT 구축
 - CI/CD 파이프라인 설계 및 구현 : 추가된 데이터를 기존 인공지능 모델에 통합하고, 모델 업데이트를 자동화하는 CI/CD 파이프라인을 설계하고 구축함. 이 시스템은 데이터 및 코드 변경사항을 자동으로 감지하고 빌드 및 테스트를 거쳐 배포 진행.
 - 지속적 학습 플랫폼 구축 : 인공지능 모델이 새로운 데이터로 지속적으로 학습할 수 있도록 지원하는 플랫폼을 개발함. 이는 모델의 정확성과 적응성을 유지하는데 중요함.
 - 데이터 및 모델 관리 전략 개발 : 추가 데이터와 모델 간의 호환성을 유지하고

최적화하기 위한 관리 전략을 수립.

- 테스트 및 품질 보증 : 새로운 데이터와 갱신된 모델이 기대하는 성능 기준을 충족하기 확인하기 위한 자동화된 테스트와 품질 검증 과정을 실시.
- K-BDS 등록을 위한 통합 데이터 검수 및 명세 작성
 - 통합 데이터 명세(데이터 종별 표준 항목 정의서) 작성: 소아 발달장애 데이터베이스에서 K-BDS로 등록하기 전에 통합 데이터 명세를 확인하고 형식, 구조, 필수 필드 및 메타데이터 요구 사항을 정의함.
 - 자동화 도구 구현: 데이터 검수를 자동화하기 위한 도구를 구현하여 대규모 데이터 세트를 효율적으로 처리함.
 - K-BDS 등록 준비: 통합 데이터 명세에 따라 데이터 준비하고 최종 검증을 실시.
- 구축된 데이터베이스의 K-BDS 등록
 - 데이터를 K-BDS에 등록하고 등록된 데이터가 시스템에 통합되는 과정을 테스트하여 문제 없이 동작하는지 확인함.
 - 또한 소아 발달장애를 분류하는 등의 AI 학습에 사용될 수 있도록 예시 코드와 데이터 전처리 등에 대한 설명을 담은 minimal common data를 함께 정의해서 데이터 설명에 포함하여 같이 등록할 예정임.

[4. 예상되는 난관과 극복 방안]

- 난관: 데이터베이스의 규모를 점진적으로 확장하는 과정에서, 다른 기관을 통해 수집된 보안에 민감한 데이터들은 연구의 목적성을 띠다고 하더라도 오픈소스 공개에 어려움을 겪을 수 있음. 또한 보안에 민감한 데이터들은 발달장애 아동 조기 진단 AI 모델의 추가적인 학습과 업데이트에 활용되기 어려울 수도 있음.

- 해결방안: 본 연구 제안서의 세부목표 3-2-3에서 제시하는 다기관 연합학습을 통해서, 데이터의 오픈소스 공개에 대한 직접적인 부담없이 AI 모델의 추가적인 학습 업데이트를 위해 보안에 민감한 데이터를 활용할 수 있음. 또한, 보안에 민감한 데이터들의 오픈소스 공개 수준에 대한 가이드라인(생성 AI 모델을 통한 개인정보 클리닝 등을 포함한 가이드라인)을 제작하여, 개인정보 보호와 오픈 사이언스 기반의 발달장애 아동 연구의 발전을 가능하게 하고자 함.

[5. 기대되는 결과 및 유의성]

- 표준화된 데이터 생성 가이드라인과 데이터 관리 인프라 구축 및 데이터베이스의 오픈소스 공개는 데이터베이스의 규모 확장의 기반이 될 수 있을 것.
- 데이터베이스에 대한 쉬운 접근은 다양한 연구자들로 하여금 발달장애 아동들의 행동 비디오 데이터에 기반한 연구들을 디자인하고 진행하는 데에 있어서 큰 기여를 할 것.
- 점진적인 데이터베이스 규모의 확장과 이를 기반으로한 발달장애 아동 조기 진단 AI 모델의 지속적인 업데이트는, 본 연구를 통해 공개될 데이터베이스가 발달장애 아동 연구의 허브로써 발돋움할 수 있는 기반을 마련해줄 것.

세부목표 2-1-2. 글로벌 뇌과학 플랫폼(brainlife.io)에 데이터 공유

[1. 근거 및 배경]

- 본 연구진의 데이터를 자체 개발하는 데이터 공유 인프라와 K-BDS를 통해서 공유할 계획이지만, 글로벌 커뮤니티와 공유하고 생태계를 넓히기 위해서 글로벌 플랫폼인 brainlife.io를 추가적으로 이용할 계획임.
- 현재 뇌이미징 및 유전 데이터를 활용하고자 하는 연구자는 늘고 있으나, 데이터 전처리 및 분석 방법의 표준화가 이뤄지지 않아 종종 연구 결과의 재현 가능성이 낮은

문제가 발생함(reproducibility crisis).

- Brainlife는 다양한 유저들이 각자가 만든 뇌영상데이터, 전처리 및 분석 방법, 그리고 기계 학습 모델을 공유할 수 있는 플랫폼임(텍사스대학 오스틴의 Franco Pestilli 교수팀에 의해 운영되고 미과학재단의 장기 지원을 받고 있음)⁹².
- Brainlife는 통일화된 데이터 구조로 손쉽게 데이터 저장이 가능한 툴(ezBIDS)와 버전 관리가 가능한 파이프라인(APPS)을 제공하여 앞서 언급한 뇌이미징 연구의 한계를 획기적으로 개선함. 또한 클라우드 서비스를 통해 무료로 유저들이 공개된 데이터를 활용해 각자의 분석에 활용할 수 있어 접근성이 높음.
- 본 연구진(서울대학교-차지욱 교수팀)은 다른 연구에서 정상 소아청소년의 뇌인지발달 데이터(뇌영상, 유전체)를 brainlife 플랫폼을 이용하여 전처리하고 글로벌 연구 커뮤니티와 공유한 경험이 있음.

[2. 최종 목표]

- 본 연구를 통해 수집된 데이터를 Brainlife를 통해 업로드 및 전처리하고, 최종 데이터를 APPS 형태로 공개 및 최종 학습된 모델을 업로드할 준비.

[3. 접근]

- 수집된 데이터를 Brainlife 플랫폼에서 제공하는 ezBIDS를 통해 표준화된 형태로 저장하고, 뇌영상의 전처리 및 분석에 필요한 툴은 APPS에 기반하여 버전 관리 및 활용함. 이때 각 데이터는 “Datatypes”라는 포맷으로 저장되며, 연구자의 필요에 따라 여러 APPS를 조합하여 활용할 수 있음. 예컨대, 뇌 이미징 전처리 파이프라인들을 연결하여 새로운 뇌영상 처리/분석 파이프라인을 손쉽게 구축 및 공유가능(그림 30).

⁹² Hayashi, S., Caron, B. A., Heinsfeld, A. S., Vinci-Booher, S., McPherson, B., Bullock, D. N., ... & Pestilli, F.(2024). brainlife. io: a decentralized and open-source cloud platform to support neuroscience research. Nature methods, 1-5.




그림 30. brainlife.io의 뇌영상과 분석 표준화된 분석 파이프라인의 구축의 개념도. 재현가능성을 높이기 위해 원데이터로부터 최종 분석 아웃풋의 분석 흐름을 APP의 형태로 연결하여 누구나 접근할 수 있도록함. brainlife.io를 통해 데이터, 전처리/분석 파이프라인, 학습 모델까지 공유 가능. brainlife.io는 미과학재단에서 후원하는 슈퍼컴퓨터를 서버로 사용하기 때문에 대규모 데이터 처리 및 공유가 가능한 bandwidth가 확보됨.

세부목표 2-1-3. 소아발달 바이오뱅크 벤치마크 및 카탈로그 시스템 구축을 통한 연구생태계 활성화

[1. 근거 및 배경]

- 인공지능의 발전 과정에서 오픈소스 벤치마크 데이터셋 기반의 다양한 챌린지들이 중요한 역할을 하였음. Kaggle, paperswithcode 등의 수치 기반의 성능평가를 통한 랭킹 시스템은 AI 모델 연구자들로 하여금, 최신 성능의 AI 모델을 파악하고 이를 바탕으로 자신들의 AI 모델을 발전시킬 수 있도록 하였음.
- 유전 관련 연구 분야에서, 웹 기반의 카탈로그 시스템은 연구자들이 자신들의 관심사인 유전체와 행동 표현형을 쉽게 탐색하고 연구 디자인을 하는 데에 도움을 주고 있음. 특히, UKBiobank GWAS catalog는 UKBiobank의 유전체 데이터를 기반으로 하는 전장 유전체 연관 분석 결과들을 종합하고 다양한 시각화 서비스를 제공함. 이를 통해 유전 연구자들은 카탈로그 시스템을 다양한 연구 결과들에서 지속적으로 나타나는 유전체들을 탐색하고 새로운 연구를 디자인하는 기반으로 삼고 있음.
- 이처럼 오픈 소스 벤치마크 데이터의 구축과 카탈로그 기반의 시스템들은 특정 연구 분야의 연구자들 뿐만 아니라, 데이터 분석가와 AI 모델 개발자를 비롯한 다양한 연구자들이 쉽게 접속하여 연구를 시작할 수 있는 환경을 구축함으로써 해당 분야의 발전에 기여하고 있음.
- 이에 본 연구팀은 다양한 분야의 연구자들이 발달 지연 및 장애 아동들에 대한 연구를 시작하고 지속할 수 있도록, 다양한 모달리티 데이터셋을 표집한 데이터베이스를 구축하고자 함. 한발 더 나아가, 웹 시스템 기반의 카탈로그 서비스를 만들어서, 본

연구진의 연구 결과를 다양한 시각화 방법으로 쉽게 파악하고 본 연구팀이 구축한 벤치마크 데이터셋을 간단하게 공유할 수 있도록 하고자 함. 이는 발달 지연 및 장애 아동들에 관한 연구를 진행하고자 하는 다양한 분야의 연구자들의 진입장벽을 낮추고 지속적으로 축적되는 연구 결과들을 종합적으로 접근할 수 있는 생태계 구축을 가능하게 할 것이다

[2. 최종 목표]

- 발달 지연 및 장애 아동들의 뇌영상, 오믹스, 행동 데이터의 다중 모달리티 벤치마크 데이터베이스 및 웹 기반의 카탈로그 서비스 구축

[3. 접근]

- 다중 모달리티 데이터셋은 다양한 분야의 연구자들이 관심을 갖고 접근할 수 있다는 장점이 있지만, 진입 장벽을 낮추고 더욱 많은 분야의 연구자들이 참여하여 다양한 접근의 연구를 진행할 수 있도록 촉진하기 위해서는 1) 데이터에 대한 접근 용이성 2) 기존 연구 결과들에 대한 접근 용이성이 만족되어야 함.
- 데이터에 대한 접근 용이성을 위하여, 세부목표 2-1-3에서 제안한 Brainlife 플랫폼을 이용한 뇌영상 데이터의 공유 뿐만 아니라, 새로운 데이터베이스를 구축하여 오믹스 데이터와 행동 데이터에 대한 접근 용이성을 증가시키고자 함. 또한 새로운 데이터베이스와 Brainlife 플랫폼을 연계하는 웹 기반의 시스템을 통해서 다양한 모달리티 데이터들을 쉽게 다운 받을 수 있도록 하고자 함. 특히 간단한 키워드 검색만으로 원하는 모달리티의 데이터들을 특정적이고 종합적으로 다운로드 받을 수 있도록 쿼리 시스템을 만들고자 함.
- 기존 연구 결과들에 대한 접근 용이성을 만족하기 위해, 유전체 연구에서 활발히 사용되는 웹 기반의 카탈로그 서비스와 kaggle이나 paperswithcode 등의 리더보드

서비스를 웹 기반의 데이터베이스 시스템에 통합하고자 함. 이는 발달 지연 및 장애에 관한 연구에 관심있는 다양한 연구자들이 발달 지연 및 장애와 연관이 있는 것으로 보고되는 뇌신경학적 특성과 유전체 발현 및 행동적 특성 등 다양한 정보들을 시각적으로 파악할 수 있게 할 것임. 이는 기존의 연구 결과들을 바탕으로 연구자들이 새로운 연구를 디자인할 수 있게 도움을 줄 것임. 또한 해당 데이터베이스를 사용하는 연구자들로 하여금 자신들의 결과를 해당 카탈로그 시스템에 등록할 수 있게하여, 새로운 연구 결과들이 축적될 수 있는 기반을 마련하고자 함. 특히나 리더보드 시스템은 데이터 분석가 및 AI 모델 개발자들로 하여금 발달 지연 및 장애 아동들을 조기발견하기 위한 특화된 기계학습 알고리즘을 개발할 수 있도록 촉진할 것으로 기대함.



그림 31. 해외 딥러닝 학습 모델 및 유전체 데이터의 카탈로그 시스템의 예시

[4. 기대되는 결과 및 유의성]

- 기존 연구 결과들을 다양한 시각화를 통해 시스템 사용자들에게 제공하는 것은 연구 시작에 대한 진입 장벽을 낮출 수 있을 것임.
- 수치 성능 평가 기반의 리더보드는 발달 지연 및 장애의 조기 예측이라는 하이리스크 하이리턴의 문제를 해결하기 위한 데이터 분석가와 AI 모델 개발자들의 경쟁적인 연구를 촉진할 수 있을 것임.

연구개발 목표 2-2: 멀티모달 뇌영상, 오믹스, 영상기반 행동데이터로부터의 후보 바이오마커 제시(기존 데이터 기반 AI 모델링 및 바이오인포매틱스)

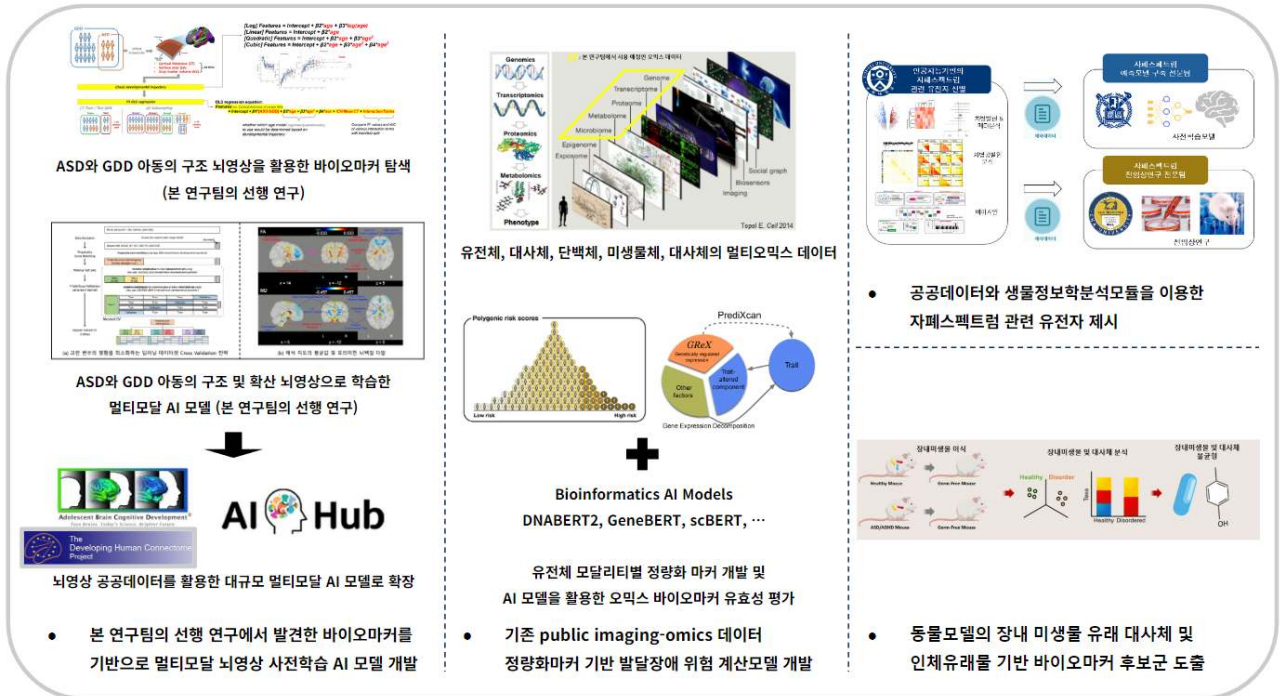


그림 32. 연구개발목표 2-2의 요약

세부목표 2-2-1. 바이오마커 후보군과 병인 기전에 대한 임상적 자문

바이오마커 후보군 예시

MRI 3D Volumetry	GDD 아동(n=246)과 ASD 아동(n=72)을 구분할 수 있는 가장 최적화된 딥러닝 모델 도출 → ASD를 보다 조기에 선별할 수 있는 바이오 마커로서의 가능성이 있음.		
	구성 요소	GDD에 비해	Region of interest(ROI)
	cortical thickness	증가	supramarginal area(L)
		감소	pericalcarine(R) pars opercularis(R)
	surface area	증가	middle temporal area(R)
		감소	pericalcarine(L) supramarginal area(L)
	gray matter volume	감소	pericalcarine(L)
fMRI 신경인지 네트워크	뇌신경 신경발달장애 중 ASD는 특히 뇌의 흥분, 억제시스템의 불균형이 병인으로 지목되고 있으나, 매크로 뇌영상으로부터의 충분한 근거가 없음. 특히 최근 salience network의 비전형적인 활성화가 ASD, 조현병과 같은 정신질환과 관련되고 있다는 보고에 근거하여 뇌핵심신경네트워크간 관계와 억제성 신호와의 관계를 ASD 같은 신경발달장애의 바이오마커 발굴을 위해 활용해볼 수 있음.		
fNIRS를 이용한 뇌활성 영역	TD 아동과 ASD 아동을 구분할 수 있는 영역별 뇌활성도의 정량적 비교 → 대규모 아동을 대상으로 측정한 추적데이터를 통해 특정 과제 수행시 나타나는 뇌활성도의 비교로 ASD를 보다 조기에 선별할 수 있는 바이오 마커로서의 가능성이 있음.		
	선행 연구	TD에 비해	ROI
	face-to-face imitation/interpersonal synchrony tasks(Su et al., 2020)	hypoactivation	middle/inferior frontal gyri middle/superior temporal gyri
		hyperactivation	inferior parietal lobule
	cooperation and competition(Kruppa et al., 2021)	localized coherence	frontopolar cortex
	Lincoln Log dyadic game	증가	inferior parietal lobe
		감소	superior temporal sulcus

표 6. 바이오마커 후보군 예시

[1. 근거 및 배경]

- 여러 모달리티의 뇌영상을 사용하여 자폐 스펙트럼 장애와 같은 발달장애의 바이오마커를 찾기 위해 최근에는 다양한 딥러닝 모델이 활용되고 있음. 특히, ABIDE(Autism Brain Imaging Data Exchange)라는 자폐 스펙트럼 장애 연구를 위한 대규모 구조 및 기능 뇌영상 데이터셋이 공개되면서, 이를 벤치마크삼아 뇌영상 딥러닝 모델의 예측 성능을 높이고 신경과학적인 해석을 하려는 시도가 계속되었음⁹³

⁹⁴

- 한편, ABIDE는 5세에서 64세를 대상으로 한 데이터셋이기에 소아 발달장애의 바이오마커를 발굴하기 위해서는 좀 더 좁은 나이대의 데이터를 사용한 딥러닝 모델을 학습해야 함. 그러나 나이대를 좁혀 0세에서 6세까지의 소아 데이터를 사용하면 데이터의 수가 딥러닝 모델을 처음부터 딥러닝 모델을 처음부터 학습하기에는 부족하고 과적합될 가능성이 높음. 이러한 경우 보다 많은 뇌영상 데이터를 사용하여 사전학습된 모델을 사용하면 윤곽이나 선 등의 기본적인 저차원 정보는 어느정도 학습된 상태에서 모델 학습을 시작할 수 있음. 차지욱 교수 연구실에서 발표한 기능 뇌영상 transformer 모델 SwiFT의 경우 약 16,000 명의 기능 뇌영상을 사용해 사전학습되었으며 이후 성별 예측이나 지능 점수 예측에서 최고 성능을 보인 바 있음⁹⁵.

⁹³ Heinsfeld, A. S., Franco, A. R., Craddock, R. C., Buchweitz, A., & Meneguzzi, F.(2018). Identification of autism spectrum disorder using deep learning and the ABIDE dataset. *NeuroImage: Clinical*, 17, 16-23.

⁹⁴ Traut, N., Heuer, K., Lemaître, G., Beggato, A., Germanaud, D., Elmaleh, M., ... & Varoquaux, G.(2022). Insights from an autism imaging biomarker challenge: promises and threats to biomarker discovery. *NeuroImage*, 255, 119171.

⁹⁵ Kim, P., Kwon, J., Joo, S., Bae, S., Lee, D., Jung, Y., ... & Moon, T.(2024). SwiFT: Swin 4D fMRI Transformer. *Advances in Neural*

- 하지만, 현재까지 소아 발달장애 연구를 위한 뇌영상 사전학습모델은 발표된 적이 없음. 비록 자폐 스펙트럼 장애나 주의력 결핍/과잉행동 장애의 예측을 위한 멀티모달 뇌영상 딥러닝 모델이 발표된 적은 있으나 개별 발달장애 및 데이터셋에 특이적이기 때문에 연구 결과의 확장가능성이나 재현가능성이 부족함^{96 97}.
- 따라서 본 연구 과제에서 수집하는 공공데이터 및 기 확보데이터를 활용하여 사전학습된 모델을 개발한다면, 자폐 스펙트럼 장애와 전반 발달 지연 등의 다양한 발달장애를 분류하는 데 전이학습이 가능해지며 특정 질환의 경계에 있던 아동들에 대한 아형 군집화(subtype clustering) 또한 가능해짐.

[2. 최종 목표]

- 구조 및 확산 뇌영상을 포함하는 공공 데이터 및 분당차병원의 뇌영상 데이터를 통합하여 멀티모달 뇌영상 사전학습 모델 개발
- 멀티모달 뇌영상 사전학습 모델을 본 기관에서 수집한 소아 데이터에 전이학습하여 자폐 스펙트럼 장애, 전반 발달 지연, 지적 장애 등의 발달장애 분류 및 아형 군집화
- 해석가능한 AI 방법론을 학습된 모델에 적용하여 구조 및 확산 뇌영상에서 각 발달장애의 바이오마커 후보 탐색

[3. 접근]

Information Processing Systems, 36.

⁹⁶ Dcouth, S. S., & Pradeepkandhasamy, J.(2024). Multimodal Deep Learning in Early Autism Detection—Recent Advances and Challenges. *Engineering Proceedings*, 59(1), 205.

⁹⁷ Zhou, X., Lin, Q., Gui, Y., Wang, Z., Liu, M., & Lu, H.(2021). Multimodal MR images-based diagnosis of early adolescent attention-deficit/hyperactivity disorder using multiple kernel learning. *Frontiers in Neuroscience*, 15, 710133.

- 멀티모달 뇌영상 사전학습 및 전이학습용 데이터셋 구성
 - 기확보된 분당차병원의 뇌영상과 developing HCP 등의 소아 뇌영상 데이터셋 외에도 차지욱 교수 연구실에서 활용가능한 대규모 뇌영상 데이터셋인 ABIDE, ABCD, HCP, UK Biobank 등에서 구조(T1w) 및 확산(DTI) 뇌영상을 최대한 확보함. 앞서 말한 모든 뇌영상 데이터셋을 포함하면 약 60,000 명의 구조 및 확산 뇌영상 데이터를 사용할 수 있을 것으로 생각함.
 - 소아 발달장애 예측 및 아형 군집화에 사전학습된 모델을 활용할 수 있도록 전이학습용 데이터셋 또한 따로 구성할 예정임. 분당차병원의 뇌영상 데이터와 developing HCP 등의 공공데이터를 융합하면 만 6세 이하의 소아 약 3,500 명의 뇌영상 데이터셋을 구성할 수 있을 것임.
- 멀티모달 뇌영상 모델의 효율적이고 효과적인 사전학습 방법 탐색
 - 뇌영상의 3차원 공간 정보를 효과적으로 학습할 수 있으면서도 대용량 데이터를 효율적으로 처리할 수 있는 모델을 개발하기 위해서는 병렬 처리가 가능한 트랜스포머 계열의 모델을 차용하는 것이 유리함. 따라서 본 모델에서는 vision transformer나 swin transformer를 변형한 구조의 모델을 학습할 예정임⁹⁸.

⁹⁸ Jiang, Y., Zhang, Y., Lin, X., Dong, J., Cheng, T., & Liang, J.(2022). SwinBTS: A method for 3D multimodal brain tumor segmentation using swin transformer. Brain sciences, 12(6), 797.

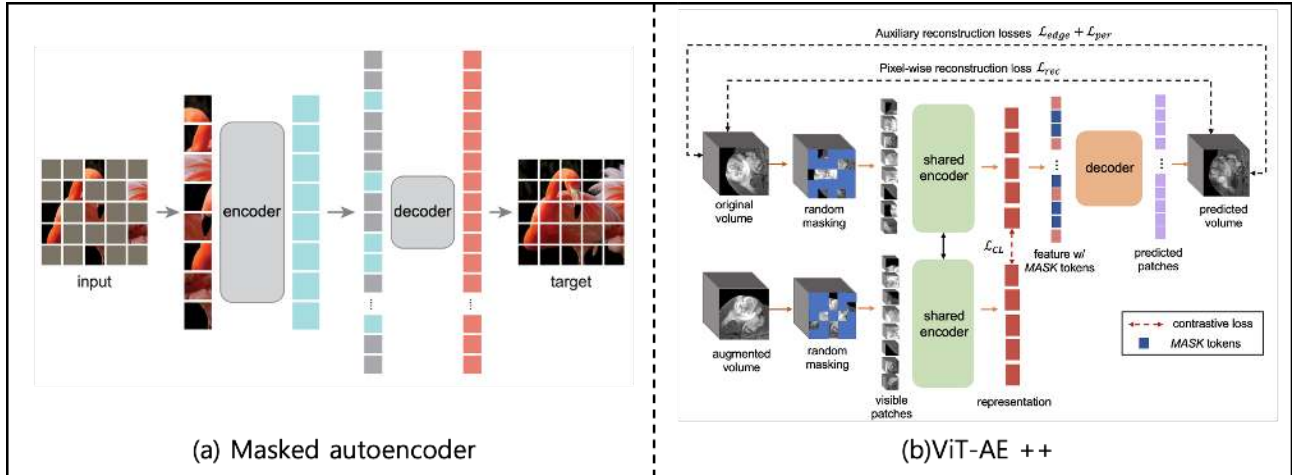


그림 33. 딥러닝 모델 사전학습에 사용될 자기지도학습 방법인 masked image modeling의 예시

- 딥러닝 모델의 사전학습에 있어 최근에 많이 활용되는 자기지도학습 방법에는 masked modeling 기법이 있음. 그림 33에서 볼 수 있듯, 이는 데이터의 일부분을 지운 후(masking) 딥러닝 모델에 통과시키고 비어 있는 부분을 채워넣어 원본 이미지를 복원해내게끔 모델을 학습하는 방법임. 이 방법은 입력 데이터의 일부만을 모델에 통과시키기 때문에 효율적인 연산을 가능하게 하면서도 이미지 데이터의 의미를 잘 학습하는 것으로 알려져 있다⁹⁹. 이러한 방식으로 뇌영상 데이터를 사용해 vision transformer 구조의 모델을 학습해 다른 자기지도학습 방법보다 더 나은 성능을 보인 선행 연구를 참조할 예정임¹⁰⁰.

⁹⁹ He, K., Chen, X., Xie, S., Li, Y., Dollár, P., & Girshick, R.(2022). Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*(pp. 16000-16009).

¹⁰⁰ Prabhakar, C., Li, H., Yang, J., Shit, S., Wiestler, B., & Menze, B.(2024, January). ViT-AE++: improving vision transformer autoencoder for self-supervised medical image representations. In *Medical Imaging with Deep Learning*(pp. 666-679). PMLR.




그림 34. 대조 학습의 대표적인 모델인 SimCLR와 뇌영상 분야에 적용된 y-Aware 알고리즘.

- 뇌영상 모델의 사전학습에서 또 다른 중요한 요소는 멀티모달 데이터인 구조 및 확산 뇌영상으로부터 유의미한 표상을 추출하도록 모델을 학습하는 것임. 이를 위해 각 피실험자의 메타데이터를 활용한 대조 학습(contrastive learning)을 진행할 예정임(그림 34).
- 대조 학습의 가장 대표적인 예인 SimCLR는 한 이미지로부터 두 개의 증강된 이미지를 생성하여 같은 이미지로부터 생성된 이미지끼리는 positive pair로 묶고, 나머지 이미지로부터 나온 이미지와는 negative pair로 묶어서 딥러닝 모델의 잠재 표상(latent feature)들이 서로 가까워지거나 멀어지도록 손실 함수를 설계하여 모델을 학습함¹⁰¹. 이외에도 뇌영상 분야에서 나이와 같은 메타데이터를 고려하여 나이가 비슷하면 잠재 공간 상에서 표상을 더 가깝게 학습시키는 대조 학습 모델이 제시된 바 있음¹⁰². 이러한 방법들을 기반으로

¹⁰¹ Chen, T., Kornblith, S., Norouzi, M., & Hinton, G.(2020, November). A simple framework for contrastive learning of visual representations. In *International conference on machine learning*(pp. 1597-1607). PMLR.

¹⁰² Dufumier, B., Gori, P., Victor, J., Grigis, A., Wessa, M., Brambilla, P., ... & Alzheimer's Disease Neuroimaging Initiative.(2021). Contrastive learning with continuous proxy meta-data for 3D MRI classification. In *Medical Image Computing and Computer Assisted Intervention–MICCAI 2021: 24th International Conference, Strasbourg, France, September 27–October 1, 2021*,

해서 같은 피험자의 데이터일 경우와 메타데이터가 유사할수록 잠재 표상을 더욱 가깝게 학습시키는 대조 학습 방법을 멀티모달 표상 학습에 사용할 예정이다.

- 사전학습된 모델을 활용한 자폐 스펙트럼 장애, 전반 발달 지연 등의 발달장애 바이오마커 탐색




그림 35. 분당차병원의 소아 멀티모달 뇌영상을 사용한 자폐 스펙트럼 장애 및 전반 발달 지연 분류 모델 연구

- 발달장애의 뇌영상 바이오마커를 탐색하기 위해서는 훈련-검증 데이터셋을 적절히 구성하는 것부터 시작해서 모델의 학습이 끝난 뒤 해석가능한 AI 방법론을 사용하여 학습된 모델을 치밀하게 분석하는 과정이 필요함. 이와 관련해 자폐 스펙트럼 장애 및 전반 발달 지연의 바이오마커를 탐색하기 위해 차지욱 교수 연구실에서 분당차병원의 소아 구조 및 확산 뇌영상 데이터를 사용한 멀티모달 딥러닝 모델 연구를 수행하여 논문 제출을 준비 중에 있음. 그림 36에서 볼 수 있듯, 이 연구에서는 성별이나 나이와 같은 교란 변수(confounder)의 집단간 차이를 최소화하는 방식으로 훈련-검증

데이터셋을 구성하였음. 또한, 가장 성능이 좋았던 모델을 사용하여 시험(test) 데이터셋에서 올바르게 예측된 아동의 뇌영상으로부터 integrated gradients와 noise tunnel을 결합한 해석가능 AI 방법을 적용함. 이후 통계적으로 유의미한 뇌 박셀(voxel)을 얻어내어 자폐 스펙트럼 장애와 전반 발달 지연의 분류에 주요하게 기여한 뇌백질의 특성을 찾아내는데 성공함(뇌영상 후보 바이오마커).

- 뿐만 아니라, 차지욱 교수 연구실에서는 공공 데이터를 활용하여 발달장애를 비롯한 아동들의 정신질환의 뇌영상 바이오마커를 탐색하는 연구들 또한 진행하고 있음. 미국 아동들의 뇌 인지 발달에 대한 대규모 인구학적 공공 데이터인 ABCD study(Adolescent Brain Cognitive Development study)데이터를 활용하여, 뇌 구조 공명영상으로부터 아동들의 BMI 지수를 예측하는 AI 모델을 개발함. 또한 이 AI 모델을 전이학습하여 아동들의 미래 비만 여부와 우울증 진단 여부의 예측 정확도를 크게 상승시킴.
- 추가적으로, 해석가능 AI 방법을 적용하여 과체중/비만 아동들의 문제적 행동 점수와 라이프 스타일의 차이를 발견함으로써, AI 모델을 활용한 뇌 구조 바이오마커의 활용가능성에 대해서 확인하였고 현재 논문 제출을 준비 중임. 이는 AI 방법론을 다각적으로 활용하고 성별과 신체 상태 등의 질환 관련 정보들을 통합적으로 활용하여 발달장애 아동들의 뇌영상 바이오마커를 발견하고자하는 전략을 찾아냄에 있어서 본 연구진이 크게 기여할 수 있음을 보여줌.
- 현재까지 발표된 뇌영상 딥러닝 연구들은 해석 지도를 개별 데이터 수준에 적용해 그 결과를 나열하는 수준에 그쳤음. 이러한 한계를 극복하기 위해 위

연구에서 사용한 해석가능한 AI 방법론을 발전시켜 적용할 예정임. 구체적으로는 다중 타겟을 예측하게끔 학습한 모델에서 각 타겟 질환 별로 딥러닝 모델이 학습한 표상을 잠재 차원에서 분석하여 교란 변수와의 상관관계는 없는지 확인하고, 해석 지도 수준에서는 통계적으로 유의미한 영역들을 찾아낸 뒤 집단간 통계분석을 거친 결과와 일관적인 결과를 보이는지 검증할 것임. 또한 질환 라벨을 임의로 섞은 뒤 학습한 모델의 해석 결과와도 비교하여 모델이 학습한 표상이 실제로 타겟 발달장애와 관련이 있는 유의미한 표상인지 확인할 것임.

- 신뢰가능하고 투명한 AI 연구 문화를 위한 사전학습된 모델의 공개
 - 인공지능 연구가 사회에 미치는 영향을 고려하는 것은 모델의 개발 및 검증만큼이나 중요한 일임. 특히 인간 임상 데이터를 사용하는 경우에는 윤리적인 측면을 충분히 고려하여 신뢰가능한 AI 연구를 수행해야 함. 또한 본 과제에서 개발한 모델이 수많은 소아 발달장애 연구에 확장되기 위해서는 사전학습된 모델을 공개할 필요가 있음. 이러한 과정은 딥러닝 연구의 재현가능성과 투명성을 확보하는 데 기여할 것임. 따라서 본 과제를 수행하는데 사용된 코드나 사전학습된 모델은 특허 등록 등의 절차에 관해 합의를 거친 뒤 공개하여 국내외 연구자들이 소아 발달장애 연구에 활용할 수 있도록 만들 예정임.

[4. 예상되는 난관과 극복 방안]

- 다국적, 다기관 데이터의 이질성 문제

- [난관] 사전학습을 위해 사용할 데이터셋에서 해외 아동의 데이터가 차지하는 비율이 95% 이상이 때문에 국내 데이터를 사용하는 경우 도메인 전환이 생길 것임. 또한 자기공명영상 특성상 서로 다른 기기나 프로토콜을 통해 획득한 데이터 사이에 유의미한 차이가 존재함.
- [극복 방안] 사전학습 단계에서 인종(ethnicity)이나 촬영 기관과 같은 변수를 고려할 수 있도록 data 및 mri harmonization에 관한 손실 함수를 설계할 것이다¹⁰³. 또한 전이학습 단계에서도 모델이 발달장애에 관련된 표상을 학습할 수 있게끔 deconfounding module을 추가하여 학습할 예정이다¹⁰⁴.

[5. 기대되는 결과 및 유의성]

- 자폐 스펙트럼 장애, 전반 발달 지연 등의 발달장애를 갖는 아동들의 뇌에서 구조적인 차이를 확인할 수 있을 것임. 이를 통해 기존에 알려지지 않았던 소아 발달장애의 신경과학적 지식을 확장할 수 있음.
- 전세계 최초로 소아 발달장애 분야에서 멀티모달 뇌영상 사전학습 딥러닝 모델 및 발달장애 전이학습 모델을 공개할 것임. 이를 통해 다른 연구자들이 소아 발달장애 연구 등에 활용할 수 있는 기초가 되는 모델로서 작용할 것임.
- 투명하고 신뢰가능한 AI 연구 문화를 구축하는 데 동참함으로써 추후에 진행될 뇌영상 딥러닝 연구의 본보기를 제시할 수 있을 것임. 또한 임상의학 분야와 인공지능 분야가 융합될 수 있는 다학제적 연구의 기틀을 마련할 것임.

¹⁰³ Liu, S., & Yap, P. T.(2024). Learning multi-site harmonization of magnetic resonance images without traveling human phantoms. *Communications Engineering*, 3(1), 6.

¹⁰⁴ Zhao, Q., Adeli, E., & Pohl, K. M.(2020). Training confounder-free deep learning models for medical applications. *Nature communications*, 11(1), 6010.

세부목표 2-2-3. 기존 public imaging-omics 데이터 정량화마커 기반 발달장애 위험 계산모델 개발

[1. 근거 및 배경]

[자폐 스펙트럼 장애에서 객관적인 정량적 오믹스 바이오마커의 필요성]

- 자폐 스펙트럼 장애(ASD) 같은 발달장애는 다양한 유전적-환경적 요인의 복합적인 영향을 받는 다인자성(multifactorial) 질환으로, 개인별 임상 증상은 중증 장애 및 지적 장애(ID)부터 평균이상의 지능 지수(IQ, intelligence quotient)나 높은 학업 수준과 직업을 가진 개인까지 매우 이질적임¹⁰⁵.
- ASD는 80~90%에 가까운 높은 유전율을 가진 질환으로¹⁰⁶, 초기 연구는 연관된 구조적 DNA 변이 규명에 집중된 반면, 최근의 연구에는 연관된 유전자 발현(gene expression)과 후생유전학(epigenetics) 연구까지 함께 다방면으로 수행되어 오며 다각적인 데이터가 축적되고 있음. 이에 발달장애의 발생과 치료 과정의 총체적인 이해를 위해 전형적/비전형적인 생리적, 행동적 요소와 상호작용하는 다양한 생체 메커니즘에 대한 오믹스 바이오마커를 통해 포괄적으로 접근하는 진단법 개발이 필수적임. 이에 따라 ASD에 오믹스 바이오마커의 발굴과 더불어 이들의 예측 마커로서의 성능을 평가하여 높은 예측력이 기대되는 바이오마커를 선별하고, 궁극적으로 개발하고자 하는 ASD 위험 및 중증도 진단/예측 파운데이션 모델에 도입하여 진단 보조 도구로써 탐구할 수 있을 것으로 기대함.

¹⁰⁵ Grove, J., Ripke, S., Als, T. D., Mattheisen, M., Walters, R. K., Won, H., ... & Børglum, A. D.(2019). Identification of common genetic risk variants for autism spectrum disorder. *Nature Genetics*, 51(3), 431-444.

¹⁰⁶ Schafer, G. B.(2016). Clinical genetic aspects of autism spectrum disorders. *International Journal of Molecular Sciences*, 17(2), 180. <https://doi.org/10.3390/ijms17020180>

[발달장애에서 spectrum 형 표현형을 정량화할 수 있는 생체기반 위험도 계산법 접근의 필요성]

- 최근 NGS시퀀싱(next-generation sequencing) 기술발전에 따른 DNA 유전체(genomics) 데이터의 폭발적인 증가는 인간 염색체에 존재하는 수백만 개의 단일염기다형성(SNP, Single Nucleotide Polymorphism)과 인간 복합형질 표현형과의 연관관계를 데이터 기반(data-driven)으로 탐구하는 전장유전체 연관분석법(GWAS, Genome Wide Association Study)의 등장과 함께 활발하게 탐구되어왔음.. 그러나 멘델리안 유전질환(mendelian trait)이 아닌 이상, 인간 복합형질 대부분은 단독 유전변이(SNP or genomic variant)만으로 결정되지 않고, 여러가지 유전변이들이 동시에 상호작용하여 발현하는 다인자 유전(polygenic inheritance)의 패턴을 가짐. 이외에도 하나의 유전변이가 하나의 표현형이 아닌 여러가지 표현형의 발현과 조절에 동시다발적으로 영향을 미치는 다면발현성(polytropy) 탐구의 한계에 부딪히며, GWAS결과의 임상적 해석과 적용이 어려운 방법론적 한계에 직면해 있음.
- 유전체 데이터 이외에도, 근래 대용량 고효율(high-throughput) 데이터 생성기술의 발전에 따라 환자의 표현형을 다각도로 측정하는 생체기반 데이터의 양이 폭발적으로 증가하고 있지만, 이러한 이종 데이터를 융합해 통합적인 이해를 추구하는 연구는 미비함. 더욱이 뇌-오믹스-표현형의 비선형적인 관계를 설명하는 이론과 정량적인 모델이 드물고, 현재 활발히 시도되는 질병 예측모델의 경우 유전체, 전사체 등 단편적인 오믹스 데이터를 한정적으로 이용하는데에 머무르고 있어, 복잡한 병인(multifactorial) 을 가진 발달장애의 포괄적인 이해에는 부족함. 발달장애의 정밀/맞춤형 치료를 위해서는 멀티 오믹스 데이터의 다차원 융합 분석을 통해 기존에

발견할 수 없었던 위험요인들을 밝혀내고, 발견된 인자들의 조합을 통한 더욱 고도화된 예측 알고리즘 구축이 필요함.

- 이러한 한계를 해결하기 위해, 타겟형질에 영향을 주는 수십, 수백만개의 연관 DNA 마커들을 하나의 숫자로 표현한 다중유전자점수(PRS, polygenetic risk score) 접근법이 개인의 유전적 경향성과 데이터를 단일 수치로 표현해내는 용이성으로 주목받고 있음. 다중유전자점수(PRS)는 개인의 타고 태어난 유전적 성향을 간편한 숫자값(numerical value)으로 정량화 함으로써, 특정 질병 및 형질의 발현에 대한 예측지표로 사용가능성이 활발히 탐구되어 오며^{107 108}, 단편적인 숫자값으로서 타 이종 데이터 모달리티와의 연관가능한 편리성으로 인해, 뇌영상이나 사회행동적 지표와 결합되어 사용되는 등¹⁰⁹ 방법론적 용이성이 주목받고 있음. 그러나 형질에 따라, 다중유전자점수(PRS)의 예측성능에 편차가 있으며, PRS만으론 충분한 설명력을 보이지 않는 등 적용되는 형질과 데이터의 품질에 따라 임상적용의 한계를 부분적으로 보이고 있는 상황임.
- 이에 유전체 변이 데이터에 기반한 PRS의 프레임워크에 영감을 받아 다른 오믹스 데이터 모달리티의 정량화된 형태들이 속속이 등장중임. 특히, 최근 2년내 JAMA본지를 비롯한 유수의 연구들에서 혈액의 혈장 단백질체(plasma proteomics) 데이터가 다양한 질병 위험 및 건강 결과를 예측하는데 있어 임상 지표와 성능이 비슷하거나, 더 우수한 성과를 보인다는 결과들이 발표됨. 다중유전자점수(PRS)와

¹⁰⁷ Joo, Y. Y., Atkins, K. E., Pacheco, J. A., Basile, A. O., Carroll, R., Crosslin, D. R., ... & Hakonarson, H.(2020). A polygenic and phenotypic risk prediction for polycystic ovary syndrome evaluated by phenome-wide association studies. *The Journal of Clinical Endocrinology & Metabolism*, 105(6), 1918–1936.

¹⁰⁸ Joo, Y. J., Moon, S.-Y., Wang, H.-H., & et al.(2022). Association of genome-wide polygenic scores for multiple psychiatric and common traits in preadolescent youths at risk of suicide. *JAMA Network Open*, 2022(5):e2148585.

¹⁰⁹ Park, J., Lee, E., Cho, G., Hwang, H., Kim, B. G., Kim, G., ... & Cha, J.(2024). Gene–environment pathways to cognitive intelligence and psychotic-like experiences in children. *Elife*, 12, RP88117.

비슷한 관점으로, 개인의 단백질 기반 ‘성향’을 추정 함으로써 다양한 예측적/실용적 지표로 사용될 수 있는 단백질기반 위험점수(ProRS, protein risk score)접근법은 뇌와 말초를 연결하며, 뇌의 변화를 반영하는 단백질과 같은 혈장 구성요소의 변화를 나타내기 때문에, 뇌 질환과 관련된 분자 단위의 변화를 예측할 수 있으며 우울증 등 다양한 정신 질환의 발달, 진행 또는 증상 예측의 주요마커로 활용할 수 있다는 실험적 근거가 점점 늘어나고 있기에, 생체유래 데이터 기반 정신건강 진단의 새로운 마커로 주목받고 있음^{110 111} 이런 방식으로 생체신호를 정량화한 오믹스 데이터 기반 점수화와 결합은 연속적인 스펙트럼 형태로 발현되는 발달장애의 위험도를 객관적으로 추정할 수 있고, 동시에 dimension-spectrum 표현형을 정량화할 수 있어 결정요인으로서 유용성을 객관적으로 표현할 수 있음.

[자폐 스펙트럼 장애의 유효한 바이오마커로서의 차등 발현 유전자 선정 및 도입]

- 유전자의 발현(gene expression)은 해당 유전자를 켜고 끄거나, 전사(transcription)되는 RNA에 차이를 나타냄으로써 세포와 조직의 행태(behavior)를 조절하기 때문에¹¹² 많은 연구에서 유전자 발현 분석은 다양한 질병의 새로운 진단 도구로 거론되고 있음¹¹³. 특히, 자폐 스펙트럼 장애(ASD)의 경우, 많은 유전자 변이(genetic variant)들이 해당 변이를 가지고 있는 사람들 중 일부에서만 연관된 표현형(phenotype)이 나타나는 불완전 침투(incomplete

¹¹⁰ You, J., Guo, Y., Zhang, Y., Kang, J.-J., Wang, L.-B., Feng, J.-F., et al.(2023). Plasma proteomic profiles predict individual future health risk. *Nature Communications*, 14(1), 1-13.

¹¹¹ de Sousa Maciel, I., Piironen, A-K., Afonin, A.M., et al.(2023). Plasma proteomics discovery of mental health risk biomarkers in adolescents. *Nat. Mental Health*, 1, 596 - 605.

¹¹² Nature Education.(n.d.). Gene expression regulates cell differentiation. *Nature Education Knowledge Project*.

¹¹³ Martínez-Iglesias, O., Naidoo, V., Carril, J. C., Seoane, S., Cacabelos, N., & Cacabelos, R.(2023). Gene expression profiling as a novel diagnostic tool for neurodegenerative disorders. *International Journal of Molecular Sciences*, 24(6), 5746.

penetrance)의 양상을 보이며, 발현되는 표현형 또한 다양하기 때문에¹¹⁴ 유전자에 변이가 존재하는지에 더불어 해당 유전자의 발현 정도를 함께 고려하는 것이 ASD의 위험을 조기에 예측하고 진단하는 것에 유의미함¹¹⁵. 이에 따라, 그간 연구들을 통해 ASD 환자군과 대조군 간에 발현되는 정도의 중요한 차이를 보이는 많은 유전자들이 밝혀져 왔음^{116 117 118}. 또한 서로 다른 임상증상의 ASD를 가진 일란성 쌍둥이를 대상으로 한 분석을 통해 유전자 발현의 차이가 해당 질환과 언어 장애의 중증도와 연관되어 있음이 보고된 바도 있음¹¹⁹. 또, ASD 아동의 혈액 유전자 발현의 특징이 질환의 예후를 예측하는 데 유의미하게 작용할 수 있음을 확인한 선행 연구도 존재함¹²⁰.

- 따라서 본 연구에서 궁극적으로 영유아기 한국 아동의 ASD 위험, 중증도, 예후 등의 조기 예측을 위한 파운데이션 모델을 개발하기 위하여 높은 예측력을 가진 적합한 차등 발현 유전자(differentially expressed gene)를 선정하고, 유전체, 단백질체 등의 다른 오믹스 데이터와 함께 최종 모델에 도입하는 것이 중요함.

¹¹⁴ Codina-Solà, M., Rodríguez-Santiago, B., Homs, A., Santoyo, J., Rigau, M., Aznar-Lain, G., Del Campo, M., Gener, B., Gabau, E., Botella, M. P., Gutiérrez-Arumí, A., Antiñolo, G., Pérez-Jurado, L. A., & Cuscó, I.(2015). Integrated analysis of whole-exome sequencing and transcriptome profiling in males with autism spectrum disorders. *Molecular autism*, 6, 21.

¹¹⁵ Oh, D. H., Kim, I. B., Kim, S. H., & Ahn, D. H.(2017). Predicting Autism Spectrum Disorder Using Blood-based Gene Expression Signatures and Machine Learning. *Clinical psychopharmacology and neuroscience : the official scientific journal of the Korean College of Neuropsychopharmacology*, 15(1), 47–52.

¹¹⁶ Gregg, J. P., Lit, L., Baron, C. A., Hertz-Picciotto, I., Walker, W., Davis, R. A., Croen, L. A., Ozonoff, S., Hansen, R., Pessah, I. N., & Sharp, F. R.(2008). Gene expression changes in children with autism. *Genomics*, 91(1), 22–29.

¹¹⁷ Wright, C., Shin, J. H., Rajpurohit, A., Deep-Soboslay, A., Collado-Torres, L., Brandon, N. J., Hyde, T. M., Kleinman, J. E., Jaffe, A. E., Cross, A. J., & Weinberger, D. R.(2017). Altered expression of histamine signaling genes in autism spectrum disorder. *Translational psychiatry*, 7(5), e1126.

¹¹⁸ Hu, V. W., Frank, B. C., Heine, S., et al.(2006). Gene expression profiling of lymphoblastoid cell lines from monozygotic twins discordant in severity of autism reveals differential regulation of neurologically relevant genes. *BMC Genomics*, 7, Article 118.

¹¹⁹ Hu, V. W., Frank, B. C., Heine, S., et al.(2006). Gene expression profiling of lymphoblastoid cell lines from monozygotic twins discordant in severity of autism reveals differential regulation of neurologically relevant genes. *BMC Genomics*, 7, Article 118.

¹²⁰ Lombardo, M. V., Busuoli, E. M., Schreiban, L., et al.(2021). Pre-treatment clinical and gene expression patterns predict developmental change in early intervention in autism. *Molecular Psychiatry*, 26, 7641–7651.

[자폐 스펙트럼 장애의 유효한 바이오마커로서의 Microbiome 및 Metabolome 선정 및 도입]

- 최근의 연구에서는 숙주와 장내 미생물(gut microbiota) 사이에 긴밀한 상호 작용이 있으며, 장내 미생물 불균형이 유아의 자폐 스펙트럼 장애(ASD) 증상을 유발할 수 있음이 보고되고 있음¹²¹. 아직까지 장내 미생물과 ASD간의 명확한 인과관계 및 교류 메커니즘이 명확하게 밝혀지지 않았지만, 유수의 연구에서 주요 대사체(metabolite) 및 사이토카인(cytokine)과 같은 장내 미생물의 특정 요인들이 어떤 방식으로든 중추신경계 발달에 영향을 미쳐서 ASD와 같은 발달/정신 장애를 유발할 수 있다고 주장하고 있으며, 미생물군집-장-뇌 축(microbiome-gut-brain axis)의 존재에 대한 가정을 뒷받침 하고 있음^{122 123}.
- 본 연구에서는 다른 오믹스 데이터와 함께 마이크로바이옴(microbiome)과 대사체(metabolomic) 데이터를 수집할 예정이며, 자폐 스펙트럼 장애를 가진 개인과 정상 개인간에 유의한 차별적 특성을 보이는 장내 미생물 군집 및 대사물질 바이오마커를 선정할 것임. 이어 앞서 소개한 다중유전위험점수(PRS)와 비슷한 프레임워크로 이러한 미생물 프로필을 활용 가능한 정량적 지표로 집계할 수 있는 Microbial risk score(MiRS)¹²⁴ 접근법과 각 대사체 농도와 효과 크기를 곱하여 개별

¹²¹ Dinan, T. G., & Cryan, J. F.(2017). Gut instincts: microbiota as a key regulator of brain development, ageing and neurodegeneration. *The Journal of physiology*, 595(2), 489 – 503.

¹²² Alharthi, A., Alhazmi, S., Alburae, N., & Bahieldin, A.(2022). The Human Gut Microbiome as a Potential Factor in Autism Spectrum Disorder. *International journal of molecular sciences*, 23(3), 1363. <https://doi.org/10.3390/ijms23031363>

¹²³ Agustí, A., García-Pardo, M. P., López-Almela, I., Campillo, I., Maes, M., Romaní-Pérez, M., & Sanz, Y.(2018). Interplay Between the Gut-Brain Axis, Obesity and Cognitive Function. *Frontiers in neuroscience*, 12, 155. <https://doi.org/10.3389/fnins.2018.00155>

¹²⁴ Wang, C., Segal, L. N., Hu, J., et al.(2022). Microbial risk score for capturing microbial characteristics, integrating multi-omics data, and predicting disease risk. *Microbiome*, 10, Article 121. <https://doi.org/10.1186/s40168-022-01310-2>

대사체를 점수화하고 집계하는 Metabolomic risk score(MRS)¹²⁵ 접근법을 도입하여 탐구할 예정이다.

[발달장애의 복잡한 병인 규명을 위한 멀티모달 뇌이미징-오믹스(imaging-omics) 데이터 활용의 필요성]

- 영상유전학(imaging genetics) 혹은 영상오믹스학(imaging omics)은 고효율(high throughput) 멀티모달 데이터의 축적에 따라 최근 등장한 융합 분야로, 신경발달 연구에서 중요한 접근법으로 간주됨¹²⁶. 이 방법은 뇌의 구조와 기능을 정량화하고, 특정 발달장애 표현형과 관련된 신경학적-생물학적 변화를 매핑(mapping)함으로써 유전적 위험을 명확히 하는데에 강력한 도구로 사용됨. 한 예로 ASD의 경우, 뇌의 구조적 및 기능적 특성이 병리학적 변화와 밀접하게 연관되어 있으며, 이러한 뇌 회로의 구조적, 기능적 이상 소견은 관련 유전체 및 오믹스 다형성에 따라 차이를 나타냄¹²⁷. 이에 환자의 오믹스 정보와 뇌 이미징 데이터를 통합하여 접근함으로써, 특정 오믹스계의 변이가 뇌 구조 및 기능에 미치는 영향과, 더 나아가 발달장애 표현형에 어떠한 결과를 초래하는지 종합적으로 이해할 수 있음.
- 영상-오믹스(imaging-omics)를 연계하는 접근법은 환자 멀티오믹스 데이터의 수집과 축적량이 늘어남에 따라, 발달장애의 복잡한 병인을 다각적으로 이해하고 새로운 위험/예측마커를 규명하는 데에 더욱 중요한 역할을 할 것으로 기대됨¹²⁸.

¹²⁵ Wang, Z., Zhu, C., Nambi, V., Morrison, A. C., Folsom, A. R., Ballantyne, C. M., Boerwinkle, E., & Yu, B.(2019). Metabolomic Pattern Predicts Incident Coronary Heart Disease. *Arteriosclerosis, thrombosis, and vascular biology*, 39(7), 1475 – 1482.

¹²⁶ Klein M, van Donkelaar M, Verhoef E, Franke B. Imaging genetics in neurodevelopmental psychopathology. *Am J Med Genet B Neuropsychiatr Genet*. 2017 Jul;174(5):485–537

¹²⁷ Nisar, S., Haris, M. Neuroimaging genetics approaches to identify new biomarkers for the early diagnosis of autism spectrum disorder. *Mol Psychiatry* 28, 4995 – 5008(2023).

¹²⁸ Arnatkeviciute A, Fulcher BD, Bellgrove MA, Fornito A. Imaging Transcriptomics of Brain Disorders. *Biol Psychiatry Glob Open Sci*. 2021 Oct 21;2(4):319–331. doi: 10.1016/j.bpsgos.2021.10.002. PMID: 36324650; PMCID: PMC9616271.

- 이러한 접근은 단순히 발달장애의 병리학적 메커니즘과 분자 경로(molecular pathway)를 관찰하는 것을 넘어서, 복잡한 뇌 기능과 유전적 요인들을 통합적으로 이해하고, 이를 바탕으로 한 새로운 통합 바이오마커의 발견이나 개인별 치료 및 관리 전략 개발에 활용될 수 있음. 특히 개인의 유전적 특성에 따라 뇌 구조 및 기능변화의 양상이나 그에 따른 발달장애 표현형이 다를 수 있으므로, 이러한 개인차를 고려한 맞춤형 진단 및 치료 전략 개발에도 기여할 수 있을 것임.

[2. 최종 목표]

- 자폐스펙트럼 및 발달장애의 spectrum형 표현형 위험도를 정량화 할 수 있는 멀티오믹스 바이오마커 개발 및 예측모델 수립
 - 유전체, 전사체, 단백질체, 미생물체, 대사체 등의 데이터에 기반하여, ASD 및 발달장애 표현형과 유의하게 연관되어 오믹스 기반 위험성을 정량적으로 제시할 수 있는 바이오마커의 발굴
 - 예측마커로서 유의한 성능을 보이는 멀티 오믹스 바이오마커를 선별 및 검증하고, ASD 및 발달장애 표현형의 위험 및 중증도, 임상적 표현형을 효과적으로 예측할 수 있는 딥러닝 및 기계학습 기반의 예측 계산모델 개발
 - 공공데이터의 뇌 이미징 표현형(IDP)과 멀티오믹스 데이터간의 연관패턴을 매핑하고, 그중 발달장애 타깃 표현형에 유의한 영향을 미치는 영상오믹스적 지표를 규명
- 영유아기 한국 아동의 ASD 위험, 중증도, 예후 등의 조기 예측모델을 개발을 위한, 오믹스 데이터 모달리티별 고성능의 발달장애 위험도를 정량화 바이오마커 규명
 - 유전체(Genome) - 발달장애 표현형에 유의하게 연관된 핵심 DNA마커들의

영향을 다양한 플랫폼을 이용해 점수화하고 종합하여 PRS(Polygenic risk score) 접근법으로, 유전체 기반 발달장애 위험을 정량화하는 최적의 마커를 개발함.

- 전사체(Transcriptome) - RNAseq(시퀀싱)결과 혹은 유전체의 microarray genotype 데이터 기반으로 예측된 유전자 발현(gene expression) 수준의 데이터 중 더 높은 예측성을 가진 입력값을 선택하여 다양한 정량화 기법을 탐구함.(1)표현형에 미치는 영향을 종합하여 점수화하는 PTRS(Polygenic Transcriptome Risk Score) 접근법과(2) gene expression 결과를 2차원 이미지로 취급하여 딥러닝 모델을 통한 위험점수화 방법을 고려함.
- 단백질체(Proteome) - 기존 공공데이터 및 omics 데이터에 존재하는 혈장 내 단백질 수준 또는 활성을 기반으로 하여 표현형에 대한 이들 영향을 수치화하는 혈장단백질위험점수(ProRS, protein risk score) 접근법을 도입하여 단백질체 기반 마커의 예측요인으로서의 유효성을 탐구함.
- 미생물체(Microbiome) - 질병과 관련된 대표적 미생물 분류군으로 떠오르고 있는 장내 미생물(gut microbiome) 프로필을 질병 민감성을 측정하고 예측하는 데 사용할 수 있는 요약 위험 점수로 집계하는 Microbial risk score(MiRS) 접근법을 응용하여 마커로서의 유용성 검증을 목표로 함.
- 대사체(Metabolome) - 질병군과 대조군 사이에 차별적인 특성을 보이는 대사물질 식별하고, 각 대사체의 농도와 효과 크기를 곱하여 개별 대사체를 점수화 및 집계하는 Metabolomic Risk Score(MeRS) 접근법 사용하여 ASD 및 발달장애 고성능 예측마커를 규명함.

[3. 접근]




그림 36. 표현형에 투영되는 다양한 오믹스 데이터와 정밀의료를 위한 데이터 통합 모식도¹²⁹




그림 37. 다양한 오믹스 바이오마커 정량화 접근법 예시

¹²⁹ Topol, E. J. (2014). Individualized medicine from prewomb to tomb. *Cell*, 157(1), 241–253.

- 기존 문헌 및 공공데이터를 이용해 ASD 및 발달장애의 표현형과 유의미하게 연관된 멀티오믹스 마커 후보군 발굴

Genomics(유전체)	MTHFR, RFC, MTR(Jensen AR et al, 2022) ¹³⁰ NRXN1, SHANK3, SHANK2, SNC2A, CHD8, DYRK1A, POG2, GRIN2B, KATNAL2(Goldani AAS et al, 2022) ¹³¹
Transcriptome (전사체)/ Differentially Expressed Gene (차등 발현 유전자)	(예) SPON2, IL2RB, PRF1, SH2D1B, GZMB, CX3CR1, PAM(Jeffrey P. Gregg et al, 2008) ¹³² , HNMT, HRH1, HRH2, HRH3(C Wright et al, 2017) ¹³³ , ASS, CHL1, FLAP, DAPK1, F13A1, IL6ST, NAGLU, PTGS2, ROBO1, CD44, EGR2, FLT1, ITGB7, NAGLU(Valerie W Hu et al, 2006) ¹³⁴
Proteome(단백체)	MAPK14, IgD, DERM, EPHB2, suPAR(Hewitson et al, 2021) ¹³⁵ ApoA1, ApoA4, PON1 ¹³⁶

¹³⁰ Jensen, A. R., Lane, A. L., Werner, B. A., McLees, S. E., Fletcher, T. S., & Frye, R. E.(2022). Modern Biomarkers for Autism Spectrum Disorder: Future Directions. *Molecular diagnosis & therapy*, 26(5), 483–495. <https://doi.org/10.1007/s40291-022-00600-7>

¹³¹ Goldani, A. A., Downs, S. R., Widjaja, F., Lawton, B., & Hendren, R. L.(2014). Biomarkers in autism. *Frontiers in psychiatry*, 5, 100. <https://doi.org/10.3389/fpsy.2014.00100>

¹³² Gregg, J. P., Lit, L., Baron, C. A., Hertz-Picciotto, I., Walker, W., Davis, R. A., Croen, L. A., Ozonoff, S., Hansen, R., Pessah, I. N., & Sharp, F. R.(2008). Gene expression changes in children with autism. *Genomics*, 91(1), 22–29. <https://doi.org/10.1016/j.ygeno.2007.09.003>

¹³³ Wright, C., Shin, J. H., Rajpurohit, A., Deep-Soboslay, A., Collado-Torres, L., Brandon, N. J., Hyde, T. M., Kleinman, J. E., Jaffe, A. E., Cross, A. J., & Weinberger, D. R.(2017). Altered expression of histamine signaling genes in autism spectrum disorder. *Translational psychiatry*, 7(5), e1126. <https://doi.org/10.1038/tp.2017.87>

¹³⁴ Hu, V. W., Frank, B. C., Heine, S., et al.(2006). Gene expression profiling of lymphoblastoid cell lines from monozygotic twins discordant in severity of autism reveals differential regulation of neurologically relevant genes. *BMC Genomics*, 7, Article 118. <https://doi.org/10.1186/1471-2164-7-118>

¹³⁵ Hewitson, L., Mathews, J. A., Devlin, M., Schutte, C., Lee, J., & German, D. C.(2021). Blood biomarker discovery for autism spectrum disorder: A proteomic analysis. *PloS one*, 16(2), e0246581. <https://doi.org/10.1371/journal.pone.0246581>(Retraction published PLoS One. 2024 Mar 28;19(3):e0301648)

¹³⁶ Ngounou Wetie, A. G., Wormwood, K., Thome, J., Dudley, E., Taurines, R., Gerlach, M., Woods, A. G., & Darie, C. C.(2014). A pilot proteomic study of protein markers in autism spectrum disorder. *Electrophoresis*, 35(14), 2046–2054. <https://doi.org/10.1002/elps.201300370>

Microbiome (미생물군유전체)	Eubacterium_sp_CAG_248, Prevotella copri ¹³⁷
Metabolome (대사체)	FAHFA(18:1(9Z)/9-O-18:0), DL-2-hydroxystearic acid, 7(S),17(S)-dihydroxy-8(E),10(Z),13(Z),15(E),19(Z)-docosapentaenoic acid, miR-328-3p, miR-3135a, miR-3135a, miR-328-3p, sAPP- α ¹³⁸

표 7. 기존 문헌 및 공공데이터 분석을 통해 발굴한 멀티오믹스 마커 후보군

- 유전체 기반: Polygenic risk score(PRS) 및 단백질 기반 ProRS 를 통한 표현형 관련 멀티오믹스 바이오마커의 정량화
 - [다중유전자위험점수 계산]
 - 다중유전자위험점수(Polygenic Risk Score) 및 혈장 단백질 기반 위험점수(Plasma Proteomic Risk Score)를 활용한 다차원 바이오마커 정량화를 실시함. GWAS catalogue 등을 통한 전장유전체 연관분석(GWAS, genome-wide association study) 결과의 공개로 핵심 DNA 마커들을 통한 형질예측이 가능해졌음. GWAS 연구는 전통적인 회귀분석을 사용하여 수백만 개의 SNP을 분석하는 유용한 방법으로 인류유전학 연구에서 주목받아왔음. 그러나 인간 복합형질의 다중유전성(polygenicity), 변이들의 다면발현성(pleiotropy) 등의 문제로 인해 임상적 해석과 적용에 있어 어려움이 많은 상황임. 이에 인간의 표현형에 영향을 미치는 수많은 DNA마커들을 점수를 수치화 시킨 다중유전자점수(PRS, polygenic risk score) 접근법이 개인의

¹³⁷ Wang, W., & Fu, P.(2023). Gut Microbiota Analysis and In Silico Biomarker Detection of Children with Autism Spectrum Disorder across Cohorts. *Microorganisms*, 11(2), 291. <https://doi.org/10.3390/microorganisms11020291>

¹³⁸ Liu, J., Tan, Y., Zhang, F., Wang, Y., Chen, S., Zhang, N., Dai, W., Zhou, L., & Li, J. C.(2024). Metabolomic analysis of plasma biomarkers in children with autism spectrum disorders. *MedComm*, 5(3), e488. <https://doi.org/10.1002/mco2.488>

유전적 특성을 효과적으로 반영하는 용이함으로 인해 주목을 받고 있음.

○ [PRS의 한계를 보완할 타 오믹스 기반 점수 정량화 개발]

- 그러나 다중유전자점수(PRS) 접근법 역시 유전적 복잡성을 완전히 반영하지 못해 GWAS 연구가 가지는 근본적인 한계는 해결하지는 못하고 환경적·생활습관 요인을 반영하지 못하는 한계가 있음. 이러한 한계를 보완하기 위해 혈장 내 단백질 수준 또는 활성을 기반으로 한 혈장단백질위험점수(ProRS, protein risk score) 접근법 및 다른 오믹스 모달리티 기반 정량화 마커를 다각적으로 도입예정임. 혈장 내 단백질은 환경요인, 생활습관, 약물 등과의 상호작용을 반영하고 현재의 생물학적 활동(ongoing biological processes)을 보여주며, 이를 통해 인간의 생물학적(biological) 프로필과 표현형 발현 경향을 효과적으로 나타낼 수 있음.
- 다만 단백질체는 본 연구를 통해 전향적(prospective)으로 모을 환자의 오믹스 데이터 모달리티에는 고비용의 문제로 포함되지 않으나, UK Biobank 등 공공데이터에 Olink panel 형태로 존재할 데이터를 활용하여 점수화 및 예측마커로서의 성능을 테스트할 예정임. ProRS가 건강결과 예측마커(health outcome predictive marker)로서의 유용성을 주목받는 최근의 해외 연구 추세에 미뤄볼때 반드시 필요한 검증과정임.
- → 점수화 된 수치를 통해 유전체, 단백질체 데이터의 차원을 축소시킬 수 있고 이는 다양한 멀티모달 데이터(영상 데이터, 뇌 영상 등)와

연계하여 탐구 가능하고 구조방정식 모델링(SEM), 멘델리안 무작위분석(MR) 등 주요 요인들의 연관/공변/인과관계 분석 시 확장 가능하며 추후 계산진단 모델 구축에 유용함.

- 전사체 기반: PrediXcan을 활용한 유전자 발현 수준 예측 및 PTRS를 통한 정량화 마커 개발 전략
 - 본 연구에서는 전사체(transcriptome) 검출을 위해 1차원 RNA sequence 데이터와 유전자별로 맵핑된 발현량 값등 다양하게 대상군들의 RNA 데이터를 수집할_π 예정임¹³⁹. 그러나 RNA전사체 특유의 불안정성과 그로 인한 짧은 반감기는 데이터의 신뢰도를 떨어뜨릴 수 있다는 단점이 있기 때문에¹⁴⁰, RNA seq data와 병행하여 유전자형(genotype) 데이터에 기반해 유전자 발현 수준을 추정할 수 있는 PrediXcan¹⁴¹을 추가로 활용하여 더 안정적인 예측모델 구축을 목표로 접근하고자 함.
 - PrediXcan은 개인의 유전자형 데이터에 regularized linear regression의 일종인 elastic net regression을 적용함으로써 각 유전자의 내부 혹은 시작과 끝 지점으로부터 각각 1MB 범위 내에 존재하는 SNP들인 cis-SNP들을 통해 유전자별 발현 수준을 예측하고, 타겟 표현형(target phenotype)과의 상관관계를 분석함¹⁴². 이에 따라 각 샘플의 유전자별 발현 예측값들이 포함된

¹³⁹ Rai, M. F., Tycksen, E. D., Sandell, L. J., & Brophy, R. H.(2018). Advantages of RNA-seq compared to RNA microarrays for transcriptome profiling of anterior cruciate ligament tears. *Journal of Orthopaedic Research*, 36, 484-497. <https://doi.org/10.1002/jor.23661>

¹⁴⁰ Wang, C., & Liu, H.(2022). Factors influencing degradation kinetics of mRNAs and half-lives of microRNAs, circRNAs, lncRNAs in blood in vitro using quantitative PCR. *Scientific Reports*, 12, Article 7259. <https://doi.org/10.1038/s41598-022-11339-w>

¹⁴¹ Gamazon, E., Wheeler, H., Shah, K., et al.(2015). A gene-based association method for mapping traits using reference transcriptome data. *Nature Genetics*, 47, 1091-1098. <https://doi.org/10.1038/ng.3367>

¹⁴² Zhang, W., Voloudakis, G., Rajagopal, V. M., Readhead, B., Dudley, J. T., Schadt, E. E., Björkegren, J. L. M., Kim, Y., Fullard, J.

2차원 matrix 형태의 데이터와 연관 분석 결과 도출된 각 유전자의 효과 크기(effect size)에 대한 정보가 출력됨. 해당 기법은 뛰어난 성능을 보이는데, 같은 목적의 다른 인기 기법인 eGenScore과 비교하였을 때, PrediXcan을 통해 예측된 82-93%의 유전자 발현 수준이 실제 유전자 발현 수준과 더 높은 상관관계를 가짐이 보고된 바 있음¹⁴³.

- 따라서 본 연구에서는 PrediXcan을 도입함으로써 ASD 위험에 대하여 유의미한 조기 예측력을 가질 것으로 기대되는 유전자의 추정 발현 정도를 바이오마커로 활용하고자 함. 뿐만 아니라, 각 유전자의 발현 수준에 해당 유전자의 효과 크기를 가중치로 곱한 값을 모두 더한 샘플별 다중유전자전사체위험점수(PTRS, Polygenic Transcriptome Risk Score)¹⁴⁴를 유전자 발현 및 전사체의 또 다른 바이오마커로 사용하고자 함.
- 장내 미생물체 및 대사체 기반: 미생물 위험도 점수(MiRS, microbial risk score) 및 대사체 위험도 점수(MeRS, metabolic risk score)를 통한 오믹스 바이오마커 정량화 기법 도입
 - 본 연구에서는 유전체, 단백질체, 전사체를 포함해 장내 마이크로바이옴(미생물군유전체) 및 대사체 데이터를 수집 예정임. 최근 과학계의 주목을 받으며 활발히 진행되고 있는 미생물군집 연관성 연구(MWAS, Microbiome-wide association study)는 미생물군집과 인간의

F., Hoffman, G. E., & Roussos, P.(2019). Integrative transcriptome imputation reveals tissue-specific and shared biological mechanisms mediating susceptibility to complex traits. *Nature communications*, 10(1), 3834.

¹⁴³ Tavares, V., Monteiro, J., Vassos, E., Coleman, J., & Prata, D.(2021). Evaluation of Genotype-Based Gene Expression Model Performance: A Cross-Framework and Cross-Dataset Study. *Genes*, 12(10), 1531.

¹⁴⁴ Jiang, Y., Pividori, M., Manichaikul, A., et al.(2022). Polygenic transcriptome risk scores(PTRS) can improve portability of polygenic risk scores across ancestries. *Genome Biology*, 23.

다양한 건강형질과 유의미한 연관관계를 보여주고 있음¹⁴⁵. 예컨대, 염증성 장 질환 및 과민성 대장 증후군과 같은 장질환들과 비만, 심혈관 질환, 대장암, 류마티스 관절염과 같은 질환들도 장내미생물 군집과의 연관성이 여러 연구를 통해 잘 알려져 있음. 특히 장-뇌 축의 중요성이 강조되며 자폐 스펙트럼 장애, 주요 우울증, 파킨슨병과 같은 신경계 발달과 진행에 장내미생물이 영향을 미칠 수 있음이 주목받고 있음.¹⁴⁶

- 나아가 다중유전자위험점수(PRS, polygenic risk score) 프레임워크에 영감을 받아 제안된 미생물 위험도 점수(MiRS, microbial risk score)¹⁴⁷는 복잡한 마이크로바이옴 데이터를 효과적으로 요약하여 질병 위험도를 예측할 수 있는 유용한 접근법으로 주목받고 있음.
- 첫번째로 질병과 관련된 대표적인 미생물군으로 구성된 하위 군집을 식별하고, 두번째로 식별된 미생물군집을 직관적인 연속형 점수로 통합할 수 있음. 대사체 위험도 점수(MeRS, metabolic risk score)는 다양한 대사 지표 농도와 효과 크기를 곱하여 개별 대사체를 점수화하고 이를 집계하여 하나의 점수로 나타내는 접근법임^{148 149}. 특히나 아동의 경우 성장 연령에 따라 생리적 특성이 다양하게 변하여, 이를 기준치를 기준으로 이분화 했을때 발생할 수 있는

¹⁴⁵ Gilbert, J., Quinn, R., Debelius, J., et al.(2016). Microbiome-wide association studies link dynamic microbial consortia to disease. *Nature*, 535, 94 – 103. <https://doi.org/10.1038/nature18850>

¹⁴⁶ Gilbert, J., Quinn, R., Debelius, J., et al.(2016). Microbiome-wide association studies link dynamic microbial consortia to disease. *Nature*, 535, 94 – 103. <https://doi.org/10.1038/nature18850>

¹⁴⁷ Wang, C., Segal, L. N., Hu, J., et al.(2022). Microbial risk score for capturing microbial characteristics, integrating multi-omics data, and predicting disease risk. *Microbiome*, 10, Article 121. <https://doi.org/10.1186/s40168-022-01310-2>

¹⁴⁸ Stocks, T., Bjørge, T., Ulmer, H., Manjer, J., Häggström, C., Nagel, G., Engeland, A., Johansen, D., Hallmans, G., Selmer, R., Concini, H., Tretli, S., Jonsson, H., & Stattin, P.(2015). Metabolic risk score and cancer risk: pooled analysis of seven cohorts. *International journal of epidemiology*, 44(4), 1353 – 1363. <https://doi.org/10.1093/ije/dyv001>

¹⁴⁹ Sha, H., Hu, D., Wu, S., Peng, F., Xu, G., Fan, G., Lin, X., Chen, G., Liang, B., Chen, Y., Li, C., Zhang, H., Xia, Y., Lin, J., Zheng, X., & Niu, W.(2018). Baseline Metabolic Risk Score and Postsurgical Esophageal Cancer-Specific Mortality: The Fujian Prospective Investigation of Cancer(FIESTA) Study. *Journal of Cancer*, 9(7), 1173 – 1181. <https://doi.org/10.7150/jca.23631>

오류가 있음. Metabolic risk score는 이분법적인 정의 대신 연속적인 지표 사용으로 대사 위험 정도를 표현하는데 더 적합할 것임¹⁵⁰.

- ML/DL 모델을 활용한 발달장애 특이 오믹스 바이오 마커들의 유효성 평가
 - 상기 세부목표 1~4를 통해 발굴한 멀티오믹스 바이오마커들의 유효성을 다양한 머신러닝 및 딥러닝 모델을 적용하여 두 단계에 걸쳐 검증하고자 함. 1단계에서 다양한 모델을 통해 발굴한 바이오마커의 유효성을 검증 및 선별하고 2단계에서는 선별된 바이오마커들을 이용하여 발달장애 관련 세부 표현형의 진단여부(자폐, 자폐 스펙트럼 장애, 지적장애) 및 임상적 경과(clinical representation) 예측의 유효성을 최종 검증함.
 - 데이터 전처리
 - [유전체, 단백체, 미생물군유전체, 대사체]
정량화 된 PRS(Polygenic Risk Score), ProRS(Protein Risk Score), MiRS(Microbial Risk Score), MeRS(Metabolomic Risk Score) 중 특정 점수가 결과에 지나치게 큰 영향을 주지 않도록 정규화 또는 표준화 함. 그리고 이상치가 있을 경우 모델의 성능을 저하시킬 수 있으므로 이상치를 탐색하고 필요에 따라 제거함.
 - [전사체]
전사체 측정으로 활용된 RNAseq 이외에 gene expression label 을 matrix로 변환시켜서 이용하되, 추가적으로 유전체(genotype data)

¹⁵⁰ 김효진, 이해자, 장한별, & 박상익.(2015). Application of Metabolic Risk Scores for Metabolic Syndrome in Korean Adolescents. Public Health Weekly Report, 8(10), KCDC.

기반 유전자 발현정도를 예측한 PrediXcan을 통해 하나의 ‘이미지’로 취급 가능한 2차원 matrix로 변환하여 입력값으로 사용함.

○ 예측 및 유효성 검증 모델 구축

■ [1단계]

전처리 된 바이오마커를 사용하여 발달장애 관련 세부 표현형의 진단여부(자폐, 자폐 스펙트럼 장애, 지적장애) 및 임상적 경과(clinical representation)을 예측했을 때 모델의 성능향상에 기여하거나 높은 중요도를 보이는 바이오마커를 파악함.

오믹스 데이터는 고차원 특성으로 인한 다중공선성, 과적합 문제 등을 방지하기 위해 불필요한 변수를 제거하고 설명력이 크거나 예측성능에 핵심적인 변수만 선별함으로서, 변수의 유효성 및 설명력을 극대화하고자 함.¹⁵¹ 의료 데이터에서는 세 가지 접근 방법(Filter, Wrapper, Embedded)을 결합한 앙상블 feature selection 방법이 다른 방법에 비해 모델의 정확도와 feature 감소율 모두에서 효과적인 성능을 보여주었음¹⁵². 앙상블 feature selection 방법을 통해 각 접근법의 장점을 활용하고 feature importance 및 confusion matrix 지표를 통해 유효한 바이오마커들을 선별함.

유전체, 단백체, 대사체, 전사체 데이터(1차원 점수)에 Random Forest, SVM, NB, XGBoost 등 머신러닝 모델을, 전사체 데이터(2차원

¹⁵¹ Huang, C., Du, J., Nie, B., Yu, R., Xiong, W., & Zeng, Q.(2019). Feature selection method based on partial least squares and analysis of traditional Chinese medicine data. *Computational and Mathematical Methods in Medicine*, 2019, Article 9580126. <https://doi.org/10.1155/2019/9580126>

¹⁵² Chen, C. W., Tsai, Y. H., Chang, F. R., & Lin, W. C.(2020). Ensemble feature selection in medical datasets: Combining filter, wrapper, and embedded feature selection results. *Expert Systems*, 37, e12553. <https://doi.org/10.1111/exsy.12553>

이미지)에 CNN, ResNet, Vision Transformer 등 딥러닝 모델을 적용함. 추가적으로 전사체 데이터의 경우, KEGG나 Reactome을 활용한 gene pathway 나 gene co-expression, interaction network 정보들을 그래프로 표현하여 네트워크 데이터를 효과적으로 다룰 수 있는 그래프합성곱신경망(GCN) 모델 등에 학습시키는 전략도 가능함. 또한 뇌의 주요한 구조적, 기능적 변화와 연관되어있는 오믹스 바이오마커를 규명하기 위해 다변량 분석법인 CCA(canonical correlation analysis)나 SGCCA(sparse generalized CCA) 등을 멀티모달 뇌영상 데이터셋에 적용하여, 영상-오믹스 간의 관계를 통합적으로 매핑 후, 유의한 관계에 있는 마커를 선별하는 방식을 병렬적으로 진행할 것임.

■ [2단계]

1차에서 선별된 바이오마커를 모든 입력 데이터로 사용하여 예측 모델을 구축함. 모델의 성능을 다양한 지표로 평가하고 바이오마커의 유효성을 종합적으로 검증함. 이 과정을 통해 모델 입력 데이터로서 바이오마커의 유효성을 검증하고 이후 개발될 oimcs-text 모델 및 통합 모델의 성능과 설명력을 최적화 함.

전통적인 통계기법과 최신 머신러닝, 딥러닝 모델을 활용하여 고차원 오믹스 데이터를 처리하고자 함. 로지스틱 회귀와 같은 전통적인 방법은 변수 간의 비선형 관계를 효과적으로 모델링하는 데 한계가 있음. 이에 랜덤 포레스트(Random Forest), SVM(Support Vector Machine), XGBoost, LightGBM 등 머신러닝 모델과 MLP(Multi

Layer perceptron), Autoencoder, CNN, ResNet, Vision Transformer 등 딥러닝 모델을 다양한 퓨전방식으로 결합하여 고차원 오믹스 데이터를 효과적으로 처리하고 복잡한 비선형 관계를 정확하게 모델링하고자 함. 또한, 이러한 모델들을 조합하여 각 모델의 약점을 보완하고 모델의 견고성을 증가시켜 예측의 일관성을 높이며 오류 가능성을 줄일 계획임¹⁵³.

선별된 멀티 오믹스 바이오마커의 유효성 평가를 위해 정확도(accuracy), 정밀도(precision), 재현율(recall), F1 score, AUROC, AUPRC 등 다양한 성능 지표를 활용함. 지표들을 사용하여 모델의 성능과 예측력을 체계적으로 검증하고 최종적으로 바이오마커의 실질적인 예측 유효성을 확인함. 이 과정을 통해 보다 정교하고 신뢰성 높은 모델 구축 가능.

[4. 예상되는 난관과 극복 방안]

- 오믹스 바이오마커의 예측성능 향상 방안
 - 난관: 정량화된 멀티오믹스 바이오마커들이 모델의 예측 성능에 기여할 만큼 유효하지 않는 문제가 발생할 수 있음. 이런 문제는 다양한 원인으로 인해 발생할 수 있다:(1) 오믹스 데이터를 처리하는 방법에 따라 데이터 간 정보를 손실하거나 일관성을 잃을 수도 있고,(2) 또한, 데이터의 고차원성과 복잡성으로 앞서 제시한 모델로는 비선형 관계와 복잡한 특성을 모델링하는데 한계가 있을 수 있음. 이와 같은 문제를 해결하고 모델의 예측정확성을

¹⁵³ Poirion, O. B., Jing, Z., Chaudhary, K., Huang, S., & Garmire, L. X.(2021). DeepProg: an ensemble of deep-learning and machine-learning models for prognosis prediction using multi-omics data. *Genome Medicine*, 13(1), Article 112. <https://doi.org/10.1186/s13073-021-00930-x>

극대화하고자 다음과 같은 연구전략을 제시함.

○ 극복방안:

- 다양한 딥러닝 구조 및 최신 계산모델링 적용을 통한 모델의 성능향상
기대: DNAbert2, GeneBERT, Geneformer, scBERT, gLM(Genomic language model) 등과 같은 최신 딥러닝 아키텍처를 도입하여 유전체, RNA, 대사체 내 복잡한 패턴과 상호작용을 보다 정밀하게 포착할 수 있음. 추후 이와 같은 모델을 통해 오믹스 데이터의 고차원성을 효과적으로 다루면서도 바이오마커의 예측 유효성을 크게 향상시킬 수 있음¹⁵⁴
- 단편적인 모달리티가 아닌 통합 멀티오믹스 데이터를 활용한 성능향상:
단일 오믹스 데이터로는 생물학적 시스템의 단편적인 부분만을 확인할 수 있음. 본 연구에서는 유전체, 단백질체, 대사체, 전사체 등 다양한 차원과 정보를 담고있는 생체유래 오믹스 데이터를 통합하여 분석함으로써, 각 데이터의 정보를 극대화하고, 측정되지 않은 측면을 통합(additive)하며 상호 보완할 수 있음. 멀티오믹스 기반 접근을 통해 발달장애와 관련된 다양한 생물학적 원인, 생물학적 경로 및 과정을 종합적으로 탐색할 수 있고 질병의 잠재적 병인을 효과적으로 규명할 수 있음¹⁵⁵.
- 입력 데이터 형태의 다양화: 아직 이미징(imaging)이나 텍스트(text)

¹⁵⁴ Ji, Y., Zhou, Z., Liu, H., & Davuluri, R. V.(2021). DNABERT: pre-trained Bidirectional Encoder Representations from Transformers model for DNA-language in genome. *Bioinformatics*, 37(15), 2112–2120. <https://doi.org/10.1093/bioinformatics/btab083>

¹⁵⁵ Kang, M., Ko, E., & Mersha, T. B.(2022). A roadmap for multi-omics data integration using deep learning. *Briefings in Bioinformatics*, 23(1), 1–16. <https://doi.org/10.1093/bib/bbab454>

데이터처럼 딥러닝등의 최신 계산모델에 정형화/규격화되지 않은 개인의 오믹스 데이터를 본 연구를 통해 다양한 형태로 변환하여 입력 데이터로 사용하며 적합한 모델을 탐구할 예정임. 데이터를 시퀀스(1차원), 매트릭스의 행렬(2차원), 이미지, 수치 값 등으로 변환하여 모델이 데이터 복잡성을 효과적으로 처리하고 학습할 수 있도록 함. 이러한 데이터의 다양화는 모델이 복잡한 데이터 구조를 더 잘 이해하고 타겟의 예측력에 효과적으로 기여할 것이라 기대함.¹⁵⁶

- 한국인/동아시아인 특이 정량화 마커 개발을 위한 인종적 차이를 고려한 접근
 - 난관: 현재까지의 의생명 연구는 주로 WEIRD(Western, Educated, Industrialized, Rich and Democratic) 및 서양 국가의 유럽인종(European ancestry)을 대상으로 진행되어, 한국인이 속한 동아시아인을 포함한 비유럽인종(non-European ancestry)을 위한 연구나, 유럽인종 위주의 의과학적 발견을 비유럽인종으로 일반화하는 연구가 매우 부족함. 현재 이러 연구 불균형의 원인에는 한국인 특이적인 멀티모달 바이오-임상 데이터의 부재가 큼. 유럽인종과는 확연하게 차이가 있는 생물학적 조성과 문화의 차이를 고려했을 때, 상대적으로 소수인 한국인이 포함된 동아시아인(East Asian)에게 발생하는 스트레스성 뇌질환의 정밀/개인맞춤형 진단과 치료를 위해서는 한국인 특이 위험요인의 통합적 발굴과 기작이해가 절실함. 따라서, 하나의 개인에 대한 멀티모달 생체정보들이 다양한 측면에서 기록된 한국인

¹⁵⁶ Khosla, C., & Saini, B. S.(2020). Enhancing performance of deep learning models with different data augmentation techniques: A survey. In *2020 International Conference on Intelligent Engineering and Management(ICIEM)*(pp. 79-85). London, UK. <https://doi.org/10.1109/ICIEM48762.2020.9160048>

특이 데이터의 구축이 반드시 필요함. 본 연구를 통해 한국인 특이적인 발달장애의 위험요인들을 spectrum 측면에 규명하고, 한국인 맞춤형 의료서비스 구현을 위한 체계적이고 객관적인 근거 마련이 필요함.

- 극복 방안: 인종 특이적인 성격이 있을 것이므로 인종 특이로 만들어서 유효성을 실험할 예정임. 인종적 차이를 고려한 다중유전자점수 계산 소프트웨어(ex. PRS-CSx, LD-pred, TL-PRS) 및 혈장단백질위험점수 계산 소프트웨어(ex. MaxQuant, Perseus) 등을 활용해 유전체 데이터의 차원을 탄력적으로 축소 및 확대 가능.

[5. 기대되는 결과 및 유의성]

- 개인 맞춤형 진단 및 치료 개발
 - 유전체/단백체 데이터 기반의 뇌질환의 발병 메커니즘을 더 정밀하게 이해가능. 이는 개인의 유전적, 분자적 프로파일을 바탕으로 한 맞춤형 진단 및 치료 전략의 개발로 이어질 수 있음. 예를 들어, 특정 유전자 변이와 발달장애 간의 관계를 밝혀내면, 이 변이를 가진 환자들에게 보다 효과적인 치료법을 제안가능. 오믹스 데이터의 분석은 고도의 데이터 처리 기술을 요구함. 이러한 연구는 빅데이터 분석, 인공지능, 기계 학습 등의 기술 발전을 촉진하며,(특히 유전체 데이터에는 이런 적용이 현저히 저조하기에) 이 기술들은 의료뿐만 아니라 다른 산업 분야에도 응용될 수 있음.
- 정량화된 바이오마커의 질환예측/계산진단 모델로의 활용
 - 대부분의 질병은 유전적, 환경적, 생활습관 등 다양한 요인이 복합적으로

작용하여 발생함. 본 연구에서 인체유래 대사지표를 포함한 오믹스 데이터와 최신 계산 기법으로 구축한 진단/예측 모델을 구축. 이를 통해 생체신호 오믹스 데이터를 기반한 만성질환의 예측 및 관리, 특정 유전자 변이나 단백질 발현 패턴을 암의 바이오마커로 사용하여 암의 발병 위험도 평가 및 예측, 유전적 요인이 매우 크게 작용하는 유전질환의 조기 발견 및 치료법 개발에 활용 가능.

- 다인종 및 한국인 특이적 스트레스성 뇌질환 예측/진단 모델로 단계적 활용
 - 현재까지의 의생명정보학 연구는 주로 유럽인종 대상으로, 비유럽 인종으로 일반화하는 연구가 매우 저조함. 이러한 불균형에는 아시안/한국인 특이 융합데이터의 부재가 컸는데, 기 확보한 국내외 바이오뱅크 데이터의 한국인 및 아시안 데이터를 활용하여 유럽인종과 비교되는 특이 양상을 발굴하고 공통/대조되는 발달장애의 다각적 바이오마커들을 발굴함. 본 연구를 통해 구축한 한국인 데이터베이스를 확장하여 유럽인종과 아시아인을 아우르는 다인종 대상 및 한국인 특이적인 뇌질환 예측 모델로 활용 가능할 것으로 기대함. 동아시아인 및 비유럽(non-European) 인종에서 특이적으로 발견되는 특정 유전 변이나 생체 지표 등의 요인을 통해 뇌질환 원인과 진행 과정에 대한 새로운 이해를 도출할 수 있으며, 특정 인종에서 더 빈번하게 발생하는 질병에 대한 조기 진단 및 치료 전략을 개발하고 더 효과적인 예방법을 제안할 수 있음.[멀티 오믹스 기반 발달장애 예측 모델 구축]
- 멀티 오믹스 기반의 발달장애 조기 진단 가능
 - 현재 암에 대한 멀티 오믹스 기반 예측 모델 연구는 많으나 발달장애를 조기 예측할 수 있는 멀티 오믹스 데이터 기반의 연구는 부재한 상황임. 이번 연구로 기존에 없던 멀티 오믹스 데이터 기반 발달장애 예측 모델을 구축할 수 있음.

예측 모델을 통해 아직 발달장애가 발현되지 않는 3살 이전 아동의 이후 자폐 양상에 대해 예측 가능할 것임. 발달장애 아동을 조기에 식별하고 필요한 치료 전략을 사전에 제공할 수 있는 근거를 마련함으로써 잠재적인 문제를 예방할 수 있을 것임. 또한 이러한 조기 진단과 개입은 장기적으로 사회 경제적 비용을 줄이는 효과를 기대할 수 있음. 본 연구는 의료 전문가들에게 정확하고 신뢰할 수 있는 정보를 제공하여 발달장애 아동의 질 높은 관리가 가능하도록 지원할 것이며 이는 결국 국가 정신보건의 질을 향상시키는데 기여할 것임.

세부목표 2-2-4. 공공데이터와 생물정보학분석모듈을 이용한 자폐스펙트럼 관련 유전자 제시

[1. 근거 및 배경]




그림 38. 공공데이터 및 생물정보학 분석방법 요약

- 질병관련 바이오마커 발굴을 위해서는 많은 비용과 인적자원이 필요함. 경제적이고, 효율적이고, 성공적인 바이오마커 발굴을 위해서는 인공지능 기반의 접근이 필요함.
- 최근, 자폐스펙트럼관련 바이오마커 발굴을 위해 다양한 인공지능 기반의 생물정보학분석 방법(차별발현분석, 차별공발현분석 등)이 이용됨.

[2. 최종 목표]

- 인공지능 기반의 생물정보학분석모듈을 사용한 자폐스펙트럼 관련 바이오마커 선별




그림 39. 본 세부목표의 최종목표 도식

[3. 접근]

- 자폐 유전자 발굴을 위한 다학제팀 구성
 - 자폐스펙트럼 치료전문의, 인공지능 전문가, 생물정보학전문가, 전임상연구 전문가 팀으로 포함한 다학제팀을 구축함.
 - 자폐스펙트럼 관련 유전자바이오마커의 세계적인 연구를 리뷰하고, 유전자 결과, 분석 방법, 기구축된 사전학습모델 등을 리뷰함.




그림 40. 본 세부목표의 연구 접근 도식.

● 공공 데이터 수집 및 전처리

GEO는 전장전사체유전체, 차세대 염기 서열 등의 데이터를 저장하고, 검색, 수집할 수 있는 국제적인 공용 플랫폼이다. GEO는 미국의 NCBI (National Center for Biotechnology Information)를 주축으로, 2000년에 개발되어 현재까지 운영되고 있으며, 세계 각지의 대학, 연구소에서 생성된 데이터가 매년 저장되고 있다. 2016년 6월 기준으로 3,848건의 코호트(혹은 데이터셋), 69,229건의 series, 15,913건의 platform, 1,816,869건의 sample 정보가 등록되어 있다.

ArrayExpress는 EMBL, the European Commission (TEMBLOR grand), the EBI Industry Programme (Biostandards) and the International Life Sciences Institute (ILSI/HESI) toxicogenomics database grant로부터 지원을 받아 구축된 공공데이터베이스이다. ArrayExpress는 MAGE-ML 파일 형태, MIAMEExpress 데이터, MIAME 호환 행기만 데이터, EBI 제출도구를 통하여 데이터를 수집한다.

CODA는 임상-역학정보, 건강기록, 이미지, 다중 오믹스정보 등을 다양한 연구과제로부터 보건의료 연구데이터를 수집하여 현재까지 153건 과제의 정보(171,985명, 약2.9PB)가 수집되어 활용되고 있다.

Pan-UK Biobank

MSSNG

WGS samples: 2017 N=5,152, 2022 N=11,312

Genetic variants: 100,000,000, 100,000,000, 100,000,000

그림 41. 공공데이터 유전자/임상데이터베이스의 예

- 다학제연구팀은 분석가능한 공공 유전자/임상데이터베이스를 리뷰하고, 이용가능한 코호트를 수집함.




그림 42. 코호트 특이적 전사체 데이터 전처리 도식

- 코호트 특이적인 전사체 데이터 전처리 소스코드 제작 및 전처리: 코호트별로 데이터가 상이한 구조로 공개되어 있기 때문에, 코호트 특이적인 전처리 알고리즘이 필요함.

- 차별발현분석 기반의 자폐스펙트럼 관련 유전자 선별




그림 43. 차별발현분석 기반의 ASD 바이오마커 선별

- 자폐스펙트럼 관련 유전자를 선별하는데, 대표적으로 사용하는 알고리즘은 Limma와 DESeq2를 사용함. Limma와 DESeq2는 모두 linear regression 학습모델을 기본으로 하고 있고, 유전자 발현량의 분포패턴에 따라 어떤 모델을 사용할 지가 선택됨.
- 상기 두 개의 모델은 모두 유전자 발현량을 종속변수로 지정되도록 기본세팅이 되어 있고, 분석가는 자폐스펙트럼의 상태를 독립변수로 지정하고, 알고리즘을 구동하면, 자폐스펙트럼 관련 유전자가 선별됨. 이 때, 자폐스펙트럼의 상태는 유무와 같은 binomial distribution, 아니면 심각도와 같은 categorical 패턴 모두 가능함.

자페스펙트럼(차별발현분석) 바이오마커의 메타데이터 구축

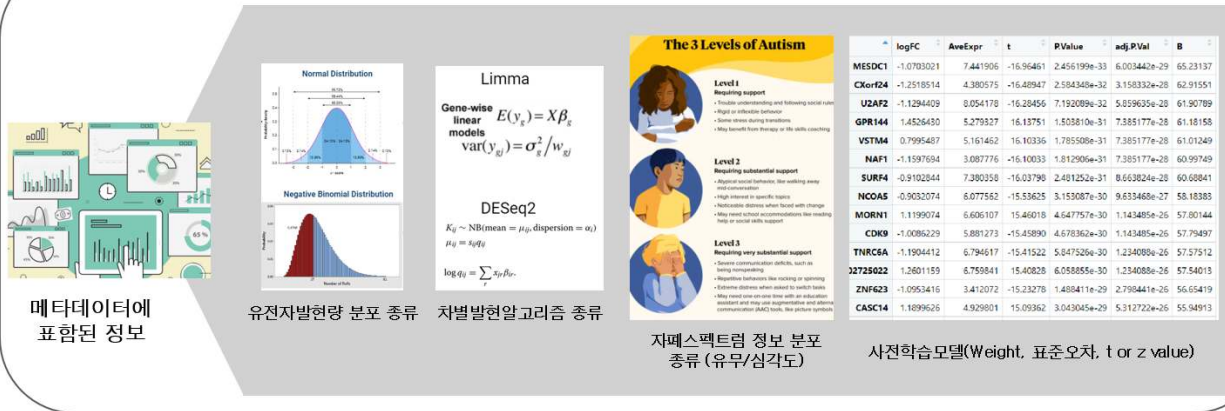


그림 44. ASD 바이오마커 메타데이터 구축

- 차별발현 알고리즘으로 산출된 결과는 모든 input 유전자에 대해, 자페스펙트럼 관련된 fold change, 표준오차, t-value가 테이블형태로 제시되고, 이를 summary statistics라고 불리며, 이는 메타데이터를 의미함.
- 유전자 발현량 분포도, 자페스펙트럼의 상태, 공변량, 사용된 차별발현 알고리즘의 종류, fold change, 표준오차, t-value 등은 메타데이터 형태로 저장됨.
- 차별공발현분석 기반의 자페스펙트럼 관련 유전자 선별




그림 45. 차별공발현분석 기반 ASD 바이오마커 선별

- 최근 생물정보학 선도그룹들은 비지도학습(공발현네트워크, 차별공발현분석, 클러스터링)을 적극적으로 사용하여, 자페스펙트럼관련 유전자를 선별함. 본

연구팀도, 비지도학습 기반의 인공지능 알고리즘을 사용하여 자폐스펙트럼 관련 유전자를 선별하고자함.

- 자폐스펙트럼 멀티오믹스 기반의 유전자 데이터 생성



그림 46. 멀티오믹스 기반 유전자 데이터 획득원

- 표피 피부 세포와 뇌신경 세포는 발생학적으로 기원이 외배엽으로 같아서, 자폐스펙트럼 유전자 선별연구를 위해 피부 조직을 유전자 프로파일링 대상으로 선택함. 더 나아가, 비침습적으로 채취가능한 혈액조직을 프로파일링 대상으로 설정함.



그림 47. ASD 바이오마커 발굴에 사용할 데이터 종류

- 실제 자폐스펙트럼 환자의 피부, 혈액조직에 대해 유전체, 전사체, 후성유전체, 마이크로바이옴에 대한 프로파일링을 시행함.
- 메타데이터 구축 및 AI/전임상연구팀에 자폐스펙트럼 유전자 연계




그림 48. ASD 멀티오믹스 메타데이터 구축을 위한 과정

- 공공데이터베이스를 통해, 멀티오믹스데이터가 메타데이터 형태로 1차 데이터베이스화됨.
- 인공지능 알고리즘 모듈과 공공데이터셋으로 부터 산출된 자페스펙트럼 관련 유전자를 메타데이터 형태로 데이터베이스화함.
- 이를 사전모델 학습을 하는 인공지능 전문팀과 전임상연구를 통해 유전자를 검증하는 기초과학팀에게 인계함.

[4. 예상되는 난관과 극복 방안]

- Technical 배치 효과 및 데이터셋 간의 이질성




그림 49. 배치 효과 및 데이터셋 이질성 극복의 예

- 난관: 배치효과는 유전자프로파일링 환경으로부터 발생하는 bias 타입 중 하나로, 보통 ComBat 알고리즘으로 제거하는 알고리즘을 사용함. 하지만, 유전자데이터는 초고차원 데이터이고, ComBat은 linear model 기반의 알고리즘으로 배치효과 제거 효과가 충분하지 않음.
- 극복 방안: 이러한 데이터셋 간의 이질성을 최소화하기 위해, 수집된 데이터간의 유사도 기반의 네트워크를 구축하고, 네트워크 기반으로 아웃라이어 위치의 데이터를 제거하고, inliers의 유전자 데이터셋만을 자폐관련 유전자데이터셋으로 선별함.
- 선별된 자폐스펙트럼 관련 유전자의 위양성/위음성 결과
 - 난관: 유전자분석은 위양성, 위음성의 두가지 문제 중 1개에 보통 직면함. 위양성은 너무 많은 유전자가 산출되는 경우로, 이는 사전지식을 이용한 베이지안 방식으로 유전자를 narrowing down하는 전략을 세움으로써,

신뢰도가 높은 자폐유전자를 선별함.

- 극복 방안: 위음성의 문제는 통계학적 기준이 너무 엄격함에 따라 너무 적은 유전자가 산출되는 경우로, 이는 메타분석을 이용하여 통계학적 파워는 약하지만 잠재적인 자폐유전자를 선별함.




그림 50. 위양성 위음성 문제의 극복 예

- 공공유전자데이터셋의 임상데이터 부족
 - 난관: 공공유전자데이터셋은 모든 유전자에 대한 정보는 공개되어있지만, 보통 환자의 임상적 특징, 혈액검사 결과등의 임상내용이 거의 공개되지 않고, 자폐의 유무, stage 만 공개하고 있음.
 - 극복 방안: 이를 극복하기 위해, 다양한 코호트를 수집한 이후, 공통적인 패턴을 보이는 유전자를 선택하는 메타분석의 접근이 필요함.
- 인공지능-기초의학간의 소통의 어려움
 - 난관: 인공지능과 전임상연구분야에서 사용하는 학문적언어는 서로 다양함.

예를 들면, 인공지능분야에서 메타데이터를 구축하고, 이를 전임상연구팀에 인계하였을 때, 기초의학연구자들이 가장 먼저 직면하는 문제는 메타데이터 로딩의 어려움, 메타데이터의 난해성 등이 있음.

- 극복 방안: 비대면플랫폼을 이용한 지속적이고, 정기적인 토의를 해야함. 본 연구팀은 충분한 사전연구 및 미팅을 통해 상기 문제에 대해 어느정도 해결한 상태임.

[5. 기대되는 결과 및 유의성]

- 자페스펙트럼 관련 유전자는 광범위의 의미를 포함하는 바이오마커를 발굴하는 것으로, 이들은 먼저, 자페스펙트럼 조기에측모델을 위한 패널을 구축할 수 있음.
- 시스템생물학 기반으로 유전자를 선별하는 것이기 때문에, 굉장히 많은 바이오마커가 동시다발적으로 제시되고, 이는 자페스펙트럼에 대한 병태생리학적 메커니즘을 규명하는데 많은 기여를 할 수 있을 것으로 사료됨.
- 자페스펙트럼에 대한 치료반응 바이오마커, 치료타겟 등을 규명하는 데 많은 경제적, 인적 자원을 절약하는 데 많은 도움을 줄 수 있을 것으로 사료됨.

세부목표 2-2-5. 동물모델의 장내 미생물 유래 대사체 및 인체유래물 데이터 분석 기반 바이오마커 후보군 도출

[1. 근거 및 배경]

- ASD와 GDD 아동들에게서 장 관련 문제가 높은 빈도로 보고되어 왔음. 이외에도 학습장애나 ADHD, 조현병 등의 뇌 신경 장애 아동들에게서도 장내미생물군 다양성 감소나 불균형 문제가 보고된 바 있음.
- 장내미생물 유도 대사체는 동적인 세포 경로를 추적하고 질병 특이적인 경로를 차단하는 방식으로 대사성질환을 연구할 수 있을 뿐 아니라 ASD처럼 발병 시기와 진행의 시점이 중요한 발달장애의 진단에 기여할 수 있는 데이터임.
- 따라서 분당차병원에서는 동물 모델을 활용한 소아 발달장애의 장내 미생물 유래 대사체 및 혈액, 피부조직, 분변 등의 인체유래물 데이터 분석을 통해 ASD, GDD, 그리고 ID의 바이오마커 후보군을 도출하고자 함

[2. 최종 목표]

- GDD, ASD, ID 마우스의 분변을 통하여 장내미생물 이식한 무균 마우스에서 장내미생물 대사체 분석
- 전·임상 데이터의 상관관계 분석을 통한 바이오마커 후보군 도출

[3. 접근]

- GDD, ASD, ID 마우스의 분변을 통하여 장내미생물 이식한 무균 마우스에서 장내미생물 대사체 분석
 - 발달장애 아동의 분변과 혈액에서 표적 대사체를 발굴하는 것 뿐 아니라,

GDD, ASD, ID 마우스의 분변에서도 장내 미생물 유래 대사체를 분석 가능함(그림 51). 마우스 분변을 통해 GDD, ASD, ID 질환에 따른 대사체 특성화를 확인함.




그림 51. 대사체 파이프라인의 데이터 수집 및 분석 워크플로우(Han et al., 2021)

- 구축한 장내 미생물 유래 대사체 플랫폼으로 GDD, ASD, ID 마우스의 분변을 통하여 장내 미생물 이식한 무균 마우스에서 장내미생물 대사체 분석이 가능함(그림 52). 이를 통해 장내 미생물 불균형에 의한 대사체의 특이성을 판단하고 바이오 마커로 발굴할 수 있음.




그림 52. 질환 특이적 장내미생물 및 대사체 불균형에 대한 바이오마커 발굴

- 전·임상 데이터의 상관관계 분석을 통한 바이오마커 후보군 도출
 - 1차연도에 수집한 혈액, 피부조직, 분변 등 다양한 전·임상 샘플로부터 얻은 유전자, 대사체 정보를 통합하여 상관관계를 규명하고 질환과 관련된 바이오마커 후보군을 선별함.

다. 2단계 - 3차 연도: 발달장애 분류 및 진단을 위한 응용 AI 모델 개발 과 바이오마커 임상유효성 평가 준비 및 추가적으로 수집된 데이터 등록

연구개발 목표 3-1: 정제한 데이터를 활용하여 발달장애 분류 및 진단을 위한 뇌영상, 오믹스, 행동 데이터의 모달리티별 AI 모델 개발

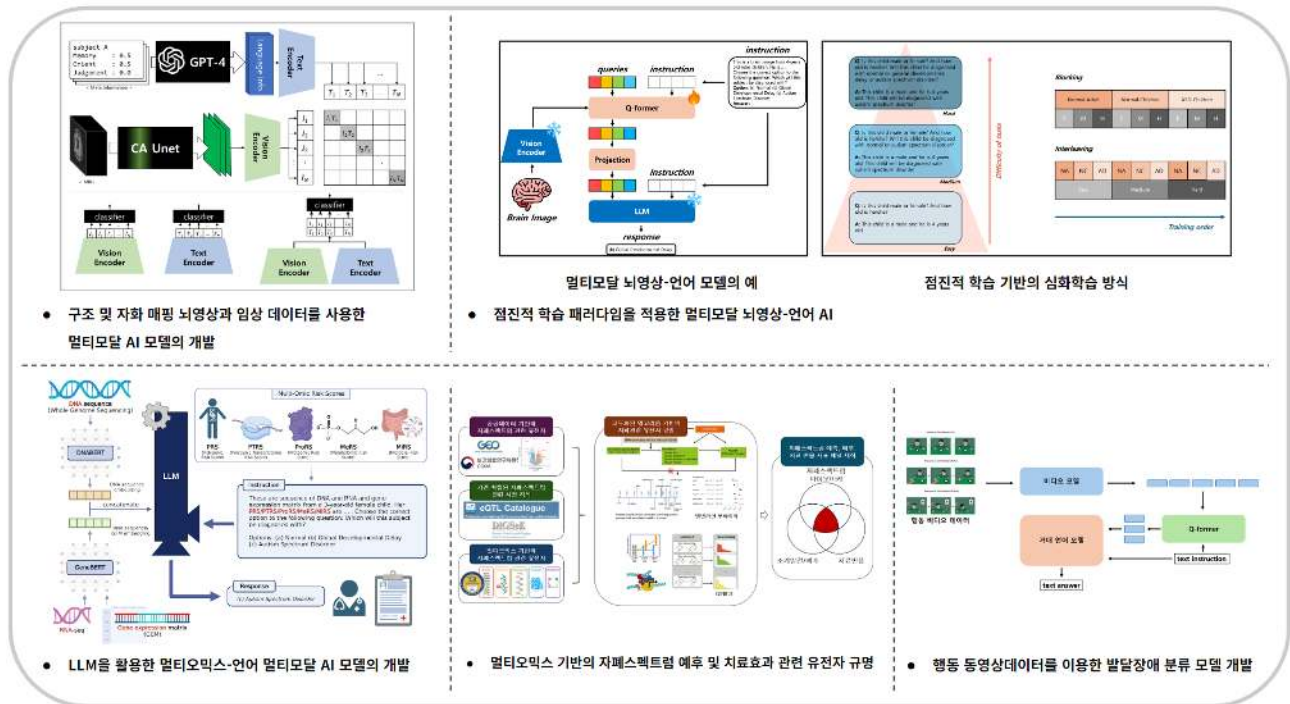


그림 53. 연구개발목표 3-1의 요약

[1. 근거 및 배경]

- 자폐 스펙트럼 장애(ASD)는 MRI 뇌영상을 통해 진단될 수 있음. 다양한 MR 시퀀스를 사용한 멀티모달리티 자폐 스펙트럼 장애 진단 시도가 이미 수행되었으며¹⁵⁷
¹⁵⁸, 멀티모달리티 AI 진단 모델의 유용성은 이전 연구를 통해 어느 정도 입증되었음.
- 그러나 실제 임상환경에서는 환자의 MRI 데이터 뿐만 아니라 나이, 키, BMI 등의 임상 정보를 활용해 진단을 내리는 반면, AI 진단 모델은 이러한 임상 정보를 활용하지 않고 학습되었음. 따라서 단일 모달리티에 의존하지 않고 다양한 모달리티를 융합하는 진단 모델을 사용한다면 더욱 향상된 성능을 기대할 수 있음.
- 컴퓨터 비전 분야에서는 CLIP¹⁵⁹이 텍스트와 이미지 정보를 융합하여 학습하는 새로운 방식으로 제안되었음. CLIP은 OpenAI에서 제안한 딥러닝 방식으로, 대조학습 (contrastive learning)을 사용해 이미지와 텍스트의 매칭되는 데이터 특성들은 가까워지고 나머지 특성들은 멀어지도록 학습함. 이 모델은 텍스트-이미지 쌍을 보고 이들이 어떤 관련성을 가지는지 학습함. 멀티모달을 훌륭하게 수행하는 CLIP은 방대한 양의 텍스트-이미지 쌍으로 학습되어 이미지 검색, 캡션 생성, 질문 답변 등 다양한 작업에 활용 가능하며, 특히 새로운 작업에 대한 명시적인 학습 없이도 수행 가능함.
- CLIP의 텍스트-이미지 멀티모달리티 데이터 융합 방식을 의료 멀티모달리티

¹⁵⁷ Kim, J. I., Bang, S., Yang, J. J., Kwon, H., Jang, S., Roh, S., ... & Kim, B. N.(2022). Classification of preschoolers with low-functioning autism spectrum disorder using multimodal MRI data. *Journal of Autism and Developmental Disorders*, 1-13.

¹⁵⁸ Wang M, Xu D, Zhang L, Jiang H. Application of Multimodal MRI in the Early Diagnosis of Autism Spectrum Disorders: A Review. *Diagnostics*. 2023; 13(19):3027.

¹⁵⁹ Radford, A., Kim, JW., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Aspell, A., Mishkin, P., Clark, J., Krueger, G., & Sutskever, I. Learning Transferable Visual Models From Natural Language Supervision. arXiv. 2021.

데이터의 통합 진단 방식으로 확장해 사용한다면 진단 성능 향상에 도움이 될 것임.




그림 54. 영상정보와 메타정보로부터 생성된 언어정보를 상호보완적으로 사용하여 증증도를 판단하는 알고리즘. 여러가지 정보를 종합적으로 판단해야하는 자폐 스펙트럼 장애 진단 및 예후 예측에 적용할 것임.

- 본 연구진의(서울대학교 이종호 교수) 이전 연구¹⁶⁰에서 알츠하이머병이 뇌영상과 다른 영상정보들과 환자와 관련된 정보들, 그리고 인지기능 관련 검사 결과 등을 종합적으로 고려하여 최종 진단을 하게 된다는 것에 착안하여 언어정보와 영상정보를 상호보완적으로 사용하여 AD의 증증도 진단에 활용하는 연구를 진행하였으며, 영상 또는 언어정보만을 단편적으로 활용하였을 때 보다 높은 성능을 보여줌.
- 이는 이미지와 텍스트를 결합하는 방식이 유사한 진단 분류 과제인 자폐 스펙트럼 장애 진단 분류에도 좋은 성능을 기대할 수 있을 것임을 시사함.

¹⁶⁰ Yoon, et al. "Multimodal Approach for CDR: Vision-Language Integration for Enhanced Clinical Demetia Rating Classification in Alzheimer's Disease." ISMRM(2024).

[2. 최종 목표]

- 대조학습을 사용하여 이미지-텍스트 데이터를 효과적으로 융합하는 인코더를 학습함.
- 각 모달리티 정보를 잘 융합해 높은 진단 성능을 달성함.

[3. 접근]

- 훈련 데이터 준비
 - AI 모델 훈련을 위해 ASD 환자군과 대조군에 대한 이미지 정보인 구조적 MRI(T1강조영상), 자화영상(QSM 및 χ -separation)과 텍스트 정보인 임상정보 데이터를 수집함.
- 학습을 위한 훈련 데이터 정제
 - BMI나 나이와 같은 임상 정보는 정형 데이터(tabular data) 형태로 존재하는데, 이를 GPT-4를 사용해 문장으로 만들어 입력으로 사용함. 실제 임상환경에서는 모든 환자에 대해 동일한 정보를 사용하지 않아 빠진 정보가 존재할 수 있음. 이 방식을 통해 실제 임상환경에서 빠진 정보에 대한 문제를 유연하게 해결할 수 있음.
 - 트랜스포머 기반 방법 사용 시 메모리 등의 문제를 해결하기 위해 3D 뇌영상을 낮은 차원의 특징벡터로 바꾸는 채널 어텐션 UNet을 사용함.
- 멀티모달리티 잠재공간표현 생성
 - 트랜스포머, CLIP 등의 기법을 활용하여 다양한 모달리티 데이터를 통합할 수

있는 멀티모달리티 잠재공간표현을 생성함.

- 뇌영상과 임상정보 등 다양한 형태의 모달리티를 효과적으로 처리할 수 있는 모델을 학습시킴.
- 각 모달리티마다 인코더와 디코더를 훈련하여 잠재 공간에 매핑함.
- 연관된 서로 다른 모달리티 데이터가 잠재공간 상에서 인근에 위치하도록 대조학습을 통해 학습함.

● ASD 진단 모델 학습 및 입력 데이터의 다양화




그림 55. 모달리티의 개수를 늘리며 대조학습 진행

- ASD 환자군과 대조군을 분류하는 이진 분류 또는 발달장애 관련 세부 진단(자폐, 자폐 스펙트럼 장애, 지적장애)를 분류하는 AI 모델을 학습함.
- 2가지 모달리티를 융합하여 진단하는 AI 모델을 학습함. 구조 MRI 영상(T1w)-임상정보, 자화 영상-임상정보의 조합으로 사용하여 ASD 진단 AI 모델을 학습함.

- 2가지 모달리티의 연구를 3가지 이상의 모달리티 연구로 확장시켜 구조 MRI 영상(T1w)-자화 영상-임상정보를 사용한 진단 AI 모델을 학습함.
- 멀티모달리티 데이터로 학습한 AI 모델을 적은 수의 모달리티로도 사용할 수 있도록 네트워크를 디자인하여 학습에 사용한 모달리티가 모두 존재하지 않는 사람에 대해서도 진단이 가능하도록 함.

[4. 예상되는 난관과 극복 방안]

- 난관: 모달리티의 수가 증가할수록 차원의 저주에 취약해짐. 차원의 저주는 데이터 분석과 머신러닝에서 고차원 데이터를 다룰 때 발생하는 다양한 문제들을 총칭함. 고차원 공간에서 데이터 포인트 간의 거리가 기하급수적으로 증가하면서 데이터가 희박해지고(즉, 각 데이터 포인트들이 서로 멀어지고), 이는 대조학습의 효율성을 저하시키는 주된 원인이 됨.
- 극복 방안: PCA(주성분 분석), LDA(선형 판별 분석) 등의 차원 축소 방법을 적용함. 이들은 고차원 데이터에서 중요한 정보를 유지하면서 차원을 줄이는 데 도움을 줌. 불필요한 데이터를 줄이고, 더 낮은 차원에서 데이터의 중요한 특성을 더 명확하게 파악할 수 있게 하므로써 효과적인 모달리티 간 대조학습을 함.

[5. 기대되는 결과 및 유의성]

- 이미지와 텍스트를 통합하여 단일 모달리티로만 진단했을 때보다 더 높은 진단 성능을 보이는 발달장애 관련 세부 표현형을 진단하는 멀티모달 AI 모델을 구성할 수 있음. 또한 텍스트에서 의도적으로 일부 정보를 제외하거나 추가함으로써 각 임상 정보 중

어떤 정보가 진단에 도움이 되었는지에 대한 연구가 가능함.

- 이미지, 텍스트 외 모달리티의 종류와 개수를 확장하는 방향으로 연구를 확장할 수 있음. 추후 다른 연구팀의 영상 데이터, 행동 데이터, 오믹스 데이터의 각 인코더를 대조학습을 통해 학습하여 모델이 정보를 종합적으로 판단할 수 있게 함. 진단에 사용하는 모달리티의 정보 조합을 바꿔가며 실험하고 성능을 비교하여 견고한 바이오마커를 탐색함.
- 멀티모달리티 데이터 간 상관관계 및 인과관계 연구가 가능함.

[1. 근거 및 배경]

- 아동들의 발달 지연과 연관된 신경학적 기전을 보고하는 뇌 이미징 연구들은 많이 있으나, 다양한 임상 환경에서 재현 가능한 발달 지연의 뇌 이미징 바이오마커를 찾는 것은 여전히 어려움으로 남아 있음.
- 이는 발달 지연 및 발달장애 아동들의 데이터 샘플이 적으며, 인간의 육안으로는 뇌 이미지 상의 재현 가능하면서도 명확한 차이점을 찾기 어렵기 때문이기도 함.
- 따라서, 본 연구를 통해서는 발달 지연과 발달장애에 대한 기존 연구들의 한계를 극복하기 위해 최근의 AI 모델들의 발전을 활용하고자 함.
- NLP와 computer vision 등의 분야에서의 AI 모델들의 발전에 힘입어, 최근에는 다양한 모달리티의 데이터를 처리할 수 있는 통합된 인공지능 모델들을 만들고자 하는 움직임이 일고 있음.
- 그중 특히 이미지-언어 AI 모델은 이미지의 의미적 특징들과 표현적 특징들이 언어로써 설명될 수 있다는 점에 착안해, 언어 생성의 형태로 이미지 속의 물체들을 예측하고 설명하며 의미를 파악할 수 있는 이미지-언어 모델들을 만들 수 있다는 것을 보여주고 있음^{161,162,163,164}.
- 이러한 이미지-언어 AI 모델들은 이미지를 표면적인 의미를 언어로써 이해하는 것에서 한발 더 나아가 이미지와 텍스트를 동시에 활용한 심층 추론이 가능하다는

¹⁶¹ Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., ... & Sutskever, I.(2021, July). Learning transferable visual models from natural language supervision. In International conference on machine learning(pp. 8748–8763). PMLR.

¹⁶² Driess, D., Xia, F., Sajjadi, M. S., Lynch, C., Chowdhery, A., Ichter, B., ... & Florence, P.(2023). Palm-e: An embodied multimodal language model. arXiv preprint arXiv:2303.03378.

¹⁶³ Liu, H., Li, C., Wu, Q., & Lee, Y. J.(2024). Visual instruction tuning. Advances in neural information processing systems, 36.

¹⁶⁴ Alayrac, J. B., Donahue, J., Luc, P., Miech, A., Barr, I., Hasson, Y., ... & Simonyan, K.(2022). Flamingo: a visual language model for few-shot learning. Advances in neural information processing systems, 35, 23716–23736.

것을 보여주고 있음⁹⁵.

- 다양한 이미지 데이터와 텍스트 데이터들이 존재하는 의료 분야에서도 이미지-언어 AI 모델을 활용하여 의료 분야의 데이터들을 통합적으로 활용할 수 있는 AI 모델들을 개발하고자 하고 있음.
- 최근에 등장하는 Med-Palm M¹⁶⁵, LLaVA-med¹⁶⁶ 등의 AI 모델들은 CT와 MRI 등의 다양한 의료 이미지 데이터로부터 진단을 비롯한 다양한 의료적 소견을 제공해줄 수 있음을 보여주며, 의료 분야에서의 이미지-언어 AI 모델의 잠재성을 보여주고 있음.
- 이렇게 대규모의 데이터로 학습된 모델들은 학습과정에서 접하지 않았던 데이터에 대해서도 몇개의 예시들만으로 정확하게 확장 적용될 수 있는 few-shot learning이 가능함. 이는 적은 수의 데이터 샘플이 있는 경우에도 대규모 언어-이미지 AI 모델을 전이학습함으로써 AI 모델을 사용하여 의료 이미지를 분석할 수 있다는 것을 의미함.
- 또한 최근 NLP 분야에서는 사전학습된 거대 언어 모델을 기반으로 하여, 심층적인 추론이 가능한 모델로 발전시키고 있음. 점진적 학습 방법(curriculum learning)은 정보들을 취합하는 낮은 수준의 추론에서부터 훨씬 더 복잡한 고차원의 추론 과정을 점진적으로 학습시키는 방법으로, 보다 고차원의 심층 추론이 가능한 모델 개발의 가능성을 보여주고 있음¹⁶⁷.
- 따라서 본 연구에서는 대규모 언어-이미지 AI 모델을 점진적 학습의 방식으로 전이학습함으로써, 데이터 샘플의 수가 적은 발달 지연 및 발달장애 아동들의 뇌 이미징 데이터와 신체 상태나 나이와 같은 부가적인 언어적 정보들로부터 통합적으로

¹⁶⁵ Tu, T., Azizi, S., Driess, D., Schaeckermann, M., Amin, M., Chang, P. C., ... & Natarajan, V.(2024). Towards generalist biomedical ai. NEJM AI, 1(3), A10a2300138.

¹⁶⁶ Li, C., Wong, C., Zhang, S., Usuyama, N., Liu, H., Yang, J., ... & Gao, J.(2024). Llava-med: Training a large language-and-vision assistant for biomedicine in one day. Advances in Neural Information Processing Systems, 36.

¹⁶⁷ Lee, B. W., Cho, H., & Yoo, K. M.(2023). Instruction Tuning with Human Curriculum. arXiv preprint arXiv:2310.09518.

발달 지연 정도를 추론할 수 있는 의료 AI 모델을 개발하고자 함.

[2. 최종 목표]

- 발달 지연 및 발달장애 아동들의 뇌 이미징 데이터로부터 발달 지연 정도를 예측하고 타당한 임상적 소견을 제시할 수 있는 AI 모델의 개발 및 검증

[3. 접근]

- 멀티모달 뇌이미징-언어 모델 개발

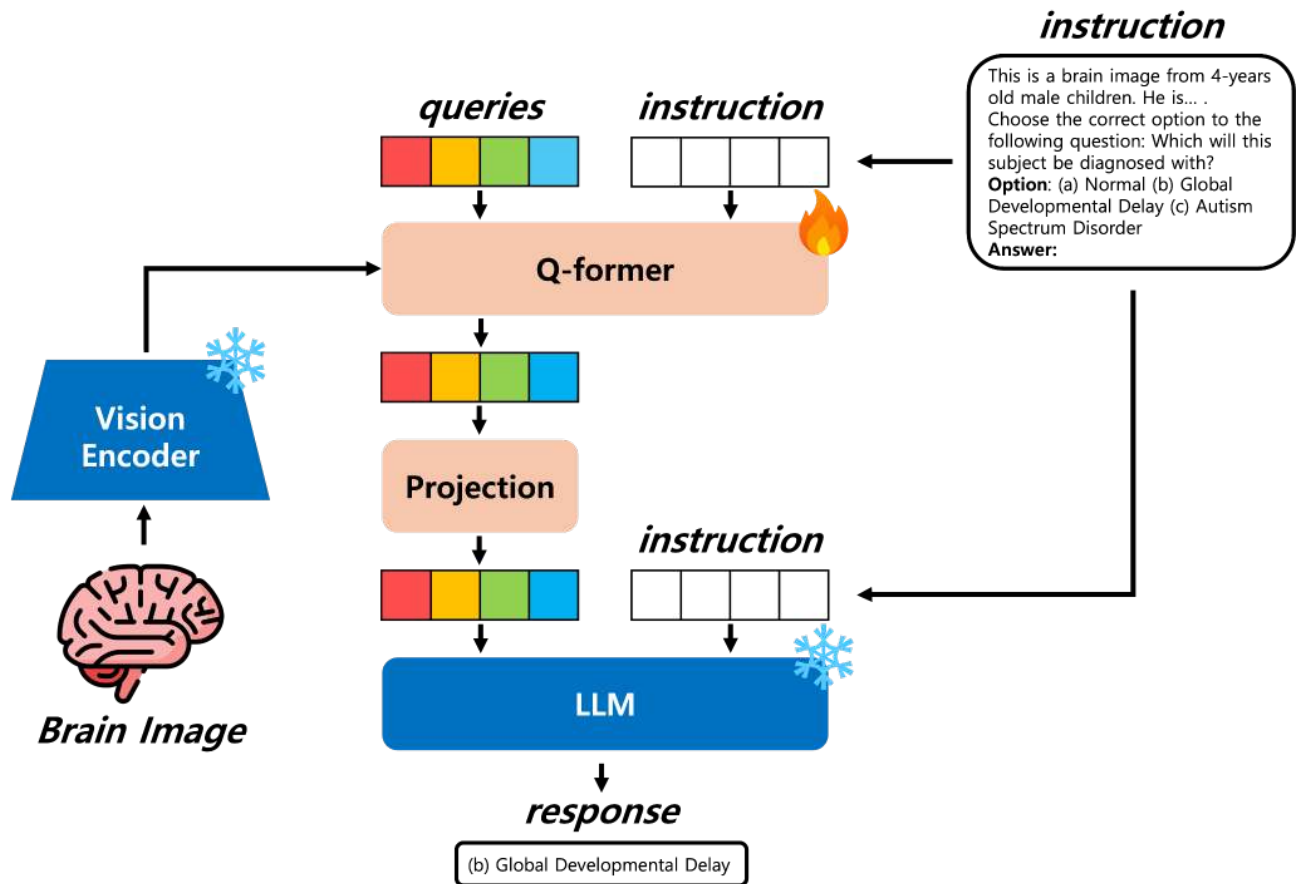
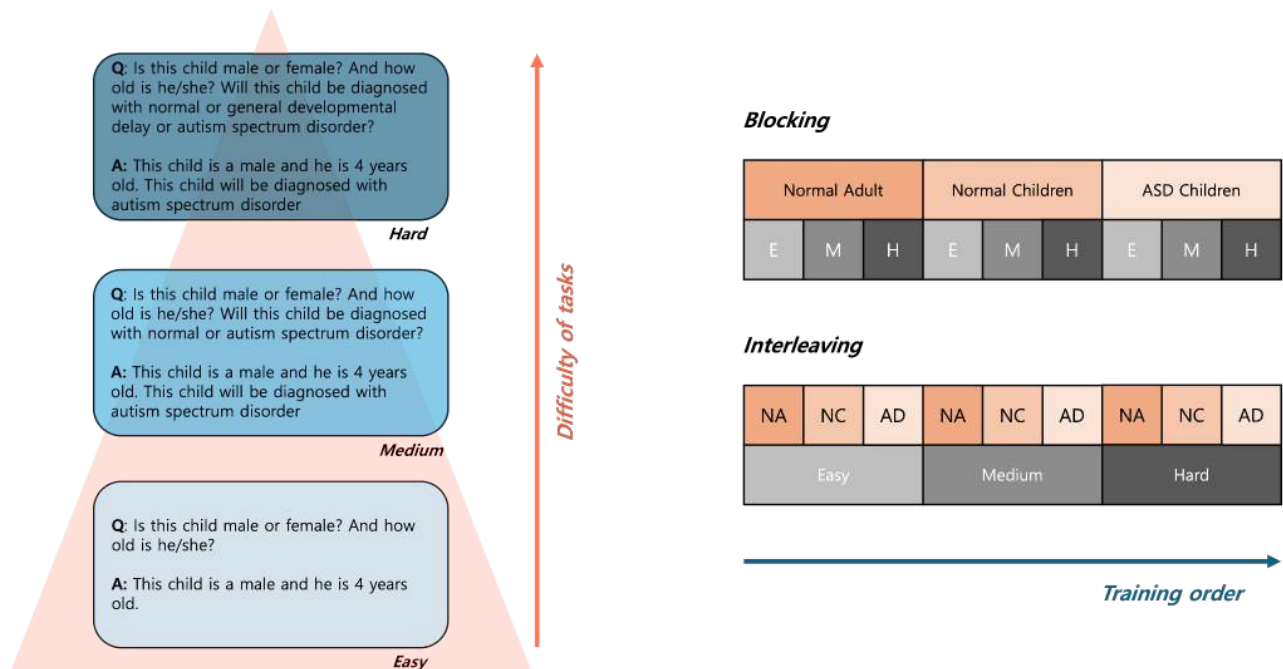


그림 56. 이미지-언어 모델 기반의 멀티모달 뇌이미징-언어 AI 모델

- 거대 규모 데이터로 학습된 오픈 소스 이미지 모델과 오픈 소스 언어 모델을 활용하여 visual instruction learning을 하고자 함¹⁶⁸.
- 거대 규모 오픈 소스 이미지 모델의 경우 2D 이미지로 학습되었기 때문에, 3D와 4D 뇌 이미지를 활용하여 전이학습하기 위해서는 사전학습된 모델에서 이미지를 토큰화하는 과정을 3D와 4D 전용으로 교체하여 학습하고자 함.
- 전체 모델을 전이학습하는 것이 아니라, 이미지 모델과 언어 모델을 연결해주는 일부 레이어만을 재학습함.
- 의료 데이터에 특화되어 전이학습을 진행할 수 있도록, 이미지 모델과 언어 모델은 가중치를 고정한 상태로 간접적인 방식의 재학습을 진행하는 Low Rank Adaptation(LoRA)을 적용하고자 함. 이를 통해 모델의 가중치를 업데이트하여 발생하는 학습의 난이도와 연산 비용을 획기적으로 줄이고자 함.
- 점진적 학습의 적용을 통한 발달장애 진단의 정확성과 구체성 고도화



¹⁶⁸ Li, J., Li, D., Savarese, S., & Hoi, S.(2023, July). Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. In International conference on machine learning(pp. 19730-19742). PMLR.

그림 57. 점진적 학습 기반의 심화학습 방식

- 고등 교육기관으로 갈수록 점차 인간의 학습과 추론이 심화되는 것처럼, 사전 학습된 거대 규모 언어모델을 조정하여 쉬운 학습과 추론에서부터 점차 심층적인 학습과 추론이 가능해지도록 순차적으로 학습하는 것임.
- 최근의 논문들에서는 점진적 학습 방식을 사용하여 거대 규모 언어 모델이 점차 개념에 대한 심층적인 이해와 이를 바탕으로한 추론이 가능해짐을 보이고 있음.
- 다만, 이미지-언어 모델에서도 점진적 학습을 활용하여 이미지에 대한 이해를 심화시킬 수 있는지에 대한 연구는 이루어지지 않았음.
- 이 연구에서는 나이와 성별과 같이 발달 지연 및 장애와 연관이 있으면서도 AI 모델이 사람들의 뇌 이미지로부터 쉽게 예측할 수 있는 변수들로부터 학습을 시작하여, 발달장애 및 발달 지연의 정도와 같이 어려운 문제에 대한 학습으로 점차 심화시켜나가는 방식으로 AI 모델의 학습을 진행하고자 함.
- 특히, 발달 지연 및 장애는 아동들에게서 조기 발견되어야할 필요성이 있으며 아동들의 뇌 이미지에서의 특징을 추출하는 것이 중요함. 따라서 성인 뇌 이미지와는 다른 아동 뇌 이미지의 특징을 학습하고, 더 나아가 아동 뇌 이미지 중에서 발달 지연 및 장애를 갖고 있는 아동 뇌 이미지의 특징적인 모습을 잘 구분하기 위해서, interleaving의 방식을 활용하여 성인-아동-발달 지연 및 장애 아동들의 차이를 바탕으로 점차 난이도 높은 학습이 진행될 수 있도록 AI 모델 학습 패러다임을 설계하고자 함.

[4. 예상되는 난관과 극복 방안]

- 전이 학습을 위한 충분한 데이터 샘플의 부재
 - 난관: 거대 규모의 언어 모델과 이미지 모델을 활용하여 전이학습을 한다고 해도, 발달 지연 및 장애 아동들에 대한 데이터는 매우 적음. 이는 3차원 혹은 4차원의 뇌 이미지 데이터를 학습하는 것과 발달 지연 및 장애와 관련된 뇌 신경학적 기전을 동시에 찾아야 하는 AI 모델의 학습을 어렵게 할 수 있음.
 - 극복 방안: 다양한 나이의 대규모 공공 데이터를 통해 1차적인 학습을 진행함으로써, AI 모델이 3차원과 4차원의 뇌 이미지 데이터의 특징을 학습할 수 있도록 하고자 함. 그 이후에 발달장애 아동 데이터를 사용해 2차적인 학습을 진행함으로써 발달 지연 및 장애와 관련된 뇌 신경학적 기전을 찾도록 순차적인 학습을 진행하고자 함.

[5. 기대되는 결과 및 유의성]

- 발달 지연 및 발달장애 아동들의 뇌 이미징 데이터로부터 발달 지연 정도 예측 뿐만 아니라, 나이와 신체 상태 등의 종합적인 정보에 근거한 임상적 소견을 제시할 수 있는 AI 모델을 개발할 수 있으리라 기대함.
- 다양한 데이터셋을 종합하여 AI 모델을 학습시킴으로써, AI 모델의 데이터 편향 문제를 줄이고 독립적인 데이터셋에 확장적으로 일반화 가능할 것으로 기대됨.
- 뇌 이미지에 대한 이해 뿐만 아니라 나이와 신체 상태 등의 정보를 종합하여 심층 추론을 함으로써, 다양한 병리학적 위험 가능성을 알려줄 수 있는 AI 모델 개발이 가능함.

[1. 근거 및 배경]

[LLM 모델을 활용한 멀티오믹스 데이터 통합연구의 필요성]

- 거대언어모델(LLM, large language model) 은 멀티모달리티 데이터 활용에서 효과적인 결과를 보여주는 범용성으로 파운데이션 모델로 불리며 AI 확산의 주역이 되고 있음. 생물학적 연구를 위해서도 이러한 모델의 활발한 응용 및 개발이 진행 중이지만, 빠른 발전 속도를 가진 이미징 기반의 비전(vision), 텍스트기반의 언어(text), 음성(voice) 등의 데이터 모달리티와 달리, 어떠한 생물학적 신호를 어떤 방식으로 입력하여 어떤 발견(insight)를 끌어낼지 파악하는 것은 고도의 생물정보학 및 컴퓨팅기술의 융합지식을 요하는 분야로, 여전히 미제로 남아 있음.
- 병리학, 유전학 등 다양한 분야에서 활발하게 자폐 스펙트럼 장애(ASD) 및 발달장애 연구가 진행되어 왔음에도 불구하고¹⁶⁹ 진단을 보조할 수 있도록 생체신호를 정량가능한 객관적인 바이오마커는 여전히 부족한 상황이다¹⁷⁰. 앞서 강조된 바와 같이 ASD는 다양한 스펙트럼의 표현형과 여러 빈번한 연관된 동반 질환을 가지는 특성이 있음에도, 현재 행동 특징에 대한 임상적 평가를 기반으로 진단되고 있음. 더불어 ASD는 최근 수십년 동안 나아지지않고 오히려 뚜렷한 유병률 증가를 보이고 있어¹⁷¹ 객관적인 조기 진단 및 치료 개입의 필요성이 절실한 상황임.

¹⁶⁹ Rossignol, D. A., & Frye, R. E.(2012). A review of research trends in physiological abnormalities in autism spectrum disorders: immune dysregulation, inflammation, oxidative stress, mitochondrial dysfunction and environmental toxicant exposures. *Molecular psychiatry*, 17(4), 389 – 401. <https://doi.org/10.1038/mp.2011.165>

¹⁷⁰ Cusick, S. E., & Georgieff, M. K.(2016). The Role of Nutrition in Brain Development: The Golden Opportunity of the "First 1000 Days". *The Journal of pediatrics*, 175, 16 – 21. <https://doi.org/10.1016/j.jpeds.2016.05.013>

¹⁷¹ Maenner, M. J., et al(2020). Prevalence of Autism Spectrum Disorder Among Children Aged 8 Years – Autism and Developmental Disabilities Monitoring Network, 11 Sites, United States, 2016. *Morbidity and mortality weekly report. Surveillance summaries*(Washington, D.C. : 2002), 69(4), 1 – 12. <https://doi.org/10.15585/mmwr.ss6904a1>

- 현재 ASD 진단을 목표로 하는 의료 모델이 사용하는 모달리티는 상당히 파편화되어 있고, 환자에게 심리교육적, 생물학적인 치료 개입에 대한 통합적인 방안을 마련하기에 어려움이 많음¹⁷². 따라서 유전적 요인부터 생화학적, 행동적 요인들을 종합적으로 고려하여 다면적인 임상 표현형과 연결하고 ASD 조기 진단과 맞춤형 지원을 제공해야 할 것임. 이에 현실 속 다양한 종류의 데이터 간의 복잡한 관계를 텍스트 임베딩(embedding)을 이용해 활용하며 근래에 각광받고 있는 LLM을 사용하여 다양한 오픈 데이터 소스에서 추출된 정보를 결합하고, 병인과 관련된 복잡한 패턴을 학습시킴으로써 이에 근거한 개인의 ASD 진단 및 중증도 예측을 시도한다면, 향후 혁신적인 접근 방식을 제공할 수 있을 것으로 기대됨.

[오픈 데이터 간의 의미적 관계를 표현한 최적의 임베딩 생성의 필요성]

- BERT(Bidirectional Encoder Representations from Transformers), GPT(Generative pre-trained transformer) 등과 같은 심층 언어 모델(deep language model)에 의하여 생성되는 의미적 임베딩(contextual embedding)은 데이터에 내재된 ‘의미’와 ‘문맥’을 반영한 임베딩으로, 구문/의미/실용적인 측면에서 단어들 간의 관계를 반영하여 자연어(natural language)의 통계학적 구조를 연속적인 임베딩 공간에 나타낸 값을 의미함¹⁷³. 이는 비단 텍스트에만 국한되는 기법이 아니며, 이미지, 음성 등과 같은 다른 여러 데이터 형태들에 대해서도 활발히 확장 적용되고 있음¹⁷⁴.
- 다차원 데이터로부터 추출된 임베딩 값은 거대 언어 모델(LLM: large language

¹⁷² Panisi, C., et al(2021). Autism Spectrum Disorder from the Womb to Adulthood: Suggestions for a Paradigm Shift. *Journal of personalized medicine*, 11(2), 70. <https://doi.org/10.3390/jpm11020070>

¹⁷³ Goldstein, A., Grinstein-Dabush, A., Schain, M., et al.(2024). Alignment of brain embeddings and artificial contextual embeddings in natural language points to common geometric patterns. *Nature Communications*, 15, Article 2768.

¹⁷⁴ Trinh, T. H., Luong, M.-T., & Le, Q. V.(2019). Selfie: Self-supervised pretraining for image embedding.

model)의 입력 값으로 사용될 수 있음. 이러한 처리방식은 이질적인(heterogenous) 차원의 오믹스계를 의미론적으로 처리하는 것에서 더 나아가, 오믹스와 텍스트, 혹은 타 이종 데이터 모달리티의 입력을 추가로 받을 수 있는 심층 추론을 가능하게 만들 것임. 때문에 본 연구의 궁극적 결과물인 LLM 기반의 ASD 및 발달장애의 조기 예측 알고리즘이 심층추론과 다양한 데이터 모달리티의 통합적인 이해를 통해 보다 높은 성능을 보이기 위해서는 데이터 내 요소들의 관계를 잘 반영하는 질 좋은 representations의 의미론적 임베딩이 요구됨.

- 본 연구에서는 사전에 생성한 각 오믹스 데이터의 형태와 모달리티(modality)에 적합한 사전 학습 심층 언어 모델을 개별적으로 도입하여 모달리티 차이로 인한 noise의 발생을 최소화함으로써 오믹스 데이터별 최적의 임베딩을 구하고자 함.

[언어모델 기반 오믹스 데이터 임베딩 추출의 발전 흐름]

- 해독하기 어려운 인간 유전체 데이터의 의미론적 구조를 고도의 언어모델을 통해 이해하고 설명하기 위해, 최근 몇년간 최신 딥러닝 모델들이 오믹스 데이터에 적용되는 주요한 시도들이 있었음.
- 초기에는 딥러닝의 중추적인 모델인 CNN(합성곱 신경망) 혹은 RNN(순환신경망) 모델을 통한 유전체 및 오믹스 데이터 분석 방법이 제안되었음. 이미징 형태의 데이터를 처리하는데에 특화된 CNN은 주로 지역적 특성을 추출하는데 유용했지만 필터 크기에 의한 제한으로, 유전체처럼 상당히 긴 범위의 의미적 의존성을 포착하는데 한계가 있었음. LSTM과 GRU와 같은 RNN 기반 모델은 장기 의존성을 학습할 수 있는 장점이 있지만, 긴 입력 시퀀스를 순차적으로 처리할 때 발생하는 그라디언트

소실 문제와 낮은 효율성 문제를 보였음. 딥러닝의 핵심적인 두 모델은 유전체 데이터 분석에 있어 한계점을 보였음.¹⁷⁵

- 구글의 Devlin(2018)이 제안한 BERT(Bidirectional Encoder Representations from Transformers)는 사전 학습된 대용량의 레이블링 되지 않는(unlabeled) 데이터를 이용하여 언어 모델(Language Model)을 학습하고 이를 토대로 다양한 텍스트 기반 작업(문서 분류, 질의응답, 번역 등)을 위한 신경망을 추가하는 학습 방법임. 이전에 자연어 처리 분야에 사용되던 Word2Vec, Glove, Fasttext 방식에 비해 다양한 분야에서 높은 성능을 내는 BERT 모델은 최근 유전체 데이터를 이용한 몇몇 오믹스 분야에 활발히 확장적용되는 추세임.
- DNABERT는 BERT 구조를 주요 DNA 조절인자인 ATAC seq(Assay for Transposase-Accessible Chromatin using sequencing) 데이터에 적용한 **대표적인 오믹스 기반 사전학습 AI모델**로, 양방향 컨텍스트 파악을 통해 유전체 시퀀스의 전반적인 의미론적 정보를 포착하여, 시퀀스의 주요 영역을 판별함으로써 유전자 조절의 복잡한 메커니즘을 효과적으로 이해한 성과와 높은 성능으로 주목 받았음.¹⁷⁶ 또한, 유전체와 전사체를 multimodal self-supervised learning 방식을 통해 사전 학습한 GeneBERT 역시 발표되어 주목받았는데, 해당 모델은 1차원 유전체 시퀀스 데이터는 물론 2차원(Matrix) 전사체 데이터를 효과적으로 임베딩하여 여러 downstream task에서 뛰어난 성능을 보이며 그 효과를 입증하였음.¹⁷⁷ 최근, BERT 아키텍처를 바탕으로 단일 세포 수준에서 발현되는 유전자의 복잡한 패턴을

¹⁷⁵ Ji, Y., Zhou, Z., Liu, H., & Davuluri, R. V.(2021). DNABERT: Pre-trained Bidirectional Encoder Representations from Transformers Model for DNA-language in Genome. *Bioinformatics*, 37(15), 2112–2120. <https://doi.org/10.1093/bioinformatics/btab083>

¹⁷⁶ Ji, Y., Zhou, Z., Liu, H., & Davuluri, R. V.(2021). DNABERT: Pre-trained Bidirectional Encoder Representations from Transformers Model for DNA-language in Genome. *Bioinformatics*, 37(15), 2112–2120. <https://doi.org/10.1093/bioinformatics/btab083>

¹⁷⁷ Mo, S., et al(2021). Multi-modal self-supervised pre-training for regulatory genome across cell types. *arXiv*.

임베딩하는 데 최적화 된 scBERT가 개발됨¹⁷⁸. 긴 유전체 시퀀스를 처리할 수 있고 이를 통해 유전자의 기능과 조절 메커니즘을 임베딩하는 GeneFormer도 개발되어 주목받음.¹⁷⁹

- 상기 언어 모델들은 여러 차원의 오믹스 데이터들을 각기 입력값으로 받아, 각 오믹스계의 다의성, 복잡한 상호작용 및 기능을 함축한 텍스트 임베딩 형태로 출력 및 변환시킴. 이러한 임베딩 값들은 본 연구를 통해 궁극적으로 목표하고 있는 발달장애 통합 LLM 모델 구조의 오믹스테이터를 대표하는 입력값으로 쓰일 수 있음. 또한 텍스트 임베딩 형태로 오믹스 이외의 다른 정보를 가진 데이터 모달리티를 추가적으로 처리할 수 있는 언어모델 고유의 프레임워크를 통해, 여러가지 생체유래 데이터를 통합하여 심층추론할 수 있는 효과적인 고차원 AI모델 개발의 뼈대가 될 예정임.

[2. 최종 목표]

- 발달 지연 및 발달장애 아동들의 멀티오믹스 데이터를 모달리티별로 혹은 통합 모달리티로 효과적으로 임베딩화 하여, 구체적인 임상적인 표현형을 예측하고 타당한 임상적 소견을 제시할 수 있는 오믹스-언어(omics-text) AI모델의 개발 및 검증을 목표로 함.
- 특히 인간 오믹스계의 다의성과 복잡한 의미관계를 포착하여, 발달장애의 발달정신병리학적 배경에 중요한 의미적/표현적 생물학적 특징들을 계산적인 임베딩

¹⁷⁸ Yang, F., Wang, W., Wang, F., et al.(2022). scBERT as a large-scale pretrained deep language model for cell type annotation of single-cell RNA-seq data. Nature Machine Intelligence, 4(10), 852–866. <https://doi.org/10.1038/s42256-022-00534-z>

¹⁷⁹ Theodoris, C. V., Xiao, L., Chopra, A., et al.(2023). Transfer learning enables predictions in network biology. Nature, 618(7889), 616–624. <https://doi.org/10.1038/s41586-023-06139-9>

형태로 추출할 수 있는 효과적인 언어 모델의 발굴을 목표로 함.

[3. 접근]

본 연구는 기존에 각기 오믹스 모달리티에 특화되어 성능이 검증된 오픈소스 언어모델을 활용함으로써 의미적 임베딩을 효과적으로 추출하고자 함.

- 오믹스 기반 오픈소스 언어모델의 경우 1차원 및 2차원 데이터로 학습되었으므로, 본 연구를 통해 모을 유전체, 전사체, 대사체 등의 데이터를(1) 시퀀스 형태의 경우 1차원 데이터 처리에 특화된 BERT 및 DNABERT 모델 활용,(2) 발현량 레벨 데이터의 경우 2차원 matrix화 하여 이미지형태 데이터 처리에 특화된 Swin transformer 등 GeneBERT 내재모델 활용 예정임.
- 출력된 오믹스 기반 임베딩과 텍스트 기반(text-based instruction) 입력값을 받을 수 있는 언어모델(LLM)을 연결하여 최종 레이어를 재 학습함.
- 이 과정에서 image-text 모델 개발에 사용되었던 Low Rank Adaptation(LoRA)를 적용하여, 모델의 가중치를 간접적으로 업데이트함으로써 발생하는 학습의 난이도와 연산 비용을 획기적으로 줄일 예정임.




그림 58. 본 연구를 통해 개발될 멀티오믹스-언어 AI 모델의 도식도

- DNABERT 모델을 통한 유전체 임베딩 추출 전략
 - DNABERT는 상기 BERT 구조를 기반으로 한 유전체 시퀀스 분석 모델로, k-mer 방식으로 토큰화 된 DNA 시퀀스를 입력값으로 받아 처리함. 해당 모델은 마스킹 된 언어 모델링 기법을 통해 훈련되어, 일부 시퀀스가 마스킹 처리되고 이를 모델이 예측하도록 하는 기법을 통해 입력받은 DNA 시퀀스의 맥락 중에 주요부위를 판별하고 의미를 학습함. 또한 Transformer 아키텍처를 활용하여 시퀀스 내 각 부분의 상호작용과 중요도를 평가함.
 - DNABERT는 유전자 조절 관련 다양한 테스크 - 프로모터(promoter) 예측,

전사인자(transcription factor) 결합 부위 식별, 유전자 발현 변이 예측 등 – 다양한 작업에서 상당한 성능을 보여줌으로 주목받았음. 이는 DNABERT가 DNA 시퀀스의 생물학적 특성과 복잡성을 효과적으로 처리하고 해석할 수 있음을 보여줌.

- 본 연구에서는 이러한 DNABERT 모델을 최적화 및 fine-tuning 한 DNABERT2 모델을 이용해 발달지연 및 발달장애 아동의 유전체(DNA-seq) 데이터에 응용하고자 함. DNABERT2의 향상된 학습 능력은 더욱 복잡한 유전체 데이터의 효율적인 임베딩을 가능하게 하며¹⁸⁰, 이를 통해 구축된 임베딩 값은 최종 파운데이션 모델의 입력 데이터로서 사용될 때 높은 예측 정확도와 효율성을 제공할 것으로 기대됨.
- GeneBERT를 통한 RNA-seq 및 유전자 발현 수준 임베딩
 - GeneBERT는 유전자의 발현을 조절하는 regulatory element들의 1차원 DNA 서열과 각 regulatory element에 결합하는 전사인자(transcription factor)들을 표시한 2차원 matrix 형태의 데이터로부터 각각 임베딩을 구하고, 같은 regulatory element에 대한 두 임베딩의 내적 값을 최대화하는 방식으로 사전 학습함으로써 여러 세포 종류에 걸쳐 유전자 발현 조절(gene expression regulation)과 관련하여 인코딩(encoding)을 할 수 있는 언어 모델임.¹⁸¹
 - 특히, GeneBERT를 통해 얻어진 임베딩은 promoter를 비롯한 전사인자 결합 부위 분류, 전구 mRNA(pre-mRNA)로부터 단백질 번역(protein

¹⁸⁰ Zhou, Z., Ji, Y., Li, W., Dutta, P., Davuluri, R. V., & Liu, H. (2023). DNABERT-2: Efficient foundation model and benchmark for multi-species genome. *arXiv*. Retrieved from <https://arxiv.org/abs/2306.15006>

¹⁸¹ Mo, S., Fu, X., Hong, C., Chen, Y., Zheng, Y., Tang, X., Shen, Z., Xing, E. P., Lan, Y. (2021). Multi-modal self-supervised pre-training for regulatory genome across cell types. *arXiv*. Retrieved from <https://arxiv.org/abs/2110.05231>

translation)을 위한 성숙한 mRNA가 생성되는 RNA splicing 부위 예측, 질병 위험 예측 등의 다양한 downstream task들에 적용될 수 있는데, 앞서 언급한 모든 task들에서 기준(baseline) 모델로 만들어진 임베딩을 적용하였을 때에 비하여 뛰어난 성능을 보여줌¹⁸².

- 이처럼, GeneBERT는 2가지의 데이터 모달리티(modality)를 다루며, regulatory element들에 관한 사전 학습을 통하여 보다 풍부한 유전자 발현 조절 지식을 가지고 있기 때문에 본 연구의 1차원 RNA-seq 데이터와 2차원 유전자 발현 수준 행렬(gene expression matrix) 데이터를 임베딩하는 과정에서 해당 모델을 도입하고자 함. 그에 따라 임베딩으로 변환된 RNA-seq과 유전자 발현 수준 데이터는 유전체, 뇌 영상 및 행동 데이터에 대한 임베딩, 그리고 instruction-multiple choice question 형식의 텍스트와 함께 ASD 위험 및 예후 조기 예측 최종 파운데이션 모델의 입력 값으로 사용될 예정이다.

¹⁸² Mo, S., et al(2021). Multi-modal self-supervised pre-training for regulatory genome across cell types. *arXiv*.




그림 59. 효과적인 오믹스의 입력 데이터를 위한 다양한 데이터 변환계획의 도식도

[4. 예상되는 난관과 극복 방안]

- 일부 사전학습 AI모델 코드의 부재와 재현방안
 - 난관: 해당 연구를 위해 사용될 오픈믹스 기반 사전학습 모델 중에는 DNABERT처럼 모든 소스코드와 weights가 공개된 모델도 있지만, GeneBERT 처럼 모델 알고리즘의 개략적인 개요만 출판되고 코드가 비공개인 모델도 존재함.
 - 극복 방안: 미공개 모델을 구현하기 위하여, 해당 모델의 발표 논문(Shentong Mo, 2021)¹⁸³에 보고된 사전 학습 데이터와 도식화된 코드를 기반으로 모델을 적극적으로 재현할 계획인데, 이 과정에서 딥러닝 계산알고리즘 개발경험이 풍부한 본 주관기관 연구진(차지욱, 김태섭, 오민환 교수님 등)과 협력이 필수적임.
- 오픈믹스 입력데이터의 한정된 포맷에 따른 변환 계획
 - 난관: DNABERT 모델은 텍스트 형식의 문장처리에 특화된 언어 기반 모델로, fasta 등의 시퀀스 형태로 기록된 DNA유전체 데이터를 처리하고 임베딩하는데 있어 유용함. 반면, 1차원 형태의 DNA 시퀀스가 아닌 2차원 형태의 유전자 발현 데이터나 RGB정보가 추가된 이미지 데이터 등 이미 정형화된 특정 모달리티의 데이터를 입력값으로서 활용하는데 제한이 있음.
 - 극복 방안: 이러한 문제를 해결하고자 본 연구를 통해 사용될 BERT 모델의 입력값으로, 다양한 포맷의 오픈믹스 데이터를 변환해 적용하고자 함. 즉, swin transformer 등 이미지 특화 모델 적용을 위해 데이터를 1차원에서 2차원으로

¹⁸³ Mo, S., Fu, X., Hong, C., Chen, Y., Zheng, Y., Tang, X., Shen, Z., Xing, E. P., Lan, Y.(2021). Multi-modal self-supervised pre-training for regulatory genome across cell types. arXiv. Retrieved from <https://arxiv.org/abs/2110.05231>

변환하는 등 필요에 따라 데이터의 차원과 형태를 적절히 변형함으로써 각종 오믹스 데이터에 대해 효과적인 입력 포매팅을 구현할 계획임.

- 시퀀스 길이에 의한 모델링의 어려움
 - 난관: GeneBERT 모델은 1차원의 시퀀스 데이터를 처리할 수 있는 BERT Transformer와 2차원의 이미지 혹은 matrix 형태의 데이터를 다룰 수 있는 Swin Transformer를 기반으로 구조화되어 있기 때문에 서로 다른 차원의 멀티모달 데이터를 동시에 효과적으로 처리할 수 있는 이점이 있음. 하지만 해당 모델의 BERT Transformer를 사전 학습하는 과정에서 10개 단위로 나뉘어진 regulatory element들의 시퀀스를 입력 데이터로 사용하였기 때문에 fasta 파일의 매우 긴 시퀀스 전체를 한 번에 다루는 데는 어려움이 존재할 수 있음.
 - 극복방안: 본 연구에서도 fasta 파일을 subsampling 등을 통해 입력 데이터의 길이를 조정함으로써 성능을 보완하고 강화할 예정임.

[5. 기대되는 결과 및 유의성]

- 높은 복잡도의 멀티오믹스 및 바이오 데이터를 처리하고 설명하는 고차원 언어모델 개발
 - 본 연구로 개발할 오믹스-언어 AI모델은 오믹스계의 의미적/표현적 특징들이 텍스트 임베딩의 형태로 변환될 수 있다는 점에 착안하여, 언어 생성의 형태로 멀티 오믹스 내의 변이들과 개인의 생물학적 배경을 이해하고 설명하며 의미를 파악할 수 있는 언어 모델의 확장성을 증명할 예정임. 이러한 모델의 이해방식은 다양한 차원의 오믹스계를 의미론적으로 처리하는 것에서 더

나아가, 오믹스와 텍스트 입력을 동시에 받을 수 있는 심층 추론을 가능하게 만들 것임. 정형화된 생체유래 오믹스 데이터 이외에 비정형화된 텍스트 데이터들이 풍부하게 존재하는 의료 분야에서 해당 모델을 사용하여, 개인의 의료기록 및 생체유래 데이터들을 통합적으로 활용할 수 있는 AI모델을 개발하고자 함.

- 유전자 조절의 메커니즘의 이해

- DNABERT와 GeneBERT를 통한 임베딩은 복잡한 오믹스 데이터를 효과적으로 처리하여 전례없는 깊이로 학습된 생물학적 인사이트를 제공할 것으로 기대됨. 고도로 최적화된 임베딩 과정을 통해 정보의 손실을 최소화하며 오믹스 요인들 간의 다의성과 복잡한 상호작용을 정밀하게 분석하고 이해하는 것을 목표로 하며, 특히 해당 모델들이 처리할 각 모달리티별로 발달지연 및 발달장애에 영향을 미치는 주요 요소들을 효율적으로 식별함으로써 발달장애의 병리학적 이해에 기여할 것으로 예상됨.

- 생체 유래 바이오마커 임베딩을 통한 개인 맞춤형 의료 서비스 제공

- 각종 오믹스 데이터 기반 정량화된 바이오마커인 PRS(polygenic risk score), ProRS(protein risk score)등의 환자별 점수는 최종적으로 개발될 해당 omics-text 모델의 추가적인 입력값으로서 활용되어 더 강화된 배경지식을 제공할 수 있음. 다시말해, 각종 오믹스 데이터에서 유래한 의미적 임베딩과 함께 ASD 및 발달장애의 예측마커로서 성능을 인정받은 각종 정량화 생체유래 바이오마커들을 통합적으로 처리함으로써, 발달장애와 관련된 유전자 변이 및 오믹스 패턴의 심층추론이 가능함. 해당 모델의 성공적인 개발은 추후 뇌 영상 및 행동 데이터를 추가 입력값으로 받아 동시에 처리하며, 개인의

유전적-생물학적-행동학적 특성에 근거한 맞춤형 ASD 위험/중증도/예후 예측을 가능케 할 것으로 기대되며, 질병원의 유전적 원인을 규명하고, 개별 환자에게 질병 이환의 위험 가능성을 제시할 수 있을 것으로 전망됨. 궁극적으로 ASD에 대한 높은 위험성을 가진 영유아에 대한 조기 개입 및 원활한 치료 전략 수립이 이루어지도록 해당 언어모델이 도울 수 있으며, 동시에 정밀 의료의 실현과 의료 서비스의 질적 향상을 향한 큰 도약이 될 것이라 기대됨.

세부목표 3-1-4. 멀티오믹스 기반의 자폐스펙트럼 예후 및 치료효과 관련 유전자 규명

[1. 근거 및 배경]



그림 60. 멀티오믹스 기반의 자폐스펙트럼 예후 및 치료효과 관련 유전자 규명의 배경

- 최근 멀티오믹스 기반의 사전학습모델(eQTL 메타데이터)을 이용해서, 질병관련 upstream 유전자를 선별한 연구가 발표됨. 그리고, 전사인자 데이터베이스, 질병-유전자 데이터베이스에서 도메인 지식을 이용하여, upstream 질병유전자를 발굴한 여러 연구들이 발표됨.
- 자폐스펙트럼에 대한 유전자 데이터가 다양한 코호트에서 상이한 유전자 플랫폼으로 프로파일링이 실행됨. 그래서, 배치효과, 위음성, 위양성이 있을 수 있고, 이를 최소화하기 위해서는 단일기간의 충분한 샘플수를 확보하거나, 사전지식을 통해, 산출된 결과를 조정할 필요가 있음.

현재까지 자페스펙트럼 관련 바이오마커를 규명하는데, 사용된 적은 없음.

[2. 최종 목표]

- 인공지능 기반의 자페스펙트럼 예측, 예후, 치료반응 관련 upstream 유전자 제시




그림 63. 본 세부목표의 최종 목표 도식

[3. 접근]

- 자페스펙트럼 관련 유전자 pool 형성



그림 64. 자페스펙트럼 관련 유전자 pool 생성의 도식

- 공공데이터에서 생물정보학분석모듈을 이용한 자페스펙트럼 바이오마커를 통합함.

- 질병-유전자 데이터베이스, 단백질상호작용네트워크 데이터베이스, 전사인자 데이터베이스에서 upstream 유전자 리스트를 수집함.
- 병원기반의 실제 환자의 멀티오믹스 데이터 기반으로 자페스펙트럼 바이오마커를 선별하고, 앞서 제시된 바이오마커 리스트와 통합함으로써, 자페스펙트럼 유전자 pool을 형성함.
- 멀티오믹스 기반의 Upstream 자페스펙트럼 유전자 규명




그림 65. 멀티오믹스 기반의 Upstream 자페스펙트럼 유전자 규명의 도식

- 전체 자페스펙트럼 유전자 리스트 중에, 피부/혈액 전사체가 자페스펙트럼 환자그룹에서 유의하게 변화되어 있는 경우를 선별함. 이후, eQTL을 갖고 있는 유전자(전사체)를 2차 선별함. 이후, 자페스펙트럼 관련 마이크로바이옴과 상관성을 보이는 유전자를 upstream 유전자로 최종 선택함.
- 인과관계 규명을 통한 Upstream 자페스펙트럼 유전자 규명




그림 66. 인과관계 규명을 통한 Upstream 자페스펙트럼 유전자 규명의 도식

- 다양한 경로를 통해서 구축된 자페스펙트럼 유전자 전체 pool을 이용하여 유사도 및 PPI 사전정보를 통해 유전자 네트워크를 구축함. 이때의 네트워크는 인과관계정보가 없는 무향네트워크임.
- 이후, 구축된 네트워크에 멘델리안 무작위화/GENIE3를 적용하여 유향네트워크를 구축함. 유향네트워크와 TF, eQTL 등의 사전지식을 이용하여, 최종 인공지능 기반의 자페스펙트럼 upstream 유전자를 제시함.
- 자페스펙트럼 예측, 예후, 치료반응 관련 유전자 제시




그림 67. 자페스펙트럼 예측, 예후, 치료반응 관련 유전자 제시의 도식

- 인공지능 기반으로 규명된 자페스펙트럼유전자를 자페스펙트럼의 예후지표,

자폐스펙트럼의 치료반응지표와 연관성분석을 시행함으로써, 자폐스펙트럼
예후 및 치료반응 관련 유전자 바이오마커를 제시함.

- 자폐스펙트럼 조기에측패널 제작
 - 인공지능/전임상연구를 통해 제시된 자폐스펙트럼 바이오마커를 통합하여,
정확함, 경제성, 신속성 등을 고려하여 다학제협의체와 성능평가를 통해
자폐스펙트럼 조기에측패널을 제작함(아래 그림 68)



그림 68. 자폐스펙트럼 조기에측패널 제작의 도식

[4. 예상되는 난관과 극복 방안]

- 임상/인공지능/전임상 간에 데이터 및 연구결과 소통의 지연
 - 임상, 인공지능, 전임상 간에 사용하는 학문적 언어가 다르므로, 결과가 산출되더라도 시간적, 지리적, 지식적 이질성에 의해 소통 및 연계가 지연될 것으로 사료됨.
 - 이를 극복하기 위해 다학제 소통 및 mini-심포지엄을 통해 체계적이고

정기적인 소통의 기회를 좀더 많이 얻을수 있음.

- 비교적 적은 유전자프로파일링 케이스로 인한 바이오마커 발굴의 어려움
 - 공공데이터, 사전지식을 적극적으로 활용하여, 신뢰성 높은 자페스펙트럼 바이오마커를 제시함.

[5. 기대되는 결과 및 유의성]

- 자페스펙트럼에 대한 조기 예측모델 제시
 - 조기에측모델에 따른 환자의 예후가 향상되며, 자페 진단 및 치료에 따른 의료비가 감소되는 효과를 보일 수 있음.
 - 체계적인 환자 스크리닝, 진단, 치료를 통해, 빅데이터 구축 및 novel한 바이오마커 제시를 할 수 있음.
- 자페스펙트럼 치료전략 수립을 위한 기반확립
 - 본 연구는 자페스펙트럼 관련 바이오마커, 예후지표, 치료반응 관련 바이오마커를 제시하고, 이 중, 치료타겟도 존재할 것으로 사료됨.
 - 추후, 개발되면, 본 연구는 치료타겟을 제시하는 연구의 중요한 기반으로써 많은 기여를 할 것으로 사료됨.
- 인공지능/바이오의 이상적인 다학제 연구모델 제시
 - 본 연구는 다학제 팀들간에 공동연구를 진행하는 과정 가운데 발생하는 시행착오 및 해결방안에 대해 많은 노하우를 갖을것으로 사료되고, 이에 따라, 실무적인 부분을 효율적이고, 정확하게 해결해나갈 수 있는 우수한 다학제

연구모형을 제시할 것으로 사료됨.

[1. 근거 및 배경]

- 자폐 스펙트럼 장애는 사회적 상호작용과 의사소통의 비정상적인 패턴이 특징인 신경 발달장애로, 발달 지연을 겪고 있는 아동들을 진단하고 예후를 평가하기 위한 목적으로써 아동들의 행동 비디오 데이터 기반의 AI 모델을 개발하고자 하는 움직임이 활발하게 진행되고 있음^{184,185,186,187}.
- 최근 루먼랩은 공동 주의(joint attention) 과제를 수행하는 아동들의 행동 비디오를 기반으로 자폐 스펙트럼 장애를 분류하는 AI 모델을 개발 검증하여 의학 분야의 명망있는 학술지인 JAMA Network open에 연구 결과를 게재하였음.
- 공동 주의는 대상이나 사건에 대한 주의를 타인과 공유함으로써 사회적 상호작용의 학습에 도움을 주는 것으로, 일반적인 발달 과정을 따르는 유아에게서는 6개월 무렵부터 관찰되지만 발달 지연을 겪고 있는 아동들에게는 공동 주의가 결여되어 있음.
- 공동 주의는 디지털화된 평가가 가능하며 특정 과제 관리 지침을 적용한 프로토콜을 통해서 비디오 데이터를 수집할 수 있다는 점에서, 기존의 AI 모델의 개발과 학습에 사용되었던 행동 비디오 데이터의 수집 과정에서의 자동화 부족, 고가의 장비 필요, 전문 인력 의존도 등의 문제를 해결할 수 있었음.

¹⁸⁴ Abbas H, Garberson F, Liu-Mayo S, Glover E, Wall DP. Multi-modular AI approach to streamline autism diagnosis in young children. *Sci Rep*. 2020;10(1):5014.

¹⁸⁵ Zunino A, Morerio P, Cavallo A, et al. Video gesture analysis for autism spectrum disorder detection. Paper presented at: 24th International Conference on Pattern Recognition. September 2018.

¹⁸⁶ Tariq Q, Daniels J, Schwartz JN, Washington P, Kalantarian H, Wall DP. Mobile detection of autism through machine learning on home video: a development and prospective validation study. *PLoS Med*. 2018;15(11):e1002705.

¹⁸⁷ Kojovic N, Natraj S, Mohanty SP, Maillart T, Schaer M. Using 2D video-based pose estimation for automated prediction of autism spectrum disorders in young children. *Sci Rep*. 2021;11(1):15069.

- 이는 특히 의료 보조 도구로서 AI 모델이 활용되기 위해 필요한 정밀도와 재현율을 향상시키는 데에 크게 도움을 줄 수 있는 가능성이 있음.
- 본 연구에서는 최신의 AI 연구에서의 발견들을 활용하여, 기존 연구에서 개발된 공동 주의 아동 행동 데이터 기반의 AI 모델을 더욱 고도화하고자 함.
- 이를 통해 발달 지연의 진단과 수치적인 예후 평가를 넘어서, 더욱 정밀하고 상세한 임상적 소견을 제공할 수 있는 AI 모델 개발하고자 함.
- 또한, AI 모델 개발에 있어서 잘 정립된 과제 중심의 데이터 수집을 통해 데이터 생성 과정의 자동화와 균질화가 가지고 있는 잠재성을 확인하고, 추후 이를 확장 적용하여 임상적으로 유용하게 활용될 수 있는 지에 대한 검증을 진행하고자 함.

[2. 최종 목표]

- 발달 지연 조기 진단을 위한 아동의 공동 주의 행동 데이터 기반의 언어-비디오 다중 모달리티 AI 모델 개발 및 검증

[3. 접근]




그림 69. 행동 비디오 데이터를 사용한 발달장애 예측 모델의 구조

- 연구개발 목표 1-4를 통해서 수집하는 고품질의 균질화된 아동들의 공동 주의 행동 비디오 데이터와 아동들의 각종 임상 평가 데이터를 결합하는 언어-비디오 다중 모달리티 AI 모델을 개발하고자 함.
- 최근 자연어와 비디오 분야에서의 AI 모델 개발이 점차 고도화 되면서, 비디오로부터 행동 분류와 같은 예측 및 분류 과제를 수행하던 기존의 비디오 AI 모델을 넘어 비디오에 담긴 정보들을 텍스트의 형태로 생성하고 이를 기반으로 심층 추론을 하는 언어-비디오 AI 모델들이 개발되고 있음.
- 2024년 Sanghai AI lab에서 발표한 InternVideo2는 비디오와 오디오 그리고 거대 언어 모델을 결합함으로써 행동 분류, 오디오 및 비디오 캡션, 오디오 및 비디오 검색(retrieval) 등 다양한 과제에서 엄청난 정확도의 상승을 보여줌¹⁸⁸.
- 특히, 추가적인 미세조정 없이 새로운 비디오 데이터에 대해서 AI 모델로 하여금 과제를 수행하도록 하였을 때 아주 높은 정확도의 성능을 보여줌.
- 이는 발달 지연 아동과 같이 대규모의 데이터를 활용하여 AI 모델을 학습시키기 어려운 상황에서, 이러한 사전학습된 언어-비디오 모델을 활용하여 정확도를 끌어올릴 수 있다는 것을 시사함.
- 또한 언어-비디오 모델은, 다양한 임상 평가 데이터를 텍스트 데이터로 변환한 뒤 거대 언어 모델을 활용하여 정보를 압축적으로 추출하고 이를 비디오 모델링에 활용할 수 있다는 점에서, 아동 행동 비디오로부터 심층 추론을 통한 임상 소견을 제공할 수 있도록 AI 모델을 고도화시킬 수 있다는 장점을 가지고 있음.
- 이러한 다중 모달리티 AI 모델을 개발하기 위해 최근 각광을 받고 있는 방법은 각각의 모달리티를 잘 처리할 수 있는 AI 모델들을 활용하여, 서로 다른 모달리티들의 정보를

¹⁸⁸ Wang, Y., Li, K., Li, X., Yu, J., He, Y., Chen, G., ... & Wang, L.(2024). Internvideo2: Scaling video foundation models for multimodal video understanding. *arXiv preprint arXiv:2403.15377*.

잘 조정해줄 수 있는 추가적인 가중치 레이어(e.g., Q-former)를 새롭게 학습하는 것임.

- 언어 모델을 기반으로 뇌이미징이나 유전체 데이터등의 다른 모달리티를 통합하는 AI 모델이 없기 때문에 이를 새로 개발하여야할 필요(예를 들면, 세부목표.3-1-1 ~ 세부목표.3-1-4)가 있는 다른 모달리티 데이터들과 달리, 행동 비디오 데이터는 InternVideo2와 같이 비디오-언어의 대규모 데이터로 사전학습된 다중 모달리티 AI 모델들을 직접적으로 활용할 수 있음.
- 또한, 대부분의 거대 언어 모델들이 의학 지식에 관한 텍스트 데이터들을 학습에 사용함으로써 상당 수준의 의학 지식 기반의 추론과 임상 소견을 제공할 수 있다는 점을 고려해보면, 비디오-언어의 대규모 데이터로 사전학습된 다중 모달리티 AI 모델들을 직접적으로 활용하는 것은 아동 공동 주의 행동 비디오 데이터 기반의 발달 지연 진단 및 임상 소견의 정확도와 타당도를 상당부분 상승시킬 수 있으리라 예상됨.
- 이에 본 연구에서는 InternVideo2와 X Instruct BLIP 등 비디오-언어의 다중 모달리티 AI 모델을 직접적으로 활용하여, 아동 공동 주의 행동 비디오 데이터와 각종 임상 평가 데이터를 통합하는 발달 지연 아동 조기진단 AI 모델을 개발하고자 함.

[4. 예상되는 난관과 극복 방안]

- 난관: 거대 언어 모델들이 의학 지식에 대해 학습했다고 하더라도, 본 연구를 통해서 수집될 예정인 각종 임상평가 데이터에 대한 지식은 충분하지 않을 수 있음. 이는 비디오-언어의 대규모 데이터로 사전학습된 다중 모달리티 AI 모델들을 직접적으로 활용하는 것 외에 추가적인 조정을 통해 발달 지연 아동들을 위한 AI 모델의 고도화를 요구함.
- 극복 방안: Low Rank Adaptation(LoRA) 등의 테크닉을 활용하여 효율적인

비디오-언어 다중 모달리티 AI 모델의 미세조정을 진행하고자 함. 이는 대규모 발달 지연 아동 데이터를 요구하지 않으며 비디오-언어 다중 모달리티 AI 모델 가중치의 미세 조정을 위한 거대한 규모의 연산 자원을 요구하지 않는다는 점에서, 샘플 및 연산 효율적이면서도 효과적인 발달 지연 아동 조기진단을 위한 AI 모델의 고도화를 달성하는 것을 가능하게 할 것임.

[5. 기대되는 결과 및 유의성]

- 높은 수준의 진단 정확도와 진단에 대한 디테일한 임상적 소견을 제시할 수 있는 발달 지연 아동 조기진단을 위한 AI 모델을 개발할 수 있을 것임.
- 고품질의 균질한 데이터를 생성할 수 있는 파이프라인의 효용성을 검증함으로써, 추후 더 많은 데이터 생성을 기반으로 아동 공동 주의 행동 비디오 데이터 기반의 발달 지연 조기진단 AI 모델을 더욱 확장적으로 고도화할 수 있는 가능성을 확인할 수 있음.

연구개발 목표 3-2: 대규모 파운데이션 AI 모델을 이용한 뇌영상-오믹스-행동 비디오-임상평가 기반 발달장애 모델 개발




그림 70. 연구개발목표 3-2의 요약

세부목표 3-2-1. 뇌영상-오믹스-행동비디오-임상평가 멀티모달 AI 모델의 개발

[1. 근거 및 배경]

- 최근 자연어와 컴퓨터 비전에서의 AI 모델들의 눈부신 발전에 힘입어, 언어와 이미지 뿐만 아니라 동영상과 오디오 등 다양한 모달리티를 통합하는 단일 AI 모델을 개발하고자 하는 움직임이 많이 이루어지고 있음^{189,190}.
- 특히 거대 언어 모델은 풍부한 텍스트 언어라는 풍부한 표현력을 가진 매체이자 추론이 가능한 매체라는 점에서, 예측과 생성을 넘어 적응형 문답과 심층 추론이

¹⁸⁹ Han, J., Gong, K., Zhang, Y., Wang, J., Zhang, K., Lin, D., ... & Yue, X.(2023). Onellm: One framework to align all modalities with language. arXiv preprint arXiv:2312.03700.

¹⁹⁰ Panagopoulou, A., Xue, L., Yu, N., Li, J., Li, D., Joty, S., ... & Niebles, J. C.(2023). X-InstructBLIP: A Framework for aligning X-Modal instruction-aware representations to LLMs and Emergent Cross-modal Reasoning. arXiv preprint arXiv:2311.18799.

가능한 일반 인공지능의 발전의 핵으로 여겨지고 있음.

- 거대 언어 모델은 텍스트 생성의 형태로 분류와 예측을 진행할 수 있을 뿐만 아니라, 숫자와 텍스트의 형태로 구성될 수 있는 모든 데이터를 표현할 수 있다는 것이 점차 밝혀지고 있음^{191,192,193}. 그리고 거대 언어 모델이 가지고 있는 이러한 잠재성은 거대 언어 모델을 중심으로 하여 다양한 모달리티의 데이터를 합치고자 하는 방향으로 AI 분야를 발전시키고 있음.
- 거대 언어 모델을 중심으로 다양한 모달리티의 데이터를 통합 모델링하고자 하는 움직임은, 거대 규모의 데이터로 사전학습된 각각의 모달리티별 거대 AI 모델을 활용함. 이를 통해 사전학습된 모델들의 지식들을 활용하여 확장적이면서도 새로운 가능성을 가지는 통합 모델의 개발을 가능하게 함.
- 메디컬 분야에서도 다중 모달리티 통합 AI 모델의 가능성을 보여주는 연구들이 최근 등장하고 있음. 구글 연구진들은 유전체와 다양한 의료 이미지 및 텍스트 데이터들을 통합하는 AI 모델인 Med-Palm M을 발표하였고¹⁹⁴, 마이크로소프트 연구진들 또한 의료 이미지 및 텍스트 데이터들을 통합하는 LLaVA-med를 발표하였다¹⁹⁵. 이 모델들은 의료 이미지로부터 진단 및 임상 소견과 같은 의료 텍스트를 높은 정확도로 생성해낼 수 있다는 것을 보여주었다 점에서 그 의의가 있음. 다만, 의료 이미지 및 텍스트 외의 다양한 모달리티의 데이터들을 통합하였을 때에 다양한 모달리티의 데이터들로부터 통합적이며 상보적으로 정보를 추출하고 이를 바탕으로 임상적

¹⁹¹ Liu, H., Li, C., Wu, Q., & Lee, Y. J.(2024). Visual instruction tuning. Advances in neural information processing systems, 36.

¹⁹² Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., ... & Liu, P. J.(2020). Exploring the limits of transfer learning with a unified text-to-text transformer. Journal of machine learning research, 21(140), 1-67.

¹⁹³ Chung, H. W., Hou, L., Longpre, S., Zoph, B., Tay, Y., Fedus, W., ... & Wei, J.(2024). Scaling instruction-finetuned language models. Journal of Machine Learning Research, 25(70), 1-53.

¹⁹⁴ Tu, T., Azizi, S., Driess, D., Schaeckermann, M., Amin, M., Chang, P. C., ... & Natarajan, V.(2024). Towards generalist biomedical ai. NEJM AI, 1(3), A10a2300138.

¹⁹⁵ Li, C., Wong, C., Zhang, S., Usuyama, N., Liu, H., Yang, J., ... & Gao, J.(2024). Llava-med: Training a large language-and-vision assistant for biomedicine in one day. Advances in Neural Information Processing Systems, 36.

추론을 진행할 수 있는지 여부를 보여주지는 못하였음.

- 최근 공개된 다중 모달리티 AI 모델들은 각 모달리티의 데이터들을 상보적으로 종합하여 더욱 심층적이고 정확한 추론이 가능하다는 점에서, 단순히 다양한 모달리티의 데이터를 하나의 AI 모델로 다룰 수 있다는 것을 넘어 새로운 창발적 가능성을 보여주고 있음^{196,197}.
- 특히, 작년에 등장한 X instruct BLIP은 이미지, 오디오, 비디오, 언어 등의 다양한 모달리티의 데이터들로부터 통합적이며 상보적으로 정보를 추출하고 이를 바탕으로 심층적 추론이 가능하다는 것을 보여주었음. 이는 다중 모달리티 데이터들을 하나의 AI 모델 프레임워크로 통합하는 것이 새로운 창발적 가능성을 형성해낼 수 보여주었다는 점에서 다중 모달리티 AI 모델 개발에서 그 의의를 가짐. 하지만, 의료 데이터에서의 다중 모달리티 통합 AI 모델이 새로운 창발적 가능성을 형성해낼 수 있는지는 아직 확인되지 않았음.
- 이에 우리 연구진들은 발달 지연 및 장애 아동들의 조기발견을 위해, 언어를 중심으로 하여 뇌이미징과 오믹스, 행동 비디오의 다양한 모달리티의 정보들을 통합할 수 있는 AI 모델을 개발하고자 함.
- 이러한 AI 모델은 발달 지연 및 장애 아동들의 뇌이미징, 오믹스, 행동 비디오, 수치 및 텍스트 등의 데이터 각각에서 추출할 수 있는 정보들을 다각적이며 상보적으로 통합하여 발달 지연 및 장애에 대한 더욱 정확한 예측과 관련 임상적 소견을 제공할 수 있으리라 기대함.

¹⁹⁶ Panagopoulou, A., Xue, L., Yu, N., Li, J., Li, D., Joty, S., ... & Niebles, J. C.(2023). X-InstructBLIP: A Framework for aligning X-Modal instruction-aware representations to LLMs and Emergent Cross-modal Reasoning. arXiv preprint arXiv:2311.18799.

¹⁹⁷ Han, J., Gong, K., Zhang, Y., Wang, J., Zhang, K., Lin, D., ... & Yue, X.(2023). Onellm: One framework to align all modalities with language. arXiv preprint arXiv:2312.03700.

[2. 최종 목표]

- 발달 지연 및 장애 아동들을 조기발견하기 위한 뇌영상-오믹스-행동 비디오-영상평가 데이터의 다중 모달리티 AI 모델 개발

[3. 접근]




그림 71. 이미지, 오디오, 비디오, 언어 등의 멀티모달 데이터 통합 모델: X instruct BLIP




그림 72. 본 세부목표에서 개발할 뇌영상-오믹스-행동 비디오-임상평가 데이터의 다중 모달리티 AI 모델

- 최근 공개된 X instruct BLIP은 사전 학습된 각 모달리티별 AI 모델들을 거대 언어 AI 모델을 중심으로 통합한 AI 모델임¹⁹⁸.
- 언어 모델을 중심으로한 다양한 모달리티의 통합을 위해서, 각 모달리티별 AI 모델들과 언어 모델을 연결해주는 가중치 레이어들을 추가하여 학습시킴. 이때 각 모달리티별 AI 모델들과 언어 모델의 가중치는 업데이트 되지 않으며, 새롭게 추가된 가중치 레이어들만 학습을 진행함. 이를 통해 각기 다른 모달리티별 AI 모델들의 잠재 공간을 언어 모델의 잠재공간과 연결시키는 것임.
- 이때, 새롭게 추가된 가중치 레이어는 cross-attention 연산을 통해서, 각 모달리티별 AI 모델로부터 얻어낸 임베딩과 언어 instruction을 언어 모델에 통과시켜 얻어낸 임베딩을 통합함. 언어 instruction은 질문을 비롯하여 언어 형태로 된 다양한 맥락 정보로 구성됨으로써, 통합 AI 모델로 하여금 모달리티 데이터들과 질문이 주어졌을 때 이에 대한 대답을 생성해내도록 만듦. 이를 통해 언어 생성 기반의 예측 과제를 비롯한 captioning 과제와 문답 과제 등을 수행할 수 있게 됨.
- 본 연구에서는 X instruct BLIP에서의 실험 결과들을 바탕으로, 앞선 세부목표들에서 개발된 뇌이미징, 오믹스, 행동 비디오 데이터 특화 AI 모델을 활용하여 사전학습된 거대 언어 모델을 중심으로 다중 모달리티 통합 AI 모델 개발을 진행하고자 함.
- 특히 성별을 비롯한 수치화된 행동 평가 데이터들과 신체 상태에 관한 정보들을 언어 텍스트로 변환하여 언어 instruction에 활용함으로써, 더욱 풍부한 정보를 학습할 수 있도록 다중 모달리티 통합 AI 모델 개발을 진행하고자 함.

¹⁹⁸ Panagopoulou, A., Xue, L., Yu, N., Li, J., Li, D., Joty, S., ... & Niebles, J. C.(2023). X-InstructBLIP: A Framework for aligning X-Modal instruction-aware representations to LLMs and Emergent Cross-modal Reasoning. arXiv preprint arXiv:2311.18799.

[4. 예상되는 난관과 극복 방안]

- 난관: 발달 지연 및 장애 아동들의 다중 모달리티 데이터 샘플의 숫자가 한정되어 있기 때문에 거대 AI 모델을 학습시키는 데에 어려움이 있음.
- 극복 방안:
 - 사전 학습된 거대 언어 모델과 뇌이미징, 오믹스, 행동 비디오 데이터 특화 AI 모델을 활용한다고 하더라도 이 사전학습 모델들을 결합하기 위해 추가되는 가중치 레이어들의 학습을 위해서는 많은 양의 데이터가 필요함. 이에 본 연구에서는 연구 개발 목표 2-1을 통해서 표집한 공공 데이터를 활용하여 다중 모달리티 통합 AI 모델을 1차적으로 학습시키고자 함. 이후, 발달 지연 및 장애 아동들의 데이터를 이용한 2차 학습을 진행함으로써 한정된 숫자의 발달 지연 및 장애 아동 샘플들을 위한 다중 모달리티 통합 거대 AI 모델 개발을 실현하고자 함.
 - 세부목표 3-1-1에서 제시되었던 점진적 심화학습 방법을 활용하여, 적은 데이터로도 높은 정확도로 예측이 가능하면서도 발달 지연 및 장애와 연관이 있는 성별과 행동 수치 데이터들을 통해서 샘플 효율적인 학습을 진행하고자 함.
 - 세부목표 3-2-2에서 제시하는 샘플 효율적 다중 모달리티 학습 방법을 이용하여 적은 샘플의 다중 모달리티 데이터에서 효과적인 AI 모델 학습을 가능하게 하고자 함.

[5. 기대되는 결과 및 유의성]

- 뇌이미징, 오믹스, 행동 비디오 데이터들을 통합함으로써 AI 모델의 정확도를 향상

시킬 수 있으며, AI 모델이 더욱 풍부한 임상 평가 소견을 제공할 수 있음.

- 성별을 비롯한 행동 평가 수치 데이터와 신체 상태 등의 데이터를 언어 텍스트의 형태로 AI 모델 학습에 활용하기 때문에, AI 모델이 다양한 정보들을 더욱 풍부하게 학습할 수 있음. 이는 AI 모델이 제공하는 발달 지연 및 장애 아동들에 대한 임상 평가 소견을 더욱 풍부하게 만들 수 있을 것임.

[1. 근거 및 배경]

- Multimodal 데이터 통합은 소아 발달장애의 생물학적, 유전적, 행동적 측면에 대한 포괄적인 통찰력을 제공함으로써 소아 발달장애에 대한 이해를 향상시키는 유망한 잠재력을 보여주었음. 전통적인 접근 방식은 데이터 다양성과 양이 부족하여 발달장애의 복잡한 상호 작용을 포착하는 데 효율성이 제한되는 경우가 많음. 또한 기초 모델과 같은 대규모 AI 모델은 의료 분야에 적용되기 시작했지만 고도로 전문화된 의료 데이터 세트에서 흔히 볼 수 있는 작은 표본 크기로 인해 일반화 수준이 낮고 결과가 편향되는 문제에 직면해 있음.
- 최근 연구에서는 MRI, PET, 유전 데이터와 같은 다양한 데이터 유형의 통합이 복잡한 소아 질환의 이해를 깊게 할 수 있는 잠재력을 보여주었음. Multimodal 학습은 진단 정확성과 치료 계획을 향상시키는데 중요한 역할을 할 수 있음.
- 하지만, 전통적인 기계 학습 방법들은 특수한 의료 데이터셋의 작은 표본 크기로 인해 성능과 적용 가능성이 제한되곤 함. 이는 모델이 일반화하는 능력을 저하시키고, 편향된 결과를 초래할 수 있음. 고차원이고 복잡한 입력 공간에서 비용이 많이 드는 블랙박스 함수를 최적화하는 것은 과학과 공학의 많은 중요한 문제들에서 공통적임. 기존의 머신러닝 기법들은 이러한 문제들을 해결하는 데 샘플 효율성이 크게 부족함.
- 또한, 다양한 데이터 소스로부터의 정보를 통합할 때 발생하는 불확실성을 측정하고 정량화하는 것은 임상 결정을 내리는 데 있어 매우 중요함. 특히 고위험 분야에서 예측 모델이 신뢰할 수 있는 신뢰도 추정치를 제공하는 것은 필수적임. 이를 위해 베이지안 접근법과 확률 모델을 사용하는 방법이 연구되고 있음.

[2. 최종 목표]

- 신뢰도가 어느 분야보다 중요하지만 샘플의 수가 절대적으로 부족한 의료 분야에서 sample efficient한 multimodal learning 방법론 도입 및 uncertainty 정량화

[3. 접근]




그림 73. Latent Space Optimization with Weighted Retraining

- "Latent Space Optimization with Weighted Retraining"¹⁹⁹에서는 잠재 공간 최적화(Latent Space Optimization, LSO)를 통한 목적 함수 최적화 과정에서 생성 모델을 가중치를 두어 재학습하는 방법을 제안함. 이 접근법은 데이터의 가중치 부여와 주기적 재학습이라는 두 주요 요소를 통해 잠재 공간을 지속적으로 조정함.
- 본 연구에서는 고차원의 데이터들의 data fusion²⁰⁰을 통해 생성된 멀티모달 데이터를 잠재 공간의 최적화를 통해 샘플 효율성을 확보하고자 함.

¹⁹⁹ Tripp, A., Daxberger, E., & Hernández-Lobato, J. M.(2020). Sample-efficient optimization in the latent space of deep generative models via weighted retraining. Advances in Neural Information Processing Systems, 33, 11259–11272.

²⁰⁰ Stahlschmidt, S. R., Ulfenborg, B., & Synnergren, J.(2022). Multimodal deep learning for biomedical data fusion: a review. Briefings in Bioinformatics, 23(2), bbab569.




그림 74. Deep Ensemble 방법론

- 불확실성 정량화(Uncertainty Quantification, UQ)를 활용하는 대표적인 방법으로(Monte Carlo Dropout, MCD)²⁰¹을 멀티모달리티 AI모델에 적용함. 훈련된 딥러닝 모델에서, 테스트 시에도 드롭아웃 층을 활성화시키고 여러 번의 추론을 수행함. 각 추론 결과를 모아 평균과 분산을 계산하고, 이를 통해 예측의 불확실성을 평가함.
- 좋은 학습 결과는 학습 데이터 세트와 테스트 데이터 세트의 분포가 비슷해질때 이루어짐. 하지만 실제 직면한 문제에서는 테스트 데이터 세트의 분포를 알 수 없음. 따라서 추가적으로 본연구에서 딥 앙상블(Deep Ensemble, DE)^{202 203} 방법론을 제안할 수 있음. 딥 앙상블 방법론을 통해 테스트 데이터에 대해 더 나은 결과를 얻고 learner에게 ‘분포 이탈(out-of-distribution)’ 데이터가 제공될 때 모델 불확실성 추정치를 생성함.

[4. 예상되는 난관과 극복 방안]

²⁰¹ Brach, K., Sick, B., & Dürr, O.(2020). Single shot mc dropout approximation. arXiv preprint arXiv:2007.03293.

²⁰² Ashukha, A., Lyzhov, A., Molchanov, D., & Vetrov, D.(2020). Pitfalls of in-domain uncertainty estimation and ensembling in deep learning. arXiv preprint arXiv:2002.06470.

²⁰³ Pop, R., & Fulop, P.(2018). Deep ensemble bayesian active learning: Addressing the mode collapse issue in monte carlo dropout via ensembles. arXiv preprint arXiv:1811.03897.

- 효과적인 잠재 공간 최적화 개선

- 난관: 잠재 목적 모델을 효과적으로 최적화하는 것이 여전히 개선의 여지로 남아 있음. 잠재 공간을 최적화에 더 적합하게 만드는 추가적인 기법이 필요함. 또한 상당한 계산 비용이 요구될 수 있으며, 이는 장기적인 최적화 동작을 특성화하는 데 제한적일 수 있음.

- 극복방안:

- 잠재 공간을 더 잘 최적화하고, 적은 데이터로도 효과적인 학습이 가능하도록 모델을 개선하는 방법을 탐색해야 하며, 이론적 분석을 통해 가중치 재학습과 잠재 공간 최적화의 이론적 기초를 더욱 깊이 이해하고, 이를 통해 더 정교한 모델을 개발하도록 해야함.
- 잠재 공간 최적화과정에서 가중치 일정을 사용하여 탐색과 활용 사이의 균형을 맞추는 것과 같은 강화학습 기법이 향후 유용할 수 있음.
- 서울대학교 데이터사이언스 대학원 및 각 기관들의 컴퓨팅 자원의 활용과 추가적인 시스템 구축을 통해 극복될 것으로 예상됨.

- 멀티모달 데이터에의 MCD 적용

- 난관: MCD의 경우 딥러닝 모델에서 여전히 좋은 기록을 보여주고 있으나, 본연구에서는 다양한 멀티모달 데이터를 활용한 모델을 활용하기에 그만한 성능을 보여줄지는 미지수임.
- 극복 방안: 멀티모달리티 AI 모델에 Vanilla MCD뿐 아니라 적합한 Uncertainty Quantification 방법을 실험 및 계획하여 적용함. 또한 추가적으로 새로운 DE 모델이 연구실 차원에서 개발된다면 신뢰성 및 안정성이 강화될 것임.

[5. 기대되는 결과 및 유의성]

- 샘플 효율성 알고리즘 개발을 통해 고차원의 멀티모달 데이터 학습을 더욱 신속하고 비용 효율적으로 가능하게 할 것이며, 이는 과학적, 공학적 문제해결 뿐만 아니라 비즈니스와 산업에도 긍정적인 영향을 미침.
- 불확실성 정량화를 통해 모델의 신뢰성과 안전성을 보장하고, 불확실한 상황에서도 효과적으로 작동할 수 있도록 함.

[1. 근거 및 배경]

- 발달 지연 및 장애를 가진 아동들의 조기 발견은 그 중요성을 강조하기에 충분하며, 이를 위해 뇌 영상, 오믹스 데이터, 행동 비디오 등 다양한 정보 모달리티의 활용이 필요함.
- 그러나 발달장애 소아 임상군에서는 다른 그룹에 비해 데이터 수집 및 관리의 어려움이 존재하며, 환경이나 조건에 따라 데이터의 특성이 두드러지게 나타나는 경우가 많음
- 이는 대량의 데이터를 수집하여 활용하는 기존의 인공지능 학습 방법론을 적용하기 어렵게 만듦.
- 또한, 병원이나 연구소에서는 보안 문제 및 기타 이유로 데이터를 외부와 공유하는 데 소극적인 상황임
- 이러한 여러 이유는 발달 지연 및 장애 아동의 조기 발견을 위한 인공지능 모델 개발을 더욱 어렵게 만드는 요인임.
- 이에 대한 해결책으로, 연합학습(federated learning) 기반의 인공지능 학습 방법론이 제안 효과적일 것으로 기대됨.
- 더 나아가, 연합학습 과정 중에 도메인 일반화와 적응(domain generalization and adaptation)을 동시에 고려한 방식을 통해서 학습의 효과를 증대가 기대됨
- 이 방법론은 여러 기관에서 데이터를 직접 공유하지 않고도 중요한 정보를 활용할 수 있도록 하여, 발달장애 소아 임상군에 특화된 인공지능 모델을 효과적으로 학습할 수 있도록 도움

- 이러한 접근은 보다 효율적이며, 보안이 유지되는 방식으로 다양한 모달리티의 정보를 결합하여 발달 지연 및 장애를 가진 아동들의 조기 및 개입에 크게 기여할 수 있음

[2. 최종 목표]

- 발달 지연 및 자폐스펙트럼 장애 소아의 조기 발견 예측 모델의 효과적 성능 향상을 위한 연합학습 기반의 다중 모달리티 인공지능 모델 고도화

[3. 접근]

- 발달장애 소아 임상군이 아닌 다양한 임상군의 데이터를 대량으로 수집하는 것을 가정하고, 이를 활용한 다중 모달리티 파운데이션 모델(multi-modal foundation model)이 학습되어 주어진 상황을 가정함
- 이를 기반으로 하여 소량의 발달장애 소아 임상군 관련 데이터를 활용하여, 발달 지연 및 장애 소아의 조기 발견 예측 모델을 학습하는 것을 목표로 하며, 이때 파라미터 효율이 높은 전이학습 방법론(parameter-efficient transfer learning)의 활용을 기본적으로 사용.
- 이는 주어진 다중 모달리티 파운데이션 모델의 전체를 새로 학습하지 않고, 다양한 임상군의 데이터로 기학습된 지식(pretrained knowledge)을 최대한 활용하는 방식으로, 모델의 일부만을 새로 학습하거나 모델에 추가적인 모듈을 붙이는 형태로 학습을 진행
- 더 나아가, 다양한(다른 인종, 지역 혹은 병원) 발달장애 소아 임상군에 대해 효과적으로 대응하기 위해서는 연합학습(federated learning)을 기반한 학습 방식 활용
- 연합학습 방식에서는 각 기관 혹은 병원이 하나의 클라이언트(client)로 정의되며, 여러 클라이언트를 중앙에서 학습을 통제하고 관리하는 서버(server)가 존재함

- 연합학습을 통해서, 클라이언트들은 도메인 적응(domain adaptation)의 방식으로 각 기관 혹은 병원의 발달장애 소아 임상군에 특화된 형태로 주어진 파운데이션 모델을 학습하는 것으로 목표하며, 이를 통해 클라이언트들은 데이터를 외부와 공유하지 않은 상황에서 각 기관에 특화된 예측 모델을 얻음
- 반대로, 중앙 서버에서는 클라이언트들에서 데이터가 아닌 기관 혹은 병원에 특화된 모델을 전달 받고, 이를 바탕으로 중앙에서 관리하는 모델을 도메인 일반화(domain generalization)의 방식으로 다양한 발달장애 소아 임상군에서 강인한 예측 모델을 얻음
- 이는 연합학습을 통해서 도메인 일반화와 적응의 방식을 동시에 적용하여, 기관 혹은 병원 별 데이터의 보안을 제공하면서 발달 지연 및 장애 소아의 조기 발견 예측 모델의 성능을 효과적으로 향상시킬 것으로 기대됨




그림 75. “도메인 일반화와 적응을 동시에 고려한 연합학습 방법론”을 통해 기관 혹은 병원의 데이터를 보호하면서 여러 데이터를 효과적으로 활용하여 모델을 학습

[4. 예상되는 난관과 극복 방안]

- 이중 데이터간의 연합학습의 어려움

- 난관: 연합학습에 있어서 각 기관 혹은 병원(클라이언트)이 서로 다른 형태의 다중 데이터를 가지고 있어, 클라이언트들 간의 학습 관점에서의 결합이 어려울 수 있음
- 극복 방안:
 - 이기종 연합학습(heterogeneous federated learning) 기법을 활용하여, 서로 다른 형태의 다중 데이터를 효과적으로 처리
 - 데이터 형태 별로 모델에 별도의 모듈을 추가하여, 학습 과정이 데이터 형태별로 독립적으로 진행 가능하도록 함
- 도메인 일반화와 적응의 동시 적용에 의한 간접 효과
 - 난관: 연합학습 과정 중에 도메인 일반화와 적응의 방식을 동시에 적용함에 따라 서로 간접 효과가 나타나 전체적 성능 저하 현상을 야기할 수 있음.
 - 극복 방안:
 - 기학습된 다중 모달리티 파운데이션 모델에 도메인 일반화와 적응을 위한 개별적인 모듈을 추가하여, 도메인 일반화와 적응간의 간접 현상을 최소화 함.
 - 메타러닝의 학습 방법론을 활용하여, 도메인 일반화와 적응을 상호보완적인 형태로 정의하여 접근.

[5. 기대되는 결과 및 유의성]

- 다양한 임상군의 다량의 데이터로 기학습된 지식(pretrained knowledge)을 최대한 활용하되, 발달장애 소아 임상군에 특화된 형태의 모델을 효과적으로 학습할 수 있음
- 특히, 기관 혹은 병원이 소유하고 있는 소량의 발달장애 소아 임상군 데이터를 외부에 공유하지 않은 상황에서 도메인 일반화와 적응을 동시에 고려한 연합학습을 통해

모델의 성능 향상을 극대화할 것으로 기대됨

연구개발 목표 3-3: 전향적 코호트 데이터의 추가적 수집 및 바이오마커의 임상유효성 평가 준비

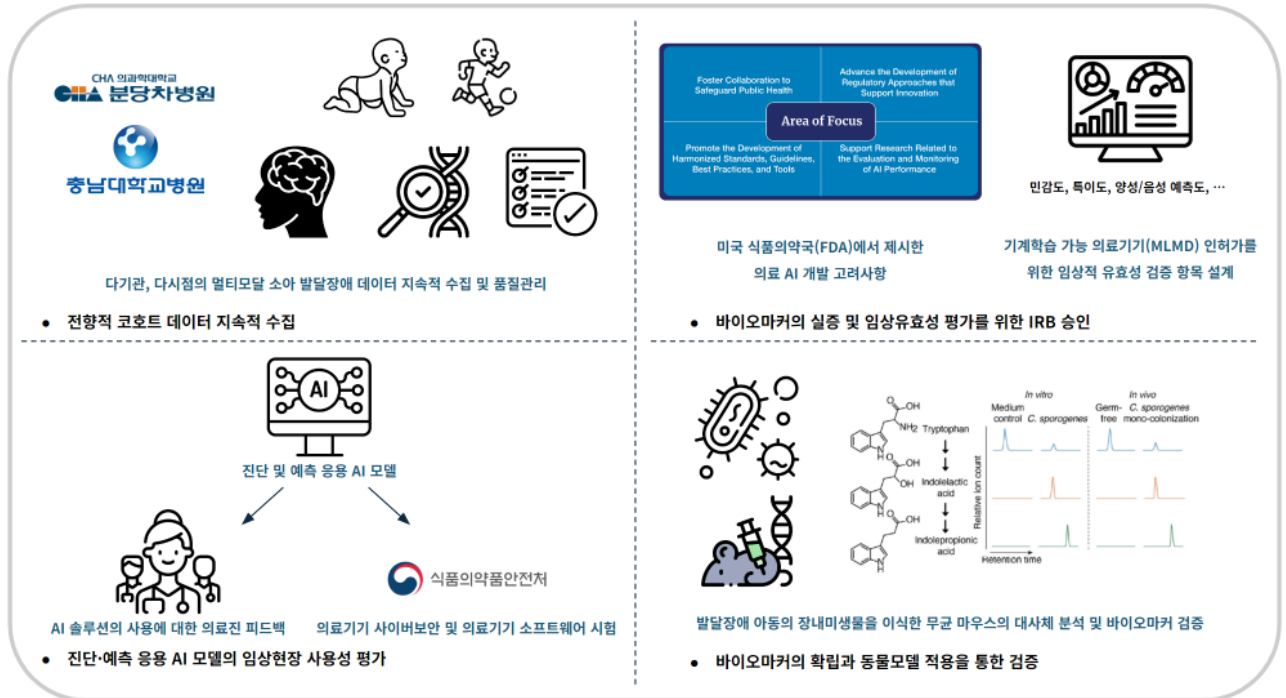


그림 76. 연구개발목표 3-3의 요약

세부목표 3-3-1. 전향적 코호트 데이터 지속적 수집

[1. 접근]

- 다기관 후향적 임상데이터 수집 지속 - 분당차병원, 충남대병원 재활의학과
- 전향적 임상데이터 수집 지속 - 분당차병원, 충남대병원 재활의학과
- 2차 연도에 개발한 K-BDS과 동기화된 발달장애 통합 데이터베이스에 추가로 수집된 데이터 등록

세부목표 3-3-2. 진단·예측 응용 AI 모델의 임상현장 사용성 평가

[1. 접근]

- 예측/진단 응용 AI 모델의 사용성 평가 및 인허가 가이드
 - 테스트 데이터의 일부를 활용하여 개발 모델의 파일럿 사용을 진행함.
 - 향후 빠른 임상현장 적용을 위한 AI 솔루션의 User Interface/User Experience(UI/UX) 사용에 대한 의료진 피드백 제공
 - 의료기기 사이버보안 요구사항에 대한 자문제공
 - MLMD 사용적합성 평가에 대한 설계

세부목표 3-3-3. 바이오마커의 실증 및 임상유효성 평가를 위한 IRB 승인

[1. 접근]

- 발달장애의 타겟 질환군에 대한 예측/예후 조기진단을 위한 AI 모델의 실증
- AI 모델과 바이오마커의 임상유효성 평가를 위한 타겟 질환 아동 대상 임상연구 프로토콜 계획
 - 향후 MLMD 인허가를 위한 성능 및 임상적 유효성 검증 항목 설계.
 - 민감도(Sensitivity): 실제로 특정한 질병에 걸린 사람 중에서 그 질병이 있다고 분류해내는 확률

- 특이도(Specificity): 실제로 특정한 질병이 없는 사람 중에서 그 질병이 없다고 분류해내는 확률
 - 양성 예측도(Positive Predictive Value): 특정한 특성이 있는 것으로 분류된 사람들 가운데 실제로 그 특성이 있는 사람이 차지하는 분률
 - 음성 예측도(Negative Predictive Value): 특정한 특성이 있지 않은 것으로 분류된 사람들 가운데 실제로 그 특성이있지 않은 사람이 차지하는 분률
 - ROC(Receiver Operating Characteristic) Curve: 진단검사 결과를 근거로 민감도와 위양성률(1-특이도)을 이용하여 그린 그래프로, 양성과 음성을 구분하는 진단의 성능을 평가할 수 있음.
 - AUC(Area Under the Curve): ROC(Receiver Operating Characteristic) Curve의 아래 면적으로 진단 정확도를 의미하고 0.5~1.0 사이의 값에서 1에 근접할수록 이상적인 성능이라고 할 수 있음.
- 참고문헌을 활용한 참조표준 구축 기준 및 방법 제시함.

세부목표 3-3-4. 바이오마커의 확립과 동물모델 적용을 통한 검증

[1. 접근]

- GDD, ASD, ID 아동의 장내미생물 대사체 분석
 - 1차 연도에 구축한 장내 미생물 대사체 프로파일링 플랫폼은 마우스 분변에서 분리한 대사체를 기준으로 함. GDD, ASD, ID 아동의 분변에서 대사체를 추출 후, 장내 미생물 대사체 프로파일링 플랫폼을 통해 특이성을 확보함. 마우스 모델과 공통으로 또는 상이한 대사체들의 클러스터를 분석하여 동정함.
- 발달장애 아동의 장내미생물을 이식한 무균 마우스의 대사체 분석 및 후보 대사체 발굴




그림 77 전구체, 중간물질, 그리고 최종 대사체의 미생물과 마우스이식에서의 대사체 분석 예시. Tryptophan은 전구체, indolelactic acid는 중간물질, indolepropionic acid는 최종 대사체²⁰⁴

- 발달장애 아동의 분변과 마우스의 대사체 분변의 특이성을 먼저 분석 후, 발달장애 아동의 분변을 이식한 마우스의 분변에서 장내 미생물 유래 대사체를 분석함.

²⁰⁴ Han, S., Van Treuren, W., Fischer, C. R., Merrill, B. D., DeFelice, B. C., Sanchez, J. M., . . . Dodd, D.(2021). A metabolomics pipeline for the mechanistic interrogation of the gut microbiome.Nature, 595(7867), 415-420.

- 특히, 대사체는 전구체, 중간물질, 그리고 최종 대사체의 다양한 형태로 존재함. 이를 m/z-RT로 확인하여, 쥐의 분변에서 장내 미생물 유래 대사체의 특이성을 확보함(그림 77).
- 발달장애 아동의 장내미생물을 이식한 무균 마우스의 뇌에서 전사체 데이터와 대사체 비교 분석
 - 발달장애 아동의 장내 미생물 유래 대사체가 뇌까지 전달되는지 확인하기 위해서, 특이적인 대사체의 BBB 통과 유무를 문헌을 통해 분류함.
 - 무균 마우스의 뇌 조직에서 80% 메탄올로 대사체를 추출 후, 대사체 프로파일링을 통해 무균 마우스 뇌에서 특이적으로 증감되는 대사체를 확인함.
 - 대사체를 조절하는 표적 유전자를 확인하기 위해, 장내미생물을 이식한 무균 마우스의 뇌 조직에서 공공데이터 및 보유 전사체 데이터 확보, 대사체와 멀티오믹스 분석을 통해 표적 대사 경로 및 표적 유전자 확인함.

라. 2단계 - 4차 연도: 바이오메디컬 빅데이터 기반 응용 AI 모델의 예측력 검증, 임상적 유용성 확인 및 AI 모델 공개

연구개발 목표 4-1: 개발된 예측/진단 응용 AI 모델 및 바이오마커의 임상적 유용성 확인




그림 78. 연구개발 목표 4-1의 요약.

세부목표 4-1-1. 뇌영상-오믹스-행동비디오-임상평가 멀티모달 AI 모델의 임상적 유용성 검증

[1. 근거 및 배경]

- 학습된 모델의 임상적 유용성을 검증하기 위해서는 해당 모델이 모델 학습에는 사용되지 않은 다양한 임상 데이터에서도 일관된 예측 성능을 보이는지를 확인할 필요가 있음.
- 또한 MedPALM M²⁰⁵과 같은 최근 의료 파운데이션 AI 모델에서는 임상 데이터에

²⁰⁵ Tu, T., Azizi, S., Driess, D., ... & Natarajan, V.(2024). Towards generalist biomedical ai. NEJM AI, 1(3), AIoa2300138.

대해 실제 소견서와 AI가 생성한 소견서 중 어느 것이 더 나은지를 의사가 평가하는 방식으로 모델을 평가하고 있음. 이같은 방법은 AI 파운데이션 모델을 실제 의료 현장에서 잠재적으로 활용할 의사들이 유용성을 평가한다는 점에서 타당한 방식임.

- 따라서 후향적으로 다양한 병원에서 수집된 소규모 테스트 샘플들에 대해 학습된 모델이 얼마나 잘 작동하는지, 그리고 해당 예측에 대한 타당성과 만족도를 의사들이 평가함으로써 모델의 임상적 유용성을 검증하고자 함.




그림 79. 모델 예측 성능 비교와 임상적 유용성 검증을 통한 멀티모달 AI 모델 평가

[2. 최종 목표]

멀티모달 뇌영상-오믹스-행동 데이터 통합 AI 모델이 다양한 소규모 데이터에서 기능하는지 검증하고, 의사들의 교차 검증을 통해 임상적 유용성 검증.

[3. 접근]

- 차병원, 충남대학교 병원에서 후향적으로 수집된 데이터를 기반으로 모델을 파인튜닝하여 모델의 예측 성능을 측정함. 이 과정에서 단일한 임상 데이터에만 기반하는 기존 딥러닝 모델과 성능을 비교함.
- 의사들을 대상으로 의료 데이터에 대해 모델이 생성된 소견서가 전반적으로 만족도가 높은지, 중대한 오류를 포함하고 있는지(오류율), 그리고 반드시 포함되어야 하는 내용이 누락되었는지(누락율)를 기준으로 평가함.

[4. 기대되는 결과 및 유의성]

- 다양한 소규모 데이터를 학습된 모델의 일반화 가능성과 신뢰성에 대해 검증함으로써 차후 임상 장면에서 해당 모델이 활용될 수 있는 근거를 마련.
- 잠재적 고객이 될 수 있는 의사들의 만족도를 평가함으로써 AI 모델을 사업화하였을 때 진단 보조 도구로서 얼마나 도움이 될지 검증이 가능함.
- 검증 과정에서 수집되는 피드백을 통해 모델을 수정, 보완하여 최종 배포 단계까지 모델을 지속적으로 고도화할 수 있을 것으로 기대함.

세부목표 4-1-2. 신규 바이오마커 및 AI 솔루션의 다기관 실증 및 유효성 평가

[1. 접근]

- 분당차병원과 충남대학교 병원에서 동시에 발굴된 바이오마커와 AI 솔루션의 실증 및 임상적 유효성을 평가함.
 - 분당차병원은 2022년도부터 연구중심병원 유닛 사업에 선정되어 산모와 아동을 대상으로 하는 통합 데이터 플랫폼과 의료기술 기기 실증 플랫폼을 구축하여 해당 플랫폼을 본 연구개발 결과물의 실증 및 평가에 활용할 수 있음.




그림 80. 분당차병원 연구중심병원 유닛 플랫폼

세부목표 4-1-3. 다양한 중재치료(집중재활치료, rTMS, 약물치료 등)에 따른 효능이 도출된 바이오마커에 의해 입증되는지 검증

[1. 접근]

- 다양한 중재치료를 대상으로 아동들의 증상 개선도가 도출된 바이오마커로 확인되는지 검증

- 기존 치료 약물, repetitive transcranial magnetic stimulation(rTMS), 집중재활 치료 등의 중재를 수행하여 전후 도출된 바이오마커의 특이값을 확인함.
- 임상평가지표와의 비교를 통하여 바이오마커의 증상 개선도 입증력을 확인함.

연구개발 목표 4-2: 개발된 AI 모델의 공개를 통한 발달장애 바이오마커 검증 후속 연구 장려

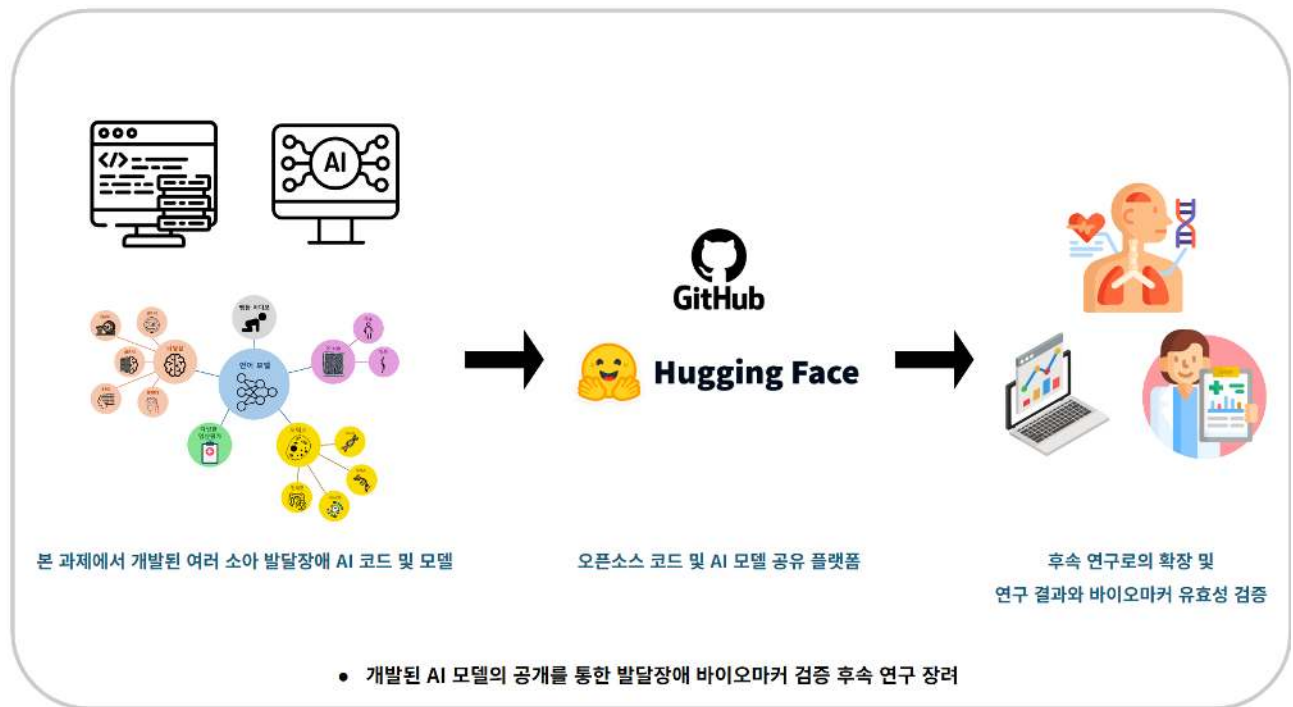


그림 81. 연구개발 목표 4-2의 요약.

- 세부목표 4-2-1. 글로벌 플랫폼에 개발된 응용 AI 모델 공개

[1. 근거 및 배경]

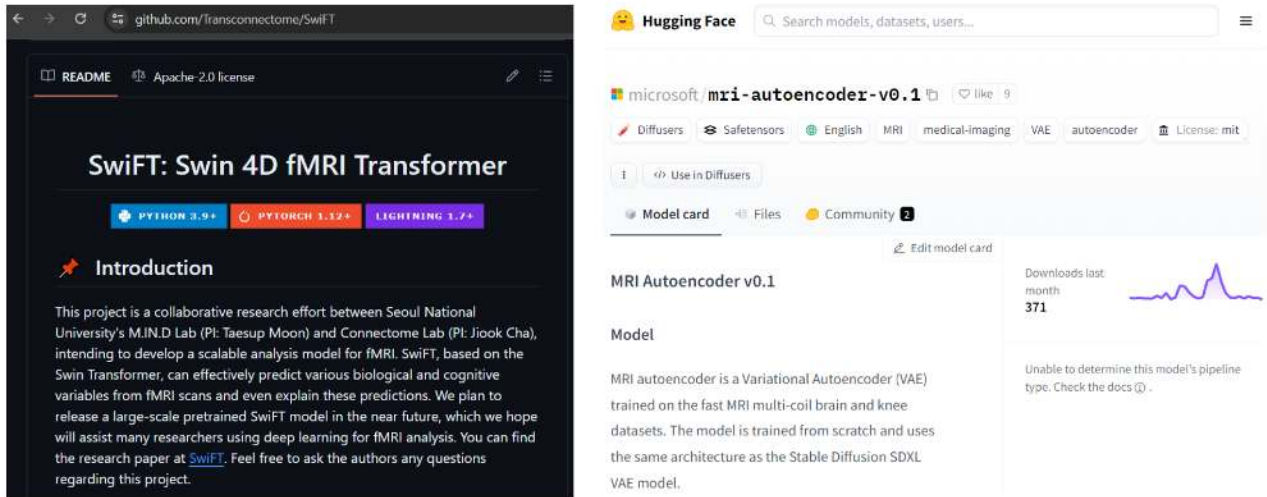


그림 82. Github와 Hugging Face에 공개된 뇌영상 모델의 예시

- 인공지능 분야의 급속한 발전에 있어 가장 중요한 요소 중 하나는 바로 누구나 모델 개발에 필요한 데이터나 코드에 접근하여 사용할 수 있도록 하는 오픈소스 방침임. 최근에 Meta에서 발표한 Llama 3를 비롯하여, 차지욱 교수 연구실에서 발표한 뇌영상 딥러닝 모델인 SwiFT²⁰⁶나 단백질 구조 예측 딥러닝 모델인 RoseTTAFold²⁰⁷와 같이 다양한 연구 도메인에서 AI 모델과 코드가 공개되고 있음.
- 오픈 소스 딥러닝 개발 및 배포에 있어 가장 많이 사용되는 사이트 중 하나는 Github이다. Github(<https://github.com/>)는 마이크로소프트 산하의 플랫폼으로, 개발자들이 코드를 공유하여 협업하거나 본인이 만든 코드 등을 모두에게 공개하기 위해 사용되는 플랫폼임. 이를 사용하면 편리하게 전세계의 연구자들과 코드 및 모델을 공유할 수 있어 본 과제에서 개발한 소아 발달장애 AI 모델을 확장한 후속 연구의 진행에 기여할 것임.
- 또 다른 오픈소스 플랫폼인 Hugging Face(<https://huggingface.co/>)를 이용함.

²⁰⁶ Kim, P., Kwon, J., Joo, S., Bae, S., Lee, D., Jung, Y., ... & Moon, T.(2024). SwiFT: Swin 4D fMRI Transformer. Advances in Neural Information Processing Systems, 36.

²⁰⁷ Baek, M., DiMaio, F., Anishchenko, I., Dauparas, J., Ovchinnikov, S., Lee, G. R., ... & Baker, D.(2021). Accurate prediction of protein structures and interactions using a three-track neural network. Science, 373(6557), 871–876.

사용자는 이 플랫폼을 통해 본인이 개발한 코드와 모델을 손쉽게 배포할 수 있으며, 다른 사용자가 업로드한 모델을 웹사이트 상에서 테스트해보거나 직접 내려받아서 활용할 수 있음. 이 플랫폼을 통한 모델의 공유는 Hugging Face를 사용하던 AI 개발자들이 손쉽게 본 모델을 사용할 수 있는 기회를 제공할 것임.

- 위의 두 플랫폼에 코드와 모델을 공개함으로써 본 과제에서 개발한 소아 발달장애 AI 모델이 단순히 특허 등록이나 논문 작성에 쓰이고 그치는 게 아니라 함께 공개한 데이터와 더불어 다른 발달장애 연구자나 AI 연구자들에게 연구의 출발점으로 사용될 수 있을 것임. 이는 자연스레 다른 연구자들에 의한 연구 결과의 재현가능성을 검증으로 이어질 것이며 발달장애 바이오마커의 또 다른 발굴 및 임상적 유용성 확인 등의 긍정적 효과를 산출할 것임.

[2. 최종 목표]

- 개발된 응용 AI 모델 및 코드를 글로벌 연구 커뮤니티와 공개(Github 및 Hugging Face)

[3. 접근]

- 개발된 응용 AI 모델 및 코드를 Github 및 Hugging Face에 공개
 - 본 연구과제에 포함된 연구개발 목표 2-2에서 개발된 모달리티별 AI 모델과 연구개발목표 3-1과 연구개발목표 3-2에서 개발된 멀티모달 AI 모델 및 대규모 파운데이션 모델 기반 AI 모델에 대해 논문 발표 및 특허 등록 등의

절차 선완료.

- 이후 각 연구진이 Github에 모델을 공개할 수 있게 지원하고, 본 과제에서 개발한 모든 모델을 한 번에 확인할 수 있게끔 하나의 새로운 Github repository를 만들어서 관리함.
- 그렇게 만든 통합 Github repository를 참고로 하여 Hugging Face에도 개발된 AI 모델들을 공개함.

3-2. 연구개발과제의 추진체계

뇌영상 및 AI 연구팀
차지욱, 이종호 외 7명  서울대학교

뇌영상 전처리

- 구조, 확산, 기능 뇌영상 전처리
- brainlife.io를 활용하여 표준화된 전처리 파이프라인 구축
- 딥러닝 기반 정량적 자화율 영상법
- 생체물리학적 고급 정량적 자화율 매핑 (χ -separation)

뇌영상 AI 모델 개발

- 멀티모달 뇌영상 사전학습 AI 모델 개발
- 정량 자화 매핑 뇌영상 및 임상 데이터 활용 멀티모달 AI 모델 개발
- 점진적 학습 패러다임을 적용한 멀티모달 뇌영상-언어 AI 모델 개발

코어 AI 연구팀
김태성, 오민환 외 7명  서울대학교

샘플 효율적 학습 및 연합학습

- 샘플 효율적인 멀티모달 학습 방법론
- 불확실성 정량화 기법을 통한 모델 예측의 불확실성 추정
- 도메인 일반화/적응을 고려한 멀티모달 AI 모델 개발
- 병원의 데이터 보안을 유지하는 연합학습 방법론

멀티오믹스 및 AI 연구팀
주윤정, 이태식 외 3명  삼성 AI 센터

멀티오믹스 AI 모델링

- 발달장애의 스펙트럼형 표현형 위험도 정량화
- 오믹스 데이터 모델러티별 발달장애 위험도 바이오마커 규명
- 공공데이터와 생물정보학 분석모듈을 이용한 발달장애 관련 유전자 제시
- LLM을 활용한 멀티오믹스-언어 멀티모달 AI 모델 개발
- 멀티오믹스 기반의 자체 스펙트럼 장애 예후 및 치료효과 관련 유전자 규명



대규모 파운데이션 모델을 활용한 멀티모달 AI 개발/공개 및 임상적 유용성 검증

- 대규모 파운데이션 LLM을 활용한 뇌영상-오믹스-행동비디오-임상평가 멀티모달 AI 모델의 개발
- 각 모델러티별 AI 모델 및 멀티모달 AI 모델 등을 통해 발굴한 바이오마커의 임상적 유용성 검증
- 글로벌 플랫폼에 개발된 응용 AI 모델 공개 및 이를 통한 후속 소아 발달장애 연구 장려

주관연구개발기관 1 - 서울대학교의 연구개발과제 추진체계



공동연구개발기관 1 - 분당차병원의 연구개발과제 추진체계



공동연구개발기관 2 - 루먼랩의 연구개발과제 추진체계

그림 83. 연구개발과제의 추진체계

3-3. 추진 일정

1차 연도													
추진내용	추진 일정												책임자 (소속기관)
	1	2	3	4	5	6	7	8	9	10	11	12	
소아발달장애 뇌영상 공공데이터 수집 및 분당차병원 데이터 전송													차지욱 (서울대학교)
구조, 확산, 기능 뇌영상 수집 및 정제													차지욱 (서울대학교)
정량적 자화율 매핑 뇌영상 수집 및 정제													이종호 (서울대학교)
도메인 일반화와 적응을 동시에 고려한 연합학습 방법 구현을 위한 실험 설계													김태섭 (서울대학교)
샘플 효율성 확보 및 불확실성 정량화를 위한 실험 설계													오민환 (서울대학교)
정량화마커 기반 발달장애 위험 계산모델 개발을 위한 오믹스 공공데이터 탐색 및 수집													주윤정 (성균관대학교 삼성융합의과학원)
자폐스펙트럼 장애 유전자 제시를 위한 오믹스 공공데이터 수집 및 정제													이태식 (연세대원주의과대 학)
국내외 공공데이터 탐색 및 선행 연구 등을 통한 플랫폼 구축 대상 멀티모달 데이터군 정의 및 단위 확립													김민영(분당차병원)
확립된 멀티모달 데이터군을 대상으로 기존 공공데이터에 수가 부족하거나 없는 데이터에 대한 다기관 다시점 후향적 임상 데이터 제공													김민영/최자영(분당 차병원 /충남대병원)

[illegible]

[illegible]

[illegible]

무균 마우스에 후보 대사체 처리후 행동 분석														정상용(차의과학대학교)
BBB 통과 후보 대사체 분석														윤혜진 (울산과학기술원)
발달장애 대사체 후보군 발굴														윤혜진 (울산과학기술원)
표준 데이터 관리 인프라 도입 및 사용성 정확도 평가														임재현 (루먼랩)
구축 데이터에 대한 반자동 데이터 검토 알고리즘 개발														임재현 (루먼랩)
공공 데이터 허브 데이터 정제 및 가공														임재현 (루먼랩)
행동 데이터 품질 평가 및 정제														임재현 (루먼랩)
행동 데이터 표현형 평가 및 전문가 검증														임재현 (루먼랩)
표준 데이터 관리 인프라 도입 및 사용성 정확도 평가														임재현 (루먼랩)
행동 동영상데이터를 이용한 발달장애 분류 모델 개발														임재현 (루먼랩)
4차 연도														
뇌영상-오믹스-행동비디오-영상평가 멀티모달 AI 모델의 임상적 유용성 검증														차지욱/이종호 (서울대학교)
병원과 연계한 멀티모델 AI 모델의 연합학습 모델 적용 및 사용성 검증														김태섭/오민환 /차지욱 (서울대학교)

4. 연구개발 성과의 활용 방안 및 기대효과

4-1. 연구개발성과의 활용방안

- **신규 바이오마커 및 AI 모델을 활용한 새로운 임상 연구 촉진:** 본 연구를 통해 발견된 신규 바이오마커와 새롭게 개발된 AI 모델은, 장기 추적 임상경과가 반영된 기 구축 데이터를 통하여 어린 나이에서 발견된 뇌구조와 임상적 특성에 따른 향후 임상 경과 예측에 활용될 수 있음. 본 연구들을 통해 수집되는 다양한 모달리티의 바이오뱅크 데이터는 추후 발달 지연의 기저에 있는 임상적 특성, 유전체 및 대사체의 특성과 뇌구조 각각의 메커니즘 뿐만 아니라 복합적인 메커니즘을 밝히는 연구를 촉진할 것임. 뇌 영상(구조 및 기능)이 현재의 명확한 이상만을 판독할 수 있는 수준을 넘어 미세구조를 파악하여 질환을 이해할 수 있는 자료로 활용될 수 있을 것임. 시계열로 수집한 임상평가 결과와 시기에 맞춘 mRNA, non-coding RNA 결과 및 대사체의 분석은 임상적 경과를 반영할 수 있는 유전체와 대사체를 밝히는데 도움이 될 것으로 예상함. 조기 치료적 개입을 위해 조기 감별 진단이 필요한 GDD 아동들에서 개발된 바이오 마커를 통해 보다 어린 연령에서도 정확하게 진단을 내릴 수 있음.
- **웹 기반의 발달장애 아동 바이오뱅크 데이터 및 연구 결과 카탈로그 시스템 구축을 통한 연구 촉진:** 뇌이미징, 오믹스, 행동 영상 데이터의 다중 모달리티 데이터와 이를 통한 연구 결과들을 정리하고 시각화하여 웹 기반의 카탈로그 시스템을 구축하는 것은 신경과학자, 유전과학자, 임상가를 비롯한 다양한 분야의 연구자들이 연구의 흐름을 파악하고 디자인하는 데에 있어서 큰 도움을 줄 것임. 본 연구를 통해서 표집되는 데이터들은 다중 모달리티 데이터들이라는 점에서 다양한 분야의 연구자들이 관심을 갖고 자신들의 전문성을 살려 새로운 연구를 진행할 수 있는 기반이 됨. 따라서, 웹

기반의 데이터 카탈로그 시스템을 구축하고 서비스하는 것은 다양한 분야의 연구자들이 데이터들을 탐색하고 활용하는 진입장벽을 낮춤으로써 새로운 연구들을 촉진할 수 있을 것임. 또한, 본 연구팀의 연구들을 통해 발견될 새로운 연구 결과들을 압축적으로 시각화하여 웹 기반의 시스템으로 서비스하는 것은 새로운 연구자들이 기존의 연구 결과들에서 새로운 관계성을 탐색하고 이를 바탕으로 연구를 디자인하는 데에 큰 도움이 될 수 있을 것임. 또한 이렇게 진행되는 새로운 연구들을 통해서 발견되는 내용들은 시스템에 통합됨으로써, 새로운 지식의 축적과 이를 바탕으로 한 새로운 연구 탐색이라는 선순환의 구조를 만들 수 있을 것임. 이는 연구 및 임상 분야에서 새로운 진단 도구나 치료법 개발을 촉진할 것임.

- **고품질 데이터 수집 도구의 개발 및 배포:** 본 연구를 통해 개발되는 고품질의 영유아의 행동 데이터 수집 도구는 추후 다른 연구 기관이나 병원, 사후 연구에서 도입하여 사용할 수 있음. 이는 도구의 표준화를 통해 다양한 임상 환경에서의 데이터 호환성을 보장함. 또한 이를 통해 수집된 고품질의 균질한 데이터는 연구의 신뢰도를 높이고 더 정밀한 분석 결과를 제공하는데 기여할 수 있음.
- **데이터 품질 관리 기준 설정:** 본 연구팀은 데이터 품질을 보장하기 위한 엄격한 가이드라인을 개발하고 적용함. 이 가이드라인은 데이터 수집, 저장, 처리 과정에서 일관된 품질 유지를 돕는 규범으로 작용하며, 이후 추가적인 데이터 수집 및 연구에서 동일한 가이드라인 적용을 통해 데이터의 질을 담보할 수 있음. 데이터 품질 관리는 연구 결과의 정확도를 높이는 핵심 요소로, 품질 관리 도구를 개발하여 데이터 관리의 자동화와 효율성을 증대함.
- **향상된 데이터 분석 및 활용 교육 프로그램 개발:** 본 연구팀은 데이터 관리 및 분석 기술을 교육하는 프로그램을 개발하여, 발달지연 진단 및 치료 분야의 연구자와 의료

전문가들이 연구 데이터를 보다 효과적으로 활용할 수 있도록 지원할 예정임. 이 교육 프로그램을 활용한다면 실제 사례를 바탕으로 한 인터랙티브 워크숍을 통해 참가자들이 데이터 분석 도구를 직접 사용해보고, 이를 통해 얻은 인사이트를 실제 임상 상황에 적용하는 방법을 학습할 수 있음. 또한 최신 데이터 분석 트렌드와 기술을 소개하고, 이를 아동 발달 지연 연구에 어떻게 적용할 수 있는지에 대한 교육을 제공함. 이러한 교육 프로그램은 발달지연 진단의 정확성을 높이고, 조기 개입 프로그램의 개발을 촉진하는데 기여함.

4-2. 연구개발성과의 기대효과

- **소아 발달장애의 조기 진단:** 파운데이션 모델 기반의 뇌영상-오믹스-행동표현형 발달장애 예측 모델의 개발은 자폐 스펙트럼 장애의 조기 진단을 가능하게 할 것임. 또한 국내 의료 현장에서 비교적 손쉽고 표준화된 방법으로 획득이 가능한 데이터에 기반한 예측 모델의 개발은 확장성이 있을 것으로 기대됨. 이런 AI 솔루션에 기반한 진단 방법은 최근 국내에서 유병률이 심각하게 올라가고 있는 자폐 스펙트럼 장애의 조기 진단과 개입을 가능하게 하여, 심각한 사회 문제 해결에 꼭 필요한 기술이 될 것으로 예상함.
- **발달장애 조기진단을 위한 다중모달리티 AI 모델의 발달장애 바이오마커 발굴 촉진:** 뇌이미징, 오믹스, 행동 비디오 데이터의 통합 다중 모달리티 AI 모델은 서로 다른 모달리티 데이터 간의 연결을 통해서 발달장애 바이오마커의 발굴을 촉진할 수 있음. 다중 모달리티 AI 모델은 개별 모달리티 데이터로부터 비슷한 발달장애 증상을 보이는 경우 나타나는 다른 모달리티 데이터들을 검색가능하게 할 것임. 예를 들어, 다중 모달리티 AI 모델을 통해 발달장애 아동의 뇌이미징 데이터로부터, 비슷한 증상을 갖고 있는 다른 아동들의 오믹스 데이터를 검색할 수 있음. 이는 서로 다른 증상을 갖고 있는 아동들 간의

데이터의 유사성과 차이점을 찾고, 이를 바탕으로 새로운 바이오마커를 발굴하는 데에 도움을 줄 것임. 또한 활용가능한 데이터의 모달리티가 제한되어 있을 때에도, 다중 모달리티 AI 모델을 활용한 다중 모달리티의 통합적인 연구를 가능하게 함으로써 발달장애 바이오마커를 찾고자 하는 연구들에 큰 도움이 될 것임.

- **한국의 발달 지연 아동 연구에 대한 기준점 설정 및 글로벌화:** 한국인집을 이용한 genome-wide SNP 분석을 통해서 발달지연, 지적장애 질환에 대한 한국인 참조 DNA 데이터베이스를 구축하여, 향후 진단 및 관련분야 연구에 활용할 수 있음. 우리나라에 적합한 발달장애의 장내세균총에 대한 이해가 발생할 것으로 보이고, 이를 기반으로 한 치료적 방법이 연구, 제안될 수 있을 것으로 기대됨. 뿐만 아니라, 기존에 장내 미생물의 구성 및 다양성이 대륙별, 나라별, 개인별로 상당한 차이가 있어 글로벌화하기가 매우 어려운 문제점에서 탈피해, 새로운 기전에 대한 이해로 뇌 발달 및 다양한 뇌질환에 대한 진단용 바이오마커를 개발하고 글로벌화 할 수 있음.
- **발달장애 조기진단을 위한 다중모달리티 AI 모델의 맞춤 의학:** 거대 언어 모델 기반의 뇌이미징, 오믹스, 행동 비디오 데이터의 통합 다중 모달리티 AI 모델은 발달장애 조기진단을 위한 맞춤 의학을 향상시킬 수 있음. 다중 모달리티 데이터를 동시에 사용함으로써 다중 모달리티 AI 모델은 발달장애에 대한 조기 진단을 넘어서 훨씬 더 복잡적이고 다각적인 의학적 소견을 제공할 수 있음. 이는 발달장애 조기진단 AI 모델이 임상 장면에서 보조적인 도구로써 더욱 유용하게 활용될 수 있는 밑거름을 제공할 것임.
- **발달장애 연구 오픈 벤치마크 데이터를 통한 AI 모델 개발 촉진:** AI 분야의 발전에 있어서 벤치마크 데이터셋은 중요한 역할을 함. 오픈소스 데이터의 수치적인 평가 기준을 바탕으로, 재현 가능한 연구와 연구자들간의 자유로운 논의를 가능하게 함으로써 신뢰도 높은 연구가 이뤄졌음. 또한 평가 성적 기반의 순위 리더보드를 통해서 연구자들은

자신들의 AI 모델을 발전시키기 위해 경쟁적으로 연구를 진행할 수 있었음. 발달장애의 조기진단을 위한 AI 모델 개발은 매우 시의적이고 중요한 문제임에도 데이터셋에 대한 진입장벽이 매우 높기 때문에 각종 AI 분야의 연구자들이 문제 해결을 위해서 뛰어들기 어려웠음. 이러한 점에서 본 연구를 통해서 오픈소스로 공개되는 뇌이미징, 오믹스, 행동 비디오 데이터의 다중 모달리티 벤치마크 데이터셋과 AI 모델은, 글로벌 AI 연구자들과 데이터 과학자들의 발달장애의 조기진단 연구에 참여를 촉진할 것임. 이는 발달장애 아동 조기 진단 AI 모델의 고도화를 촉진할 것임.

- **발달장애 연구의 국제적 협력 및 파트너십 구축:** 본 연구팀이 제안하는 연구의 진행 과정에서 전 세계 연구 기관 및 의료 기관과의 협력 네트워크를 구축할 수 있음. 이 네트워크는 데이터 공유, 공동 연구를 통해 발달지연에 대한 국제적인 이해와 대응을 증진할 것임. 또한 파트너십을 통해 얻은 통찰력을 통해 국내외 정책 결정 및 공공 보건 프로그램 개선에도 기여할 수 있음. 뿐만 아니라 추후 협력을 통해 발달지연 진단 및 치료법에 대한 새로운 국제 표준을 제안할 수 있음.
- **신규 바이오마커 발굴을 통한 발달장애의 진단과 치료 고도화:** 본 연구를 통하여 우리나라 발달장애 아동의 선천적 후천적 이상 원인을 파악할 뿐 아니라, 치료 효과를 반영할 수 있는 유전체와 대사체 바이오마커를 발굴함으로써 아직 진단과 치료 경과 파악이 어려운 진료현장에 큰 지침이 될 수 있을 것으로 기대됨. 또한 새롭게 개발되고 있으나 효능을 판단하기 어려운 여러 가지 치료방법들의 효능을 생물학적으로 파악할 수 있는 중요한 참고자료가 될 것임. 특히나, 다면적 임상평가 결과, 뇌 영상, 유전체, 대사체 등 총체적인 접근을 통한 진단적 플랫폼 구축에 따라 개인별 특성을 파악할 수 있게될 것이며, 개인 맞춤형 중재 내용에 대한 제안이 가능할 것으로 기대됨.
- **기타 임상 응용 및 조기 진단 향상의 기대 효과:** 자동화되고 균질화된 데이터 수집과 이를

바탕으로한 신규 바이오마커 및 AI 솔루션은 발달장애 아동들에 대한 지속적인 모니터링 시스템 구축의 기반이 될 수 있음. 이러한 지속적인 모니터링 시스템 도입은 장기적인 발달지연 환자의 대응 정책 구축에 도움이 될 것임. 또한 이러한 시스템은 기존에 조기 진단을 위해서 필요했던 비용을 크게 줄일 수 있으며, 신속하고 정확한 조기 진단 및 치료는 뒤늦은 진단과 이로 인한 비용을 크게 감소시킴으로써 사회적 자원의 효율적 사용이 가능해 질 것임.

5. 연구수행 역량

5-1. 연구팀의 구성 및 역량

“뇌영상, 오믹스, 임상연구, 행동표현형을 통합하는 오픈 발달 연구 데이터의 수립과 AI 파운데이션 모델 구축 및 임상 검증 연구를 위한 최적의 연구팀.”

1. 연구단 구성

- **거대AI모델의 임상 적용 연구:** 차지욱 교수는 슈퍼컴퓨터를 활용하여 초거대규모(공개) 뇌영상 데이터 기반의 거대 뇌 모델 연구를 수행중이며, 이런 모델을 정상과 질환의 유소아 뇌인지 발달에 적용하는 것이 중장기적인 연구 목적임. Core AI 의 세계적 전문가인 김태섭 교수, 오민환 교수와, 뇌영상-오믹스의 전문가인 주윤정 교수와 함께, 다모드데이터 통합의 파운데이션 모델 기반의 발달장애 AI 모델 구축을 이끌 수 있음.
- **젊고 역동적인 팀:** 본 연구팀은 젊고 역동적인 연구자들로 구성되어 있으며, 오픈 사이언스를 위한 새로운 아이디어와 혁신적인 연구 방법을 통해 국내 뇌영상, 오믹스, AI 연구를 세계적 수준으로 이끌고 있음. 또한 폭넓은 해외연구자 네트워크의 허브 역할을 수행하고 있으며 해외 유수의 대학(U PENN-이종호교수, 싱가포르국립대 NUS-정상용교수, 컬럼비아의대- 차지욱교수)에서 교수로서 연구프로그램을 성공적으로 운영한 경험이 있음.
- **성공적인 다학제적 오픈 데이터 연구의 모델:** 본 연구진은 방대한 의료데이터를 글로벌 연구진과 공개하여 발달장애 벤치마크 데이터로 만들고, 만들어진 AI 모델도 오픈 소스로 공개하는 비전을 공유하고 있음. 본 제안서의 연구와 연구진은 성공적인

다학제적 의료 AI 연구의 롤 모델로서 제시될 것임.

[주관연구개발기관] - 서울대학교

- 서울대학교: 차지욱 교수, 이종호 교수, 김태섭 교수, 오민환 교수
- 성균관대학교 삼성융합의과학원: 주윤정 교수
- 원주세브란스병원: 이태식 교수

[공동연구개발기관 1] - 차의과학대학교 분당차병원

- 차의과학대학교 분당차병원: 김민영 교수, 심성한 교수, 정상용 교수, 전형민 교수
 - 분당차병원의 재활의학과 및 디지털혁신의료센터는 재활의학 분야 선도 연구팀으로 본 연구팀은 기관 내 조직에 따라 센터장: 의사(재활의학과), 팀장: 공학자, 팀원: 의사, 이학자, 임상심리사, 치료사 등으로 구성하여 연구 진행에 있어 각 분야 전문가 간의 원활한 소통이 가능하도록 조직되어 있으며, 특히 아동재활과 뇌신경 분야 연구에 특화되어 있음.
 - 외부기관과 산학연병 협력 연구를 위하여 “개방형 실험실”, “아동 리빙랩 기반 실증 플랫폼”을 운영하고 있음.
- 울산과학기술원: 윤혜진 교수
- 충남대학교병원: 최자영 교수

[공동연구개발기관 2] - 루먼랩

- 연구개발 분야와 역량: 루먼랩은 행동 데이터 수집, AI 모델의 개발 및 상용화, 의료기기 인허가 및 마케팅 역량을 기반으로 영유아 발달 지연 문제 해결을 위한

AI기반 전주기 솔루션을 개발하는 기업임. 루먼랩의 임재현 대표는 디지털치료제 개발회사 루먼랩 임재현 대표는 한국과학기술원(KAIST)에서 바이오·뇌공학을 전공한 뒤 서울대 의학전문대학원에서 석·박사 학위를 받은 의사과학자임(MD/PHD).

- 루먼랩은 인공지능(AI) 영상 분석 기반 영유아 발달지연을 진단하고 치료하는 솔루션 ‘굿비기닝’을 개발했음. 또 이 솔루션을 기반으로 하는 온라인 발달 평가 앱(응용 프로그램)을 출시했음. 만 12~36개월된 아이들을 대상으로 하는 앱인 ‘엘턴’은 스마트폰으로 아이의 행동을 촬영하고 설문 조사를 받게 하면 AI가 발달 상태를 평가해줌. 기존 발달 평가 프로그램은 평가에만 2~3시간이 걸리지만 이 앱은 5~10분 만에 간단하게 검사 결과를 알려줌.
- 이 최근 임상연구에서 이 솔루션을 활용하여 ADHD 아동(평균 12세)의 행동표현형 기반 분류에서 AUC 정확도 79.8%라는 의미있는 성과를 거두었음(JAMA Network Open, 2023 출판²⁰⁸). 이러한 성과는 아동 발달장애 진단에 있어서 AI 기술의 효용성을 입증하는 것이며, 루먼랩의 솔루션은 본 연구진에서 제안하는 통합적 멀티모달 데이터와의 결합과 함께 발달장애연구 분야에서의 기술적 진보를 더욱 가속화할 수 있는 가능성을 보여줌.
- 추가적으로, 스마트폰 기반의 행동분석 솔루션은 부모와 보육 전문가들에게도 큰 도움이 되며, 실시간으로 아동의 발달 상태를 모니터링하고 필요한 조치를 취할 수 있도록 지원할 예정임. 루먼랩은 이러한 혁신적인 접근 방식을 통해 영유아 발달 지연 문제에 대한 조기 개입과 지속적인 관리의 중요성을 강조하고 있음.

²⁰⁸ Kim, W. P., et al(2023). Machine learning – based prediction of attention-deficit/hyperactivity disorder and sleep problems with wearable data in children. JAMA Network Open, 6(3), e233502–e233502.

2. 연구단의 정량적 연구 역량 요약

- 본 연구단의 정량적 연구 역량 metric은 아래와 같다(최근 5년 업적, 출처: SciVal, scopus).

연구자	기관	논문수	h-index	분야보정 임팩트지수 (평균=1)	피인용수	논문당 피 인용수
차지욱	서울대	24	21	1.76	342	14.3
김태섭	서울대	15	8	7.65	1240	82.7
이중호	서울대	37	30	1.66	677	18.3
오민환	서울대	19	7	1.48	194	10.2
주윤정	성균관대	19	7	3.65	440	23.2
이태식	원주세브란스	27	6	0.88	175	6.5
전형민	차의과대	13	7	0.91	69	5.3
정상용	차의과대	29	10	1.08	301	10.4
김민영	차의과대	34	18	0.74	240	7.1
심성한	차의과대	40	26	0.82	313	7.8
윤혜진	UNIST	15	17	2.25	649	43.3

그림 84. 연구단의 정량적 연구 역량 요약

3. 연구단의 연구 역량

3-1. 주관연구개발기관

가) 차지욱 교수-책임연구자

AI-뇌영상-오믹스-행동표현형-임상으로 이어지는 다학제적 연구단을 성공적으로 이끌고,
뇌과학과 디지털바이오 및 임상연구를 연계하여 임팩트 있는 연구를 수행할 책임자.

- [전문분야] 슈퍼컴퓨터 기반 대규모 뇌영상 AI 연구. 소아청소년 뇌인지 발달 연구.
유소아 커넥톰 연구.
- [본제안서 관련 연구업적] 최근 5년간 정신과학, 디지털 의학, 신경과학, AI 최상위 저널(IF 상위 10%) 및 우수 CS학회에 13편 주저자 출판: Biological Psychiatry(IF: 12.81), Molecular Psychiatry(IF: 13.437), npj Digital Medicine(IF: 15.357), JAMA Network Open(13.8), Neurips, AAAI, MICCAI.

- [뇌영상 학습을 위한 “거대 뇌 파운데이션 모델” 개발 연구 역량] 2016년부터 현재까지 미에너지부 국가연구소의 슈퍼컴퓨터를 이용한 고성능데이터분석법을 뇌영상에 적용중임. 본 제안서의 해외 협업 연구자인 브룩헤이븐 국가연구소의 Shinjae Yoo 박사팀과 2020년부터 미에너지국 최대 슈퍼컴퓨터 센터(National Energy Research Scientific Computing Center)의 Exascale Science Application Program에 함께 “Extreme Scale Computational Learning for Neuroscience” 라는 주제로 리드중임. 수백 테라바이트의 다모드 뇌영상 데이터(구조, 확산, 기능적 MRI)로 부터 확장적 학습을 통해 시공간적 표상을 학습하는 트랜스포머를 최초로 개발하여 CS 탑 학회 NeurIPS에 교신저자로 출판함²⁰⁹. 현재 이 방법을 이용한 후속 연구를 활발히 진행중임(1편 리뷰중, 1편 준비중).
- 현재 1페타바이트가 넘는 뇌영상 및 유전체 데이터베이스를 구축하였으며, 국내외 GPU 슈퍼컴퓨터의 액세스를 확보하여 더욱 확장적인 거대 AI 모델 연구를 수행하고 있음. 이런 연구 전문성을 인정 받아, 현재 과기부 뇌선도융합과제에서 뇌파운데이션 모델을 적용한 디코딩 연구를 책임연구자로서 수행중임.
- [유소아 뇌발달/영상 연구 역량] 2016-2020년 까지 미국 뉴욕의 컬럼비아의대 소아청소년 정신과에서 신생아 뇌발달 연구를 통해 산모의 우울증, 스트레스, 항우울제 복용, ADHD 등과 뇌 커넥톰의 발달의 관계를 보고하는 임팩트 있는 연구를 수행함(아래 표 참조). 그 중 산모의 항우울제 복용과 신생아 뇌커넥톰 이상 패턴의 관계를 보고한 JAMA Pediatrics 논문은 해외 주요 미디어(예, Times)에 소개되어 미국사회에 큰 관심을 받음.

²⁰⁹ Kim, P., Kwon, J., ..., Cha, J. & Moon, T.(2024). Advances in Neural Information Processing Systems, 36.

유소아 뇌발달/영상 연구 대표 업적(주저자)	
논문	Impact Factor
JAMA Pediatrics	26.1
Neuropsychopharmacology	8.29
Translational Psychiatry	6.8

- [유소아 뇌영상-유전체 연구 역량] 소아청소년의 정상과 질환에서의 뇌인지발달의 유전적 영향을 연구하는 뇌영상-유전체 연구 프로그램을 구축함. 유전체기반 다형질유전점수(Genome-wide Polygenic Scores)와 뇌영상기법을 주로 사용하여 임상, 신경과학, 생물학의 다양한 분야의 탐저널에 주저자로 임팩트 있는 연구 발표함.

유소아 뇌영상-유전체 연구 대표 업적(주저자)	
논문	Impact Factor
JAMA Network Open	13.8
ELIFE	9.21
Biological Psychiatry	12.81
Molecular Psychiatry	13.43
Journal of Child Psychology and Psychiatry	8.98

- [수상] 위와 같이 유소아 뇌영상과 유전체, 확장적 AI를 이용한 연구프로그램을 인정받아 해외의 다양한 연구재단과 학회에서 수상함. NARSAD Young Investigator(신경과학/정신과학 전세계 사립연구재단 젊은연구자상), NIMH K01

Award(70만불; 2016-2020), 2017 한미과학자협회 우수신진연구자,

정신과학회/신경과학회의 젊은 연구자상 수상 Young Investigator Travel Grant(ACNP,

SOBP, ADAA, CINP; 2016-2019).

나) 참여연구진

성명	이종호	소속	서울대학교 공과대학 전기정보공학부
연구역량 (정량적)	“MRI 기반의 뇌영상 기전, 획득, 재구성, 후처리 및 적용 연구를 해 왔으며 특히, 뇌영상 기전, 획득, 재구성 분야에서 국제적으로 연구 성과를 인정 받는 책임자.” 최근 5년간 의료영상 분야의 최상위 저널에서 총 26편의 논문을 발표하였고 주저자로 19편의 논문을 출판: Nature Machine Intelligence(IF: 23.8), IEEE Trans on Medical Imaging(IF: 10.6), NeuroImage(IF: 5.7, 분야 1위)		
연구경력 (정성적)	- Susceptibility기반 Microstructure 뇌영상법(χ-separation)과 인공지능 RF 설계기술(DeepRF)를 세계 최초로 제안함. 또한 Deep Learning기반 영상법(QSMnet과 QuadContrast)을 개발함. χ-separation(2021): 혁신적 Biophysical 모델과 영상재구성방식으로 뇌의 핵심물질(Myelin과 Iron)을 정량적 영상화. NeuroImage 발표(IF = 5.7, 분야 1위), Highlight of ISMRM(제출된 6,780개 초록 중 TOP 5) 선정 및 Summa Cum Laude 수상, ISMRM Plenary 초청발표 등 국제학회 초청 강연 7회. - DeepRF(2021): AI 기반 RF Pulse 설계기술 세계 최초로 제안. Nature Machine Intelligence 발표(IF = 23.8, Nature 자매지, 분야 1위), ISMRM의 Highlight로 소개(전체 초록 중 1% 내외) 및 Summa Cum Laude 수상, MLMIR Workshop at MICCAI에서 Keynote 발표 등 국제학회 초청 강연 3회. - QSMnet&QSMnet+(2018, 2019): Neural Network으로 QSM문제를 세계 최초로 해결, NeuroImage 발표(IF = 5.7, 분야 1위, QSMnet 인용 횟수 = 194회), ISMRM Summa Cum Laude 수상(6,017개 초록 중 13등), ISMRM Educational Session 발표 등 국제학회 초청 강연 6회, 초청 리뷰페이퍼 발표. - QuadContrast(2021): 초고속 다중 뇌 영상 촬영 기술 제안, IEEE TMI 발표(IF = 10.6, 분야 상위 3%), ISMRM Magna Cum Laude 수상, 랩에서 Spin-Off한 스타트업 AIRS MEDICAL 기반 기술. - 연구 성과는 국내외 연구기관 107곳(미국 25, 한국 21, 독일 11, 일본 15, 캐나다 8곳 등 총 16개국)에 직접 배포되었고 또한 연구팀 Github 사이트를		

	통해 1,454회 다운로드(2020년 8월 이후) 되어 후속 연구 및 임상에 활용 중. ● 최근 5년간 국내특허출원(11건), 국제특허출원(7건), 국내특허등록(6건), 국제특허등록(4건).
연구분야 및 역할	● MRI 기반의 뇌영상 기전, 획득, 재구성, 후처리 및 적용 연구
수상	● MRI 분야의 2023년 대한자기공명영상학회 GOLD MEDAL 수상 및 2022년 국가연구개발 우수성과 100선에 선정, ISMRM 학회 Highlight 3회, Summa Cum Laude(상위 5%) 12회, Magna Cum Laude(15%) 12회 수상.

성명	김태섭	소속	서울대학교 데이터사이언스대학원
주요경력	● (2022.03~현재) 서울대학교 데이터사이언스대학원 조교수 ● (2020.09~2022.02) 아마존 웹서비스(AWS) 연구과학자 ● (2018.10~2020.05) 카카오 브레인 연구원 ● (2014.02~2015.04) 인텔(Intel) 코리아 연구원 ● (2011.10~2014.02) 엘지전자 연구원 ● 딥러닝 기반의 인공지능 관련 학습 알고리즘 및 응용 연구를 해 왔으며, 특히 현실 세계에서 발생할 수 있는 인공지능 기술의 여러 한계점을 극복하는 알고리즘에 대한 연구를 진행함.		
연구 경력	정성적	● 소량의 데이터를 기반으로 하는 학습 방법론으로 메타러닝 알고리즘 연구 진행(NeurIPS 2018, CVPR 2019, CIKM2023, CVPR2023) ● 딥러닝 기반의 인공지능 관련 방법론을 다양한 응용 분야에 적용하는 연구 진행(음성처리, 자연어처리, 영상인식) ● 파운데이션 모델을 기반으로 새로운 태스크를 효율적으로 학습하는 전이학습 방법론 연구 진행(오디오/자연어/이미지 데이터)	
	정량적	● Google Scholar 기준 논문 총 피인용수 3790건 이상(2024 5월 기준) ● CVPR, ICCV, ICLR, NeurIPS, AAAI 등 세계 최고 기계학습/인공지능 학술대회에 1저자 및 교신저자로 다수 출판하였음. ● 20223 ● 2023년 K-데이터사이언스 컨퍼런스 연구분야 창의상 수상	
연구분야		● 딥러닝, 전이학습, 표현학습	

과제에서 역할	전이학습 기반의 연합학습을 통한 데이터보호 및 학습 효과증진 방법론 연구
---------	--

성명		오민환	소속	서울대학교 데이터사이언스대학원
주요경력		(2020.09~현재) 서울대학교 데이터사이언스대학원 조교수 - 효율적 탐색(exploration) 알고리즘 및 샘플 효율적인 통계적 기계학습 방법론에 대한 연구를 진행함. 불확실성의 수량화를 바탕으로 학습의 효율성을 보장하는 이론적 연구 및 실용적인 성능을 지닌 알고리즘에 대한 연구를 진행함.		
연구 경력	정성적	- 고차원 데이터를 활용한 Lasso 기반의 실시간 학습 및 의사결정 알고리즘 개발(ICML 2021).), 최적 성능 수렴에 대한 이론적 증명 통해 샘플 효율적 학습 이론 보장 및 실험 검증. INFORMS 응용확률학회 최우수 학생논문상 Finalist 선정. - 불확실성 수량화를 통해 upper-confidence bound를 계산하여 행동하는 neural network기반의 조합적 contextual bandit 알고리즘 개발(ICML 2023), 최적 성능 수렴에 대한 이론적 증명 및 실험 검증. - 불확실성 수량화를 활용하여 conservatism원리를 적용한 오프라인(offline) 강화학습 알고리즘 개발(ICML 2023) - Linear 마르코프 의사결정 과정(MDP)이 지닌 표현적 한계를 이론적으로 증명한 연구 결과를 제시함(ICLR 2024). 강화학습 이론연구에서 널리 사용되었던 Linear MDP가 전체 상태공간에 비례하는 복잡도를 지닐 수 있음을 보여줌. 이론적 발견에 대한 실험 결과도 제공함.		
	정량적	- ICML 4편, NeurIPS 2편, ICLR 1편, AAAI 6편, AISTATS 1편 등 세계 최고 기계학습/인공지능 학술대회에 1저자 및 교신저자로 다수 출판하였음. - 학습 이론(Learning Theory) 분야의 세계 최고 학술대회인 COLT에 2024년 합격되어 논문 출판 예정 2023년 K-데이터사이언스 컨퍼런스 연구분야 과학기술정보통신부 장관상 수상 - 한국인공지능학회 2023년 하계학술대회KT 최우수논문상 수상 - 한국인공지능학회 2023년 하계학술대회 우수논문상 수상 - 한국인공지능학회 2022년 하계학술대회 우수논문상 수상		
연구분야		통계적 기계학습, 강화학습, 컨텍추얼 밴딧		

과제에서 역할		● 샘플 효율적 학습과 불확실성 정량화 방법론 연구	
성명		주윤정	소속 성균관대학교 삼성융합의과학원 디지털헬스학과
주요경력		“개인의 멀티모달(multimodal) 생체오믹스 데이터 기반 질병예측 ML/AI알고리즘 개발 전문가” (2023.08 ~ 현재) 성균관대학교 삼성융합의과학원 디지털헬스학과 조교수 (2023.08 - 현재) 삼성서울병원 미래의학연구원 유전체연구소 조교수 (2024.03 - 현재) 서울대학교 사회과학연구원 객원연구원 (2021.01 - 2023.08) 고려대학교 데이터과학원 연구교수 (2021.11 - 2023.10) 서울대학교 AI연구원 객원연구원 (2020.04 - 2020.12) 서울대학교 사회과학대학 심리학과 박사후연구원 (2014.09 - 2020.03) 미국 노스웨스턴 의과대학 학생연구원(박사과정)	
연구 경력	정성적	● 대표적인 해외 대형 DNA-linked multimodal biobank 에 속하는 eMERGE(미국, 성인 15만명), ABCD(미국, 아동 1만명), Wisconsin Longitudinal Study(미국, 중장년층 2만명) 및 UKBiobank(영국, 50만명) 등에 기반한 다인종 데이터 기반 질병역학 연구 수행 경험 ● 자살성향, 주요우울장애, 양극성장애 등의 정신질환부터 인지기능의 감퇴(cognitive decline)까지 다양한 정신-인지-뇌질환 대상 뇌영상-오믹스 기반 고성능 질병예측 알고리즘의 구축 경험 ● 인종 특이적인 생물학적 배경을 고려한 다인종(multi-ancestry) 오믹스 데이터 기반 차세대 다중유전자점수(polygenic risk score) 제조 노하우 보유 ● 멀티스케일 임상-뇌영상-인지-유전체 데이터 구축 및 분석 역량 보유	
	정량적	● 박사 취득(2020) 후 지난 4년 간 <JAMA Network Open>, <eLife>, <JCEM> 등 JCR 상위 10% 우수저널 포함한 SCIE급 주저자 논문 9건 게재 ● 해외 협업연구자들과 <Nature> 본지 2편, <Nature Genetics> 등 공저자 논문 발간 및 SCI 급 논문 21여편 출판	
연구분야		● 의료/유전체/라이프로그 빅데이터 기반 개인별 건강결과와 질병의 예측, 예방 및 처방적분석 ● 인공지능(AI) 기술의 적용을 통한 멀티오믹스 기반의 정밀의료	
과제에서 역할		● 유전체, 전사체, 대사체, 미생물체 등 멀티오믹스 기반 발달장애의 정량화 마커 구축	

		● 거대언어모델(LLM) 기법을 도입한 유전체 및 오믹스 데이터 특이 AI모델 구축을 담당함		
성명		이태식	소속	연세대원주의과대학
주요경력		컴퓨터공학 박사과정동안 질병관련 유전자 선별/제시 연구를 주로 하였으며, 가정의학과 전문의동안 임상데이터 기반의 만성질환 예측모델을 구축함. 가정의학과 전문의  다양하고 있는 의료관련 이슈를 파악하기 용이 만성질환/소아질환 등을 전반적으로 파악할 수 있음 생물정보학 전문가  인공지능과 기초의학의 융합에서 소용 가능 컴퓨터공학 박사  통계/기계학습/딥러닝 모델 대부분을 직접 훈련/구축 가능		
연구 경력	정성적	● 퇴행성뇌질환/만성질환 관련 유전자바이오마커 발굴 논문 4편 ● 만성질환 예측모델 6개 구축		
	정량적	● 뇌질환 관련 유전자 바이오마커를 주로 연구를 하였음. ● 공공유전자데이터베이스에서 데이터를 수집하고 전처리하는 연구형태를 주로 하였음. ● 최근 인공지능 기반의 바이오마커 선별/전임상연구 기반의 검증 연구를 주로 하고 있음.		
연구분야		● 유전자 인공지능		
과제에서 역할		● 자폐스펙트럼 관련 유전자 바이오마커 제시 ● 공공 유전자데이터 수집 및 전처리 ● 자폐 유전자 정보에 대한 메타데이터 구축		

3-2. 공동연구개발기관 1 -차병원

성명	김민영	소속	차의과학대학교 분당차병원
----	-----	----	---------------

주요경력		대한민국 의학한림원 정회원(현) 대한의학회 정책이사 혁신의료기술위원회 위원장(현) 대한소아재활발달의학회 이사장(역임) 보건복지부 신의료평가위원회 심사위원(현) Scientific Committee member, International Alliance of Academies of Childhood Disability(현) 한국전자통신연구원 가상현실의료연구팀 초빙연구원(역임) 차미래의학연구원 디지털혁신의료센터장(현) 차의과학대학교 분당차병원 재활의학과 교수(현) 재생의료진흥재단 첨단재생의료임상연구지원사업단 부단장(현)
연구 경력	정성적	● 뇌기능 발달 이상을 보이는 장애 아동의 재활을 위한 연구활동을 지속적으로 수행하여 왔음. - 아동에서 측정이 어려운 행동, 전반적 발달 상태 등의 평가 신뢰도 확립, 발달 지연 관련 여러 원인 유전자 발견, 발달 중인 뇌 MRI 활용한 데이터정량 ● 2024년 “제52회 보건의날 국무총리 표창 수상” 뇌성마비 아동의 제대혈 세포치료 효능을 증대시키기 위해 적혈구생성인자 복합치료를 시행해 임상뿐 아니라 동물 실험으로 복합치료의 치료적 효능이 향상된 것을 확인하는 등 난치성 질환 첨단재생의료 임상연구 활동으로 국민보건 향상에 기여함을 인정받아 수상함 ● 확장현실(XR) 디지털치료제를 사용한 뇌 재활, 경두개자극 치료, 세포치료 등 다양한 치료적 접근을 통한 뇌기능 회복을 위하여 지속적으로 연구하여 왔음. ● 현재 과기정통부 연구과제로 한국전자통신연구원과 함께 “의료수준 전신 메디컬트윈 핵심기술 개발” 과제 진행 중임. ● ICT기술을 활용한 치료법 특허 “인지능력 훈련 장치 및 방법(출원번호: 10-2018-0151336)(2021. 5 등록)”는 최근(주)플레이투큐어에 기술이전함. ● 뇌성마비의 마우스 저산소성 뇌손상 모델을 사용하여 치료 목적의 다양한 중개연구
	정량적	● SCI급 논문 60건, KCI급 논문 25건, 특허 14건, 대규모 국제학회 강의 9건 ● 정부 과제수행 책임자로서 6건, 민간연구비 수주 19건, 저역서 12건, 기술이전 2건 ● Research Interest Score: 698.0, Citations: 1,207, h-index: 19(ResearchGate)

연구분야		● 발달지연과 뇌성마비의 치료적 예후 예측 ● 뇌졸중 등 뇌손상 환자에서 뇌 MRI와 뇌파 신호 변화 측정과 임상적 양상의 연관성 ● 뇌질환에서 세포치료의 효과와 세포치료 방법의 다양성에 의한 차이 비교 ● 경두개반복적뇌자기자극 치료의 뇌질환에서 나타나는 치료적 효과와 기전 ● 아동과 성인 뇌질환 환자의 행동과 심리 기능 측정		
과제에서 역할		● 영유아의 주기적 발달 진행 상황 파악 ● 고위험, 혹은 비정상 발달 아동의 이학적 평가, 뇌영상, 뇌파 측정 등 ● 아동 멀티모달 평가로써 예후를 예측할 수 있는 주요인의 제시, 결과 해석 ● 의료영상, 오믹스 등의 결과와 의료데이터의 임상적 의미 종합과 최종적 발달장애 결과와의 연관성 파악		
성명		심성한	소속	차의과학대학교 의생명과학과
주요경력		한양대학교 의학박사(의학유전학) American Board of Medical Genetics certified clinical cytogeneticist/clinical molecular geneticist 강남차병원 유전학 연구실장(역임) 차의과학대학교 의생명과학과 교수(현) 차바이오텍 유전체사업본부 센터장(현)		
연구 경력	정성적	● 20여 년간 유전체 분석을 통해 희귀질환, 난임질환의 원인을 규명하는 연구를 수행하였음. ● 모체 혈액내 태아 DNA에 대한 유전체분석을 통해서 비침습적 방법으로 태아의 유전체 이상을 예측하고 진단하는 연구와 임상검사를 시행하고 있음. 또한 난임시술과정에서 배아 배양과정 중 배양액 내에 용출된 세포유리 DNA(cell-free DNA)를 이용 배아의 유전체 이상을 예측하는 연구를 수행하고 있음. ● 세포 조작 또는 배양과정에서 유전체 및 후성유전체 변이를 분석하여, 세포의 유전학적 안전성을 알아보는 연구를 수행하였음.		
	정량적	● 최근 5년간 SCI(E) 저널23편, 국내논문 1편 발표 ● 최근 5년간 연구과제 3건 수행		
연구분야		● 발달지연 및 희귀질환 가계에서 유전체 변이 규명 ● 난임의 유전학적 원인 규명 및 비침습적 착상전 유전체 검사기법 개발 ● 세포 조작과정에서의 유전체 변이 연구		

연구팀 내 역할		- 발달장애 아동 및 가계를 대상으로, SNP, CNV, rare variants를 발굴하고 관련 DB구축에 기여 - 환자 말초혈액에서 RNAseq 데이터 생성 및 발현분석		
성명		윤혜진	소속	울산과학기술원
주요경력		Harvard Medical School Post-doctoral fellowship(역임) 울산과학기술원 생명과학과 조교수(현)		
연구 경력	정성적	- 미토콘드리아의 산화 능력이 대사질환에 미치는 영향을 PHD 단백질을 연구하여 Cell Metabolism(2020) 및 Molecular Cell(2016)에 출판하였음. - 따라서 PHD 단백질의 조절과 제어에 대한 분자생물학적인 이해가 높으며, 이에 따른 질환과 생리적 연관성에 대한 적용을 할 수 있음. 따라서 본 연구자는 해당 연구주제에 대해서 국제적인 경쟁력을 가진 전문가라고 판단됨. - PHD의 생화학적 조절 및 PHD가 세포 및 생리에 미치는 영향에 대한 연구주제로 국가 R&D 사업 연구책임 2건(과기부) 수행. - 또한, 본 연구팀은 대사체 정량 분석 기술을 확립함. 장내 미생물에서 대사체로 정량적/정성적 평가하는 기술은 국내에서 선도그룹이 없으므로, 유효물질의 평가를 더욱 고도화 할 수 있을 것이라 기대됨.		
	정량적	본 연구자는 다년간 세포의 대사 연구를 진행하였고, 이를 바탕으로 한 PHD 단백질이 수산화 활성 능력을 통해 세포에 미치는 다양한 대사 활성 연구를 진행 중임. 그 결과, 주저자로서 Cell Metabolism(2020) 등에 7편의 논문을 주저자로서 출판하였으며, 대사체 분석과 생화학적 접근방식을 통한 활발한 공동연구를 통해 Science(2017)와 Cell(2020) 등에 13편의 연구 결과를 국외 top 저널에 논문들을 게재한 경험이 있음.		
연구분야		- 대사체를 통한 암에서의 바이오마커와 표적 치료제 개발 - 대사질환을 치료할 수 있는 기전연구 - 근육생리학 및 근육 대사질환 연구		
연구팀 내 역할		본 연구팀에 의한 장내 미생물 유도 대사체에 의한 뇌 발달을 밝히는 기전 및 표적 대사체 플랫폼은 혁신적이며, 역사적으로 지속적으로 시도되어왔던 장내 미생물이 뇌 발달에 미치는 기전연구 분야에 국제 경쟁력 우위를 점하는 계기가		

		될 전망이다.		
성명		정상용	소속	차의과학대학교 의전원/차종합연구원
주요경력		독일의 막스플랑크연구소 박사후 연구원 및 직원(역임) 싱가포르 국립대학교 의과대학 조교수(역임) 싱가포르 국가연구소 A*STAR 그룹장(역임) 싱가포르 국립대학교 겸임교수(현) 싱가포르 National Neuroscience Institute visiting scientist(현) 차의과학대학교 의학전문대학원 교수(현) 차종합연구원 동물실험센터장(현)		
연구 경력	정성적	- 장내미생물이 마우스의 두뇌 발달에 미치는 영향을 MR image를 이용하여 규명하고 [Gut microbes], 장내미생물의 대사체중 두뇌 발달에 필수적인 대사체를 발굴 중임. - 임신중 당뇨에 걸린 암컷 마우스 모델을 제작하여 offspring의 두뇌 발달에 대한 연구를 진행 중 장내세균의 차이에 의한 것을 규명하여 논문 투고 준비중임. - 전시냅스(Presynapse)의 축삭돌기 말단(axon terminal)에서 시냅스 소포(vesicle)를 통하여 신경전달물질의 분비를 미세한 전기 생리학 및 광학을 이용하여 측정함.		
	정량적	- 본 연구과제의 참여연구자인 정상용 교수는 전기 생리학을 전공하여 시냅스의 기능 및 구조에 대한 연구를 지속적으로 하고 있으며 [PNAS, 2008, 2010, 2015, EMBO J., 2015.], 미세아교세포를 공배양한 대뇌 오가노이드에서 미세아교세포의 새로운 기능을 규명하여 2023년 Nature에 공저자로 발표함[Nature, 2023]. - 마우스의 시상하부의 섭식을 유도하는 somatostatin 신경세포의 복잡한 신경회로를 규명하는 등 신경세포의 전기 생리학적 특성 및 신경 회로의 특성을 규명. [Nature Neuroscience, 2021]. - 전자 현미경 및 고해상도 현미경을 이용하여 전시냅스(presynapse)의 축삭돌기 말단(axon terminal)에서 시냅스 소포(vesicle)를 관측하여 다수의 논문을 발표함.		

연구분야		- 장내미생물이 마우스의 두뇌 발달에 미치는 영향 - 지질 나노 입자에 대한 연구 - 뇌신경 과학 및 시냅스 기능과 구조에 대한 연구		
연구팀 내 역할		발달장애 마우스 모델, 무균 마우스, 발달장애 아동의 분변을 무균 마우스에 이식, 동물 행동 평가 및 발굴된 대사체의 유효성 평가 등을 수행할 예정임.		
성명		전형민	소속	차의과학대학교 분당차병원
주요경력		차의과학대학교 의학전문대학원 연구교수(현) 분당차병원 차미래의학연구원 디지털치료연구팀 팀장(현) 한국정밀공학회 바이오헬스 분과이사(현) 대한생체역학회 학술이사(현)		
연구 경력	정성적	10년 가까이 의공학을 전공하며, 재활공학 연구를 진행하였음. 생체신호 처리와 디지털 바이오마커 획득 연구를 수행함. - 대표 수행 국책 연구과제로 “건강한 미래를 결정하는 소아 의료 난제 극복 디지털 의료기술개발 플랫폼 구축”이 있음. - 데이터 플랫폼 구축, 의료기기 실증 플랫폼 구축에 주요 역할을 하고 있으며, 디지털치료기기 인허가 관련 전문 역량을 보유하고 있음. - 한국연구자등록정보(KRI) 연구자 통계 논문지표 기준 의공학분야 전 연령 기준 상위 25%, 30대 기준 상위 25% 임.		
	정량적	- SCI 논문 23건, SCOPUS 논문 3건, 학술대회 62건, 수상 10건, 특허 1건, 민관 과제수행 13건, 기술이전 1건 - Research Interest Score: 119.2, Citations: 196, h-index: 7(ResearchGate)		
연구분야		- 인공지능을 활용한 재활공학 연구 - 뇌신경계 질환 디지털치료기기 개발 - 동작분석을 통한 역동역학적 해석과 생체신호 해석 연구 - 생활습관 모니터링과 증상 치료를 위한 웨어러블(인솔, 글러브, 방석) 기기 개발		
연구팀 내 역할		- 데이터 플랫폼 구축 관련 병원측 자문과 카운터 파트 담당 - 병원 실증시 병원내 아동 리빙랩 실증 플랫폼 담당 - 개발 결과물 인허가 로드맵 제시 - 행동 분석에 대한 공동연구 수행		

성명		조은영	소속	차의과학대학교 분당차병원 재활의학과
주요경력		신촌세브란스 재활병원 임상심리사(역임) 용인세브란스병원 임상심리전문가/심리실장(전) 덕성여자대학교 심리학과 겸임교수(현) 차의과학대학교 임상상담심리대학원 겸임교수(현) 한국심리학회 치매정책지원 위원(현) 한국심리학회 심리검사 심의위원(현)		
연구 경력	정성적	- 대학병원 재활의학과 아동심리치료 프로그램 및 진단 평가 도구 개발을 지속적으로 수행하여 왔음. - 아동에서 고기능 자폐치료프로그램 개발, 심리 평가 도구 개발 및 확장 - 발달장애 아동에게 적용할 수 있는 디지털 치료제 개발 연구에 참여하고 있음. - 발달지연, 뇌손상, 자폐스펙트럼 장애 아동 대상 평가 및 치료경험을 토대로 한 디지털 치료 프로그램 개발 - 발달장애 조기 진단 프로토콜 연구에 참여 중임. - 인공지능 기반 시지각 평가도구 및 자폐스펙트럼 조기 진단 프로토콜 개발에 대한 아동 평가 및 심리치료 경험 제공		
	정량적	강의활동 8건, 수상이력 2건, KCI 논문 2건, SCI급 논문 1건, 외부 자문 및 학회 활동 4건		
연구분야		- 아동과 성인 뇌질환 환자의 행동과 심리 기능 측정 - 아동 발달장애 환자의 심리 기능 평가 도구 개발 - 심리 기능 검사의 임상적 유효성 검증 - 발달장애 조기 선별 프로토콜 개발		
연구팀 내 역할		- 발달장애 아동의 심리 기능 변화에 대한 주기적 발달 상황 분석 - 심리 기능 기반 발달장애 아동의 질환별 행동 표현 예측 및 요인 제시 - 아동 심리 중재치료 적용에 의한 심리적 회복 패턴의 바이오마커 기반 분석 가능		
성명		김희구	소속	차의과학대학교 분당차병원 재활의학과
주요경력		삼성서울병원 재활의학과 연구원(역임) 차미래의학연구원 디지털치료연구팀 선임연구원(현)		
연구 경력	정성적	뇌질환 환자 대상 치료적 중재에 의한 회복 패턴에 대한 뇌영상 연구를 지속해 오고 있음. - 상지 및 하지 운동 기능, 인지 기능 등과 관련된 뇌기능 회복 패턴을 뇌 MRI, fNIRS를 활용한 brain mapping을 통해 분석함.		

		● 뇌자극 simulation을 통해 최적 뇌자극 중재 프로토콜 개발 - 뇌 MRI를 통한 뇌 해부학적 구조의 3D imaging을 통해 뇌자극 치료의 피질 상 뇌자극 최적 위치 타겟팅 ● 대규모 환자 데이터를 통한 뇌졸중 환자의 기능 회복 예후 예측 연구 - 임상연구 경험 바탕으로 대규모 전/후향적 임상데이터 수집 및 예측분석을 통한 객관적 치료 목표 제시
	정량적	● 국책과제 참여 9건, SCI급 논문 13건, KCI 논문 1건, 특허 1건
연구분야		● fNIRS를 활용한 과제 수행 중 뇌활성 패턴 및 연결성 분석 ● 뇌질환 환자에서 확산텐서영상을 활용한 신경로 및 기능 회복의 임상적 의미 분석 ● 시계열 임상평가 결과 분석을 통한 뇌질환 환자의 회복 예후 예측
연구팀 내 역할		● 전/후향 대규모 데이터 수집 파이프라인 구축 ● 확산텐서영상을 활용한 발달장애 아동의 신경로 회복에 따른 임상적 함의 제시 ● fNIRS를 활용한 뇌활성 및 연결성 패턴에 따른 바이오마커의 효과성 입증

3-3. 공동연구개발기관 2 - 루먼랩

성명	이보희	소속	루먼랩 주식회사 선행기술팀
연구분야	● 발달 평가, 디지털 치료제 콘텐츠 개발 ● 스트레스 생체지표 표준 DB 구축 ● SW 및 하드웨어 결합 디지털 플랫폼 구축 및 프로토타입 개발 ● 뇌파측정시스템 KC 인증 진행 중 ● 아동 스트레스 디지털치료제 탐색임상시험 진행		
연구팀 내 역할	● 데이터 기반 발달장애 진단 평가 플랫폼 구축		

성명	이성우	소속	루먼랩 주식회사 선행기술팀
연구분야	● 저출산 관련 분만 중 실시간 알람시스템의 임상 사용성 평가 ● 합병증 발생 예측 모델을 이용한 알람 시스템의 현장 시범 적용 분석 ● 실시간 알람시스템 UI/UX 개발 ● TTA 평가를 통한 알람시스템 검증 및 탐색임상시험 신청 설계		
연구팀 내 역할	● 기관 보유 데이터를 활용한 발달장애 분야 개발 플랫폼 구축		

성명	이인선	소속	루먼랩 주식회사 선행기술팀
연구분야	• 아동 발달장애 관련 연구 WBS 진도점검		
연구팀 내 역할	• 기관에서 기존에 진행한 연구 과제 WBS를 바탕으로 발달장애 분야 연구 진도 팔로우업 및 수행 점검		

성명	손창일	소속	루먼랩 주식회사 디자인팀
연구분야	• 아동 발달평가 및 디지털치료제 UI/UX 디자인		
연구팀 내 역할	• 행동 데이터 수집을 위한 소프트웨어 UI/UX 디자인 기획		

4. 연구팀 주요선행연구

- 구조 및 확산 뇌영상을 사용한 ASD와 GDD 아동 분류 멀티모달 딥러닝 모델 개발(논문 준비중)
 - 차지욱 교수 연구팀에서 분당차병원에 내원한 자폐 스펙트럼 장애 아동 81명과 전반적 발달 지연으로 진단된 281 명의 아동을 대상으로 구조 및 확산 뇌영상을 사용한 3차원 멀티모달 딥러닝 모델을 학습시킨 연구를 진행함. 본 연구에서는 3차원 뇌영상 데이터를 그대로 사용하여 공간 정보를 보존한 채로 딥러닝 모델의 이점을 최대한 활용할 수 있게끔 하였음. 또한 성별이나 나이와 같은 교란 변수가 타겟 질환을 예측하는 성능에 영향을 미치지 않게끔 훈련-검증-실험 데이터셋 구성에 다양한 방법을 도입함(그림 85).

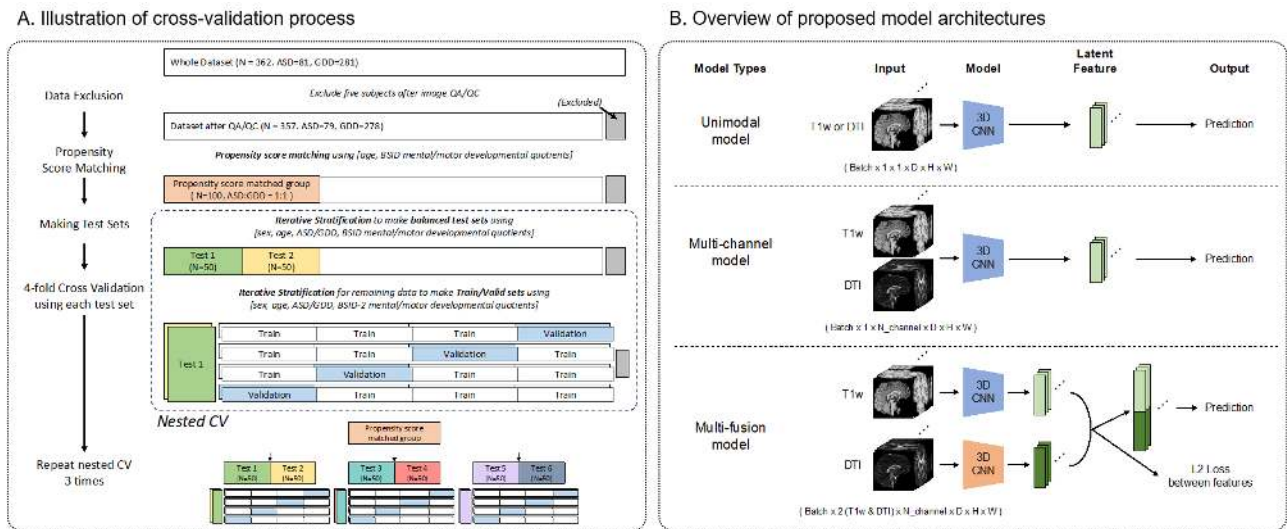


그림 85. ASD/GDD 분류 멀티모달 딥러닝 모델의 교란 변수를 통제한 훈련-검증 데이터셋 구성 및

멀티모달 모델 구조

- 딥러닝 모델 학습 결과, 확산 뇌영상의 네 가지 measure를 모두 사용한 멀티채널 딥러닝 모델이 평균 실험 AUROC 약 0.65로 괜찮은 수준의 예측 성능을 보임. 또한, 확산 뇌영상의 FA와 MD에서 어느 뇌백질 다발이 모델의

Integrated Gradients with Noise Tunnel을 활용하여 확인함(그림 86).





그림 86. ASD/GDD 분류 멀티모달 딥러닝 모델의 평균 예측 성능 및 뇌백질 바이오마커

- 이 연구를 통해 멀티모달 뇌영상을 입력으로 하는 딥러닝 모델을 학습시키면 전반 발달 지연과 자폐 스펙트럼 장애를 갖는 아동을 분류하는 것이 가능하며, 특히 360명 정도의 크기가 되는 데이터셋으로도 모델 학습이 된다는 것을 보임. 또한 바이오마커 관점에서, 기존의 전반 발달 지연이나 자폐 스펙트럼 장애 집단에서 차이가 난다고 밝혀진 뇌백질 다발들이 일관적으로 비슷하게 나타나는 것을 확인함. 따라서 본 과제에서 데이터를 다양하게 사용하고 샘플

숫자도 늘리면 보다 정확한 예측 및 바이오마커의 정교한 발굴이 가능해질 것으로 생각됨.

- 구조 뇌영상을 통한 ASD 아동 진단 바이오마커 발굴(논문 준비중)

- 분당차병원 연구팀에서 증세가 뚜렷한 72명의 자폐장애 아동(Autism)과 자폐증세가 동반되지 않은 246명의 전반적 발달 지연 아동(GDD)의 뇌MRI 3D volumetry 분석을 시행한 바 있음. 뇌구역을 68개 region of interest(ROI)로 나누어 둘을 구분할 수 있는 가장 최적화된 딥러닝 모델을 얻었음. 거의 대부분의 전형적인 Autism 아동들은 지적발달이 매우 저조하게 평가되고 어린 나이에 장기적 예측이 어려움에 따라, 두 경우에서 시간의 경과에 따라 차이가 심화되는 자폐를 예측할 필요에 따라 시행한 연구였음.




그림 87. MRI를 활용한 AI기반 ASD 진단 바이오마커 도출 개요

- 이 모델을 통해 차병원의 데이터를 분석해 본 결과 Autism 장애 아동들에서 ID 아동들에 비해 right pericalcarine, right pars opercularis area의 cortical thickness가 얇고 left supramarginal area의 cortical thickness가 두꺼움을 관찰함.
- 또한 Autism장애에서는 GDD 아동들에 비해 right middle temporal area의

surface area가 크고, left pericalcarine과 left supramarginal area의 surface area가 더 작았음. 마지막으로 Autism 장애에서는 left pericalcarine area에서 gray matter volume이 감소한 소견을 보임.




그림 88. GDD ASD 뇌구조 영상 주요지표 비교

- 이를 통해 뇌자기공명영상 검사 분석으로서 많은 경우 전반 발달 지연을 동반하고 있어 초기에 구분이 어려우나 장기적으로 비정상 행동특성이 뚜렷해지는 Autism 장애를 조기 선별할 수 있는 바이오마커로써의 가능성을 볼 수 있었음.
- 공공데이터를 활용한 뇌성마비 아동 대상 진단 및 치료를 위한 바이오마커 발굴 플랫폼 구축(논문 준비중)
 - 본 연구팀에서는 Gene Expression Omnibus(GEO) 공공데이터를 활용하여 뇌성마비 아동을 예측 및 치료할 수 있는 타겟 선정을 하기 위한 플랫폼을 구축하였음.
 - 뇌성마비 아동의 혈장에서 분석한 사람 대상 유전자 데이터와 뇌성마비

동물모델의 뇌조직 및 뇌조직 내 세포를 분리하여 분석한 설치류 대상 유전자 데이터를 선별하였음.

- 공공데이터의 유전자들은 전사인자인 Transcription factor(TF), 유전자의 SNP와 같은 유전형과 발현양의 정보를 활용하여 특정 위치의 유전형이 특정 유전자의 발현 수준에 영향을 미치는지 분석하는 Expression quantitative trait loci(eQTL), 단백질과 단백질의 상호작용에 대한 분석을 통해 유전자와 상호작용을 분석하는 HUB, 대조군과 환자군의 전장 유전정보를 비교하여 연관된 유전적 위치를 탐색하는 Genome Wide Association Study(GWAS) 분석을 통하여 각각의 데이터를 비교 분석하였음. 추후 METAL 시스템을 통한 메타 분석을 진행하여 유전자를 선별함.




그림 89. 동물조직 공공데이터를 활용한 메타분석 결과

- 선별된 유전자들의 기능 연구를 위해 Gene ontology(GO) 분석을 진행하여 세포기작(biological process), 분자기능(molecular functions), 세포 내외 위치(cellular component)를 구조화하였음.

	# of pathway	# of hits		# of pathway	# of hits
(GO:0007155) cell adhesion	1524	45	(GO:0051247) positive regulation of protein metabolic process	1469	38
(GO:0007272) ensheathment of neurons	146	11	(GO:0051347) positive regulation of transferase activity	526	20
(GO:0010001) glial cell differentiation	235	17	(GO:0051968) positive regulation of synaptic transmission, glutamatergic	35	5
(GO:0022008) neurogenesis	1667	43	(GO:0060429) epithelium development	1227	37
(GO:0030030) cell projection organization	1576	41	(GO:0098698) postsynaptic specialization assembly	28	6
(GO:0031394) positive regulation of prostaglandin biosynthetic process	7	3	(GO:0099058) postsynapse assembly	40	6
(GO:0033674) positive regulation of kinase activity	432	17	(GO:0099084) postsynaptic specialization assembly	44	6
(GO:0035249) synaptic transmission, glutamatergic	112	9	(GO:0050839) cell adhesion molecule binding	552	21
(GO:0042063) gliogenesis	320	19	(GO:0051094) positive regulation of developmental process	1352	37
(GO:0044093) positive regulation of molecular function	1513	39			
(GO:0048514) blood vessel morphogenesis	702	23			
(GO:0050790) regulation of catalytic activity	1855	46			

그림 90. GO 분석을 통한 관련 기전 선별

- 최종적으로 아동 뇌성마비 관련 진단 및 치료의 타겟 가능한 바이오마커들을 선별하였음. 선별된 바이오마커들은 직접 동물모델의 조직 및 혈장 내에서 재검증하고, 환자 대상 혈장 샘플을 활용하여 두 번의 재검증 단계를 거쳐 최종 바이오마커를 도출하고자 함.
- 본 연구팀은 아동 뇌성마비 동물모델인 hypoxic-ischemic encephalopathy 모델로 연구를 계속해서 진행한 바 있으며, 공공데이터로 선별한 바이오마커를 직접 아동 동물모델의 뇌조직에서 재검증을 진행함. 공공데이터의 분석방법과 동일하게 동물모델을 제작 후, 정상 모델과의 비교분석을 진행함.
- 추가적으로 동물모델의 뇌조직 및 혈장과 환자 대상 혈장 샘플을 활용하여 유전자의 발현 양상을 qRT-PCR을 통해 검증함으로써 명확한 아동 뇌성마비를 구분짓는 바이오마커를 도출하고 있음.
- 지방산 축적을 억제하고, 지방산을 산화시키는 시스템 개발(Yoon, H. et al., 2020)
 - 장내 미생물은 단쇄지방산을 생성하는 것으로 잘 알려져 있음. 따라서 지방산을 산화시켜 축적을 막는 시스템은 다양한 중의 대사 및 대사 증후군 치료에서 매우 중요함. Proline hydroxylase domain protein(PHD)3는 지방산

산화 억제 단백질인 acetyl coA carboxylase(ACC)2의 수산화를 통해 지방산 산화를 항상 억제하는 역할을 함.

- 특히, 에너지 필요조건인 포도당 부족 혹은 ATP 부족 조건 하에서 PHD3와 ACC2의 결합이 저해되며, AMPK에 의한 인산화에 의해 미토콘드리아 지방산 산화가 촉진되어 부족한 에너지를 생성하는 중요한 지방 항상성 단백질임. 따라서 본 선행연구를 통해 분자생물학적으로 유전자 조절을 통해 대사경로를 조절하는 시스템을 설립함(그림 91).




그림 91. 수산화 효소인 PHD3를 이용한 지방산 산화 조절기전.(A) PHD3는 ACC2를 수산화함(B) PHD3 결손시 지방산 산화(FAO:fatty acid oxidation)이 극적으로 증가됨(C) 세포에서 포도당에 의해 PHD3 단백질 활성이 촉진됨을 면역침강법으로 확인(D) 포도당 유무에 따른 PHD3 단백질 활성 변화 및 지방산 산화의 조절 모식도.

● 대사체 프로파일링 기법 구축

- 본 공동연구팀은 liquid chromatography 기반 mass spectrometry로 대사체를 확인 및 분석하는 시스템이 구축되어 있음.
- 세포 및 조직에서 유기용매로 추출한 대사체를 분리 및 동정하여 대사체의 정량 및 정성 분석이 가능함. ~600개의 시그마에서 제공하는 MSMLS 라이브러리를 통해 QE-Orbitrap으로 글로벌 대사체 프로파일링이 가능하며,

특히 분리 및 분석이 어려운 지방산 대사체들(acryl carnitine; C10-C20 carnittine)에 대한 연구로 2020년 Cell Metabolism에 결과를 게재 후 지속적으로 대사체 오믹스를 수행함.

- 특히 PHD3 손실에 의해 지방산 산화가 촉진되면서 long chain fatty acids들에 대한 증감을 대사체 오믹스를 통해 규명함[PMID:32663458](그림 92).




그림 92. 글로벌 대사체 프로파일링 구축.(A) Metabolic profiling workflow.(B) 대조군 및 PHD3 결손 쥐에서 지방산 산화 촉진을 위한 16시간 금식(fasted) 및 정상상태(fed)의 대사체 비교분석 heat map(C) 대조군 및 PHD3 결손 쥐 대퇴사두근에서의 지방산 산화 대사체들의 정량분석.

- 뇌 발달 초기 결정적인 시기(Critical period)에 장내 미생물이 역할의 중요성(Yeo et al., 2023)
 - 생애초기에 장내 미생물의 불균형은 마우스의 뇌 발달에 영향을 줌(그림 93).
 - 무균 마우스(Germ free; GF)와 특정한 미생물 또는 기생충이 없는 마우스(Specific pathogen free; SPF)의 뇌의 크기를 MR image로 비교함(6 weeks old mouse). 무균 마우스(Germ free; GF)의 뇌 크기가 상의하게 관찰됨.
 - 특정한 미생물 또는 기생충이 없는 마우스(SPF)와 생후 3주에

SFP마우스의 장내 미생물을 무균마우스에 이식한 마우스(Conventionalized; CONV)의 뇌 크기를 MR image로 비교한 결과(6 weeks old mouse). 장내 미생물을 이식한 마우스의 뇌의 크기는 회복 안 됨.

- 무균 마우스(GF)와 생후 3주에 SFP 마우스의 장내 미생물을 무균마우스에 이식한 마우스(CONV)의 뇌크기를 MR image로 비교한 결과(6 weeks old mouse). SFP 마우스의 장내 미생물을 무균 마우스에 이식한 마우스의 뇌 크기가 무균 마우스와 상당히 유사함.
- CONV의 isocortex(orange)와 Ofactory cortex(blue)의 크기는 회복되지 않은 결과를 보여줌(그림 93).




그림 93. GF 마우스, SPF 마우스와 CONV 마우스의 MRI 영상 결과.(A) GF compared to age-matched SPF,(B) CONV compared to age-matched SPF,(C) GF compared to age-matched CONV.

- 뇌 발달 초기 결정적인 시기(Critical period)에 장내 미생물이 역할의 중요성(논문

준비중)




그림 94. SFP, GF, CONV 마우스의 뇌 부위별 크기 비교

- 임신 중 당뇨에 노출된 마우스의 장내 미생물의 불균형(unpublished)




그림 95. 임신 중 당뇨에 노출된 마우스의 장내 미생물의 구성과 다양성의 불균형

- 아동 행동 영상 데이터의 발달장애 임상 연구-루먼랩(JAMA Network Open 2023a)
 - 루먼랩에서 개발한 아동 발달 영상을 수집하는 스마트폰 어플리케이션을 이용하였으며, 비디오 데이터의 정제 및 가공, AI 모델 개발을 위한 인프라를 개발하였음. 이렇게 개발된 솔루션을 아동의 자폐스펙트럼 및 ADHD 연구에서 각각 성공적으로 활용함.
 - 총 110명의 24~72개월 사이 아동을 대상으로 Joint Attention 과제를 수행하는 동영상을 수집하였으며, 딥 러닝 모델을 활용하여 동영상에서 자폐스펙트럼 장애를 분류와 중증도를 예측하는 표상을 학습시켜 높은 정확도 예측하는데 성공함. 본 연구진의 이런 기술력과 데이터의 확보는 본 제안서 연구의 실현가능성을 잘 보여줌.

Figure 1. Performance of the Joint Attention-Based Deep Learning System




그림 96. 행동 동영상 기반 딥러닝 모델의 자폐 스펙트럼 장애 분류 및 중증도 예측 성능

- 웨어러블 데이터의 아동의 ADHD 예측 연구-루먼랩(JAMA Network Open 2023b)
 - 본 연구팀에서는 웨어러블 기기(Fitbit) 및 핸드폰 사용기록 데이터, 기타 발달 데이터를 활용하여 ADHD와 수면 문제의 진단 및 평가를 위한 알고리즘을

머신러닝 기법을 활용하여 만들었던 바 있음²¹⁰.

- ABCD 데이터 허브를 통해 공개 되어 있는 6571명의 아동들의 데이터를 활용하여 모델을 만들었으며, ADHD는 AUC 0.798 , 수면 문제는 AUC 0.737 정도의 정확도를 보였음.
- 해당 모델을 최근 더 많은 후향적 데이터에 적용하여 추가적인 검증을 진행하였으며 높은 정확도를 보이는 것을 확인할 수 있었음





그림 97. 웨어러블 데이터를 활용한 ADHD 및 수면 문제 예측 성능

²¹⁰ Kim, W. P., Kim, H. J., Pack, S. P., Lim, J. H., Cho, C. H., & Lee, H. J.(2023). Machine learning–based prediction of attention-deficit/hyperactivity disorder and sleep problems with wearable data in children. JAMA Network Open, 6(3), e233502-e233502.

5-2. 연구팀 편성표



		개발 및 검증 • 뇌이미지-오믹스-행동 비디오-언어의 다중 모달리티 발달장애 조기진단 AI 개발 및 검증 분산학습 AI 연구팀 • 다기관 연합학습을 통한 뇌이미지-오믹스-행동 비디오-언어의 다중 모달리티 발달장애 조기진단 AI 학습 고도화와 보안 강화 및 검증 불확실성 AI 연구팀 • 불확실성 정량화를 통한 뇌이미지-오믹스-행동 비디오-언어의 다중 모달리티 발달장애 조기진단 AI 고도화 및 검증 멀티 오믹스 연구팀 • 멀티 오믹스 기반의 바이오인포메틱스 분석을 통한 바이오마커 발굴 및 검증
--	--	--



• 전장 유전체 DNA 데이터 분석 • 전장 엑솜 시퀀싱 데이터 분석 • 유전자 복제수 변이 데이터 분석 • 전사체(RNA) 시퀀싱 데이터 분석 • 비번역 전사체 시퀀싱(non-coding RNA-seq) 데이터 분석 임상 연구팀(후향적 기확보 및 전향적 추가 확보) • 임상 기초 데이터 생성: 나이, 성별, 연령 • 다면적 임상평가 데이터 생성: 발달, 인지, 언어, 운동, 사회성 등 • 뇌영상 데이터 생성: MRI, DTI, fMRI, fNIRS, EEG • X-ray 데이터 생성: 전체 척추 • 유전체 데이터 생성:MLPA, CMA, WES, 아동 + 가계 SNP, CNV, RNA-seq, non-coding RNA-seq • 인체 유래물 데이터 생성: 혈액, 분변, 피부 • 대사체 데이터 생성: 혈액, 분변 유래 대사체 • 행동 데이터 생성: 행동영상, 시선추적 대사체 연구팀(대사체 분석) • 동물 모델 및 아동의 혈액 대사체 분석 • 동물 모델 및 아동의 분변 속 장내 미생물 대사체 분석 • 동물 모델 및 아동의 분변 속 장내세균 유전체	데이터 통합 및 공개 • 지속적인 발달장애 빅데이터 생성을 위한 도구 및 인프라 구축
---	--

분석	
----	--

5-3. 참여인력 현황

가. 연구책임자 및 연구원 참여현황(학생연구원 포함)

구분	인력역할 (IRIS 내 인력역할 구분)	참여구분 (IRIS 내 참여구분)	국적	성명	직위	국가연구자 번호	소속기관	학위 및 전공			참여기간 (개월수)	비 고 *
								최종 학위	전공	취득 년도		
주관	책임자	내부 연구원	대한민국	차지옥	부교수	12498671	서울대학교	박사	신경과학	2013	24.07~27.12 (42 개월)	
주관	학생 연구원	내부 연구원	대한민국	배상운	박사과정	12774494	서울대학교	석사	협동과정인 공지능전공	2023	24.07~27.12 (42 개월)	
주관	학생 연구원	내부 연구원	대한민국	박정훈	박사과정	12798082	서울대학교	석사	협동과정인 공지능전공	2024	24.07~27.12 (42 개월)	
주관	학생 연구원	내부 연구원	대한민국	한동엽	석사과정	12678153	서울대학교	학사	물리학	2021	24.07~27.12 (42 개월)	
주관	참여 연구원	내부 연구원	대한민국	이종호	정교수	10026892	서울대학교	박사	전기공학	2007	24.07~27.12 (42 개월)	
주관	학생 연구원	내부 연구원	대한민국	김민준	과정	12415758	서울대학교	학사	컴퓨터공 학	2021	24.07~27.12 (42 개월)	
주관	학생 연구원	내부 연구원	대한민국	윤종효	과정	12731992	서울대학교	학사	전기정보 공학	2022	24.07~27.12 (42 개월)	
주관	학생 연구원	내부 연구원	대한민국	이하연	과정	12851419	서울대학교	학사	전기전자 공학	2023	24.07~27.12 (42 개월)	
주관	학생 연구원	내부 연구원	대한민국	최재우	과정	13001322	서울대학교	학사	전자전기 공학	2023	24.07~27.12 (42 개월)	
주관	참여 연구원	외부 연구원	대한민국	주윤정	조교수	12573921	성균관대학 교	박사	의료생명 정보학	2020	24.07~27.12 (42 개월)	
주관	참여 연구원	외부 연구원	대한민국	이태식	조교수	11704406	연세대원주 의과대학	박사	컴퓨터공 학	2021	24.07~27.12 (42 개월)	
주관	학생 연구원	외부 연구원	대한민국	고현송	학생연구 원	13133022	성균관대학 교	학사	생명과학/ 컴퓨터공 학	2021	24.07~27.12 (42 개월)	
주관	학생 연구원	외부 연구원	대한민국	박장연	학생연구 원	13161450	성균관대학 교	학사	보건행정	2021	24.07~27.12 (42 개월)	
주관	학생 연구원	외부 연구원	대한민국	윤희선	학생연구 원	13177637	성균관대학 교	석사	Business Informati on Managem	2023	24.07~27.12 (42 개월)	

									ent			
주관	참여 연구원	내부 연구원	대한민국	김태섭	조교수	11249024	서울대학교 산학협력단	박사	컴퓨터공 학	2021	24.07~27.12 (42 개월)	
주관	학생 연구원	내부 연구원	대한민국	장진관	박사 과정	12398805	서울대학교 산학협력단	석사	조선해양 공학	2023	24.07~27.12 (42 개월)	
주관	학생 연구원	내부 연구원	대한민국	정영준	박사 과정	11852013	서울대학교 산학협력단	석사	지역시스 템공학	2022	24.07~27.12 (42 개월)	
주관	학생 연구원	내부 연구원	대한민국	채규병	박사 과정	12902792	서울대학교 산학협력단	석사	데이터사 이언스	2024	24.07~27.12 (42 개월)	
주관	학생 연구원	내부 연구원	대한민국	한예원	석박 통합 과정	13164451	서울대학교 산학협력단	학사	언론정보 학	2023	24.07~27.12 (42 개월)	
주관	참여 연구원	내부 연구원	대한민국	오민환	조교수	12641829	서울대학교 산학협력단	박사	Operation s Research	2020	24.07~27.12 (42 개월)	
주관	학생 연구원	내부 연구원	대한민국	이중규	박사 과정	12790976	서울대학교 산학협력단	석사	데이터사 이언스	2023	24.07~27.12 (42 개월)	
주관	학생 연구원	내부 연구원	대한민국	김병찬	박사 과정	12740860	서울대학교 산학협력단	석사	데이터사 이언스	2023	24.07~27.12 (42 개월)	
주관	학생 연구원	내부 연구원	대한민국	조성우	석박통합 과정	13167876	서울대학교 산학협력단	학사	산업경영 공학	2023	24.07~27.12 (42 개월)	
1공동	공동연구 책임자	내부 연구원	대한민국	김민영	교수	10112557	분당차병원	박사	의학	2002	24.07~27.12 (42 개월)	25 %
1공동	참여 연구원	내부 연구원	대한민국	전형민	연구교수	11241691	분당차병원	박사	의공학	2020	24.07~27.12 (42 개월)	10 %
1공동	참여 연구원	내부 연구원	대한민국	김희구	선임연구원	11466740	분당차병 원	박사	의과학	2023	24.07~27.12 (42 개월)	20 %
1공동	참여 연구원	내부 연구원	대한민국	조은영	연구원	11729535	분당차병 원	박사	심리학	2022	24.07~27.12 (42 개월)	10 %
1공동	학생 연구원	내부 연구원	대한민국	황순성	전공의	12918538	분당차병 원	석사	의학	2021	24.07~27.12 (42 개월)	10 %
1공동	학생 연구원	내부 연구원	대한민국	안수지	전공의	11874294	분당차병 원	석사	의학	2023	24.07~27.12 (42 개월)	10 %
1공동	참여 연구원	내부 연구원	대한민국	박세영	연구원	12834040	분당차병 원	석사	재활과학	2023	24.07~27.12 (42 개월)	0%
1공동	참여 연구원	내부 연구원	대한민국	정은혜	연구원	12713198	분당차병 원	석사	의과학	2023	24.07~27.12 (42 개월)	0%
1공동	참여 연구원	내부 연구원	대한민국	정예지	연구원	12864949	분당차병 원	학사	작업치료 학	2018	24.07~27.12 (42 개월)	0%
1공동	참여	내부	대한민국	김요한	연구원	11780270	분당차병	석사	상담심리	2021	24.07~27.12	0%

	연구원	연구원					원		교육학		(42 개월)	
1공동	참여 연구원	내부 연구원	대한민국	서승수	연구원	13174520	분당차병원	학사	심리학	2024	24.07~27.12 (42 개월)	0%
1공동	참여 연구원	외부 연구원	대한민국	윤혜진	조교수	10843793	울산과학기술원	박사	의과학	2014	24.07~27.12 (42 개월)	10%
1공동	학생 연구원	외부 연구원	대한민국	임소연	대학원생(석박통합)	13179310	울산과학기술원	학사	생물공학	2019	24.07~27.12 (42 개월)	100%
1공동	참여 연구원	외부 연구원	대한민국	정상용	부교수	13089670	차의과학대학교	박사	생리학	2004	24.07~27.12 (42 개월)	10%
1공동	학생 연구원	외부 연구원	대한민국	오찬식	박사학위	12820327	차의과학대학교	석사	화학공학	2023	24.07~27.12 (42 개월)	100%
1공동	참여 연구원	외부 연구원	대한민국	최자영	부교수	11553974	충남대병원	박사	의학	2017	24.07~27.12 (42 개월)	10%
1공동	학생 연구원	외부 연구원	대한민국	선발예정	연구원		충남대병원	학사			24.07~27.12 (42 개월)	100%
1공동	참여 연구원	외부 연구원	대한민국	심성한	교수	10166212	차의과학대학교	박사	의학	2004	24.07~27.12 (42 개월)	10%
1공동	참여 연구원	외부 연구원	대한민국	선발예정	연구원						24.07~27.12 (42 개월)	100%
1공동	참여 연구원	외부 연구원	대한민국	선발예정	연구원						24.07~27.12 (42 개월)	100%
1공동	참여 연구원	외부 연구원	대한민국	선발예정	연구원						24.07~27.12 (42 개월)	100%
2공동	공동연구 책임자	내부 연구원	대한민국	임재현	대표이사	11152090	루멘랩 주식회사	박사	의과학	2018	24.07~27.12 (42 개월)	기 존
2공동	참여 연구원	내부 연구원	대한민국	이보희	책임연구원	11896517	루멘랩 주식회사	석사	뇌인지과학	2020	24.07~27.12 (42 개월)	기 존
2공동	참여 연구원	내부 연구원	대한민국	이성우	선임연구원	13129294	루멘랩 주식회사	학사	생명공학	2017	24.07~27.12 (42 개월)	기 존
2공동	참여 연구원	내부 연구원	대한민국	이성우	연구원	12514402	루멘랩 주식회사	학사	불어불문	2019	24.07~27.12 (42 개월)	기 존
2공동	참여 연구원	내부 연구원	대한민국	손창일	과장	11864834	루멘랩 주식회사	전문학 사	디자인	2008	24.07~27.12 (42 개월)	기 존

나. 현재 신청 중이거나 수행 중인 타 과제 현황

성명	연구과제명	연구개발기관	참여시작일	참여개월수	참여율	과제현황(종료,수행중,신청중)
연구자 등록번호	부처명/사업명	참여유형	참여종료일	당해년도연구비		
차지욱	소아청소년 뇌인지발달에서 신경과학, 유전, 환경 요인과 상호작용 연구	서울대학교	2021.03.01	60	10	수행중
12498671	과학기술정보통신부/신진연구자지원사업	연구책임자	2026.02.28	133,821,000		
차지욱	뇌-외부환경 상호작용시의 정서에 의해 맥락화된 지각의 디코딩	서울대학교	2023.07.01	54	10	수행중
12498671	과학기술정보통신부/원천기술개발사업	연구책임자	2027.12.31	453,500,000		
차지욱	구조적 인간 뇌커넥톰 기반의 신경생리적 시뮬레이션을 통한 정신과질환의 신경학적 기전 연구	서울대학교	2022.10.25	24	10	수행중
12498671	과학기술정보통신부/해외협력기반조성사업	연구책임자	2024.10.24	15,000,000		
김민영	뇌졸중에 대한 MK145 단백질의 치료효과 및 기전 규명	차의과학대학교 분당차병원	2023.09.01	30	20	수행중
10112557	과학기술정보통신부/개인기초연구	연구책임	2026.02.28	89,350,000		
김민영	차세대 기능강화 줄기세포 치료기술 플랫폼 개발	차의과학대학교 분당차병원	2019.01.01	72	20	수행중
10112557	보건복지부/연구중심병원 육성 R&D	연구책임	2024.12.31	535,000,000		
김민영	첨단재생의료 임상연구지원사업단 사무국 운영 사업	차의과학대학교 분당차병원	2022.05.01	32	10	수행중
10112557	보건복지부/첨단재생의료기술개발	공동연구	2024.12.31	1,129,000,000		
김민영	의료수준 전신 메디컬트윈 핵심 기술 개발	차의과학대학교 분당차병원	2021.04.01	45	20	수행중
10112557	과학기술정보통신부/실감콘텐츠핵심기술개발	공동연구	2024.12.31	200,000,000		
임재현	데이터 기반 아동 스트레스 케어 디지털 플랫폼	루먼랩 주식회사	2022.06.01	31	29	수행중

	및 기기 개발					
11152090	산업통상자원부/지역협력혁신성장사업(R&D)	연구책임	2024.12.31.	114,784,000		
임재현	동영상과 AI에 기반한 온라인 발달평가 및 발달코칭 어플리케이션 개발	루먼랩 주식회사	2023.07.01	17	20	수행중
11152090	과학기술정보통신부/디지털 콘텐츠 sw융합 제품 상용화 지원사업	연구책임	2024.11.30	187,500,000		
임재현	자폐 아동 증상 개선을 위한 디지털 치료기기 임상시험	루먼랩 주식회사	2023.07.01	54	21	수행중
11152090	보건복지부/디지털 치료기기 임상시험 기술개발	공동연구	2027.12.31	80,000,000		

5-5. 연구시설·장비

가. 연구시설·장비 보유현황

보유기관	연구시설·장비명	규격	수량	용도	활용시기	현물부담 반영여부 (해당 시 “○”)
서울대학교 산학협력단	GPU 서버 node 1 (MW-G291-280 DL Server)	GPU(NVIDIA RTX A5000(24GB))	8	AI 모델 학습	1-4차 연도	
서울대학교 산학협력단	GPU 서버 node 2(MW-G291-28 0 DL Server)	CPU(Intel Xeon 6240R x2, 512GB, SSD-32TB x5)	3	AI 모델 학습	1-4차 연도	
서울대학교 산학협력단	GPU 서버 node 3(MW-G291-28 0 DL Server)	RTX3090 GDDR6X 24GB PCI-express with G291	8	AI 모델 학습	1-4차 연도	
서울대학교 산학협력단	GPU 서버 node 4(GIGABYTE G292-280)	CPU(Intel Xeon 6342 x2, 512GB, 4TB U.2 NVMe x2)	1	AI 모델 학습	1-4차 연도	
서울대학교 산학협력단	GPU 서버 Scratch storage(MR-222 4CYP)	Intel Gold 6326, 2048TB Memory, 36TB user	1	연구파일 저장공간	1-4차 연도	
서울대학교 산학협력단	GPU 서버 storage 2(MR-4136ST Storage Server, S-ATA)	Xeon 4210R x2, 128GB, SSD 480GB x2 Raid 5 0(+2)	1	연구파일 저장공간	1-4차 연도	
National Energy Research Scientific Computing Center	NERSC Perlmutter Supercomputer	Nvidia A100 4 GPUs/node, 35PB Filesystem	연간 25,000 GPU hours (연간 1억원)	AI 모델 학습	1-4차 연도	
서울대학교 산학협력단	24노드 GPUs 서버 (Compuworks DL Server)	GPU(NVIDIA RTX A5000(24GB)	96 (4 GPU/node)	AI 모델 학습	1-4차 연도	
Brookhaven National Laboratory	Scientific Data and Computing Center(SDCC)	NVIDIA V100 8 GPUs/node	1	AI 모델 학습	1-4차 연도	
Brookhaven National	High Performance Computing	1024 TB(1PB)	1	연구파일 저장공간	1-4차 연도	

Laboratory	Cluster(HPC1)					
차의과학대학교 분당차병원	Mass spectrometer	Orbitrap Exploris480 @ TSQ Altis plus	1	단백체 연구	'24.07-'27.12	
차의과학대학교 분당차병원	동작분석 카메라	FHD	8	동작분석 카메라	'24.07-'27.12	
차의과학대학교 분당차병원	CO2 incubator	700x1000x500	1	동물실험용 장비	'24.07-'27.12	
차의과학대학교 분당차병원	Force Plate	500by600	1	지면반력기	'24.07-'27.12	
차의과학대학교 분당차병원	Micro Syringe Pump	300x200x200	1	동물실험용 장비	'24.07-'27.12	
차의과학대학교 분당차병원	Microcentrifuge	290x480x260	1	동물실험용 장비	'24.07-'27.12	
차의과학대학교 분당차병원	WESTERN BLOT ELECTROPHORESIS SET	200x80x300	1	동물실험용 장비	'24.07-'27.12	
차의과학대학교 분당차병원	역동역학 소프트웨어	1seat	2	역학해석 소프트웨어	'24.07-'27.12	
차의과학대학교 분당차병원	Clean Bench	1900x800x200	1	동물실험용 장비	'24.07-'27.12	

나. 연구시설·장비 구축 운영계획(해당 시 필수 작성)

1-1) 연구시설·장비 구축계획(구축비용이 3천만원 미만인 경우)

(단위: 천원)

연구개발기관명	연구시설·장비명	기존/신규구분	현금/현물구분	구축방식*	규격	수량	구축비용	구축기간	설치장소
차의과학대학교 분당차병원	분석용 컴퓨터 및 랩탑과 모니터 시스템	신규		구매	구매 시 최신 사양 기준	10	28,000	연구기간 내	차의과학대학교 분당차병원

차의과학대학교 분당차병원	생체신호 측정장비(근전 도, 뇌전도 등)	신규		구매	구매 시 최신사양 기준	2	20,000	연구기간 내	차의과학대 학교 분당차병원
차의과학대학교 분당차병원	뇌 혈류 측정장비	신규		구매	구매 시 최신사양 기준	4	28,000	연구기간 내	차의과학대 학교 분당차병원

* 개발, 구매, 임대, 용역 등

1-2) 연구시설·장비 구축계획(구축비용이 3천만원 이상인 경우)

(단위: 천원)

연구개발기관명	연구시설·장비명	기존/신규 구분	현금/현물 구분	구축방식*	규격	수량	구축비용	구축기간	설치장소
차의과학대학교 분당차병원	소아리빙랩	신규	현금	용역	1실	1	70,000	~2025.12.31	병원시설내
차의과학대학교 분당차병원	병원 데이터 관리서버	신규	현금	용역	시스템	1	80,000	2025.11.31	병원시설내

* 개발, 구매, 임대, 용역 등

2) 연구시설·장비 운영·활용계획

(단위: 천원)

연구개발기관명	연구시설명	기존/신규 구분	운영기간	연간운영비용	전담인력 수	활용계획	설치장소
분당차병원	Qualisys Miquis Hybrid system	기존	전 기간	3,000	2	운동역학적 데이터 획득	분당차병원
분당차병원	21ch E.E.G.(Electro Encephalogram)	기존	전 기간	2,000	1	뇌파측정	분당차병원
분당차병원	Functional near-IR spectroscopy	기존	전 기간	2,500	1	뇌영상 검사	분당차병원
분당차병원	Wireless E.M.G. system	기존	전 기간	1,000	2	근전도 검사	분당차병원
분당차병원	Deep Freezer	기존	전 기간	1,000	1	혈액샘플 보관	차바이오 컴플렉스
분당차병원	Eye tracking system	기존	전 기간	2,500	1	시선추적검사	분당차병원
분당차병원	Force plate	기존	전 기간	1,500	2	지면반발력 데이터 측정	분당차병원
분당차병원	Visual 3D	기존	전 기간	3,000	2	운동역학데이터 분석	분당차병원

6. 연구개발비 사용에 관한 계획

6-1. 연구개발비 지원·부담계획

양식A611(단위: 천원)

구분			정부지원 연구개발 비	기관부담 연구개발비			그 외 기관 등의 지원금						합 계		
							지방자치단체			기타()					
단계	연차	연구개발기관명 (주관)	현금	현금	현물	소계	현금	현물	소계	현금	현물	소계	현금	현물	합계
1	1	서울대학교 산학협력단	464,900										464,900		464,900
	2	서울대학교 산학협력단	729,800										729,800		729,800
	소계		1,194,700										1,194,700		1,194,700
2	1	서울대학교 산학협력단	729,800										729,800		729,800
	2	서울대학교 산학협력단	729,800										729,800		729,800

	소계	1,459,600											1,459,600		1,459,600
	총계	2,654,300											2,654,300		2,654,300

가. 연구개발비 지원·부담계획

(단위: 천원)

구분			정부지원 연구개발 비	기관부담 연구개발비			그 외 기관 등의 지원금						합 계		
							지방자치단체			기타()					
단계	연차	연구개발기관명 (공동1)	현금	현금	현물	소계	현금	현물	소계	현금	현물	소계	현금	현물	합계
1	1	차의과대학교 분당차병원	1,070,000										1,070,000		1,070,000
	2	차의과대학교 분당차병원	1,070,000										1,070,000		1,070,000
	소계		2,140,000										2,140,000		2,140,000
2	1	차의과대학교 분당차병원	1,070,000										1,070,000		1,070,000
	2	차의과대학교	1,070,000										1,070,000		1,070,000

		분당차병원												,000		000
		소계	2,140,000											2,140,000		2,140,000
		총계	4,280,000											4,280,000		4,280,000

(단위: 천원)

구분			정부지원 연구개발 비	기관부담 연구개발비			그 외 기관 등의 지원금						합 계		
							지방자치단체			기타()					
단계	연차	연구개발기관 명 (공동2)	현금	현금	현물	소계	현금	현물	소계	현금	현물	소계	현금	현물	합계
1	1	루먼랩 주식회사	150,000	5,000	45,000	50,000							155,000	45,000	200,000
	2	루먼랩 주식회사	150,000	5,000	45,000	50,000							155,000	45,000	200,000
	소계		300,000	10,000	90,000	100,000							310,000	90,000	400,000
2	1	루먼랩 주식회사	150,000	5,000	45,000	50,000							155,000	45,000	200,000
	2	루먼랩 주식회사	150,000	5,000	45,000	50,000							155,000	45,000	200,000
	소계		300,000	10,000	90,000	100,000							310,000	90,000	400,000
총계			600,000	20,000	180,000	200,000							620,000	180,000	800,000

다. 인건비 소요명세(영리기관의 경우에만 작성)

(공동2) 루먼랩														
성명	인력역할/ 참여 구분	참여 연차	참여 여부	학위및전공				신규 채용 여부	참여정보					
				최종학 위	전공계 열	전공명	취득연도		참여 시작 일자	참여종료일 자	현금계상률	현물계상률	미지급 계 상 률	산출근거 연봉금 액 (천원)
임재현	책임자 (내부연구 원)	1	○	박사	의학	의과학	2018	X	2024-07-01	2024-12-31	0	15	0	80,000
임재현	책임자 (내부연구 원)	2	○	박사	의학	의과학	2018	X	2025-01-01	2025-12-31	0	27	0	80,000
임재현	책임자 (내부연구 원)	3	○	박사	의학	의과학	2018	X	2026-01-01	2026-12-31	0	27	0	80,000
임재현	책임자 (내부연구 원)	4	○	박사	의학	의과학	2018	X	2027-01-01	2027-12-31	0	27	0	80,000
이보희	일반연구원 (내부연구 원)	1	○	석사	자연과 학	뇌인지과 학	2020	X	2024-07-01	2024-12-31	0	25	0	100,000
이보희	일반연구원 (내부연구 원)	2	○	석사	자연과 학	뇌인지과 학	2020	X	2025-01-01	2025-12-31	24	0	0	100,000

이보희	일반연구원 (내부연구원)	3	○	석사	자연과학	뇌인지과학	2020	X	2026-01-01	2026-12-31	24	0	0	100,000
이보희	일반연구원 (내부연구원)	4	○	석사	자연과학	뇌인지과학	2020	X	2027-01-01	2027-12-31	24	0	0	100,000
이성우	일반연구원 (내부연구원)	1	○	학사	자연과학	생명공학	2017	X	2024-07-01	2024-12-31	0	25	0	75,000
이성우	일반연구원 (내부연구원)	2	○	학사	자연과학	생명공학	2017	X	2025-01-01	2025-12-31	30	0	0	75,000
이성우	일반연구원 (내부연구원)	3	○	학사	자연과학	생명공학	2017	X	2026-01-01	2026-12-31	30	0	0	75,000
이성우	일반연구원 (내부연구원)	4	○	학사	자연과학	생명공학	2017	X	2027-01-01	2027-12-31	30	0	0	75,000
이인선	일반연구원 (내부연구원)	1	○	학사	인문과학	불어불문	2019	X	2024-07-01	2024-12-31	0	30	0	40,000
이인선	일반연구원 (내부연구원)	2	○	학사	인문과학	불어불문	2019	X	2025-01-01	2025-12-31	0	50	0	40,000
이인선	일반연구원 (내부연구원)	3	○	학사	인문과학	불어불문	2019	X	2026-01-01	2026-12-31	0	50	0	40,000
이인선	일반연구원 (내부연구원)	4	○	학사	인문과학	불어불문	2019	X	2027-01-01	2027-12-31	0	50	0	40,000
손창일	일반연구원 (내부연구원)	1	○	전문학사	디자인	디자인	2008	X	2024-07-01	2024-12-31	0	44	0	50,000
손창일	일반연구원 (내부연구원)	2	○	전문학사	디자인	디자인	2008	X	2025-01-01	2025-12-31	22	0	0	50,000
손창일	일반연구원 (내부연구원)	3	○	전문학사	디자인	디자인	2008	X	2026-01-01	2026-12-31	22	0	0	50,000

손창일	일반연구원 (내부연구원)	4	○	전문학 사	디자인	디자인	2008	X	2027-01-01	2027-12-31	22	0	0	50,000
채용예정 1	일반연구원 (내부연구원)	1	○	학사	미정	미정		O	2024-07-01	2024-12-31	100	0	0	40,000
채용예정 2	일반연구원 (내부연구원)	1	○	학사	미정	미정		X	2024-07-01	2024-12-31	100	0	0	40,000

6-2. 간접비(1차연도만 작성)

구분	연구개발기관명	1차연도 간접비 (단위 천원)	간접비율 %	연구실안전관리 비 (단위 천원)
공동연구개발 기관	차의과대학교 분당차병원	155,470	17%	
위탁연구개발 기관	루멘랩 주식회사	3,000	10%	
주관연구개발 기관	서울대학교 산학협력단	92,055	24.69%	

7. 연구개발성과의 사업화 전략 및 계획

- 본 과제 최종 결과물은 발달 장애의 조기 진단 및 예후 경과 파악이 가능한 멀티모달 AI 모델 및 구축된 데이터로, 아동의 발달 장애와 관련된 소프트웨어 의료기기 및 디지털 치료제, 디지털 관리 플랫폼등을 포함함.

가. 국내외 시장 동향

1) 국내외 시장규모 및 수출입 현황

- 디지털 치료제의 세계시장 규모는 2025년 기준 12.4조원, 국내 시장 규모는 2,225억원으로 추산됨 (Digital Therapeutics market Size(2021-2028), Grand View Research, Inc.)
- 최근 KOTRA에서는 세계에서 가장 큰 시장인 미국을 대상으로 위드코로나 시대 30대 유망품목 및 서비스에서 정신건강관리앱을 선정하였으며, 코로나19 및 오미크론 변이 바이러스 확산과 죽음의 공포, 장기간 이어진 락다운과 갑작스러운 라이프 스타일 변화로 정신건강에 적신호, 스트레스에서 벗어나기 위해 이를 관리 혹은 도움을 주는 서비스에 대한 수요가 존재한다고 보고함에 따라 데이터 기반 정신건강 관리 앱과 하드웨어를 결합한 형태의 디지털 플랫폼 시장은 더욱 성장할 것으로 예상됨.
- 본 과제 최종 결과물과 관련한 국내외 디지털 헬스케어 기술/산업별 시장현황은 다음과 같음.
 - a. 디지털 치료제(Digital Therapeutics, DTx)
 - 의학적 장애나 질병 예방·관리·치료용으로 근거 기반 치료적 개입을 제공하는

소프트웨어 의료기기로 기존의 치료제 대비 독성 및 부작용이 적고 일반의약품과 달리 저렴한 비용으로 대량 공급이 용이함.


- 미국 시장조사기관 그랜드 뷰 리서치에 따르면 세계 디지털 치료제 시장규모는 2020년부터 2028년까지 연 평균 23.1%씩 성장해 191억 달러(약 22조원) 규모에 이를 전망이다.
- 디지털 치료제 시장의 성장을 이끄는 주요 요인은 심리적 질병의 증가와 헬스케어의 성장, 정부의 투자 증가 등이며 북미, 유럽 등 의료선진시장을 중심으로 확대되기 시작해 중국, 인도, 동남아시아 등 아시아·태평양 시장의 성장 가속화가 예상됨.

b. 모바일(앱) 헬스케어

- 모바일 헬스케어 산업은 기존의 의료 및 건강 관련 산업에 스마트 모바일기기와 애플리케이션, 클라우드 컴퓨팅, 빅데이터 등의 IT 기술이 융합되어 탄생된 분야임.
- 의료기관에서 의료진을 통해서만 가능했던 개인의 건강 관련 정보의 측정과 진단, 관리를 가 개인이 속한 장소에서 실시간으로 수행하게 됨으로써 질병의 사전 진단과 예방, 관리에 있어서 더 낮은 비용에 더 질 높은 서비스를 제공할 수 있다는 것에 있음.
- 스태티스타는 모바일 기기를 활용하는 헬스케어 시장이 연평균 59%씩 성장해 오는 2025년에 3천 327억달러(약 386조 5천 641억원) 규모의 시장을 형성할 것으로 예측함.
- 모바일 헬스케어를 위해서는 다양한 웨어러블 기기와 헬스케어 관련 앱, 헬스케어 플랫폼 등 다양한 신제품과 서비스가 필요하며 이와 관련된 시장이 매우 높은 성장세를 보일 것으로 전망됨.



글로벌 디지털 치료제 시장 규모
*참고. 그랜드뷰리서치, 2020




글로벌 모바일 헬스 시장 규모
*참고. 스태티스타, 2020

2) 국내외 주요 수요처 현황

수요처	사업화 전략
국내 병원	- 병원 입원/내원 아동 대상 발달 장애 여부 및 예후 예측을 위한 진단보조 의료기기 처방 수요 - 3차 병원 뿐 아니라 1차 병원에서도 아동의 발달 상태를 파악하기 위한 도구로 사용될 수 있음 - 관련 학회 및 전시회 참가를 통한 직접 홍보 - 리빙랩 운영 - 확장을 통한 직접 홍보관 운영
학교, 교육청 등 아동 교육기관, 특수교육 센터 등	- 정부 보조금 및 바우처 형태의 아동 발달 장애 대응 비용 및 특수학급 등에 직접 판매 및 서비스 - 아동 및 학부모 상담을 위한 접근성 좋은 발달 평가 서비스에 대한 니즈가 존재

3) 국내외 경쟁기관 및 기술 현황

a. 국내외 디지털 헬스케어 주요 기업 현황



b. 디지털 표현형 데이터 수집 및 구축 동향

- 디지털 표현형 연구는 스마트폰 장치의 passive data 수집을 사용하여 정신과 및 기타 질병 표현형과 관련된 세부 정보 파악하는 것으로 진행 중임.
- 디지털 표현형을 연구하는 연구자들은 다양한 행동, 생리, 환경적 지표들을 다차원적으로 수집함으로써 개인의 표현형을 구성하고 이를 통해 인간의 다양한 측면에 대한 측정과 예측이 가능함.

- 대표적으로 고려대학교 병원 정신건강의학과 연구팀이 55명의 우울 혹은 양극성장애 집단을 대상으로 스마트폰 앱과 웨어러블 디바이스를 통해 활동량, 수면, 빛 노출, 심박수의 디지털 로그 데이터를 2년간 수집, 이 대규모 데이터에 대한 머신러닝을 통해 우울을 예측하는 알고리즘을 개발하였고, 증상 예측의 정확도는 평균 85% 이상이었음.
- 대다수의 연구에서 일관적인 상관이나 (예: 우울한 사람들은 움직임이 적다), 70-80% 수준의 행동 예측 (예: 30% 참가자의 우울에 대한 분석 자료로 나머지 70%의 우울 패턴을 예측할 수 있다)을 보고하지만, 타당성의 문제, 특히 센서의 패턴이나 조합이 과연 우울을 예측하는가에 대한 의문은 해결되지 못함.

c. 비대면 건강관리 및 모니터링 서비스

- 비대면 건강관리 및 모니터링 서비스는 병원을 중심으로 이루어지던 헬스케어의 영역이 일상으로까지 확장된 것임.
- 스마트폰과 웨어러블 기기, 다양한 건강관리 앱, 빅데이터와 인공지능 등 데이터 분석 기술의 발전을 통하여 모니터링 서비스는 일상화된 비대면 서비스로 빠르게 확장되고 있으며, 게임 등의 소프트웨어와 연계되어 행동 변화를 유도하는 방식의 기술이 포함된 제품이 등장함.
- 특히 웨어러블 장비를 활용해 일상의 식습관, 운동량 등의 모니터링을 통한 모니터링 및 건강관리 서비스도 제공 중임. 주요 웨어러블 디바이스 종류는 밴드/목걸이형, 직물/의류 일체형, 신체부착형, 의료용 센서 삽입 스마트 기기 등이 있음.
- 행동 변화와 반응에 관련되는 생체신호 정보와 헬스케어 서비스에 대한 수용성 정보를 측정 가능한 ICT 융합 스마트 헬스케어 생태계 구축의 기반이 되는 기술임.

- 개인의 일상을 스마트 기기로 기록하는 다양한 형태의 라이프 로그가 수집되고 빅데이터 분석 기술이 발전하면서 정확한 질병 예측과 맞춤형 케어가 확대되고 있어, 24시간 모니터링을 통하여 개인에게 가장 최적화된 서비스 제공하는 것이 가능함.

d. 국외 발달 장애 관련 디지털 치료제 동향 및 수준

- 국외 소아청소년 대상 정신질환 분야 디지털 치료제 개발 기업은 대표적으로 Akili interactive, Cognoa, Limbix가 있음.
- 특히 Limbix의 경우 최근 스파크Rx(SparkRx) 임상 실험 결과를 공개하였으며, 청소년 160명을 대상으로 스파크 앱과 다른 앱을 사용하게 한 결과 스파크 앱이 우울 증상을 더 낮춰준다는 결과를 얻음.
- 탐색임상 및 원격임상을 성공적으로 완료하여 FDA의 긴급사용승인을 받았고 정식 허가 및 제품 판매를 위한 확증 임상시험 진행 중임.

기업	제품명	특징
Akili Interactive	EndeavorRx(AKL-T01)	● ADHD 아동을 위한 비디오 게임으로 미국 FDA 승인을 받은 첫 디지털 치료제 ● (대상) 8-12세 ADHD 아동 ● (치료방법) 그림, 음악, 스토리 및 보상을 활용하여 환자의 참여를 유도하는 주의력 향상 비디오 게임 서비스
Cognoa	Autism Diagnostic/Therapeutic	● 자폐증 및 기타 행동 건강 질환을 앓고 있는 아동을 위한 진단 및 치료 솔루션 ● (대상) 18-72개월 자폐증 아동 ● (치료방법) 자폐아동이 구글 글래스를 착용하면 AI가 상대방의 얼굴을 감지해 헤드업 디스플레이를 통해 상대방과 눈을 맞출 수 있도록 유도

Limbox	Limbox Spark	• CBT 기반 모바일 APP을 통한 10대 우울 증상 치료 및 관리, FDA 긴급 승인 후 확증 임상 중 • (대상) 만 13-21세 청소년 • (치료방법) 최대 10주 동안 자가 모니터링 활동을 통해 즐거움 또는 숙달감을 제공, 치료 및 행동 활성화, 기분 추적 및 활동 일정, 심리 교육 프로그램 총 5단계 교육 정보 제공
--------	--------------	---

다. 사업화 계획

1) 사업화 전략

- 사업화 주체는 공동 연구개발기관인 루먼랩 주식회사로서, 주관 및 공동 연구 기관과 기술실시 계약을 맺음으로 과제를 통해 개발된 기술, 지식재산권, 노하우 등의 실시를 바탕으로 데이터 및 AI 알고리즘에 대한 비즈니스를 전개할 예정임
- 멀티모달 AI 모델 및 연관 데이터를 활용하여, 소프트웨어 기반 의료기기와 디지털 치료제를 개발하고, 이를 상용화하기 위한 제품 개발 일정을 수립함. 이 과정에서 과제 기간 내 초기 제품은 임상시험을 통해 효능과 안전성을 검증받으며, 이후 의료기기 인허가 승인을 목표로 함.
- 대상 시장을 세분화하여 발달 장애 아동을 대상으로 한 마케팅 전략을 수립하고, 구매 결정자인 전문 의료인 및 의료기관을 주요 고객으로 하여 다각적인 마케팅을 실행하게 될 것임

2) 투자 계획

연구개발비	시설자금	운영자금
-------	------	------

인건비, 연구개발비 임상시험비	클라우드 설비투자 솔루션 설비투자	마케팅비용
---------------------	-----------------------	-------

- AI 알고리즘 연구개발 및 앱/웹 개발 관련 핵심 인력 충원 예정
- 해외 진출을 위한 임상시험비용 투자 확대 및 플랫폼 구축에 따른 연구개발비 투자
- 빅데이터 관리 및 운영을 위한 클라우드 설비 및 솔루션 설비 투자
- 연구용 소프트웨어 온라인 홍보 마케팅 및 의료기기 분야 국내외 전시회/박람회 참여

3) 생산 계획

- 연구개발 기간 내 알고리즘별 소프트웨어를 개발하여 상용화를 진행하고, 임상 기관들과의 연계를 통해 알고리즘의 임상적 유효성을 검증하고 소프트웨어 의료기기 인허가를 위한 준비를 수행할 예정임
- 컨소시엄 참여 의료기관 및 기존 고객병원 중심으로 상용화를 실행하고 과제 종료 후 2028년부터 본격적인 인허가 과정을 진행하게 될 것임
- 본격 시장 진출 전 특허/노하우에 대한 배타적 권리를 확보하기 위하여 국내외 특허 및 디자인 출원을 진행하며 BM 모델에 대한 검증이 이루어질 것임
- 현재 소프트웨어 개발을 위한 전문 인력을 확보하여 테스트 프로세스를 구축하였으며, 과제 중 기술개발 및 알고리즘 분야 고용 창출을 통하여 신뢰성을 확보하고자 함

4) 해외시장 진출 계획

- 알고리즘의 유효성이 확보된 이후에는 미국, 유럽 등 발달 장애 아동에 대한 사회적

관심도가 높고 지출이 큰 선진국 위주로 시장에 진출하게 될 예정임

- 이를 위하여 현지 임상시험 및 해외 병원 및 의료기기 업체와 협약을 맺어 영업 및 서비스망을 확보하게 될 것임
- 또한, 효율적인 사업화를 위하여 가능성이 높은 국가 위주로 해외지사 설립을 통해 전략적인 사업화를 추진할 예정임

5) 사업화에 따른 기대효과

a. 고용 창출 효과

- AI 및 디지털 헬스케어 분야의 전문 인력 고용 및 데이터 관리를 위한 제반 인력 고용을 통해 고품질의 전문직 일자리를 창출함
- 이외에도 연구개발, 제조, 마케팅, 판매 등 인접 분야에서 다양한 신규 고용이 이루어질 것이며, 이는 지역 경제 활성화에 기여하며 관련 산업의 풀 확대에도 영향을 미칠 수 있음

b. 경제 기여도

- 혁신적인 멀티모달 AI 기술의 상용화로 국내 경제에 신성장 동력을 제공하며, 고부가가치 제품의 개발과 판매로 인한 경제적 수익이 증가할 수 있음
- 글로벌 시장 진출을 통한 수출 증대 및 추가적인 투자 유치가 가능함

c. 사회가치 기여도

- 발달 장애를 조기에 진단하고 치료할 수 있는 기술 개발로 사회적 부담이 경감하며, 아동의 건강한 성장과 발달을 지원하여 사회 전반의 삶의 질 향상에 기여할 것임

- 사회적 인식 개선과 함께 발달장애에 대한 이해와 관심이 높아지고 다양한 사회 계층에 걸쳐 폭넓은 접근성 제공으로 사회 통합 증진에 이바지하고자 함

d. 지역 내 파급효과

- 지역 기반의 연구개발 활동 증가로 인해 지역 경제에 직접적인 도움이 됨
- 지역 내 고급 기술력과 전문성 확보로 인해 관련 산업 및 서비스 부문의 성장을 촉진함

[첨부목록]

구분	목록	제출여부 (Y/N)
첨부1	[필수] 연구책임자의 대표적 연구실적 증빙자료	Y
첨부2	[해당 시] 연구장비도입 심의요청서	N
첨부3	[협약 시] 안전관리 계획 등	N
첨부4	[협약 시] [해당 시] 청년 의무채용 관련 계획	N
첨부5	[협약 시] 평가의견에 대한 수정·보완 대비표	N
첨부6	[해당 시] 영리기관의 연구실운영비 활용·관리계획	N

첨부1

(필수) 연구책임자의 대표적 연구실적 증빙자료

연구책임자 성명: 차지욱

논문 실적 증빙자료

번호	논문제목	저널명	ISSN	게재년월	역할(제1,교신,공동)	비고
1	Gene–environment pathways to cognitive intelligence and psychotic-like experiences in children	ELIFE	2012-9999	2024/3/5	교신	IF 8.7

Gene–environment pathways to cognitive intelligence and psychotic-like experiences in children

Junghoon Park^{1*}, Eunji Lee^{2†}, Gyeongcheol Cho³, Heungsun Hwang⁴,
Bo-Gyeom Kim⁵, Gakyung Kim⁶, Yoonjung Yoonie Joo^{2,6,7*}, Jiook Cha^{1,2,8*}

¹Interdisciplinary Program in Artificial Intelligence, College of Engineering, Seoul National University, Seoul, Republic of Korea; ²Department of Psychology, College of Social Sciences, Seoul National University, Seoul, Republic of Korea; ³Department of Psychology, College of Arts and Sciences, The Ohio State University, Columbus, United States; ⁴Department of Psychology, McGill University, Montréal, Canada; ⁵Department of Brain and Cognitive Sciences, College of Natural Sciences, Seoul National University, Seoul, Republic of Korea; ⁶Department of Digital Health, Samsung Advanced Institute for Health Sciences & Technology (SAIHST), Sungkyunkwan University, Seoul, Republic of Korea; ⁷Samsung Medical Center, Seoul, Republic of Korea

*For correspondence:
yoonjung.joo@snu.ac.kr (YY);
joo@snuc.ac.kr (JJ)

†These authors contributed
equally to this work

Competing interest: The authors
declare that no competing
interests exist.

Funding: See page 34

Preprint posted

29 March 2023

Sent for Review

18 April 2023

Reviewed preprint posted

13 June 2023

Reviewed preprint revised

04 September 2023

Reviewed preprint revised

13 November 2023

Version of Record published

05 March 2024

Reviewing Editor: Charlotte

Cecil, Erasmus MC, Netherlands

© Copyright Park, Lee et al. This
article is distributed under the
terms of the Creative Commons
Attribution License, which
permits unrestricted use and
redistribution provided that the
original author and source are
credited.

Abstract In children, psychotic-like experiences (PLEs) are related to risk of psychosis, schizophrenia, and other mental disorders. Maladaptive cognitive functioning, influenced by genetic and environmental factors, is hypothesized to mediate the relationship between these factors and childhood PLEs. Using large-scale longitudinal data, we tested the relationships of genetic and environmental factors (such as familial and neighborhood environment) with cognitive intelligence and their relationships with current and future PLEs in children. We leveraged large-scale multimodal data of 6,402 children from the Adolescent Brain and Cognitive Development Study. Linear mixed model and a novel structural equation modeling (SEM) method that allows estimation of both components and factors were used to estimate the joint effects of cognitive phenotypes polygenic scores (PGSs), familial and neighborhood socioeconomic status (SES), and supportive environment on NIH Toolbox cognitive intelligence and PLEs. We adjusted for ethnicity (genetically defined), schizophrenia PGS, and additionally unobserved confounders (using computational confound modeling). Our findings indicate that lower cognitive intelligence and higher PLEs are significantly associated with lower PGSs for cognitive phenotypes, lower familial SES, lower neighborhood SES, and less supportive environments. Specifically, cognitive intelligence mediates the effects of these factors on PLEs, with supportive parenting and positive school environments showing the strongest impact on reducing PLEs. This study underscores the influence of genetic and environmental factors on PLEs through their effects on cognitive intelligence. Our findings have policy implications in that improving school and family environments and promoting local economic development may enhance cognitive and mental health in children.

eLife assessment

This study presents a **useful** inventory of the joint effects of genetic and environmental factors on psychotic-like experiences and identifies cognitive ability as a potential underlying mediating pathway. The data were analyzed using a **solid** and validated methodology based on a large, multi-center dataset. The claim that these findings are of relevance to psychosis risk and have implications for policy changes is partially supported by the results.

번호	논문제목	저널명	ISSN	게재년월	역할(제1, 교신, 공동)	비고
2	Genome-wide Polygenic Scores for Multiple Psychiatric and Common Traits Identify Preadolescent Youth with Risk for Suicide.	JAMA Network Open	2574-3805	202202(in print)	교신	IF 8.5



Original Investigation | Psychiatry

Association of Genome-Wide Polygenic Scores for Multiple Psychiatric and Common Traits in Preadolescent Youths at Risk of Suicide

Yoonjung Yoonie Joo, PhD; Seo-Yoon Moon; Hee-Hwan Wang, BA; Hyeonjin Kim, MA; Eun-Ji Lee, BA; Jong Hun Kim, MD; Jonathan Posner, MD; Woo-Young Ahn, PhD; Incheol Choi, PhD; Jae-Won Kim, PhD; Jook Chai, PhD

Abstract

IMPORTANCE Suicide is the second leading cause of death among youths worldwide, but no available means exist to identify the risk of suicide in this population.

OBJECTIVE To assess whether genome-wide polygenic scores for psychiatric and common traits are associated with the risk of suicide among preadolescent children and to investigate whether and to what extent the interaction between early life stress (a major environmental risk factor) and polygenic factors is associated with suicidal thoughts and behaviors among youths.

DESIGN, SETTING, AND PARTICIPANTS This cohort study analyzed the genotype-phenotype data of 11 869 preadolescent children aged 9 to 10 years from the Adolescent Brain and Cognitive Development study. Data were collected from September 1, 2016, to October 21, 2018, and analyzed from August 1, 2020, to January 3, 2021. Using machine learning approaches, genome-wide polygenic scores of 24 complex traits were estimated to investigate their phenome-wide associations and utility for assessing risk of suicidal thoughts and behaviors (suicidal ideation [active, passive, and overall] and suicide attempt).

MAIN OUTCOMES AND MEASURES Genome-wide polygenic scores were used to measure 24 traits, including psychiatric disorders, cognitive capacity, and personality and psychological characteristics. The Child Behavior Checklist was used to measure early life stress, and the Family Environment Scale was used to assess family environment. Suicidal ideation and suicide attempts were derived from the computerized version of the Kiddie Schedule for Affective Disorders and Schizophrenia.

RESULTS Among 11 869 preadolescent children in the US, complete data for phenotypic outcomes, genotypes, and covariates were available for 7140 participants in the multiethnic cohort (mean [SD] age, 9.9 [0.6] years; 3588 girls [50.3%]), including 925 participants with suicidal ideation and 63 participants with suicide attempts. Among those 7140 participants, 729 had African ancestry (self-reported race or ethnicity: 569 Black, 71 Hispanic, and 89 other), 276 had admixed American ancestry (self-reported race or ethnicity: 265 Hispanic, 3 White, and 8 other), 150 had East Asian ancestry (self-reported race or ethnicity: 67 Asian, 18 Hispanic, and 65 other), 5718 had European ancestry (self-reported race or ethnicity: 7 Asian, 39 Black, 1142 Hispanic, 3934 White, and 596 other), and 267 had other ancestries (self-reported race or ethnicity: 70 Asian, 13 Black, 126 Hispanic, 48 White, and 10 other). Three genome-wide polygenic scores were significantly associated (false discovery rate $P < .05$) with suicidal thoughts and behaviors among all participants: attention-deficit/hyperactivity disorder (odds ratio [OR], 1.12; 95% CI, 1.05-1.21; $P = .001$), schizophrenia (OR, 1.50; 95% CI, 1.17-1.93; $P = .002$), and general happiness (OR, 0.89; 95% CI, 0.83-0.96; $P = .002$). In the analysis including only children with European ancestry, 3 additional genome-wide polygenic scores with false discovery rate significance were associated with suicidal thoughts and behaviors: autism

(continued)

Key Points

Question Are genome-wide polygenic scores for specific psychiatric and common traits associated with high risk of suicide among preadolescent youths?

Findings In this cohort study of 11 869 preadolescent youths in the US, multiple genome-wide polygenic scores were significantly associated with suicidal thoughts and behaviors (ideation or attempts); specific genome-wide polygenic scores associated with the risk of suicide included attention-deficit/hyperactivity disorder, general happiness, and posttraumatic stress disorder.

Meaning These results suggest that the genomic approach may be useful for identifying children at high risk for suicidal thoughts and behaviors.

Supplemental content

Author affiliations and article information are listed at the end of this article.

Open Access. This is an open access article distributed under the terms of the CC-BY License.

JAMA Network Open. 2022;5(2):e2148585. doi:10.1001/jamanetworkopen.2021.48585

February 21, 2022 1/17

번호	논문제목	저널명	ISSN	게재년월	역할(제1,교신,공동)	비고
3	SwiFT: Swin 4D fMRI Transformer	NEURIPS	1049-5258	2023/12	교신	연구재단 인정 우수 CS 학회(인정 IF 4)

SwiFT: Swin 4D fMRI Transformer

Peter Yongho Kim*
Seoul National University

Junbeom Kwon*
Seoul National University

Sunghwan Joo
SungKyunKwan University

Sangyoon Bae
Seoul National University

Donggyu Lee
SungKyunKwan University

Yoonho Jung
Seoul National University

Shinjaee Yoo
Brookhaven National Lab

Jiook Cha[†]
Seoul National University

Taesup Moon[†]
Seoul National University

Abstract

Modeling spatiotemporal brain dynamics from high-dimensional data, such as functional Magnetic Resonance Imaging (fMRI), is a formidable task in neuroscience. Existing approaches for fMRI analysis utilize hand-crafted features, but the process of feature extraction risks losing essential information in fMRI scans. To address this challenge, we present SwiFT (**Swin 4D fMRI Transformer**), a Swin Transformer architecture that can learn brain dynamics directly from fMRI volumes in a memory and computation-efficient manner. SwiFT achieves this by implementing a 4D window multi-head self-attention mechanism and absolute positional embeddings. We evaluate SwiFT using multiple large-scale resting-state fMRI datasets, including the Human Connectome Project (HCP), Adolescent Brain Cognitive Development (ABCD), and UK Biobank (UKB) datasets, to predict sex, age, and cognitive intelligence. Our experimental outcomes reveal that SwiFT consistently outperforms recent state-of-the-art models. Furthermore, by leveraging its end-to-end learning capability, we show that contrastive loss-based self-supervised pre-training of SwiFT can enhance performance on downstream tasks. Additionally, we employ an explainable AI method to identify the brain regions associated with sex classification. To our knowledge, SwiFT is the first Swin Transformer architecture to process dimensional spatiotemporal brain functional data in an end-to-end fashion. Our work holds substantial potential in facilitating scalable learning of functional brain imaging in neuroscience research by reducing the hurdles associated with applying Transformer models to high-dimensional fMRI. Project page: <https://github.com/Transconnectome/SwiFT>

1 Introduction

The human brain is a dynamic system characterized as an extensive (feedback) network generating complex spatiotemporal dynamics of its activity. Analyzing such dynamics and linking them to normative adaptive cognition and behaviors, as well as their maladaptive forms in a disease condition is of paramount importance in neuroscience and medicine. However, the fields have been hampered by a lack of predictive power owing to the gap between the complexity of the brain network and the contrasting simplicity of brain imaging analytics [1]. Hence, developing an accurate predictive model using high-dimensional brain imaging data and learning rich representations of brain function will help close this gap and advance toward precision neuroscience.

*Equal Contribution

[†]Co-corresponding author

연구 역할	논문제목	저널명	ISSN	게재년월	역할(제1, 교신,공동)	비고
----------	------	-----	------	------	------------------	----

4	Machine learning prediction of incidence of Alzheimer's disease using large-scale administrative health data	NPJ Digital Medicine	2398-6352	202003	교신	IF 11.7
---	--	----------------------	-----------	--------	----	---------

Machine learning prediction of incidence of Alzheimer's disease using large-scale administrative health data

Ji Hwan Park^{1,11}, Han Eol Cho^{2,11}, Jong Hun Kim³, Melanie M. Wall⁴, Yaakov Stern^{4,5}, Hyunsun Lim⁶, Shinjae Yoo¹, Hyoung Seop Kim^{7,8} and Joook Cha^{9,10,12}

Nationwide population-based cohort provides a new opportunity to build an automated risk prediction model based on individuals' history of health and healthcare beyond existing risk prediction models. We tested the possibility of machine learning models to predict future incidence of Alzheimer's disease (AD) using large-scale administrative health data. From the Korean National Health Insurance Service database between 2002 and 2010, we obtained de-identified health data in elders above 65 years ($N = 40,736$) containing 4,894 unique clinical features including ICD-10 codes, medication codes, laboratory values, history of personal and family illness and socio-demographics. To define incident AD we considered two operational definitions: "definite AD" with diagnostic codes and dementia medication ($n = 614$) and "probable AD" with only diagnosis ($n = 2026$). We trained and validated random forest, support vector machine and logistic regression to predict incident AD in 1, 2, 3, and 4 subsequent years. For predicting future incidence of AD in balanced samples (bootstrapping), the machine learning models showed reasonable performance in 1-year prediction with AUC of 0.775 and 0.759, based on "definite AD" and "probable AD" outcomes, respectively; in 2-year, 0.730 and 0.693; in 3-year, 0.677 and 0.644; in 4-year, 0.725 and 0.683. The results were similar when the entire (unbalanced) samples were used. Important clinical features selected in logistic regression included hemoglobin level, age and urine protein level. This study may shed a light on the utility of the data-driven machine learning model based on large-scale administrative health data in AD risk prediction, which may enable better selection of individuals at risk for AD in clinical trials or early detection in clinical settings.

npj Digital Medicine (2020)3:46; <https://doi.org/10.1038/s41746-020-0256-0>

INTRODUCTION

Screening individuals at risk for Alzheimer's disease (AD) based on medical health records in preclinical stages may lead to early detection of AD pathology and to better therapeutic strategies for delaying the onset of AD^{1–3}. Current biomarkers of AD requires the collection of specimen (e.g., serum or fluid) or imaging data. On the other hand, the electronic healthcare data, such as health records in clinical settings, or administrative health data, does not require additional time or effort for data collection. Also, with the advent of digitalization the amounts of such data have exponentially increased⁴. Since it is ubiquitous, cost-effective and enormous, the digitalized healthcare database may be an invaluable resource for testing scalable predictive models for AD and other diseases alike. However, despite of its tremendous potential value, little is known about the extents to which the large-scale administrative health data is useful in AD risk prediction.

For AD risk prediction, prior models are typically based on predefined health profile variables, such as sociodemographic (age, sex, education), lifestyle (physical activity), midlife health risk factors (systolic blood pressure, BMI and total cholesterol level)^{5,6}, and cognitive profiles^{7,8}. An important outstanding question is whether those simple predictive models based on the small sets

of selected variables may sufficiently account for the heterogeneous etiologies of multi-factorial AD in clinical settings. Indeed, a meta-analysis study shows that multi-factor models best predict risk for dementia, whereas single-factor models do poorly⁹, suggesting accurate AD risk prediction requires a large feature space. Here we test the extents to which a data-driven machine approach harvests salient information from the large-scale healthcare data containing thousands of data of individuals' health trajectories and make an individual-specific prediction of AD risk.

Machine learning is an optimal choice of analytics for analyzing the large-scale administrative health data containing thousands of descriptors from hundreds of thousands of individuals. Studies show successful applications of machine learning to the large-scale administrative data in predicting incident diseases other than AD (diabetes, metabolic syndrome, suicide death, opioid overdose or drug-resistant epilepsy, etc)^{10–12}. Given the recent rapid growth of the machine learning technology, application of the AI technology to clinical predictive modelling is likely to have a deep impact on medicine^{13–16}. But to our knowledge the data-driven predictive modeling based on nationwide population-based administrative health data has yet to be tested in AD risk prediction.

¹Computational Science Initiative, Brookhaven National Laboratory, Upton, NY 11973, USA. ²Department of Rehabilitation Medicine, Gangnam Severance Hospital and Rehabilitation Institute of Neuromuscular Disease, Yonsei University College of Medicine, Seoul, Korea. ³Department of Neurology, Dementia Center, National Health Insurance Service Ilsan Hospital, Goyang, Republic of Korea. ⁴Department of Psychiatry, Vagelos College of Physicians and Surgeons, Columbia University, New York, NY 10025, USA. ⁵Department of Neurology, Vagelos College of Physicians and Surgeons, Columbia University, New York, NY 10025, USA. ⁶Research and Analysis Team, National Health Insurance Service Ilsan Hospital, Goyang, South Korea. ⁷Department of Physical Medicine and Rehabilitation, Dementia Center, National Health Insurance Service Ilsan Hospital, Goyang, South Korea. ⁸Department of Psychology, Seoul National University, Seoul, South Korea. ⁹Department of Brain & Cognitive Sciences, Seoul National University, Seoul, South Korea. ¹⁰Graduate School of Data Science, Seoul National University, Seoul, South Korea. ¹¹These authors contributed equally: Ji Hwan Park, Han Eol Cho. ¹²email: rekhsajinhmc@nrcconnectome@snu.ac.kr

번호	논문제목	저널명	ISSN	게재년월	역할(제1, 교신, 공동)	비고
5	White matter diffusion estimates in obsessive-compulsive disorder across 1653 individuals: machine learning findings from the ENIGMA OCD Working Group	Molecular Psychiatry	1359-4184	202403	교신	IF 11.9

Molecular Psychiatry

www.nature.com/mp

ARTICLE OPEN

Check for updates

White matter diffusion estimates in obsessive-compulsive disorder across 1653 individuals: machine learning findings from the ENIGMA OCD Working Group

Bo-Gyeom Kim^{1,148}, Gakyung Kim^{2,148}, Yoshinari Abe³, Pino Alonso^{4,5,6}, Stephanie Ameis^{7,8,9}, Alan Anticevic¹⁰, Paul D. Arnold^{11,12}, Srinivas Balachander¹³, Nerisa Banaj¹⁴, Nuria Bargallo^{15,16}, Marcelo C. Batistuzzo^{17,18}, Francesco Benedetti^{19,20}, Sara Bertolin^{5,21}, Jan Carl Beucke^{22,23,24}, Irene Bollettini²⁵, Silvia Brem^{25,26}, Brian P. Brennan^{27,28}, Jan K. Buitelaar^{29,30}, Rosa Calvo^{5,31,32,33}, Miguel Castelo-Branco^{34,35,36}, Yuqi Cheng³⁷, Ritu Bhusal Chhatkuli^{38,39}, Valentina Ciullo¹⁴, Ana Coelho^{40,41,42}, Beatriz Couto^{40,41,42}, Sara Dallaspezia⁴³, Benjamin A. Ely⁴⁴, Sónia Ferreira^{40,41,42}, Martine Fontaine⁴⁵, Jean-Paul Fouché⁴⁶, Rachael Grazioplene¹⁰, Patricia Gruner¹⁰, Kristen Hagen^{47,48}, Bjarne Hansen^{48,49}, Gregory L. Hanna⁵⁰, Yoshiyuki Hirano^{38,39}, Marcelo Q. Höxter¹⁷, Morgan Hough⁵¹, Hao Hu⁵², Chaim Huyser^{53,54}, Toshikazu Ikuta⁵⁵, Neda Jahanshad⁵⁶, Anthony James⁵⁷, Fern Jaspers-Fayer^{58,59}, Selina Kasprzak^{60,61}, Norbert Kathmann²², Christian Kaufmann²², Minah Kim^{62,63}, Kathrin Koch^{64,65}, Gerd Kvale^{66,67}, Jun Soo Kwon^{68,69,70}, Luisa Lazaro^{5,31,32,33}, Junhee Lee⁷¹, Christine Lochner⁷², Jin Lu⁷³, Daniela Rodriguez Manrique^{64,65,72}, Ignacio Martinez-Zalacain^{4,73}, Yoshitada Masuda⁷⁴, Koji Matsumoto⁷⁴, Maria Paula Maziero^{75,76}, Jose M. Menchón^{4,5,6}, Luciano Minuzzi^{77,78}, Pedro Silva Moreira^{40,41,79}, Pedro Morgado^{40,41,42}, Janardhanan C. Narayanaswamy¹³, Jin Narumoto⁸⁰, Ana E. Ortiz^{31,32,33}, Junko Ota^{38,39}, Jose C. Pariente¹⁶, Chris Perriello⁸¹, Maria Picó-Pérez^{40,41,82}, Christopher Pittenger^{10,83,84,85}, Sara Poletti²⁰, Eva Real^{5,6}, Y. C. Janardhan Reddy¹³, Daan van Rooij⁸⁶, Yuki Sakai^{80,87}, João Ricardo Sato^{88,89}, Cinto Segalas^{5,6}, Roseli G. Shavitt⁹⁰, Zonglin Shen³⁷, Eiji Shimizu^{36,39,91}, Venkataram Shivakumar⁹², Noam Soreni^{93,94}, Carles Soriano-Mas^{5,49,95}, Nuno Sousa^{40,41,42}, Mafalda Machado Sousa^{40,41,42}, Gianfranco Spalletta^{14,96}, Emily R. Stern^{97,98}, S. Evelyn Stewart^{58,99,100}, Philip R. Szaszko^{101,102}, Rajat Thomas¹⁰³, Sophia I. Thomopoulos⁵⁶, Daniela Vecchio¹⁴, Ganesan Venkatasubramanian¹³, Chris Vriend^{50,61,104}, Susanne Walitza^{25,26}, Zhen Wang¹⁰⁵, Anri Watanabe⁸⁰, Lidewij Wolters¹⁰⁶, Jian Xu¹⁰⁷, Kei Yamada¹⁰⁸, Je-Yeon Yun^{109,110}, Mojtaba Zarei¹¹¹, Qing Zhao¹⁰⁵, Xi Zhu^{112,113} and, ENIGMA-OCD Working Group*, Paul M. Thompson⁵⁶, Willem B. Bruin^{104,114}, Guido A. van Wingen^{104,114}, Federica Piras¹⁴, Fabrizio Piras¹⁴, Dan J. Stein^{115,116}, Odile A. van den Heuvel^{60,61}, Helen Blair Simpson¹⁵ and Jiyoung Cha^{1,2,52}

© The Author(s) 2024, corrected publication 2024

White matter pathways, typically studied with diffusion tensor imaging (DTI), have been implicated in the neurobiology of obsessive-compulsive disorder (OCD). However, due to limited sample sizes and the predominance of single-site studies, the generalizability of OCD classification based on diffusion white matter estimates remains unclear. Here, we tested classification accuracy using the largest OCD DTI dataset to date, involving 1336 adult participants (690 OCD patients and 646 healthy controls) and 317 pediatric participants (175 OCD patients and 142 healthy controls) from 18 international sites within the ENIGMA OCD Working Group. We used an automatic machine learning pipeline (with feature engineering and selection, and model optimization) and examined the cross-site generalizability of the OCD classification models using leave-one-site-out cross-validation. Our models showed low-to-moderate accuracy in classifying (1) "OCD vs. healthy controls" (Adults, receiver operator characteristic-area under the curve = 57.19 ± 3.47 in the replication set; Children, 59.8 ± 7.39), (2) "unmedicated OCD vs. healthy controls" (Adults, 62.67 ± 3.84; Children, 48.51 ± 10.14), and (3) "medicated OCD vs. unmedicated OCD" (Adults, 76.72 ± 3.97; Children, 72.45 ± 8.87). There was significant site variability in model performance (cross-validated ROC AUC ranges 51.6–79.1 in adults; 35.9–63.2 in children). Machine learning interpretation showed that diffusivity measures of the corpus callosum, internal capsule, and posterior thalamic radiation contributed to the classification of OCD from HC. The classification performance appeared greater than the model trained on grey matter morphometry in the prior ENIGMA OCD study (our study includes subsamples from the morphometry study). Taken together, this study points to the meaningful multivariate patterns of white matter features relevant to the neurobiology of OCD, but with low-to-moderate classification accuracy. The OCD classification performance may be constrained by site variability and medication effects on the white matter integrity, indicating room for improvement for future research.

Molecular Psychiatry; <https://doi.org/10.1038/s41380-023-02392-6>

A full list of author affiliations appears at the end of the paper.

Received: 29 March 2023 Revised: 27 November 2023 Accepted: 19 December 2023
Published online: 07 February 2024

SPRINGER NATURE

